RK3576 端侧多模态系统集成与性能优化工程手册

本手册面向 Linux C++与嵌入式 AI 工程学习、复现和项目验收，覆盖 RK3576 上的 Camera、ASR、Qwen、SmolVLM2、Kokoro、异步任务、性能测量、Qt 与稳定性。5.1～5.4 已经用户验收；5.5 的最终审核以本节验收清单及真实日志为准。隔离版本没有覆盖主工程。

本版已完成记录场景内的工程验证，等待用户对最终项目审核。未独立测量的声学延迟、精确首 Token 与可靠 NPU 利用率继续保留为空；有限长测不等于任意工况的永久稳定保证。

1 工程环境与证据规则 9

2 开发时间线与最终系统关系 10

3 第五阶段 5.1 生命周期审计和安全退出 13

完整关键源码 include/app/stop_signals.h 14

完整关键源码 src/ai/rkllm_backend.cpp struct RunContext 15

完整关键源码 src/ai/rkllm_backend.cpp struct RKLLMBackend::Impl 15

完整关键源码 src/ai/rk3576_vlm_backend.cpp struct RknnOutputOwner 15

完整关键源码 src/audio/asr_pipeline.cpp void ASRWorker::run() 16

完整关键源码 src/audio/asr_pipeline.cpp void ASRWorker::runImpl() 16

本节面试题与完整答案 20

1. 为什么只使用智能指针还会出现生命周期错误？ 20

2. 为什么析构里的 join 可能一直等待？ 20

3. 为什么不把 ASR、LLM、TTS 一起 requestStop？ 20

4. shared_ptr<const ImageFrame> 是否是零拷贝？ 21

5. 两个 Engine 都有 mutex，能否证明 NPU 没有资源冲突？ 21

6. 有界队列容量 2 为什么可能存在 3 个任务？ 21

7. 如何避免 C SDK buffer 在 C++ 异常时泄漏？ 21

8. Windows 6/6 CTest 能证明什么？ 21

9 为什么不能在 signal handler 中调用条件变量 21

10 析构顺序为什么是并发接口的一部分 22
4 第五阶段 5.2 有界异步任务和 NPU 调度 22
5.2 多线程与异步 Pipeline 工程记录 22
操作 1：继承 5.1 验收与授权边界 22
操作 2：源码定位与最小方案 22
操作 3：真实线程与队列架构 23
操作 4：有界性、背压与终态 24
操作 5：生命周期、竞态与退出审查 24
操作 6：回声与 TTS 调度取舍 25
操作 7：构建问题与证据分类 25
操作 8：适用范围补充 26
5.2 实测性能数据 26
操作 1：NPU 实际 SDK 调用对照 26
操作 2：ASR 业务回调/受控提交阻塞 27
操作 3：各队列等待 28
操作 4：深度、接受/拒绝、成功率和完整交付 29
操作 5：有限批次吞吐和自然排空退出 30
操作 6：停止模式和资源采样 31
操作 7：模型计算时间与局限 32
完整关键源码 include/ai/llm_worker.h 32
完整关键源码 src/ai/llm_worker.cpp 34
完整关键源码 include/app/pipeline_admission.h 37
完整关键源码 src/audio/tts_worker.cpp void TTSWorker::run() 38
操作 1：公共类型与 C++ 语法 42
操作 2：PipelineAdmission 逐句所有权解释 42

操作 3：LLMWorker 的构造、提交与线程语句 44
操作 4：推理 run 循环的每个执行阶段 45
操作 5：TTSWorker 及不变的设备路径 45
操作 6：完整语音入口的语句与捕获 46
操作 7：测试语句及可证明范围 47
操作 8：面试题与参考答案 47
核心实测取舍 48
5 第五阶段 5.3 Camera 内存和预处理 49
完整关键源码 include/video/owned_frame_pool.h 49
完整关键源码 src/video/latest_frame_buffer.cpp 50
完整关键源码 src/video/image_preprocessor.cpp 51
5.3 关键 C++ 逐句解释与审查 53
OwnedFramePool：有界所有权，不能用 use_count 猜测独占 53
VideoCapture：减少分配，保留 QBUF 前的所有权边界 56
CameraService、LatestFrameBuffer 与退出 57
Rgb512Preprocessor：算术保持一致，缓存坐标 58
RK3576VLMBackend：输入与输出寿命 59
埋点、诊断与测试的界限 60
与实现对应的测试 60
5.3 面试题与完整参考答案 61
1. mmap 摄像头是否就是零拷贝？ 61
2. 为什么不直接把 V4L2 指针交给异步 VLM？ 62
3. shared_ptr 的 use_count()==1 能证明可以覆盖吗？ 62
4. 有界三帧池如何避免读写竞态？ 62
5. 为什么 shared_ptr 自定义 deleter 要在 mutex 外构造？ 62

6. Camera.stop 后，正在读旧帧的线程怎么办？ 62
7. stride 与 width 为什么不能互换？ 63
8. RGB 复用为什么必须考虑 Engine 锁与 SDK？ 63
9. NV12 转 RGB 优化后尺寸相同，为何还要逐像素比较？ 63
10. 如何判断缓存坐标是有效优化？ 63
11. DMA-BUF、物理连续内存和缓存一致性是什么关系？ 63
12. RGA 校验和 import 成功，为什么运行仍失败？ 64
13. 为什么 RSS 上升不一定是泄漏，但也不能忽略？ 64
14. 如何保证统计不“美化”结果？ 64
15. drain 与 cancel_pending 的安全退出区别是什么？ 64
6 第五阶段 5.4 统一 Profiling 和 TTS 优化 65
完整关键源码 include/common/request_trace.h 65
完整关键源码 include/common/image_profile.h 66
完整关键源码 src/audio/tts_service.cpp bool TTSService::synthesize(..... 68
完整关键源码 src/audio/alsa_playback_service.cpp bool AlsaPlaybackService::play(..... 70
5.4 关键源码逐句说明与生命周期审查 74
操作 1：统一时钟、日志与请求所有权 74
操作 2：沿已有队列传递上下文 75
操作 3：VAD 时间的真实意义 76
操作 4：RKLLM callback 和 VLM 状态 76
操作 5：TTS 和 ALSA 的测量边界 77
操作 6：固定输入、回放与信号等待 78
操作 7：验证如何覆盖这些语句 78
操作 8：手动 benchmark、CMake 与分析脚本 79
操作 9：最终音频回放错误检查的最小修正 80

5.4 性能工程面试题与参考答案 82
操作 1：为什么不能使用系统时间计算请求延迟？ 82
操作 2：为什么需要 Request ID，frame_id 为什么不能代替？ 83
操作 3：TLS 为什么不能自动解决 SDK 回调关联？ 83
操作 4：TTFT 应该如何定义？ 83
操作 5：TTS 首批音频就绪，是否等于用户听到声音？ 84
操作 6：如何用 RTF 公平比较 TTS？ 84
操作 7：为什么线程数越多不一定越快？ 84
操作 8：如何定位 TTS 队列等待的根因？ 84
操作 9：如何区分冷启动、预热和稳态？ 85
操作 10：如何证明一次优化是实际计算收益？ 85
操作 11：取消等待与排空退出有什么不同？ 85
操作 12：长回放等待为什么会破坏信号回归？ 86
操作 13：为什么不能把 NPU sysfs 的 load 直接当利用率？ 86
操作 14：怎样评估资源泄漏与测试覆盖的限度？ 86
7 第五阶段 5.5 Qt 和持续稳定性 86
5.5 Qt 集成与最终系统工程验收报告 87
1 继承版本与实际改动 87
2 Qt 运行环境与实际验收 90
3 ARM64 构建和确定性测试 93
4 热测试条件与安全边界 94
5 热对照的暖态延迟分布 95
6 RSS 趋势与 Linux 降频证据 100
7 最终源码性能与自然输入复核 102
8 退出背压异常及设备释放 107

9 实际问题与修复记录 111
10 保护复现与交付结论 112
5.5 Qt 适配与稳定性工具逐句说明 113
BackendSession 的对象与启动语句 113
停止与窗口关闭 114
输入缓冲与界面内存 115
共用信号类与 Qt 入口 115
故障测试和长测工具 116
真实 stdout 交错与结构化文本修复 117
本轮实际验证补充 117
5.5 新增关键源码逐行学习索引 118
src/gui/backend_session.cpp 118
src/gui/session_window.cpp 125
src/gui/main.cpp 140
include/app/stop_signals.h 144
include/gui/backend_session.h 148
include/gui/session_window.h 150
完整关键源码 include/gui/backend_session.h 154
完整关键源码 src/gui/backend_session.cpp 155
完整关键源码 include/gui/session_window.h 157
完整关键源码 src/gui/session_window.cpp 158
完整关键源码 src/gui/main.cpp 162
完整关键源码 src/audio/asr_llm_tts_smoke.cpp 163
5.5 Qt 与系统稳定性面试题及参考答案 188
1 为什么选择 QProcess 适配 CLI 而不是在窗口里重新创建模型 188

2 QProcess 的 started 是否意味着系统可接受语音 189
3 关闭 Qt 窗口时如何避免后台访问已销毁控件 189
4 为什么 Qt 中不能直接调用 waitForFinished 189
5 如何在 Qt 程序处理 SIGINT 而不在 handler 调用 Qt 189
6 2 线程与 4 线程的短时加速为什么不能决定最终默认值 189
7 如何区分 DVFS 和热降频 190
8 什么证据支持“没有发现明显内存泄漏” 190
9 为什么压力测试中的推理成功率和播放交付率要分开 190
10 固定音频回放能替代真实麦克风验收吗 190
11 Fake 故障测试为什么仍然重要 190
12 如何定义可复现的最终交付 191
8 构建运行复现和重要命令 191
5.5 重要命令及真实输出解析 191
build_final_v2 build 191
build_final_v2 configure 192
build_final_v2 ctest 193
thermal_matrix mixed_1800s_2t_command 194
thermal_matrix mixed_1800s_4t_command 196
thermal_matrix mixed_180s_2t_command 198
thermal_matrix mixed_180s_4t_command 199
gui_microphone_final_v2 command 201
gui_paired_restart_final_v2 command 202
gui_sigterm_vision_final_v2 command 204
gui_mixed_1800s_4t_final_v2 command 205
final_matrix final_burst_audio_command 206
final_matrix gui_mixed_1800s_4t_final_v2_command 208

final_matrix gui_paired_restart_final_v2_command 209
final_matrix gui_sigterm_vision_final_v2_command 210
final_matrix_retry1 final_burst_audio_retry1_command 212
final_matrix_retry1 final_expiry_audio_command 214
final_matrix_retry1 final_sigint_asr_command 215
final_matrix_retry1 final_sigint_drain_command 217
final_matrix_retry1 final_sigterm_cancel_waiting_command 219
final_matrix_retry1 final_sigterm_initialization_command 221
final_camera_followup camera64_command 222
final_camera_followup NPU_inventory_command 223
final_camera_followup protection_after_camera_command 224
camera_gap_recheck command 225
主机收集统计与文档生成 226
5.3 重要采集 固定帧和 RGA 命令 227
5.3 命令、参数与真实输出索引 227
5.4 固定输入与 ORT 诊断重要命令 231
9 最终验收边界和局限 242
10 简历项目描述与面试讲述 242
11 结果索引和源码一致性 243

1 工程环境与证据规则

硬件为 LubanCat 3 RK3576，4 个 Cortex A53 和 4 个 Cortex A72，约 4GB 物理内存、当前无 Swap；Linux 6.1.99-rk3576、aarch64、Debian GCC12.2.0、CMake/CTest3.25.1。IMX415 通过 V4L2 `/dev/video11` 采集 3840×2160 NV12，stride3840、sizeimage12441600，四个 MMAP 驱动槽。HyperX Cloud III 每次动态发现，历史实际 ID 为 III，不能把历史数字声卡写死。

模块	真实模型或 Runtime	执行与限制
ASR	Silero VAD 与 SenseVoice INT8，sherpa onnx1.13.8	CPU；实时采集与预分段回放必须区分
TEXT	Qwen2.5 1.5B W4A16，RKLLM1.3.1	模型制品 toolkit1.2.3；RKNPU driver0.9.8
VISION	SmolVLM2 256M W4A16 加 scatterfix RKNN Vision	RGB512×512，64×576 浮点特征；语言制品 toolkit1.3.1
TTS	Kokoro multi lang v1_1，ORT1.28.2	CPU，sid17，speed1，silence_scale0.2，24kHz
Qt	Qt5.15.8 Widgets 与 Test	可选构建，现有 xcb 桌面，不安装新软件

原稳定目录是`/home/cat/projects/RK3576/rk3576_multimodal`，唯一授权写目录是其同级`rk3576_multimodal_stage5_review`。模型及 SDK 继续引用原路径，源码和构建使用新目录。根目录历史笔记和早期 architecture/run 文档不能替代源码或终端；没有 Git 仓库时使用真实 git diff no-index 并验证补丁，不虚构 commit。

```
#!/usr/bin/env bash
# Source this file. Historical paths from 4.md, verified on board before use.
STAGE5_BASE=/home/cat/projects/RK3576
STAGE5_ORIGINAL="$STAGE5_BASE/rk3576_multimodal"
STAGE5_REVIEW="$STAGE5_BASE/rk3576_multimodal_stage5_review"
STAGE5_ASR="$STAGE5_BASE/asr_runtime/sherpa-onnx-sense-voice-zh-en-ja-ko-yue-int8-2024-07-17"
STAGE5_VAD="$STAGE5_BASE/asr_runtime/vad/silero_vad.onnx"
STAGE5_QWEN="$STAGE5_BASE/rkllm_sdk/models/Qwen2.5-1.5B-Instruct_RK3576_w4a16.rkllm"
STAGE5_KOKORO="$STAGE5_BASE/tts_runtime/models/kokoro-multi-lang-v1_1"
STAGE5_VLM="$STAGE5_ORIGINAL/models/vlm/smolvlm2_256m_w4a16_rk3576.rkllm"
STAGE5_VISION="$STAGE5_ORIGINAL/models/vlm/smolvlm_vision_scatterfix_rk3576.rknn"
```

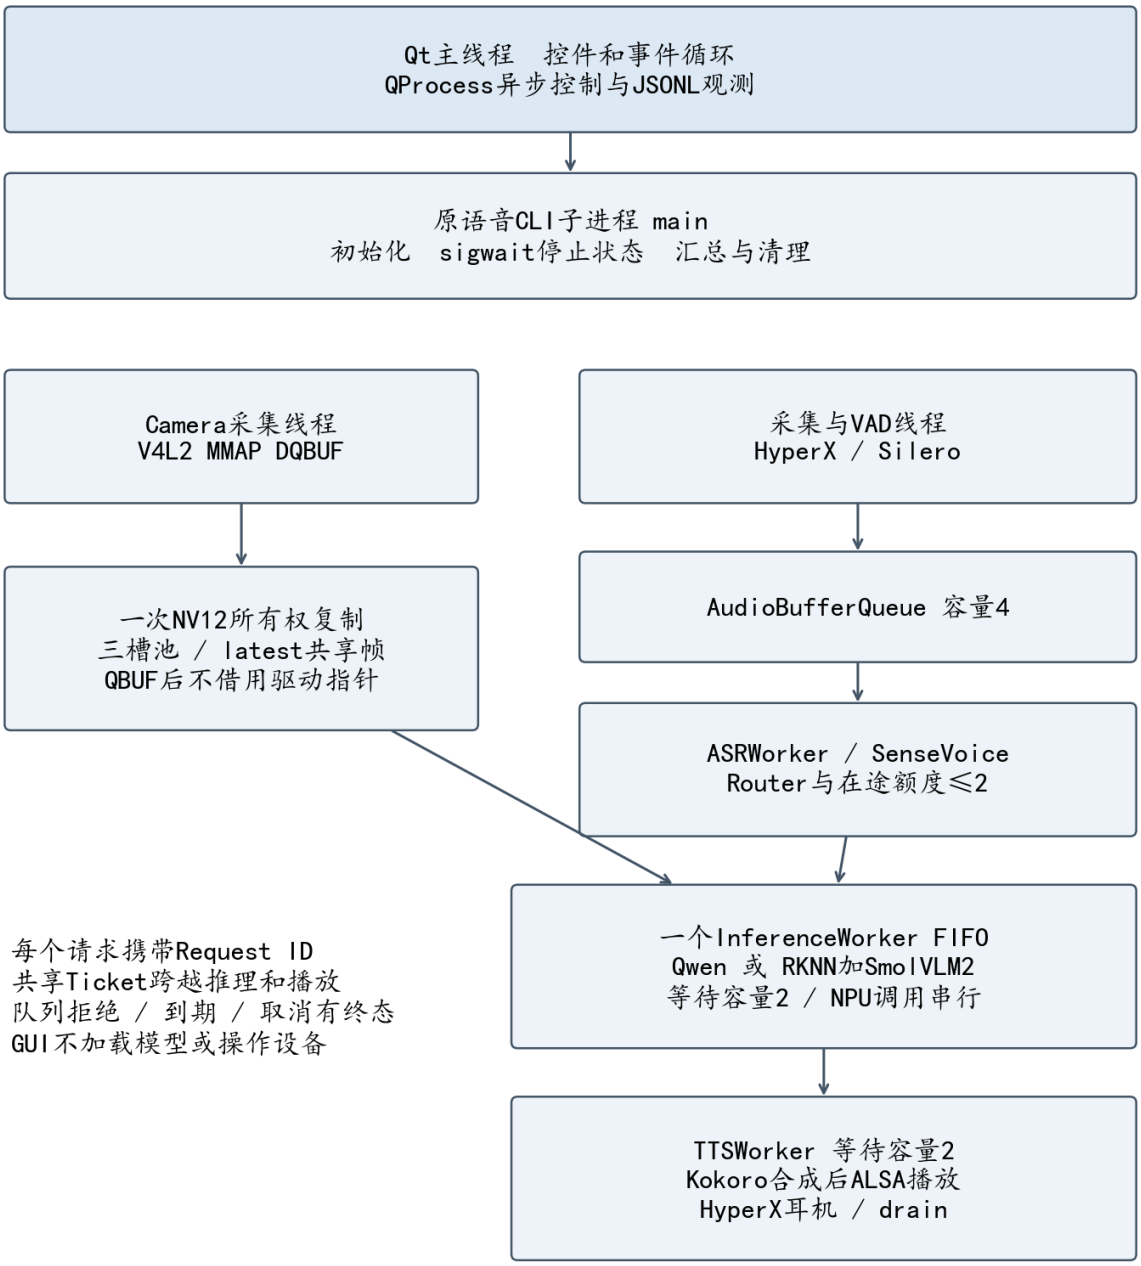
```
STAGE5_SHERPA="$STAGE5_BASE/asr_runtime/sherpa-onnx-v1.13.8-linux-aarch64-shared-cpu"
STAGE5_RKLLM="$STAGE5_BASE/rkllm_sdk"
STAGE5_RKNN_INCLUDE="$STAGE5_BASE/rknn_test/include"
STAGE5_RKNN_LIBRARY=/usr/lib/librknnrt.so
# Prefer the stable build's explicit SDK cache paths, never eval its contents.
```

路径变量只是环境引用，不复制模型。source 影响当前 shell，set -a 使变量导出到子进程；LD_LIBRARY_PATH 仅为本次进程指定已存在共享库，不修改系统缓存。每次实际参数、版本、声卡、PID、退出码、原工程指纹都与对应 case 共同保留。

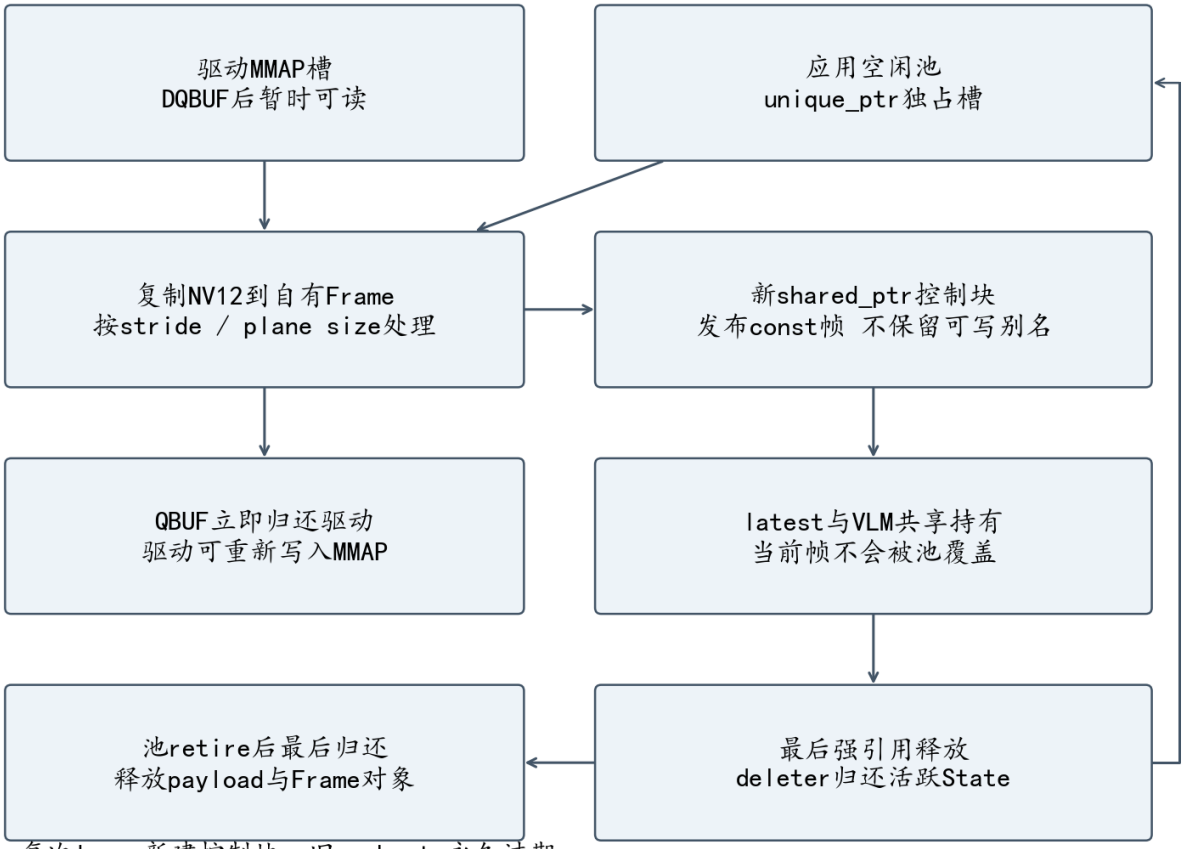
2 开发时间线与最终系统关系

阶段	时间依据	具体目标与结果
5.1	2026 年 10 月 17 日报告及 SSH 日志	生命周期审计、RKLLM 回调/输出释放、协作式 SIGINT 和 SIGTERM
5.2	2026 年 10 月 17 日报告及 ARM 日志	ASR 解耦、共同推理 FIFO、有界背压、取消与排空
5.3	2026 年 10 月 17 日报告及固定帧	三槽自有帧池、缓存预处理，RGA 失败保留
5.4	2026 年 10 月 17 日固定输入与听音	统一请求计时、TTS2/4 线程同条件 n30 比较
5.5	2026 年 10 月 17 日晚至 18 日实测	Qt 适配、热对照、最终源码长测、异常与完整交付

最终语音入口直接使用 IntentRouter，没有经过另一个 CLI 中的 RequestProcessor。Camera、采集/VAD、ASR、推理、TTS 和信号接收分别承担职责。InferenceWorker 是 include/ai/llm_worker.h 中的 using 别名，实际实现为 src/ai/llm_worker.cpp 的 LLMWorker，并不存在另一个 inference_worker.cpp。TEXT 和 VISION 共用同一个推理消费者；ASR 只提交，不同步执行 VLM。TTS 仍先合成完整 PCM 再播放，下一条不能越过当前合成和 drain。本节没有引入新的 AI 框架或模型。


Qt主线程 控件和事件循环
QProcess异步控制与JSONL观测
原语音CLI子进程 main
初始化 sigwait停止状态 汇总与清理
Camera采集线程
V4L2 MMAP DQBUF
采集与VAD线程
HyperX / Silero
一次NV12所有权复制
三槽池 / latest共享帧
QBUF后不借用驱动指针
AudioBufferQueue 容量4
ASRWorker / SenseVoice
Router与在途额度≤2
每个请求携带Request ID
共享Ticket跨越推理和播放
队列拒绝 / 到期 / 取消有终态
GUI不加载模型或操作设备
一个InferenceWorker FIFO
Qwen 或 RKNN加SmolVLM2
等待容量2 / NPU调用串行
TTSWorker 等待容量2
Kokoro合成后ALSA播放
HyperX耳机 / drain

最终进程和线程架构



每次lease新建控制块，旧weak_ptr永久过期。
RGB与Embedding按需复用；保留显式复制，不是零拷贝。

Camera 到 VLM 的所有权生命周期



安全退出和资源释放顺序

3 第五阶段 5.1 生命周期审计和安全退出

审计首先发现两个真实入口、Worker 对 Service 的借用、lambda 引用捕获以及 SDK 回调状态的寿命边界。join 只等待，不通知；开放空 ASR 队列会使析构永久等待。正确顺序是停止输入并关闭/唤醒队列，join 使用者，再销毁 Service 和 Runtime。5.1 原完整语音入口没有协作式信号处理，先记录真实缺陷，再最小修复，不能把 SIGKILL 叫安全退出。

RKLLM 的 Pimpl 保存参数和 callback，析构先 destroy handle，随后成员才析构；每次同步 run 的 RunContext 与用户 callback 状态持续到 run 返回。RKNN 输出只在 outputs_get 成功后归 owner，业务先复制 Embedding，再在正常/异常退栈路径 release。release 自身仍可能失败，当前记录错误；这不是 SDK 所有内部失败路径的证明。

完整关键源码 include/app/stop_signals.h

```
#pragma once
#include <atomic>
#include <cerrno>
#include <stdexcept>
#include <thread>
#include <pthread.h>
#include <signal.h>

// Construct before SDKs/workers: all descendant threads inherit the blocked set.
// sigtimedwait runs in an ordinary thread; there is no asynchronous signal handler.
class StopSignals {
public:
    StopSignals()
    {
        sigemptyset(&signals_);
        sigaddset(&signals_, SIGINT);
        sigaddset(&signals_, SIGTERM);
        if (pthread_sigmask(SIG_BLOCK, &signals_, &previous_) != 0)
            throw std::runtime_error("Cannot block stop signals");
        try
        {
            thread_ = std::thread([this] {
                const timespec interval{0, 100000000};
                while (!finished_.load())
                {
                    const int received = sigtimedwait(&signals_, nullptr, &interval);
                    if (received == SIGINT || received == SIGTERM)
                    {
                        int empty = 0;
                        signal_.compare_exchange_strong(empty, received);
                    }
                    else if (received < 0 && errno != EAGAIN && errno != EINTR)
                    {
                        wait_failed_.store(true);
                        break;
                    }
                }
            });
        }
        catch (...)
        {
            pthread_sigmask(SIG_SETMASK, &previous_, nullptr);
            throw;
        }
    }
    ~StopSignals()
    {
        finished_.store(true);
        if (thread_.joinable()) thread_.join();
        pthread_sigmask(SIG_SETMASK, &previous_, nullptr);
    }
    StopSignals(const StopSignals&) = delete;
    StopSignals& operator=(const StopSignals&) = delete;
    int received() const noexcept { return signal_.load(); }
    bool failed() const noexcept { return wait_failed_.load(); }
```

```
private:
    sigset_t signals_{};
    sigset_t previous_{};
    std::atomic<int> signal_{0};
    std::atomic<bool> finished_{false};
    std::atomic<bool> wait_failed_{false};
    std::thread thread_;
};
```

完整关键源码 src/ai/rkllm_backend.cpp struct RunContext

```
struct RunContext
{
    std::mutex mutex;
    std::string text;
    const LLMStreamCallback* on_chunk = nullptr;
    std::chrono::steady_clock::time_point start;
    double first_text_ms = -1.0;
    bool failed = false;
    RequestTracePtr trace;
};
```

完整关键源码 src/ai/rkllm_backend.cpp struct RKLLMBackend::Impl

```
struct RKLLMBackend::Impl
{
    std::string model_path;
    LLMHandle handle = nullptr;
    RKLLMParam params{};
    RKLLMCallback callbacks{};

    ~Impl() noexcept
    {
        if (handle != nullptr)
        {
            (void)rkllm_destroy(handle);
            handle = nullptr;
        }
    }
};
```

完整关键源码 src/ai/rk3576_vlm_backend.cpp struct RknnOutputOwner

```
struct RknnOutputOwner {
    rknn_context context;
    rknn_output output{};
    bool acquired = false;

    explicit RknnOutputOwner(rknn_context ctx) : context(ctx) {}
    RknnOutputOwner(const RknnOutputOwner&) = delete;
    RknnOutputOwner& operator=(const RknnOutputOwner&) = delete;
```

```
    ~RknnOutputOwner() noexcept {
        if (acquired) {
            auto begin=ImageProfile::Clock::now();
            const int code=rknn_outputs_release(context,1,&output);
            imageSample("rknn_outputs_release",ImageProfile::ms(begin));
            if(code)std::cerr<<"[RKNN release ERROR] ret="<<code<<'\n';
        }
    }
};
```

完整关键源码 src/audio/asr_pipeline.cpp void ASRWorker::run()

```
void ASRWorker::run()
{
    try
    {
        runImpl();
    }
    catch (const std::exception& e)
    {
        ok_ = false;
        error_ = std::string("ASRWorker exception: ") + e.what();
        queue_.close();
    }
    catch (...)
    {
        ok_ = false;
        error_ = "ASRWorker: unknown exception";
        queue_.close();
    }
}
```

完整关键源码 src/audio/asr_pipeline.cpp void ASRWorker::runImpl()

```
void ASRWorker::runImpl()
{
    AudioSegment segment;

    while (queue_.pop(segment))
    {
        using Clock = std::chrono::steady_clock;

        // 消费者真正从队列取出音频的时间。
        const auto popped_at = Clock::now();
        RequestTraceScope trace_scope(segment.trace);
        traceMark("asr_dequeued",popped_at);

        std::vector<float> samples;
        std::string error;

        if (!segment.samples.empty())
        {
            // VAD 已输出 Float32，直接移动。
```

```
    samples = std::move(segment.samples);
}
else
{
    // 兼容原始 S16_LE 录音流水线。
    if (!AudioPreprocessor::convertS16ToFloat32(
            segment.pcm,
            16000,
            1,
            samples,
            error))
    {
        error_ = "Preprocessing: " + error;
        queue_.close();
        return;
    }
}

if (samples.empty())
{
    error_ = "Empty ASR audio segment";
    queue_.close();
    return;
}

std::string text;
double latency_ms = 0.0;

// 推理开始时间。
const auto infer_start = Clock::now();
traceMark("asr_begin",infer_start);

if (!asr_.recognize(
        samples,
        text,
        latency_ms,
        error))
{
    traceMark("asr_failed");
    error_ = "ASR: " + error;
    queue_.close();
    return;
}

// 获取文字结果的时间。
const auto result_ready = Clock::now();
traceMark("asr_end",result_ready);

++processed_;

const double audio_duration_ms =
    1000.0 *
    static_cast<double>(samples.size()) /
    16000.0;

const double rtf =
    latency_ms / audio_duration_ms;
```

```
// 统一使用 steady_clock 时间差。
auto elapsed_ms = [](
    Clock::time_point first,
    Clock::time_point second)
{
    return std::chrono::duration<
        double, std::milli
    >(second - first).count();
};

{
    std::lock_guard<std::mutex> lock(
        print_mutex_
    );

    // 原始 ASR 输出格式保持不变。
    std::cout
        << "[ASR] Segment #"
        << segment.sequence
        << ": "
        << (text.empty() ? "<empty>" : text)
        << " | latency="
        << latency_ms
        << " ms"
        << " | RTF="
        << rtf
        << '\n';

    // 仅对来自 VAD 的有效时间戳计算。
    if (segment.timing_valid)
    {
        std::cout
            << "[Timing] Segment #"
            << segment.sequence

            << " endpoint_est_ms="
            << elapsed_ms(
                segment.audio_end_estimated_at,
                segment.vad_ready_at
            )

            << " vad_to_queue_ms="
            << elapsed_ms(
                segment.vad_ready_at,
                segment.enqueued_at
            )

            << " queue_wait_ms="
            << elapsed_ms(
                segment.enqueued_at,
                popped_at
            )

            << " preprocess_ms="
            << elapsed_ms(
                popped_at,
```

```
                    infer_start
                )

                << " asr_wall_ms="
                << elapsed_ms(
                    infer_start,
                    result_ready
                )

                << " total_est_ms="
                << elapsed_ms(
                    segment.audio_end_estimated_at,
                    result_ready
                )

                << '\n';
        }
    }

    // ASR 完成后调用业务回调；完整语音入口直接路由，未经过 RequestProcessor。
    // 必须在释放 print_mutex_ 后执行。
    if ((on_text_ || on_context_) && !text.empty())
    {
        try
        {
            if(on_context_)on_context_(text,segment);
            else on_text_(text);
        }
        catch (const std::exception& e)
        {
            error_ =
                std::string("ASR text callback: ") +
                e.what();

            queue_.close();
            return;
        }
        catch (...)
        {
            error_ =
                "ASR text callback: unknown exception";

            queue_.close();
            return;
        }
    }
    else if(text.empty())traceMark("asr_empty_text");
}

ok_ = true;
}
```

语法与执行次序：std::thread(&ASRWorker::run,this)借用对象地址，因此对象必须活到 join 之后。入口 catch 捕获标准和未知异常，设置错误并关闭队列；不能让异常穿出线程入口触

发 terminate。lock_guard 在 return 或异常时自动解锁；unique_lock 允许 condition_variable 临时释放并重新获取锁。状态与谓词在同一 mutex 下更新，notify_all 使空队列等待者重新判断 closed；通知本身不是可累计事件。

StopSignals 在所有线程创建前阻塞 SIGINT/SIGTERM，普通线程调用 sigtimedwait，atomic 发布首个信号。析构置 finished、join、恢复原 mask。没有 handler 调用 Qt、日志、malloc、mutex 或 join。构造/析构应由同一 owner 线程执行。活动同步推理仍允许完成；无法保证闭源 SDK 永久卡住时存在硬截止。

5.1 最终实机注册 CTest4/4、完整 TEXT/VISION 语音、实际耳机、自然及信号退出和 321 项保护检查通过。Windows 当时 6/6 只证明 portable 逻辑，不能替代 ARM64。完整缺陷原表现、修复 diff 和日志在 stage5_01_board_acceptance 及相应 reports 目录。

本节面试题与完整答案

以下问题保留 5.1 当时语境，其 Windows6 项计数与当时双 Engine 并发问题不是最终版本现状。

1. 为什么只使用智能指针还会出现生命周期错误？

unique_ptr/shared_ptr 管理其拥有的对象；本项目的 Worker 借用 Service，lambda 借用 mutex/counter。引用捕获不会延长它们寿命。必须使被引用状态先构造、后销毁，并在其销毁前 stop/join 使用者。Runtime handle 自动释放也不能代替线程先结束。

2. 为什么析构里的 join 可能一直等待？

join 只等待，不通知。消费者卡在开放空队列的 cv.wait 时，必须先在锁内改变 closed 状态，再 notify，谓词为真才能返回。即便队列已关闭，活跃的同步 SDK 卡住仍会使 join 等待；线程回收不是强制取消机制。

3. 为什么不把 ASR、LLM、TTS 一起 requestStop？

上游完成回调还可能生产下游请求。正常排空必须先结束采集/ASR，再确认 LLM 不再向 TTS 提交，最后排空 TTS。提前 stop TTS 会拒绝仍然合法的回答。异常退出允许取消等待任务，但要明确结果并保留状态寿命。

4. shared_ptr<const ImageFrame> 是否是零拷贝？

缓存交换与消费者取指针没有整帧复制，但之前 MMAP payload 已复制到 vector，后面还有 RGB 转换和 embedding 复制。局部共享对象不等于全链路零拷贝。QBUF 后驱动复用映射内存，去掉自有帧复制需要重设计归还/共享所有权和同步。

5. 两个 Engine 都有 mutex，能否证明 NPU 没有资源冲突？

不能。两个 mutex 保护两个实例，LLMWorker 与 ASR 的 VLM 分支仍可并行调用同一硬件。应记录重叠、Runtime 错误、延迟和资源；确认冲突后再选择共享调度，不能凭推测增加全局锁并声称已经解决硬件问题。

6. 有界队列容量 2 为什么可能存在 3 个任务？

代码把执行中的任务弹出 deque 后才推理，因此容量只限制等待任务。单消费者最多 1 个活跃任务加 2 个等待任务。音频队列满丢旧、LLM/TTS 满拒绝是不同策略，统计和业务反馈不能混用。

7. 如何避免 C SDK buffer 在 C++ 异常时泄漏？

取得成功后立即由不可复制的 RAII owner 管理，析构调用配套 SDK release；输出仍需复制到业务自有 vector 时也受保护。必须保证 owner 的 context 比它活得久、析构不抛异常、只释放已成功取得的资源。并不意味着 SDK release 自身永不失败。

8. Windows 6/6 CTest 能证明什么？

证明当前 MinGW 构建的六项测试符合其断言，覆盖队列/异常/状态/替身生命周期等可移植逻辑。它不编译真实 RKNN/ALSA 实现，不验证 ARM64 ABI、模型精度、NPU 并发、音质或板端性能。工程验收必须补目标端构建及真实设备日志。

9 为什么不能在 signal handler 中调用条件变量

POSIX 异步信号可能打断持有同一锁的线程；mutex、condition_variable 和 Qt 操作不保证异步信号安全，会死锁或破坏运行状态。本项目通过阻塞信号加普通 sigwait 线程，把通知和停止放回正常线程上下文。

10 析构顺序为什么是并发接口的一部分

局部对象逆声明顺序析构，成员也逆声明顺序析构。Worker 持有的引用不会自动延长 Service、mutex 或 counter 寿命；必须在析构依赖对象前 stop/join。只把句柄换成智能指针而不检查谁仍在使用它，仍可能造成 use-after-free。

4 第五阶段 5.2 有界异步任务和 NPU 调度

5.2 多线程与异步 Pipeline 工程记录

状态：5.2 工程验收通过，完整证据见 stage5_02_board_acceptance.md，本轮暂停在 5.3 之前。日期：2026-10-17。

操作 1：继承 5.1 验收与授权边界

已完整读取任务书及 stage5_01_board_acceptance.md。5.1 的真实语音闭环、用户听音及协作式信号退出是基线，不算作 5.2 已通过的证据。仅修改本地和 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review。原工程、原 build/stage5_full、模型、SDK、驱动、设备树及系统配置不写入。没有上传用户明确不需要的 stage5_01_acceptance_local.tgz。

本地无 Git 元数据，以 backups/stage5_02_before/ 的 107 文件快照、SHA256 和 Git no-index 格式差异记录版本。5.1 初始包清单与最终修复源码有差异，本节继承正式验收的最终源码。

操作 2：源码定位与最小方案

ASRWorker::run() 同步调用 on_text。原 TEXT 分支提交 LLMWorker；VISION 分支却直接执行 vlm->infer(frame, vlm_question)，包含 RKNN Vision 和 SmolVLM2 RKLLM，阻塞 ASR 工作线程。CameraService 已独立采集，LatestFrameBuffer 保存共享最新帧；无需重建 Camera 框架。原 TTSWorker 在一个线程中合成和播放，等待容量 2，但局部队列限制不代表全部在途回答有界。

实施顺序为冻结基线及 NPU 实测、复用推理 FIFO、跨阶段额度及过期/取消、Fake 并发测试、ARM64 与真实语音回归。模型算法和 SDK 不改。

文件	具体改动	验收方法
common/work_control.h	停止模式、截止时间、等待期限、取消 flag 和统计	Fake 过期与取消断言
ai/llm_worker.h/.cpp	保留 TEXT 接口，新增 submitTask、显式 restart、终态统计	FIFO、满载、抛异常、停止重启
app/pipeline_admission.h	一个 Ticket 覆盖推理至播放全过程	最后引用释放与 close 并发测试
audio/asr_llm_tts_smoke.cpp	VLM 异步提交、执行时取最新帧、ID/期限传递、退出语义	同输入 A/B、真实语音、信号
audio/tts_worker.h/.cpp	保留原合成及播放，加入过期/取消/统计/重启	Fake TTS 与 Kokoro/ALSA
audio/asr_pipeline.h/.cpp	保留原丢旧音频策略，增加 ID 日志、峰值及计数	原 ASR 测试和连续采集
TTS/ALSA service 头与实现、tts_smoke.cpp	公共头用前置声明，实际调用显式 include SDK	真实 SDK 全目标编译
tests/async_pipeline_tests.cpp	闸门控制的确定性线程测试	本地和 ARM64 CTest
tests/stage5_02_npu_probe.cpp	顺序/重叠 NPU 调用对照，手工诊断 target	真实 SDK 实测；不注册 CTest
tools/stage5_02_*、回放 TSV	隔离路径、PID 检查、超时、证据收集	原始退出码、日志、321 项指纹

操作 3：真实线程与队列架构

```
flowchart LR
  Main[主线程: stop 与 join] --> Capture[VadAudioWorker: ALSA capture + Silero VAD]
  Capture --> AQ[AudioBufferQueue: 4 个 AudioSegment]
```

```
AQ --> ASR[ASRWorker: SenseVoice + IntentRouter]
ASR --> Admit[PipelineAdmission: 默认 2 个跨阶段 Ticket]
Admit --> IQ[复用 LLMWorker FIFO: TEXT/VISION closure]
IQ --> AI[唯一推理消费者: Qwen 或 RKNN + SmolVLM2]
Camera[CameraService 独立采集线程] --> Latest[LatestFrameBuffer 最新共享帧]
Latest --> AI
AI --> TQ[TTSWorker FIFO: 文本及回调及 TaskOptions]
TQ --> TTS[同一 TTS 线程: Kokoro 合成后 ALSA 播放]
Signal[独立 sigtimedwait 线程] --> Main
```

这些是应用线程，SDK 内部线程仍由各 SDK 管理。ASR 只负责识别、路由、申请额度和提交 closure，不等待推理或 TTS。视觉帧在执行时取最新共享帧，不把 4K 图像积在队列里。共享推理消费者覆盖本入口的两种 RKLLM 与 RKNN 调用；独立程序不受该 FIFO 管理，因此运行前仍检查设备占用。

操作 4：有界性、背压与终态

默认 max_inflight=2，Ticket 一直持有到 TTS 完成或其他终态回调及 closure 释放。局部推理等待和 TTS 等待容量均保留 2；默认额度下存在活动 TTS 时最多一个等待回答。额度满拒绝新请求，打印请求 ID、路由与原因并统计；不覆盖已接收回答。

默认推理排队上限 10000 ms、TTS 排队上限 12000 ms、跨阶段生存期 45000 ms，使用 steady_clock。在阶段执行前检查，过期不调用 SDK，但仍回调终态、计数、归还额度。活跃 SDK 不强制中断，因此这些期限不构成硬实时完成保证。

completed 表示所有终态，包括取消和过期；started 才是执行过 SDK/任务体，failed 是运行错误。策略拒绝、过期、成功播放必须分别报告，不能将 completed 当推理成功或把丢弃带来的吞吐下降隐藏。配置解析严格校验范围，非法值明确失败。提供 cancel(id)，本入口尚未实现用户口头打断命令。

操作 5：生命周期、竞态与退出审查

start 保留一次性语义；restart 仅由唯一 owner 在 requestStop、join 后调用，本轮统计重置、generation 递增。submit 与 requestStop 使用同一个队列 mutex；start/join/restart/析构不能由多个 owner 并发调用，回调不能 join 自己。

Drain 关闭新入口并完成已接收任务，仍尊重原期限。CancelPending 取消尚未开始的阶段，活跃 SDK 或播放正常结束；正在推理的请求结束后若取消，不再进入 TTS。取消关闭与提交竞争产生的 NotRunning 单独记为预期取消，不误报为运行失败。

Worker 不持有队列锁执行 SDK 或业务回调。回调后先销毁 task captures，再锁内发布 completed/active=0，最后 notify；main 观察到 idle 时，TTS 转交及额度归还均已完成。Admission 表内保存 weak_ptr<atomic<bool>>，避免锁内暂时取得最后一个 Ticket 引用并析构，再次锁同一 mutex。状态、帧缓冲、VLM/Camera 声明早于 Worker，反向析构先 join Worker，后销毁被借用对象。

停止顺序为停止/唤醒录音、关闭音频队列、join VAD/ASR、关闭 Admission、排空或取消推理、join 推理、destroy Qwen、排空或取消 TTS、join TTS、close ALSA/destroy TTS、Camera stop/join、VLM/RKNN destroy。继承 5.1 sigtimedwait，不在异步 signal handler 中加锁、打印或调用 SDK。

剩余边界：SDK 永久阻塞时，C++ join 无硬截止保证。外层保护只允许终止本次已核实 PID，必须将强制终止记为退出失败。没有以有限回归宣称无任何竞态，也没有声称已完成 ASan/TSan 或长期压力。

操作 6：回声与 TTS 调度取舍

HyperX 耳机降低回灌，不等于 AEC。保持播放期间 ASR 可继续处理，以端到端额度限制误触发积压。冷却、PTT、AEC、打断需要明确产品语义，本节未实现。没有把 TTS 拆为合成和播放两个线程，避免增加预合成 PCM 积压与资源生命周期；模型计算优化留在 5.4。

操作 7：构建问题与证据分类

首次 ARM64 构建暴露 `tts_smoke.cpp` 对 SherpaOnnxWriteWave 的间接 include 依赖。公共头解耦后补显式 SDK C API include，保留原失败日志及复测日志。修复后全目标构建成功，ARM64 CTest 5/5，0.29 s；本地 portable CTest 7/7，0.53 s。CTest 中 Fake/Mock 不代表硬件推理；下文另记真实模型回归。

完整数据见 `stage5_02_performance.md` 和 `stage5_02_board_acceptance.md`；完整关键源码见 `stage5_02_source_appendix.md`，逐句解释及面试题见 `stage5_02_statement_notes.md`。本节已完成，等待用户审阅后再进入 5.3。

操作 8：适用范围补充

CancelPending 针对尚未开始的推理/TTS 阶段；音频队列仍沿用 5.1 的关闭并排空方式。已采集音频段可能继续被 ASR 识别，但 Admission 已关闭，会明确拒绝新业务提交。因此取消退出仍可能包含残留 ASR 和当前 SDK/播放的耗时，不承诺瞬时停止所有计算。

仅默认 `STAGE5_MAX_INFLIGHT=2` 完成了本轮硬件验收。上调至 8 不会无限增长，但局部等待队列仍为 2，可能产生额外 QueueFull 及程序失败状态；放宽额度前需结合容量和实际负载重新验收。

并发控制没有消除 TTS 的 CPU/内存带宽竞争。真实连续测试中 VLM 有一次 2793.65 ms，不能把单消费者描述为所有延迟均固定或下降。模型成功率和请求交付率分别报告；播放成功仍需要用户听音确认。

5.2 实测性能数据

本表由 `tools/stage5_02_performance.py` 从采集的原始终端/JSON 生成。设备、模型、构建和限制见 验收报告。日期 2026-10-17，RK3576 真机；Fake 测试不纳入这些性能数字。

统计均为毫秒（吞吐表除外），P50/P95 使用 nearest-rank，n=2 的 P50 为较小值，n≤4 的 P95 常等于最大值。每个 case 仅运行一次、请求数很小，没有置信区间或生产尾延迟结论；频率、温度、图像和生成长度未严格固定。

操作 1：NPU 实际 SDK 调用对照

调用方式（每类 n=3）	指标	平均 ms	P50 ms	P95 ms
顺序	Qwen 调用	945.432	867.519	1110.670
顺序	RKNN+SmolVLM2 调用	1927.090	1989.400	2046.740
顺序	一对任务完成	2872.523	2856.920	2904.850
顺序	SDK 调用区间交集	0.000	0.000	0.000
重叠	Qwen 调用	2338.717	2306.140	2409.420

调用方式（每类 n=3）	指标	平均 ms	P50 ms	P95 ms
重叠	RKNN+SmolVLM2 调用	2667.267	2656.390	2718.580
重叠	一对任务完成	2667.267	2656.390	2718.580
重叠	SDK 调用区间交集	2338.717	2306.140	2409.420

6/6 对成功。重叠未观察到崩溃，但 Qwen 调用变慢；区间交集不是 NPU 硬件利用率。统一消费者是响应可预测性的选择，不是“并行已经被证明不安全”的结论。

操作 2：ASR 业务回调/受控提交阻塞

case	n	平均 ms	P50 ms	P95 ms
baseline_equal_work_pair	2	868.872	0.014	1737.730
baseline_replay_overload	4	957.756	0.014	1920.580
candidate_cancel_active_vision	1	0.032	0.032	0.032
candidate_equal_work_pair	2	0.090	0.035	0.144
candidate_idle_sigint	0	—	—	—
candidate_replay_overload	4	0.128	0.047	0.367
candidate_stop_cancel_pending	4	0.075	0.024	0.183
candidate_stop_drain	4	0.078	0.037	0.195
candidate_voice_burst	4	0.031	0.031	0.039
candidate_voice_natural	2	0.310	0.023	0.597

baseline 的 VISION 耗时落在调用者线程；candidate 的 VISION 工作落在推理 Worker。表中混合 TEXT/VISION；过载 case 的 n 包括被拒绝请求，应同时读接受率。受控文本模式测同一个生产回调，不测 ASR 模型；真实 microphone case 才包含 USB/VAD/SenseVoice。

操作 3：各队列等待

case	推理排队 n / 平均 / P50 / P95 ms	TTS 终态 n / 平均 / P50 / P95 ms
baseline_equal_work_pair	1 / 0.075 / 0.075 / 0.075	2 / 7852.470 / 0.039 / 15704.900
baseline_replay_overload	2 / 706.132 / 0.085 / 1412.180	3 / 22385.326 / 22963.900 / 44192.000
candidate_cancel_active_vision	1 / 0.086 / 0.086 / 0.086	0 / — / — / —
candidate_equal_work_pair	2 / 460.445 / 0.088 / 920.802	2 / 10201.036 / 0.071 / 20402.000
candidate_idle_sigint	0 / — / — / —	0 / — / — / —
candidate_replay_overload	2 / 475.481 / 0.090 / 950.871	2 / 11021.560 / 0.020 / 22043.100
candidate_stop_cancel_pending	2 / 425.233 / 0.078 / 850.388	2 / 10222.646 / 0.092 / 20445.200
candidate_stop_drain	2 / 445.267 / 0.130 / 890.404	2 / 11128.593 / 0.087 / 22257.100
candidate_voice_burst	3 / 0.046 / 0.042 / 0.072	3 / 1274.973 / 0.095 / 3824.760
candidate_voice_natural	2 / 0.046 / 0.021 / 0.071	2 / 0.118 / 0.018 / 0.218

baseline 推理队列 n 只包含异步 TEXT，VISION 直接同步执行，没有相应 queue_ms；不能把缺失数据当零后混平均。TTS 统计包括过期/取消的真实驻留；取消回调兼容值 -1 已用 `[TTS cancelled]` 的实际驻留代替。过期出队时检查，实际驻留可超过配置期限。

操作 4：深度、接受/拒绝、成功率和完整交付

峰值与退出状态

case	推理峰值 / TTS 峰值	跨阶段峰值	子进程码
baseline_equal_work_pair	1/1	无跨阶段限制	0
baseline_replay_overload	1/2	无跨阶段限制	1
candidate_cancel_active_vision	1/0	1	0
candidate_equal_work_pair	1/1	2	0
candidate_idle_sigint	0/0	0	0
candidate_replay_overload	1/1	2	0
candidate_stop_cancel_pending	1/1	2	0
candidate_stop_drain	1/1	2	0
candidate_voice_burst	1/1	2	0
candidate_voice_natural	1/1	1	0

实际执行 完整交付与策略终态

case	推理成功/实际执行	播放/输入请求	Admission 拒绝	TTS 过期/取消
baseline_equal_work_pair	2/2	2/2	不适用	无该策略
baseline_replay_overload	4/4	3/4	不适用	无该策略
candidate_cancel_active_vision	1/1	0/1	0	0/0
candidate_equal_work_pair	2/2	2/2	0	0/0

case	推理成功/实际执行	播放/输入请求	Admission 拒绝	TTS 过期/取消
candidate_idle_sigint	0/0	0/0	0	0/0
candidate_replay_overload	2/2	1/4	2	1/0
candidate_stop_cancel_pending	2/2	1/4	2	0/1
candidate_stop_drain	2/2	2/4	2	0/0
candidate_voice_burst	3/3	3/4	1	0/0
candidate_voice_natural	2/2	2/2	0	0/0

baseline_replay_overload 另有 1 次 TTS 队列满拒绝，退出 1；其余子程序返回 0。candidate_cancel_active_vision 下游取消 1，不启动 TTS。不能把推理成功率当请求最终交付率；没有执行的请求不计进模型成功分母。音频队列两轮真实 microphone 均峰值 1、dropped 0。

操作 5：有限批次吞吐和自然排空退出

case	ready 至退出 s	成功推理 / s	完成播放 / s	输入关闭至退出 s
baseline_equal_work_pair	30.981	0.065	0.065	29.114
baseline_replay_overload	61.218	0.065	0.049	—
candidate_equal_work_pair	36.158	0.055	0.055	34.973
candidate_idle_sigint	3.918	0.000	0.000	—
candidate_replay_overload	27.033	0.074	0.037	—
candidate_voice_burst	82.621	0.036	0.036	—
candidate_voice_natural	92.016	0.022	0.022	—

吞吐分母包含 drain/退出；真实 microphone case 还包含等待用户和静音窗口，不能称持续最大吞吐。两请求 equal_work_pair 都接受并播放 2/2，TTL 放宽到 60 s 排队/120 s 生命周期以

避免策略丢弃。源输入相同，但 VLM 分别生成 12 与 17 个英文词，PCM 帧数 80696 与 107578，未保持计算工作量完全相同；candidate 的批次排空实际更慢，不能宣称端到端加速。其主要收益是 VISION 回调不再占用 ASR。

操作 6：停止模式和资源采样

case	信号	模式	信号至退出 s	采样峰值 RSS KiB	采样线程峰值
baseline_equal_work_pair	自然结束	drain	—	2511620	12
baseline_replay_overload	自然结束	drain	—	2582112	13
candidate_cancel_active_vision	SIGTERM	cancel_pending	3.413	2505916	7
candidate_equal_work_pair	自然结束	drain	—	2507400	9
candidate_idle_sigint	SIGINT	drain	1.907	2496948	9
candidate_replay_overload	自然结束	drain	—	2514388	10
candidate_stop_cancel_pending	SIGTERM	cancel_pending	1.532	2519368	10
candidate_stop_drain	SIGTERM	drain	12.229	2522504	10
candidate_voice_burst	自然结束	drain	—	2638328	12
candidate_voice_natural	自然结束	drain	—	2634780	12

信号延迟从 harness 发送时刻至子进程退出/输出 EOF，排除后续 fuser/指纹查询。Drain 与 CancelPending 完成工作量不同，不是同等计算加速。采样周期约 1 s，可能漏过短峰值；RSS 包含 SDK、模型映射和工作缓冲，不能当 C++ heap 泄漏大小。全部 case 无超时/强制终止且设备释放。长期稳定性留后续独立验收。

操作 7：模型计算时间与局限

case	成功 TTS n	合成平均 ms	P50 ms	P95 ms
baseline_equal_work_pair	2	11365.685	8659.770	14071.600
baseline_replay_overload	3	15382.090	17654.400	19986.900
candidate_cancel_active_vision	0	—	—	—
candidate_equal_work_pair	2	13256.445	8842.090	17670.800
candidate_idle_sigint	0	—	—	—
candidate_replay_overload	1	18855.800	18855.800	18855.800
candidate_stop_cancel_pending	1	17753.000	17753.000	17753.000
candidate_stop_drain	2	13819.420	8643.440	18995.400
candidate_voice_burst	3	14853.563	16361.800	18687.700
candidate_voice_natural	2	12545.760	8656.320	16435.200

回答文本长度、CPU 竞争和 Camera 场景不同，合成数值波动不能归因为异步化提升模型速度。本节未改变 Kokoro 模型或合成算法。5.4 再按固定语料、更多样本和统一时间链路分析计算性能。

前文是 5.2 当时完成记录；其“后续 5.3”属于时间线。最终仍复用同一队列和 Worker，而非两套并行 Demo。

完整关键源码 include/ai/llm_worker.h

```
#pragma once

#include "ai/llm_engine.h"

#include <chrono>
#include <condition_variable>
#include <cstddef>
#include <cstdint>
#include <deque>
#include <functional>
#include <mutex>
```

```
#include <string>
#include <thread>

enum class LLMSubmitStatus
{
    Accepted,
    NotRunning,
    QueueFull
};

using LLMWorkerChunk =
    std::function<void(std::uint64_t, const std::string&)>;

using LLMWorkerDone =
    std::function<void(std::uint64_t, const InferenceResult&, double)>;

// 单消费者、有界排队；不拥有 LLMEngine。
// Engine 必须比 Worker 活得更久。
// 回调中不得销毁 Worker，也不能 join Worker 自己的线程。
// start/join/destruction must be serialized by the owner thread.
// Callback captures (including mutexes/counters) must outlive the joined Worker.
class LLMWorker final
{
public:
    explicit LLMWorker(LLMEngine& engine, std::size_t capacity = 2);
    // Reuse the same FIFO for custom inference, including VLM; owns no Engine.
    explicit LLMWorker(std::size_t capacity = 2);
    ~LLMWorker();

    LLMWorker(const LLMWorker&) = delete;
    LLMWorker& operator=(const LLMWorker&) = delete;

    // 只允许启动一次。
    bool start(std::string& error);
    // Explicit restart only after requestStop + join; start itself retains its one-shot
contract.
    bool restart(std::string& error);

    // 正在执行的任务不占用等待队列容量。
    LLMSubmitStatus submit(std::uint64_t id,
                           std::string question,
                           LLMWorkerChunk on_chunk = {},
                           LLMWorkerDone on_done = {},
                           TaskOptions options = {});
    using Inference = std::function<InferenceResult(const LLMStreamCallback&)>;
    LLMSubmitStatus submitTask(std::uint64_t id, Inference inference,
                               LLMWorkerChunk on_chunk = {}, LLMWorkerDone on_done = {},
                               TaskOptions options = {});

    // 停止接收新请求，排队任务取消。
    void requestStop(StopMode mode = StopMode::CancelPending) noexcept;

    // 需要先 requestStop，且不能从 Worker 线程内部调用。
    void join();

    std::size_t pendingCount() const;
    std::size_t rejectedCount() const;
```

```
    WorkerStats stats() const;
    bool waitIdleFor(std::chrono::milliseconds timeout);

private:
    struct Task
    {
        std::uint64_t id = 0;
        Inference inference;
        LLMWorkerChunk on_chunk;
        LLMWorkerDone on_done;
        std::chrono::steady_clock::time_point enqueued_at{};
        TaskOptions options;
    };

    void run();

    LLMEngine* engine_ = nullptr;
    const std::size_t capacity_;

    mutable std::mutex mutex_;
    std::condition_variable cv_;
    std::deque<Task> pending_;

    std::thread thread_;

    bool started_ = false;
    bool stop_requested_ = false;
    StopMode stop_mode_ = StopMode::CancelPending;
    std::size_t rejected_ = 0;
    WorkerStats stats_;
};

// Descriptive alias; no second queue implementation or second AI framework.
using InferenceWorker = LLMWorker;
```

完整关键源码 src/ai/llm_worker.cpp

```
#include "ai/llm_worker.h"
#include <algorithm>
#include <atomic>
#include <exception>
#include <iostream>
#include <stdexcept>
#include <utility>

LLMWorker::LLMWorker(LLMEngine& engine,std::size_t
capacity):LLMWorker(capacity){engine_=&engine;}
LLMWorker::LLMWorker(std::size_t capacity):capacity_(capacity) {
    if (!capacity_) throw std::invalid_argument("LLMWorker capacity must be greater than zero");
}
LLMWorker::~LLMWorker(){requestStop();join();}
bool LLMWorker::start(std::string& error) {
    std::lock_guard<std::mutex> lock(mutex_);error.clear();
    if (started_ || stop_requested_) {error="LLMWorker can only be started once; use restart
after stop/join";return false;}
```

```
    try {thread_=std::thread(&LLMWorker::run,this);started_=true;++stats_.generation;}
    catch(const std::exception& e){error=std::string("LLMWorker thread creation failed:
")+e.what();return false;}
    return true;
}
bool LLMWorker::restart(std::string& error) {
    {std::lock_guard<std::mutex> lock(mutex_);
     if (!started_ || !stop_requested_ || thread_.joinable() || !pending_.empty())
{error="restart requires stopped and joined worker";return false;}
     started_=false;stop_requested_=false;rejected_=0;
     const auto generation=stats_.generation;stats_={};stats_.generation=generation;}
    return start(error);
}
LLMSubmitStatus LLMWorker::submit(std::uint64_t id,std::string question,LLMWorkerChunk
chunk,LLMWorkerDone done,TaskOptions options) {
    if (!engine_) throw std::logic_error("submit(text) requires an LLMEngine");
    return submitTask(id,[this,question=std::move(question)](const LLMStreamCallback&
callback){
        return engine_->inferStreaming(question,callback);
    },std::move(chunk),std::move(done),std::move(options));
}
LLMSubmitStatus LLMWorker::submitTask(std::uint64_t id,Inference inference,LLMWorkerChunk
chunk,LLMWorkerDone done,TaskOptions options) {
    if (!inference) throw std::invalid_argument("Empty inference task");
    const auto trace=options.trace;std::chrono::steady_clock::time_point enqueued{};std::size_t
depth=0;
    {std::lock_guard<std::mutex> lock(mutex_);
     if (!started_ || stop_requested_) {++stats_.rejected_stopped;if(trace)trace-
>mark("inference_rejected_stopped");return LLMSubmitStatus::NotRunning;}
     if (pending_.size()>=capacity_) {++rejected_;++stats_.rejected_full;if(trace)trace-
>mark("inference_rejected_full");return LLMSubmitStatus::QueueFull;}
     Task
task;task.id=id;task.inference=std::move(inference);task.on_chunk=std::move(chunk);task.on_done
=std::move(done);

task.enqueued_at=std::chrono::steady_clock::now();enqueued=task.enqueued_at;task.options=std::m
ove(options);

pending_.push_back(std::move(task));++stats_.accepted;depth=pending_.size();stats_.peak_depth=s
td::max(stats_.peak_depth,depth);}
    if(trace)trace->mark("inference_enqueued",enqueued,static_cast<double>(depth));
    cv_.notify_one();return LLMSubmitStatus::Accepted;
}
void LLMWorker::requestStop(StopMode mode) noexcept {
    {std::lock_guard<std::mutex> lock(mutex_);
     if (!stop_requested_ || mode==StopMode::CancelPending) stop_mode_=mode;
     stop_requested_=true;}
    cv_.notify_all();
}
void LLMWorker::join(){if(thread_.joinable())thread_.join();}
std::size_t LLMWorker::pendingCount() const {std::lock_guard<std::mutex> lock(mutex_);return
pending_.size();}
std::size_t LLMWorker::rejectedCount() const {std::lock_guard<std::mutex> lock(mutex_);return
rejected_;}
WorkerStats LLMWorker::stats() const {std::lock_guard<std::mutex> lock(mutex_);auto
copy=stats_;copy.pending=pending_.size();return copy;}
bool LLMWorker::waitIdleFor(std::chrono::milliseconds timeout) {
    std::unique_lock<std::mutex> lock(mutex_);
```

```
    return cv_.wait_for(lock,timeout,[&]{return pending_.empty() && stats_.active==0;});
}
void LLMWorker::run() {
    using Clock=std::chrono::steady_clock;
    for (;;) {
        Task task;bool cancel=false;
        {std::unique_lock<std::mutex> lock(mutex_);
         cv_.wait(lock,[&]{return stop_requested_ || !pending_.empty();});
         if (pending_.empty() && stop_requested_) return;
         task=std::move(pending_.front());pending_.pop_front();stats_.active=1;
         cancel=stop_requested_ && stop_mode_==StopMode::CancelPending;}
        const auto begin=Clock::now();
        RequestTraceScope trace_scope(task.options.trace);
        traceMark("inference_dequeued",begin);
        const double waited=std::chrono::duration<double,std::milli>(begin-
task.enqueued_at).count();
        InferenceResult result;
        result.disposition=task.options.disposition(task.enqueued_at,begin,cancel);
        const auto disposition=result.disposition;
        if (disposition!=TaskDisposition::Completed) {

traceMark(disposition==TaskDisposition::Cancelled?"inference_cancelled":"inference_expired");
            result.error_message=std::string("Inference task ")+dispositionName(disposition);
            std::cerr<<"[Inference "<<dispositionName(disposition)<<" #"<<task.id<<"]
queue_ms="<<waited<<'\n';
        } else {
            {std::lock_guard<std::mutex> lock(mutex_);++stats_.started;}
            traceMark("inference_begin");
            std::atomic<bool> chunk_failed{false};
            try {
                result=task.inference([&](const std::string& chunk){
                    if (task.on_chunk) try {task.on_chunk(task.id,chunk);} catch(...)
{chunk_failed.store(true);}
                });
            } catch(const std::exception& e)
{result.success=false;result.text.clear();result.error_message=std::string("LLMWorker inference
exception: ")+e.what();}
              catch(...)
{result.success=false;result.text.clear();result.error_message="LLMWorker inference: unknown
exception";}
            if (chunk_failed.load())
{result.success=false;result.text.clear();result.error_message="LLMWorker chunk callback threw
an exception";}
            traceMark(result.success?"inference_end":"inference_failed");
        }
        const double service=std::chrono::duration<double,std::milli>(Clock::now()-
begin).count();
        bool callback_failed=false;
        if (task.on_done) try
{task.on_done(task.id,result,disposition==TaskDisposition::Cancelled?-1.0:waited);}
        catch(...) {callback_failed=true;std::cerr<<"[Inference callback error
#"<<task.id<<"]\n";}
        const bool failed=disposition==TaskDisposition::Completed && !result.success;
        task=Task{};
        {std::lock_guard<std::mutex> lock(mutex_);
         ++stats_.completed;stats_.active=0;stats_.failed+=failed;

stats_.cancelled+=disposition==TaskDisposition::Cancelled;stats_.expired+=disposition==TaskDisp
```

```
osition::Expired;
         stats_.callback_errors+=callback_failed;stats_.queue_wait_sum_ms+=waited;

stats_.queue_wait_max_ms=std::max(stats_.queue_wait_max_ms,waited);stats_.service_sum_ms+=servi
ce;}
        cv_.notify_all();
    }
}
```

完整关键源码 include/app/pipeline_admission.h

```
#pragma once
#include "common/work_control.h"
#include <algorithm>
#include <map>
#include <mutex>
#include <stdexcept>

// One credit covers inference, TTS waiting, synthesis and playback, not just one queue.
// Captured shared tickets release credit on all callback/exception/cancellation paths.
class PipelineAdmission {
    struct State;
public:
    struct Stats {std::size_t accepted=0,rejected=0,inflight=0,peak=0;bool closed=false;};
    class Ticket {
    public:
        ~Ticket();
        TaskOptions options(std::chrono::milliseconds max_wait,RequestTracePtr trace={}) const
{
            TaskOptions
result;result.deadline=deadline_;result.max_queue_wait=max_wait;result.cancelled=cancelled_;res
ult.trace=std::move(trace);return result;
        }
        bool cancelled() const noexcept {return cancelled_->load();}
    private:
        friend class PipelineAdmission;
        Ticket(std::shared_ptr<State> state,std::uint64_t id,TaskOptions::Clock::time_point
deadline)
            :state_(std::move(state)),id_(id),deadline_(deadline),cancelled_(std::make_shared<s
td::atomic<bool>>(false)){}
        std::shared_ptr<State> state_;
        std::uint64_t id_;
        TaskOptions::Clock::time_point deadline_;
        std::shared_ptr<std::atomic<bool>> cancelled_;
        bool admitted_=false;
    };
    explicit PipelineAdmission(std::size_t capacity):state_(std::make_shared<State>(capacity))
{
        if(!capacity)throw std::invalid_argument("Pipeline admission capacity must be
positive");
    }
    std::shared_ptr<Ticket> tryAcquire(std::uint64_t id,std::chrono::milliseconds lifetime) {
        std::lock_guard<std::mutex> lock(state_->mutex);
        if(state_->stats.closed || state_->stats.inflight>=state_->capacity || state_-
>tickets.count(id)) {
```

```
            ++state_->stats.rejected;return {};
        }
        auto ticket=std::shared_ptr<Ticket>(new
Ticket(state_,id,TaskOptions::Clock::now()+lifetime));
        state_->tickets.emplace(id,ticket->cancelled_);
        ticket->admitted_=true;++state_->stats.accepted;++state_->stats.inflight;
        state_->stats.peak=std::max(state_->stats.peak,state_->stats.inflight);
        return ticket;
    }
    bool cancel(std::uint64_t id) {
        std::lock_guard<std::mutex> lock(state_->mutex);
        const auto found=state_->tickets.find(id);
        if(found==state_->tickets.end())return false;
        if(auto flag=found->second.lock()){flag->store(true);return true;}
        return false;
    }
    void close(bool cancel_waiting) {
        std::lock_guard<std::mutex> lock(state_->mutex);state_->stats.closed=true;
        if(cancel_waiting)for(auto& row:state_->tickets)if(auto flag=row.second.lock())flag-
>store(true);
    }
    Stats stats() const {std::lock_guard<std::mutex> lock(state_->mutex);return state_->stats;}
private:
    struct State {
        explicit State(std::size_t size):capacity(size){}
        std::mutex mutex;
        const std::size_t capacity;
        Stats stats;
        // Weak cancellation flags avoid destroying a Ticket recursively while this mutex is
held.
        std::map<std::uint64_t,std::weak_ptr<std::atomic<bool>>> tickets;
    };
    std::shared_ptr<State> state_;
};
inline PipelineAdmission::Ticket::~Ticket() {
    if(admitted_){std::lock_guard<std::mutex> lock(state_->mutex);--state_-
>stats.inflight;state_->tickets.erase(id_);}
}
```

完整关键源码 src/audio/tts_worker.cpp void TTSWorker::run()

```
void TTSWorker::run()
{
    for (;;)
    {
        Task task;
        bool cancelled = false;

        {
            std::unique_lock<std::mutex> lock(mutex_);

            // 没有任务时休眠，不进行忙轮询。
            cv_.wait(lock, [this] {
                return stop_requested_ ||
                       !pending_.empty();
```

```
            });

            // 队列清空且要求停止时，退出线程。
            if (pending_.empty() && stop_requested_)
            {
                return;
            }

            // FIFO: 取出队首任务。
            task = std::move(pending_.front());
            pending_.pop_front();

            // 停止请求到来后，
            // 尚未开始的排队任务转为取消结果。
            cancelled = stop_requested_ && stop_mode_ == StopMode::CancelPending;
            stats_.active = 1;
        }

        const auto begin = std::chrono::steady_clock::now();
        RequestTraceScope trace_scope(task.options.trace);
        traceMark("tts_dequeued",begin);
        const double waited = std::chrono::duration<double,std::milli>(begin -
task.enqueued_at).count();
        TTSWorkerResult result;
        result.disposition = task.options.disposition(task.enqueued_at, begin, cancelled);
        const auto disposition = result.disposition;
        const double queue_wait_ms = disposition == TaskDisposition::Cancelled ? -1.0 : waited;
        if (disposition != TaskDisposition::Completed)
        {
            traceMark(disposition==TaskDisposition::Cancelled?"tts_cancelled":"tts_expired");
            result.error_message = std::string("TTS task ") + dispositionName(disposition);
            std::cerr << "[TTS " << dispositionName(disposition) << " #" << task.id << "]
queue_ms=" << waited << '\n';
        }
        else
        {
            { std::lock_guard<std::mutex> lock(mutex_); ++stats_.started; }
            try
            {
                TTSAudio audio;
                std::string error;
                traceMark("tts_synthesis_begin");

                // 1. 在工作线程中执行 TTS。
                if (!tts_.synthesize(
                        task.text, audio, error))
                {
                    result.error_message =
                        "TTS synthesize: " + error;
                }
                else if (
                    audio.sample_rate <= 0 ||
                    audio.samples.empty())
                {
                    result.error_message =
                        "TTS returned invalid PCM";
                }
```

```
    else
    {
        result.synthesis_ms =
            audio.synthesis_ms;

        result.sample_rate =
            audio.sample_rate;

        result.audio_seconds =
            static_cast<double>(
                audio.samples.size()
            ) / audio.sample_rate;

        // 记录本次播放前的 XRUN 总数。
        const std::uint64_t xruns_before =
            playback_.xrunCount();

        const auto play_start =
            std::chrono::steady_clock::now();

        // 2. 在同一工作线程中播放 PCM。
        const bool played = playback_.play(
            audio.samples.data(),
            audio.samples.size(),
            error
        );

        const auto play_end =
            std::chrono::steady_clock::now();

        result.playback_ms =
            std::chrono::duration<
                double, std::milli
            >(
                play_end - play_start
            ).count();

        result.xrun_count =
            playback_.xrunCount() -
            xruns_before;

        if (!played)
        {
            result.error_message =
                "ALSA playback: " + error;
        }
        else if (result.xrun_count != 0)
        {
            result.error_message =
                "ALSA detected XRUN";
        }
        else
        {
            result.success = true;
        }
    }
}
```

```
            catch (const std::exception& e)
            {
                result.error_message =
                    std::string(
                        "TTSWorker exception: "
                    ) + e.what();
            }
            catch (...)
            {
                result.error_message =
                    "TTSWorker: unknown exception";
            }
        }

        const double service =
std::chrono::duration<double,std::milli>(std::chrono::steady_clock::now()-begin).count();

traceMark(result.success?"request_complete":disposition==TaskDisposition::Completed?"tts_failed
":"tts_terminal");
        bool callback_failed = false;
        if (task.on_done)
        {
            try { task.on_done(task.id, result, queue_wait_ms); }
            catch (...) { callback_failed=true; std::cerr << "[TTS callback error #" << task.id
<< "]\n"; }
        }
        const bool failed = disposition == TaskDisposition::Completed && !result.success;
        task = Task{}; // release captured admission tickets outside the queue lock
        {
            std::lock_guard<std::mutex> lock(mutex_);
            ++stats_.completed; stats_.active=0; stats_.failed+=failed;
            stats_.cancelled+=disposition==TaskDisposition::Cancelled;
            stats_.expired+=disposition==TaskDisposition::Expired;
            stats_.callback_errors+=callback_failed;
            stats_.queue_wait_sum_ms+=waited;
stats_.queue_wait_max_ms=std::max(stats_.queue_wait_max_ms,waited);
            stats_.service_sum_ms+=service;
        }
        cv_.notify_all();
    }
}
```

5.2 关键语句解释与接口审查

本文件与 stage5_02_source_appendix.md 配套：附录给出未经省略的当前完整文件及 SHA256；此处按实际语句执行顺序解释。一个跨多行的 std::cout << ...; 是一条表达式语句，不把每个输出操作误当独立控制流程。

操作 1：公共类型与 C++ 语法

- `#pragma once` 避免头文件在一个翻译单元中重复展开。`#include` 引入类型声明，不初始化设备。`std::` 指标准库 namespace，例如 `std::chrono::steady_clock` 属于嵌套 namespace；不是项目自建时钟。
- `enum class StopMode` 是强类型枚举，必须写 `StopMode::Drain`，避免与其他整数/枚举意外混用。`TaskDisposition` 的 Completed 表示执行路径正常进入，是否业务成功仍由 result.success 判断。
- `dispositionName(...) noexcept` 返回静态字符串字面量，生命周期覆盖整个进程，不返回局部 string.c_str()。嵌套条件表达式只选择三个固定名字。
- `using Clock=std::chrono::steady_clock` 是类型别名，不建立时钟对象。steady_clock 单调递增，适合等待和期限，系统校时不会改变结果。
- `Clock::time_point deadline=...::max()` 与 `milliseconds::max()` 表示默认不启用该限制。`milliseconds` 是 duration 的类型别名，实际模板包含计数表示类型和 `std::ratio<1,1000>` 周期。
- `std::shared_ptr<std::atomic<bool>> cancelled` 共享取消位的所有权。atomic 的 load/store 默认顺序一致性，保证主线程与 Worker 对标志的访问没有数据竞争；它不使其他对象自动线程安全。
- `disposition(enqueued,now,stopping) const noexcept` 不改变选项本身。先判停止/取消，再判 deadline 或 queue wait；因此同时发生时取消优先。短路 `&&` 在指针为空时不会解引用，毫秒最大值先判断再比较，避免不必要换算。
- `WorkerStats` 的 `{}` 和成员 `=0` 提供确定初始值；generation 区分显式重启轮次。size_t 是无符号容器计数类型，uint64_t 是固定宽度请求/轮次编号。统计只由 Worker mutex 保护，不能绕过 stats() 读成员。

操作 2：PipelineAdmission 逐句所有权解释

- `struct State;` 在类开头前置声明私有内部类型，使 Ticket 能先声明 `shared_ptr<State>`。完整 State 定义随后出现；没有在不完整类型上调用 sizeof 或 delete。
- `Stats` 为快照值类型，不包含 mutex。`class Ticket` 内 `friend class PipelineAdmission` 只允许外层类调用私有构造器，不把构造权限交给调用者。

- Ticket 构造器初始化列表按成员声明顺序建立 state、id、deadline 和新 atomic flag。`std::move(state)` 转移参数中的 shared_ptr 所有权，不移动底层 State 对象。
- `options(max_wait)` 创建独立 TaskOptions，把同一个 deadline 和 shared flag 复制到下游，允许不同阶段使用不同 max_queue_wait。它不把 Ticket 本身放进 flag，避免所有权环。
- `cancelled() const noexcept` 只读取 atomic，不锁 Admission mutex。调用者必须持有 Ticket，才能保证 flag 存活。
- Admission 构造器先 make_shared<State>(capacity) 建立状态，再检查 capacity 是否为零；抛 invalid_argument 时已经构造的 shared_ptr 自动析构，不泄漏。
- `tryAcquire` 的 `lock_guard<std::mutex> lock(state_->mutex)` 在构造时调用 mutex.lock()，离开块或异常退栈时析构调用 unlock()。模板参数 mutex 指定可锁对象类型，局部变量 lock 承担 RAII，不应误写成无名临时对象。
- closed、inflight>=capacity、tickets.count(id) 在同一临界区检查，拒绝时只增 rejected 并返回空 shared_ptr。重复 ID 不会覆盖已有取消标记。
- `shared_ptr<Ticket>(new Ticket(...))` 使用私有构造器，分配/控制块失败会释放已分配对象。此时 admitted_=false，因此析构不会错误扣减计数。
- `tickets.emplace(id,ticket->cancelled_)` 在所有 accepted/inflight 更新之前插入 weak flag，若 map 分配异常，Ticket 尚未计入额度，析构不会再次获取 State mutex。
- `admitted_=true` 后才增加 accepted/inflight 和 peak。`std::max` 比较历史峰值与当前在途数，不表示队列等待长度。成功返回前 lock_guard 已释放锁。
- `cancel(id)` 同锁查 map；找不到返回 false。weak_ptr.lock() 建立 flag 的临时强引用，存在时 atomic.store(true)。临时销毁的是 atomic flag 引用，不是 Ticket，因此不会锁内递归触发 Ticket 析构。
- `close(cancel_waiting)` 先设置 closed，拒绝此后新请求；若取消则逐个设置仍存活 flag。Drain 调用 close(false) 保留已有任务状态。
- `stats() const` 通过 shared State mutex 保护并按值返回快照，调用者不会持锁遍历生产对象。
- State 的 shared_ptr 由 Admission 和所有 Ticket 共享，Ticket 即使晚于 Admission 对象销毁，State mutex 仍存在。map 保存弱引用，既不保活 Ticket，也不形成循环。

- `Ticket::~Ticket()` 只有 admitted_ 为真时才锁状态、减 inflight、erase(id)。最后引用可来自推理或 TTS closure；Worker 在队列锁之外清除 closure，避免双锁反向依赖。

操作 3：LLMWorker 的构造、提交与线程语句

- 带 Engine 构造器委托给容量构造器，再保存非拥有指针 `engine_=&engine`。别名 `InferenceWorker=LLMWorker` 没有新对象布局和新队列。容量零抛 invalid_argument。
- 析构器依次 requestStop()、join()，不能由自身回调销毁 Worker。Engine、callback 引用和同步对象均必须晚于 join 才销毁。
- start 在 mutex 内清理 error、检查 started/stop_requested；创建 `std::thread(&LLMWorker::run,this)` 将成员函数指针和对象地址传给新线程。新线程需要同锁，直到创建者设置 started/generation 并解锁后才能操作队列。
- thread 创建异常被转换为 error + false，没有假装线程已启动。restart 在同锁检查已停止、已 join、队列空，重置本轮状态再调用 start；这依赖 start/join/restart 由同一 owner 串行执行。
- submit(text) 检查 engine_，无 Engine 的通用 Worker 不允许错误调用 TEXT 便捷接口。lambda `[this,question=std::move(question)]` 捕获 Worker 地址与自有文本，调用已有 inferStreaming；不引用提交栈上的 question。
- submitTask 检查 inference 非空；锁内检查 running/容量，分别增加 stopped/full 拒绝计数。创建 Task，移动函数对象和回调、写 enqueue 时间和 options，再 push_back。push 成功后增加 accepted/peak；异常前不虚增 accepted。
- 解锁后 notify_one，减少被唤醒线程立即争锁。通知不是条件本身；即使 notify 早于 wait，队列谓词仍可防丢唤醒。
- requestStop 在锁内设置 stop_requested。已经取消后不允许 Drain 降级回排空；随后 notify_all 唤醒空队列等待。该 noexcept 函数仍依赖有效 mutex，不可放进异步 signal handler。
- join 只在 joinable 时等待，不能同时由两个 owner 调用。stats/pendingCount/rejectedCount 都在锁内读取；stats 按值返回，并用当前 deque.size() 更新 pending。
- waitIdleFor 使用 unique_lock，因为 condition_variable 在等待时必须暂时解锁、醒来重新加锁。谓词要求 pending.empty 且 active==0，虚假唤醒不会提前成功。

操作 4：推理 run 循环的每个执行阶段

1. 每轮创建局部 Task 和 cancel 标记。unique_lock 后 wait(stop||非空)。空且 stop 时 return；否则 move 队首并 pop，设置 active=1，在同锁读本轮停止模式。

2. begin-enqueued_at 转为 `duration<double,std::milli>` 得毫秒浮点等待时间；TaskOptions 根据队列时刻、当前时刻、stop 决定终态。

3. 取消/过期路径只填 error_message、输出 ID/queue_ms，不执行推理体。它们仍走后面的 done 和统计，不能静默丢失。

4. 可执行路径先增加 started。局部 atomic chunk_failed 供 SDK 回调报告用户 chunk 异常；回调 lambda 引用本轮 Task 和 flag，只在同步 inferStreaming 有效期内使用。

5. task.inference 返回 InferenceResult。std::exception 和未知异常都转为 success=false、清空 text 并记录原因，防止半段答案被当完整成功结果。chunk 回调异常同样使本次失败，不让异常穿过 C SDK 边界。

6. service 计时在 done 之前截止，因此表示任务体及必要包装耗时，不包括业务 done 的转交时间。waitIdle 则包含 done 完成，不会用这两种口径混称同一指标。

7. done 在队列锁外调用。Cancelled 为兼容旧接口传 -1 等待值；统计保留实际等待。done 抛异常单独计 callback_errors 并打印 ID，继续清理，不吞成成功。

8. failed 仅对真实执行且 result.success=false 计入。`task=Task{}` 在队列锁外清空函数对象及 Ticket 捕获；随后锁内增加 completed、归零 active、累积失败/取消/过期/回调异常/等待和服务时间。最后 notify_all 允许主线程观察完整终态。

操作 5：TTSWorker 及不变的设备路径

TTSWorker 的 start/submit/stop/stats/waitIdle/restart 与推理 Worker 的锁和谓词相同，但 start 先检查 tts.ready 与 playback.ready。它借用两个 Service，仍不拥有设备。

run 将队首 Task move 到局部，锁外判取消/过期。执行分支先增加 started，调用原 `tts_.synthesize(task.text,audio,error)`；失败填合成错误，成功仍验证 sample_rate>0 和 samples 非空。audio 是局部 TTSAudio，vector<float> 自动释放 PCM。

随后保存 synthesis_ms、sample_rate、audio_seconds，读取 XRUN 基线，记录 play_start，调用原 `playback_.play(audio.samples.data(),audio.samples.size(),error)`。data() 的借用指针

只在同步 play 期间有效，audio 作用域覆盖该调用。play_end-play_start 转毫秒，XRUN 用调用前后计数差。写失败、XRUN 非零分别填错误；只有两者都正常才 success=true。

完成回调在锁外执行并捕获异常。service 和 waited 分别累计；与推理 Worker 一样，先清除 task 再发布 active=0。过期/取消时 synthesis_ms/playback_ms 保持默认零，不伪造模型执行。

TTS/ALSA 公共头改为不完整 C 类型指针，只需声明就能存储指针；具体 SDK include 在 cpp 中，析构器也在 cpp 中实现。`tts_smoke.cpp` 自己调用 SherpaOnnxWriteWave，因此必须自己 include C API；这是首次 ARM64 编译暴露并修复的具体依赖。

操作 6：完整语音入口的语句与捕获

初始化顺序继承 5.1：StopSignals 在 SDK 线程之前阻塞信号；初始化 Qwen、SenseVoice、Kokoro、ALSA，然后建立状态/互斥量/Admission/帧缓冲与 Worker。VLM/Camera 指针声明提前，但模型初始化步骤不变。异常反向析构先停止借用它们的 Worker。

每次 on_text 创建 DispatchTimer，router.route 产生 RouteDecision，next_id++ 分配唯一 ID，tryAcquire 申请 Ticket。额度失败增加 pipeline_rejected、打印 route/limit 并 return；局部计时析构仍输出本次提交耗时。计时包含同步日志开销，不是纯 CPU 指令耗时。

VISION 禁用时保持原 skipped 行为。启用时保留英文短问句，submitTask 的 `[&,vlm_question]` 按值保留问题，只按引用借用 owner 的 vlm/frames。执行时 frames.getLatest() 返回有所有权的共享帧；infer 同步结束后才释放局部帧，不捕获 ASR 的 recognized 引用。

VISION done 按值捕获 question_at 和 ticket，先在 state_mutex 下更新 completed/成功/失败/取消/过期，再单独在 print_mutex 下输出。没有同时持 state_mutex 和 print_mutex。成功非空但 ticket 已取消时只记 downstream_cancelled；未取消才向 TTS 提交，TTS done 再按值持 Ticket。submit 返回 Accepted 后计业务 accepted；失败路径记录，不泄漏额度。

TEXT 分支复用原 prompt。prefix_printed 为每请求 shared_ptr<bool>，所有流式和 done 对它的访问由 print_mutex 保护。问题和时间不是借用提交栈。TEXT done 依据 disposition 区分运行错误与取消/过期，成功答案交给已有 TTSWorker；下游捕获同一 Ticket 和原始时刻，用 steady_clock 计算 ASR 文本至播放结束时间。

原 ASRWorker 和 VAD 模型处理保持。仅测试环境指定 STAGE5_REPLAY_FILE 时，显式打印 NO_MICROPHONE_ASR_OR_VAD_INFERENCE，按 TSV 绝对偏移 sleep_until 后调用同

一个 on_text；不启动生产者/识别者，也不把其 ok 计作通过。正常麦克风路径仍启动 consumer、producer，20ms 轮询完成/信号，停止捕获后 join 二者。

ASR join 后关闭 Admission，禁止再提交。wait_for_jobs 用 Worker waitIdleFor(100ms)，不是 accepted/completed 业务条件变量。CancelPending 信号设置所有 Ticket 标志并停止接收推理；TTS 当前执行不受强制打断。等待期限到只报告失败，后续 join 仍需 SDK 协作，外层测试保护负责记录无限等待风险。

推理 join 后才 shutdown Qwen，TTS join 后才 close playback 和 shutdown TTS，Camera stop 后才 VLM shutdown。最后输出每级统计。passed 检查资源计数、终态完整、零运行/回调错误和零额度泄漏；允许有显式策略拒绝/过期，所以 PASS 是调度一致性结果，完整回答率要另看 successful。

操作 7：测试语句及可证明范围

Gate 使用 promise/shared_future：entered 通知任务已进入，release 阻塞执行直到测试主动释放，不用碰运气的 sleep 模拟重推理。OpenOnExit 在测试抛异常时释放 gate，避免析构 Worker join 死锁。ASR 测试用真实 ASRWorker/AudioBufferQueue 加 Fake recognize，第一推理阻塞时断言三段都已识别提交，随后检查 FIFO 和不同线程 ID。

满载测试容量一，先闸住活动任务，第二入队，第三必须 QueueFull；取消 flag 后断言第二执行体绝不调用。过期 deadline 在过去，同样不得执行任务体，但都要完成终态回调。restart 检查 generation=2；throwing done 必须 callback_errors=1 且 waitIdle 成功。

停止模式分别验证 Drain 执行两项、CancelPending 只执行活动一项且两项都有终态。Admission 检查总额度、按 ID 取消、归还和关闭，再运行 200 轮末引用释放与 close 竞争。Fake TTS 模拟同步 synth/play、队列满和过期/重启。它们证明指定并发交错，不证明真实 Runtime 无内部问题，也不是模型质量测试。

操作 8：面试题与参考答案

9. 为什么两个 Engine 各自 mutex 还不能证明 NPU 并行安全？锁的互斥域不同，共用 Runtime/driver 资源仍可能争用。本项目先实测调用重叠代价，再用一个消费者统一调度，不声称已证明并行崩溃。

10. 队列有界为什么还会积压？局部容量不包含其他阶段与活动任务。跨阶段 Ticket 才能限制尚未结束回答总数；PCM、音频段和最新帧仍须分别有界。

11. 为什么 condition_variable 要谓词？通知可能先于等待、也可能虚假唤醒；锁保护状态，谓词决定是否继续。停止必须改变谓词并 notify_all。

12. 为什么 done 后才 active=0？done 可能向 TTS 提交。先宣告空闲，main 会过早关闭 TTS 或销毁 callback 引用。

13. shared_ptr 能消灭死锁吗？不能。最后引用析构可能获得另一把锁；本项目将 Ticket 释放放到队列锁外，取消表只弱持 flag。

14. 为什么 cancellation 不等于中断？flag 只能影响协作检查点；硬中断 SDK 会破坏回调和模型状态。活跃阶段完成、等待阶段取消是明确可测试的语义。

15. ASR 异步化会使 NPU 更快吗？不会必然加速模型计算；它减少 ASR 被业务回调占用的时间。总吞吐和成功播放率必须单独报告。

16. 如何解释 P95？先说明样本数、nearest-rank 等算法和条件；4 个样本的 P95 等于最大值，不能宣传生产尾延迟已稳定。

17. 如何验证设备释放？Worker join、Runtime shutdown 日志之外，还查进程消失、Camera/ALSA/NPU fuser、ALSA status 和原工程指纹。仅打印 success 不够。

18. 为什么不用 TTS 播放期间关闭 ASR？会破坏连续输入。耳机环境本节保留输入并背压；AEC、PTT 和打断属于另需定义的能力。

核心实测取舍

真实 SDK 每类 n3：顺序 Qwen 调用均值 945.432ms，重叠时 2338.717ms；Vision 加 Smol 从 1927.090ms 到 2667.267ms。6/6 对均成功，所以没有证明并行必崩；选择共同消费者是降低竞争、明确顺序与背压。异步 VISION 回调 1737.730ms 到 0.034758ms 是提交阻塞改善，不能当 VLM 推理变成 0.035ms。

5.2 ARM64 CTest5/5，所有是 Fake/确定性逻辑测试；真实耳机和交替/连续输入另行验证。过载可以拒绝输入或过期旧任务，必须统计全部终态。推理成功率的分母是实际执行，语音交付率的分母是全部输入，不能混用。

5 第五阶段 5.3 Camera 内存和预处理

V4L2 采用 MMAP，不是 DMA-BUF。DQBUF 后按实际 plane stride/size 复制到自有 NV12，再 QBUF。驱动随即可以重用映射内存，因此异步 VLM 不能借用映射裸指针。LatestFrameBuffer 发布/读取只交换共享指针，没有每次再复制整帧；CPU 预处理融合 NV12 到 RGB 和 Resize，单独转换与 Resize 时间未拆分。

每帧仍有一次 12,441,600 字节自有 NV12 复制，按需生成 786,432 字节 RGB，SDK 输入内部转换/复制不透明，Vision 输出复制 147,456 字节浮点 Embedding。池有三槽，空闲是 unique_ptr 独占，发布是 shared_ptr<const ImageFrame>，最后强引用释放才归还。每次 lease 新建控制块，旧 weak_ptr 不能在地址复用后复活。池满只做 DQBUF/QBUF 并计数，不无界分配。

完整关键源码 include/video/owned_frame_pool.h

```
#pragma once
#include "common/types.h"
#include <array>
#include <exception>
#include <memory>
#include <mutex>
#include <utility>

// Bounded owned CPU frames. A lease returns only when its shared_ptr control block dies.
// Old weak_ptrs cannot lock a later lease even if the ImageFrame address is reused.
class OwnedFramePool {
    struct State {
        std::mutex mutex;
        std::array<std::unique_ptr<ImageFrame>,3> free;
        std::size_t allocated=0,in_use=0,acquired=0,reused=0,exhausted=0;
        bool retired=false;
    };
public:
    struct Stats {std::size_t allocated=0,in_use=0,acquired=0,reused=0,exhausted=0;};
    OwnedFramePool():state_(std::make_shared<State>()){}
    OwnedFramePool(const OwnedFramePool&)=delete;
    OwnedFramePool& operator=(const OwnedFramePool&)=delete;
    ~OwnedFramePool(){retire();}
    std::shared_ptr<ImageFrame> acquire() {
        std::unique_ptr<ImageFrame> owned;
        {
            std::lock_guard<std::mutex> lock(state_->mutex);
            if(state_->retired)return {};
            for(auto& slot:state_->free)if(slot){owned=std::move(slot);++state_->reused;break;}
            if(!owned) {
                if(state_->allocated==state_->free.size()){++state_->exhausted;return {};}
                owned=std::make_unique<ImageFrame>();++state_->allocated;
            }
            ++state_->in_use;++state_->acquired;
        }
```

```
        // Construct outside the mutex: shared_ptr allocation failure invokes the deleter.
        return std::shared_ptr<ImageFrame>(owned.release(),[state=state_](ImageFrame* frame)
mutable noexcept {
            auto owner=std::move(state); // weak control blocks must not retain the pool after
return.
            std::unique_ptr<ImageFrame> returning(frame);
            {
                std::lock_guard<std::mutex> lock(owner->mutex);
                --owner->in_use;
                if(!owner->retired) {
                    for(auto& slot:owner->free)if(!slot){slot=std::move(returning);return;}
                    std::terminate();
                }
            } // Retired frames and their vectors are deleted outside the pool mutex.
        });
    }
    void retire() noexcept {
        std::array<std::unique_ptr<ImageFrame>,3> discarded;
        {std::lock_guard<std::mutex> lock(state_->mutex);state_-
>retired=true;discarded.swap(state_->free);}
        // Free inactive storage now; external leases remain valid until their last release.
    }
    Stats stats() const {
        std::lock_guard<std::mutex> lock(state_->mutex);
        return {state_->allocated,state_->in_use,state_->acquired,state_->reused,state_-
>exhausted};
    }
private:
    std::shared_ptr<State> state_;
};
```

完整关键源码 src/video/latest_frame_buffer.cpp

```
#include "video/latest_frame_buffer.h"
#include "common/image_profile.h"
void LatestFrameBuffer::update(FramePtr frame) {
    const auto begin=ImageProfile::Clock::now();
    {std::lock_guard<std::mutex> lock(mutex_);latest_frame_.swap(frame);}
    const double swapped=ImageProfile::ms(begin);
    const auto old_id=frame?frame->frame_id:0;
    const auto release_begin=ImageProfile::Clock::now();frame.reset();
    const double released=ImageProfile::ms(release_begin);
    imageSample("latest_publish_swap",swapped,old_id);
    imageSample("latest_release_old",released,old_id);
}
LatestFrameBuffer::FramePtr LatestFrameBuffer::getLatest() const {
    const auto begin=ImageProfile::Clock::now();FramePtr frame;
    {std::lock_guard<std::mutex> lock(mutex_);frame=latest_frame_;}
    const double duration=ImageProfile::ms(begin);
    imageSample("latest_get",duration,frame?frame->frame_id:0);
    return frame;
}
void LatestFrameBuffer::clear(){update(nullptr);}
```

完整关键源码 src/video/image_preprocessor.cpp

```
#include "video/image_preprocessor.h"
#include <algorithm>
#include <cmath>
#include <cstdint>
namespace { constexpr size_t kWidth=512,kHeight=512,kImageBytes=kWidth*kHeight*3;
constexpr uint32_t kNV12=0x3231564e;
inline uint8_t toByte(float v) {
    return static_cast<uint8_t>(std::max(0.0f, std::min(255.0f, std::round(v))));
}

// MVP CPU preprocessing: packed NV12, BT.709 limited range -> RGB, resize 512x512.
// Unlike PIL/Lanczos this uses bilinear Y and nearest chroma; quality validation is pending.
// Only read LatestFrameBuffer's owned ImageFrame (do not access mmap after QBUF).
}
bool frameToRgb512Reference(const ImageFrame& f, std::vector<uint8_t>& rgb, std::string& error)
{
    if (f.pixel_format != kNV12 || f.width == 0 || f.height == 0 ||
        (f.width % 2) || (f.height % 2)) {
        error = "Expected packed NV12 frame with even width/height";
        return false;
    }
    // VideoCapture concatenates mmap plane payloads. Current IMX415 returns one plane.
    if (f.plane_sizes.size() != 1 || f.plane_strides.size() != 1) {
        error = "This first VLM adapter expects one packed NV12 plane";
        return false;
    }
    const size_t stride = f.plane_strides[0];
    const size_t width = f.width;
    const size_t height = f.height;
    if (stride < width || stride > 16384 || width > 8192 || height > 8192 ||
        stride * (height + height / 2) > f.data.size()) {
        error = "Invalid NV12 stride/data size";
        return false;
    }
    const uint8_t* yPlane = f.data.data();
    const uint8_t* uvPlane = f.data.data() + stride * height;
    rgb.resize(kImageBytes);
    for (size_t dy = 0; dy < kHeight; ++dy) {
        const float sy = (static_cast<float>(dy) + 0.5f) * height / kHeight - 0.5f;
        const float fy = std::max(0.0f, sy);
        const size_t y0 = std::min(height - 1, static_cast<size_t>(fy));
        const size_t y1 = std::min(height - 1, y0 + 1);
        const float wy = std::min(1.0f, fy - y0);
        for (size_t dx = 0; dx < kWidth; ++dx) {
            const float sx = (static_cast<float>(dx) + 0.5f) * width / kWidth - 0.5f;
            const float fx = std::max(0.0f, sx);
            const size_t x0 = std::min(width - 1, static_cast<size_t>(fx));
            const size_t x1 = std::min(width - 1, x0 + 1);
            const float wx = std::min(1.0f, fx - x0);
            const float yy = (1-wy) * ((1-wx) * yPlane[y0*stride+x0] + wx *
yPlane[y0*stride+x1]) +
                                    wy  * ((1-wx) * yPlane[y1*stride+x0] + wx *
yPlane[y1*stride+x1]);
            const size_t ux = (std::min(width - 1, static_cast<size_t>(fx)) / 2) * 2;
            const size_t uy = std::min(height - 1, static_cast<size_t>(fy)) / 2;
```

```
            const float u = float(uvPlane[uy*stride+ux]) - 128.0f;
            const float v = float(uvPlane[uy*stride+ux+1]) - 128.0f;
            const float Y = 1.164383f * (yy - 16.0f);
            const size_t out = (dy*kWidth+dx)*3;
            rgb[out+0] = toByte(Y + 1.792741f*v);
            rgb[out+1] = toByte(Y - 0.213249f*u - 0.532909f*v);
            rgb[out+2] = toByte(Y + 2.112402f*u);
        }
    }
    return true;
}


bool Rgb512Preprocessor::convert(const ImageFrame& f,std::vector<uint8_t>& rgb,std::string&
error) {
    if (f.pixel_format != kNV12 || f.width == 0 || f.height == 0 ||
        (f.width % 2) || (f.height % 2)) {
        error = "Expected packed NV12 frame with even width/height";
        return false;
    }
    // VideoCapture concatenates mmap plane payloads. Current IMX415 returns one plane.
    if (f.plane_sizes.size() != 1 || f.plane_strides.size() != 1) {
        error = "This first VLM adapter expects one packed NV12 plane";
        return false;
    }
    const size_t stride = f.plane_strides[0];
    const size_t width = f.width;
    const size_t height = f.height;
    if (stride < width || stride > 16384 || width > 8192 || height > 8192 ||
        stride * (height + height / 2) > f.data.size() ||
        f.plane_sizes[0] < stride*(height+height/2) || f.plane_sizes[0] > f.data.size()) {
        error = "Invalid NV12 stride/data size";
        return false;
    }

    if(width_!=width || height_!=height) {
        for(size_t dx=0;dx<kWidth;++dx) {
            const float sx=(static_cast<float>(dx)+0.5f)*width/kWidth-0.5f;
            const float fx=std::max(0.0f,sx);
            auto& x=columns_[dx];x.x0=std::min(width-1,static_cast<size_t>(fx));
            x.x1=std::min(width-1,x.x0+1);x.weight=std::min(1.0f,fx-x.x0);
            x.uv=(std::min(width-1,static_cast<size_t>(fx))/2)*2;
        }
        for(size_t dy=0;dy<kHeight;++dy) {
            const float sy=(static_cast<float>(dy)+0.5f)*height/kHeight-0.5f;
            const float fy=std::max(0.0f,sy);
            auto& y=rows_[dy];y.y0=std::min(height-1,static_cast<size_t>(fy));
            y.y1=std::min(height-1,y.y0+1);y.weight=std::min(1.0f,fy-y.y0);
            y.uv=std::min(height-1,static_cast<size_t>(fy))/2;
        }
        width_=static_cast<uint32_t>(width);height_=static_cast<uint32_t>(height);
    }
    const uint8_t* yPlane=f.data.data();const uint8_t* uvPlane=yPlane+stride*height;
    rgb.resize(kImageBytes);
    for(size_t dy=0;dy<kHeight;++dy) {
        const auto& y=rows_[dy];const float wy=y.weight;
        for(size_t dx=0;dx<kWidth;++dx) {
            const auto& x=columns_[dx];const float wx=x.weight;
```

```
            const float yy=(1-wy)*((1-
wx)*yPlane[y.y0*stride+x.x0]+wx*yPlane[y.y0*stride+x.x1])+
                           wy*((1-wx)*yPlane[y.y1*stride+x.x0]+wx*yPlane[y.y1*stride+x.x1]);
            const float u=float(uvPlane[y.uv*stride+x.uv])-128.0f;
            const float v=float(uvPlane[y.uv*stride+x.uv+1])-128.0f;
            const float Y=1.164383f*(yy-16.0f);const size_t out=(dy*kWidth+dx)*3;
            rgb[out+0]=toByte(Y+1.792741f*v);
            rgb[out+1]=toByte(Y-0.213249f*u-0.532909f*v);
            rgb[out+2]=toByte(Y+2.112402f*u);
        }
    }
    return true;
}
```

5.3 关键 C++ 逐句解释与审查

完整文件见 stage5_03_source_appendix.md，此处解释新增或改变的关键语句；原有长篇注释保留在完整源码，不以本表代替源码。行号以最终附录为准。所有权安全依据是 C++ 强引用和锁的规则，实测只是有限场景证据。

OwnedFramePool：有界所有权，不能用 use_count 猜测独占

语句	解释与约束
`struct State`	独立于 CameraService 的池状态，外部 lease 可以跨 Camera 停止存活，不能捕获 Camera 的裸 this。
`std::array<std::unique_ptr<ImageFrame>,3> free`	最多三个自有帧对象。unique_ptr 表示空闲对象只有池拥有；不是三个驱动 MMAP Buffer。
`allocated/in_use/acquired/reused/exhausted`	分别统计当前代创建过的帧、未归还 lease、取得次数、复用次数和满池次数；都由同一个 mutex 保护。
`bool retired`	停止后拒绝新 lease，归还帧改为释放，不能把旧帧加入下一代池。
`state_(make_shared<State>())`	让状态可被 lease 的 deleter 延长寿命；池对

语句	解释与约束
	象自身的生命周期与状态生命周期分离。
删除拷贝构造和赋值	禁止两个外层池意外共享同一停止职责。
~OwnedFramePool(){retire();}	析构关闭入口、释放空闲缓存，不销毁仍被消费者持有的像素。
unique_ptr<ImageFrame> owned	从空闲列表取出到局部独占对象，后续控制块创建失败也有明确回收方式。
lock_guard lock(state_->mutex)	只保护池管理数据，不包住预处理、RKNN 或像素拷贝。
if(retired)return {}	已关闭的池不能重新发放帧。Camera 重启创建新 State。
for(slot) if(slot){owned=move(slot);...}	将空闲对象转移出来，不复制 ImageFrame 的 vector，空槽不会与使用者同时写同一帧。
if(allocated==free.size()){++exhausted;return {};}	满池返回空而不额外分配第 4 帧。Camera 对应 DQ/QBUF 丢弃并计数。
owned=make_unique<ImageFrame>();++allocated	仅没有空闲对象且未达到三帧时创建对象；分配抛异常则尚未递增成功分配数。
++in_use;++acquired	已获得一个将交付给调用方的独占帧，强引用控制块创建失败的 deleter 也会减少 in_use。
shared_ptr(owned.release(), [state=state_](...) mutable noexcept {...})	每次 lease 创建新控制块。帧地址可以复用，旧 weak_ptr 却不能锁定下一次 lease。shared_ptr 构造分配失败也会调用传入 deleter；因此必须在池锁外构造。

语句	解释与约束
`auto owner=move(state)`	最后一个强引用释放时把 deleter 捕获的状态转移到局部。旧 weak_ptr 的控制块即使仍在，也不会把整个池缓存长期留住。不是等待所有 weak_ptr 析构才回收帧。
`unique_ptr returning(frame)`	原始指针重新进入独占 RAII 所有权；退出函数时若没有放回池就自动释放。
`--owner->in_use`	归还数与取得数配对，锁内修改。
`if(!retired) for(empty slot) slot=move(returning)`	活跃池接收归还对象，保留 data/stride/size vector 容量，下次取得时才允许写入。
`std::terminate()`	仅表示内部不变量被破坏：最多三个已分配对象的池不可能在归还时没有空槽。不是正常满池策略，满池发生在 acquire。
retire 分支离开锁后 `returning` 析构	大块像素存储释放不在池 mutex 内，减少持锁时间。
`discarded.swap(state_->free)`	retire 锁内仅交换 unique_ptr 数组；局部数组在解锁后析构。正在被 VLM 持有的帧不在 free 数组。
`Stats stats() const`	加同一 mutex 后按值复制计数，不暴露可变内部引用。

边界：池构造/销毁必须遵守外层生命周期，不能在另一个线程销毁同一个 Pool 对象的同时调用它的成员；外部 lease 可以晚于 Pool 对象销毁。Camera 的 start/stop 由已有 lifecycle_mutex 串行化，stop join 后才 retire。

VideoCapture：减少分配，保留 QBUF 前的所有权边界

语句/函数	逐句含义
`captureFrame(...) -> captureFrameImpl(&output,false,...)`	保留旧接口成功后才替换输出的语义，供回退路径与原调用者使用。
`captureReusableFrame(...) -> captureFrameImpl(&output,true,...)`	调用者保证 frame lease 独占；直接填入其已有容量，失败可能留下半成品，Camera 不得发布失败帧。
`discardFrame(...) -> captureFrameImpl(nullptr,true,...)`	仍正常 poll、DQBUF、QBUF，避免驱动停止流转，但不复制像素；只用于池满时。
`poll` 的开始/结束埋点	单独记录等下一帧的时间，不混入图像计算时间。超时仍沿用原错误/超时分类。
`std::array<v4l2_plane,VIDEO_MAX_PLANES>`	固定描述数组放栈上，消除旧 vector 的每帧堆分配；不是把 12 MB 像素放在线程栈上。
DQBUF 成功后 sequence 差值	无符号差值可处理序号回绕；只统计连续捕获中的驱动序号缺口，不把主动 pool discard 和 latest 替换混成一个数。
`ImageFrame temporary; ImageFrame& frame=reuse?*output:temporary`	旧语义使用临时对象，新语义直接使用独占 lease。没有把一个 ImageFrame move 赋值给自身。
`clear()` metadata/data	清 size，保留 capacity，不清空底层整幅数据。随后重新填入全部有效字节，旧帧不能在这时还有读者。
`reserve(total_bytes)`	只有容量不足才扩容；首次三个池槽分别热身，后续通常不增长。capacity 指标不等于全进程 malloc 总数。

语句/函数	逐句含义
`insert(end,start,start+used)`	每个有效 plane 的 CPU 显式拷贝仍然存在；mmap 指针不能跨 QBUF 借给 VLM。
`bytesused-data_offset` 与 plane 记录	按有效负载复制，不使用映射最大长度当作有效图像大小；保留 stride 和 plane_sizes 作后续校验。
QBUF	只有数据已复制到自有帧才把驱动 Buffer 归还；discard 分支不读取像素，直接归还。
`if(!reuse) *output=move(temporary)`	旧接口只在成功后提交结果，vector 的存储转移，不发生第二次整帧拷贝。
`capture_stats_={}`	每次初始化清除上一代驱动计数，防止重启把不同流的序号连接起来。

CameraService、LatestFrameBuffer 与退出

start 先锁生命周期、join 已退出的旧线程、shutdown 旧设备、clear latest、清统计。在 try 内解析 `STAGE5_CAMERA_POOL`，只接受 `0` 和 `1`，然后创建新池、初始化设备、设置 running、创建线程。非法配置成为可观察的 start=false/last_error；不在工作线程中才抛一个启动配置错误。

captureLoop 每次 acquire 独占可写 lease，成功才 captureReusableFrame；池满调用 discardFrame，并增加 pool_discarded。捕获成功后转换为 `shared_ptr<const ImageFrame>` 发布，不再通过可写别名继续修改。回退使用旧 captureFrame 和 make_shared(move(frame))。Stats 在采集线程写，外部按已有 stats_mutex 读；底层 CaptureStats 只有采集线程或 join 后的 stop 访问。

LatestFrameBuffer::update 的 `swap` 和 getLatest 的 shared_ptr 复制在 mutex 内；旧引用 reset 在锁外。getLatest 取得的是强引用，不是某个像素裸指针。重置 latest 不会使 VLM 已取得的 frame 失效。这里原本没有 NV12 memcpy，本节没有宣称消除一个并不存在的拷贝。

stop 保持 running=false→join→shutdown→clear→统计→retire 的顺序。循环尾也会 clear/shutdown，依赖 5.1 已验证的幂等关闭。池停止时空闲对象立即释放；外部 lease 可以继续

读，最后归还时因 retired 被释放。重启不会重新使用旧 State。没有新增 Worker，也没有改变 5.2 的推理 FIFO 或信号处理线程。

Rgb512Preprocessor：算术保持一致，缓存坐标

语句	含义		
验证 NV12、非零偶数宽高	UV 为 2×2 子采样，奇数布局不在当前支持范围。		
验证单 plane、stride、尺寸、data 与 plane_sizes	只接受一块打包 NV12，限制尺寸避免不受控索引；candidate 比 reference 多检查 plane_sizes 有效界限。		
`if(width_!=width		height_!=height)`	输入尺寸不变时不重复为每个输出像素计算坐标。stride 不进入坐标表，真正读取时仍使用本帧 stride。
`(dx+0.5f)*width/512-0.5f`	保留半像素中心变换和原 float 运算顺序，不能用另一个插值库替换后假定像素相同。		
`max(0, sx)`、`min(width-1,...)`	边界采样钳制；x1/y1 不越界。		
缓存 `x0/x1/weight/uv` 与对应 y 字段	每个方向 512 项 std::array，无额外堆分配；UV 仍用旧算法的		

语句	含义		
	最近邻规则。		
rgb.resize(512*512*3)	复用 Impl 的 vector 容量；首次增长初始化的成本包含在融合预处理里，热身后 size 不变。		
yy 双线性表达式	按原次序混合 Y，保留 float 精度、舍入与编译选项；测试在本地与 ARM 分别比较，不把跨编译器相同当成无需验证的保证。		
u/v -128, 1.164383*(yy-16)	BT.709 limited-range 数值约定，仍与旧路径一致。与设备 Full Range 元数据的既有差异另记。		
三个 toByte 写入 RGB	R/G/B 顺序、饱和/舍入沿用旧函数，没有中间全尺寸 RGB，也没有 crop。		

RK3576VLMBackend：输入与输出寿命

Impl 新增 cached 开关、坐标表和两个复用 vector；由 VLMEngine 已有 mutex 串行保护。initialize 在 Runtime 创建前拒绝未知预处理模式。reference 模式使用局部 RGB/embeddings vector，保留旧分配路径。

auto& rgb=... 选择持久或局部存储；capacity()<kImageBytes 只记录容量增长。预处理完成后栈上 rknn_input img{} 零初始化使 pass_through 保持 0；设置 UINT8、NHWC、786432 B、buf=rgb.data()。应用没有另一个 RGB memcpy。rknn_inputs_set 与 rknn_run 各自计时，闭源 SDK 的转换/拷贝不被当成“没有”。

RknnOutputOwner 先构造，outputs_get 成功才 acquired=true；校验 result.buf 和浮点输出精确大小。embeddings.assign(ptr,ptr+36864) 在 owner 存活时复制，随后检查所有元素 finite。正常、早返回和 assign 抛异常都沿用 5.1 的 RAII 输出释放；释放后不再使用 ptr。持久 embedding vector 不因 SDK 输出释放失效。诊断 dump 检查文件状态，失败返回错误，不伪造比较文件。

RKLLM 同步调用借用 embedding.data()；n_image_tokens=64、n_image=1、height/width=512、提示模板保持不变。栈上的 GenerationState 覆盖整个同步 rkllm_run，未改为异步回调；5.1 的 callback/destroy 顺序保持。Worker 停止并 join 后 Engine 才 shutdown，Impl close 依次 destroy LLM 和 RKNN 后成员 vector 才析构。

埋点、诊断与测试的界限

ImageProfile 的静态初始化由 C++ 保证只完成一次。enabled 在构造后不再改变，多个线程用同一 mutex 写 JSONL；计时结束后才序列化和 flush。诊断 I/O 仍可能影响整个系统负载，上层 wall time 不能与内层计时直接相减得到“纯计算”。打不开或写失败有 ERROR，测试 harness 明确检查，不把诊断失败当成功。该 logger 不保存 frame 引用。

memory_probe 复用生产 CameraService 和 VLMEngine，不另建推理框架；固定帧从原始 fixture 读入，真实 Camera 模式保存前三帧。首次保存会增加 Frame Age，因此主比较剔除前三个请求。rga_probe 是独立手动实验目标，不被完整语音调用；其三条硬件路径实际失败，不能以编译或 imcheck 成功替代图像正确性。

与实现对应的测试

image_pipeline_tests 在 Fake Camera 与实际 CPU 代码上检查：尺寸/padding/非法布局、RGB 与 reference 精确相等、颜色通道与上下方向、复用 capacity、三槽满载、旧 weak_ptr、持有帧期间更新、池析构后 lease、retire、Camera stop/restart、非法启动配置与主动 discard。它不包含 V4L2 ioctl、真实 DMA 或 RKNN 硬件。

async_pipeline_tests、llm_worker_tests、asr_pipeline_tests保留原确定性 Fake Worker/队列测试；ARM64 CTest 的真实 SDK 链接并不把这些 Fake 变成 NPU 推理测试。另以 memory_probe、固定帧 SDK 推理、真实语音与信号测试提供硬件证据。没有运行 ASan/TSan 或长期泄漏检测，不给出数学意义上的无竞态/无泄漏证明。

5.3 指标	优化前	优化后	统计边界
融合预处理平均/P50/P95 ms	11.052/10.540/12.640	8.325/8.378/9.495	各 n12，含首次调用
显式 NV12 复制平均 ms	9.459	9.736	每帧仍一次全帧复制，没有加速
Frame Age 平均 ms	26.851	28.384	各 n9，剔除前三个保存 fixture 请求，未改善
RKNN run 平均 ms	1160.708	1163.491	各 n12，模型计算没有加速
Vision 进程采样 RSS 峰值 MiB	554.426	552.043	非完整多模态进程，不宣称大幅省内存

预处理平均下降 24.67%，约 2.727ms，不等于完整语音按比例加速。暖态源码可见每帧分配点 5 降 1，最终 636 次 acquire、633 次复用、3 帧创建、0 满池，停止 in_use=0；每次 lease 控制块仍分配，不是零分配。RGA 三条硬件路径首 job 失败，未用于生产；未实现端到端零拷贝。NV12 元数据 Full Range 与原 limited 算法的既有差异、模型内部 mean/std 未反查等限制保留，优化只要求与原 CPU 路径回归一致。

5.3 面试题与完整参考答案

1. mmap 摄像头是否就是零拷贝？

不是。mmap 把驱动 Buffer 映射到用户虚拟地址，减少 read 系统调用搬运，但本工程在 DQBUF 和 QBUF 之间仍把 NV12 复制到 ImageFrame::data。此后 SDK 的 inputs_set 还可能转换

/传送。要声称端到端零拷贝，必须证明各消费者共享同一合适的存储、同步与所有权都成立，且没有暗含 staging memcpy；不能仅凭一个 mmap 或 DMA-BUF FD。

2. 为什么不直接把 V4L2 指针交给异步 VLM？

QBUF 之后驱动可以立即重写 Buffer，而推理可能持续数秒。shared_ptr 只管理包装对象，不能约束驱动重用。可以建立 dequeue lease 并延迟 QBUF，但这会占用有限驱动槽、影响采集；还需要停止时处理所有外借 Buffer。5.3 选择保留一次所有权拷贝，池化自有帧，风险更小。

3. shared_ptr 的 use_count()==1 能证明可以覆盖吗？

不能用一次计数观察替代同步协议，其他线程可能从 weak_ptr.lock 取得强引用。若复用同一个控制块，旧 weak_ptr 甚至可能在帧被重新填充后读到另一代数据。本实现每次 lease 生成新控制块，只有最后一个强引用消失、deleter 执行后才回池；旧 weak_ptr 永久过期，地址复用不会复活旧 lease。

4. 有界三帧池如何避免读写竞态？

空闲帧由 unique_ptr 独占，acquire 将它移出池后才填像素，发布后只交付 shared_ptr<const ImageFrame>。采集线程不保留可写别名。latest 与 VLM 可以共享一帧，最后强引用释放才归还。三槽支持一个推理持有帧、一个 latest 和一个正在采集的帧；若额外消费者保留更多帧，池满只 DQ/QBUF、计数丢弃，不无界分配。池大小是应用策略，不能假定任意消费者都不触发背压。

5. 为什么 shared_ptr 自定义 deleter 要在 mutex 外构造？

shared_ptr 的控制块分配可能抛 bad_alloc；接受裸指针和 deleter 的构造失败时会调用 deleter。如果此时仍持池 mutex，deleter 再锁池会死锁。因此在锁内完成槽位和计数转换，锁外构造控制块；失败也由同一归还逻辑恢复 in_use。

6. Camera.stop 后，正在读旧帧的线程怎么办？

停止采集、join、关闭驱动、clear latest 后 retire 池。空闲像素立即释放；外部强引用仍保护已取得的自有帧。State 被 lease 延长寿命，归还时发现 retired 就直接删除。Camera 重启用新 State，不接纳旧代帧。消费者必须持有 FramePtr，不能只提取 data() 裸指针后丢掉所有者。

7. stride 与 width 为什么不能互换？

width 是有效像素宽度，stride 是相邻行起点间的字节跨度，可能包含 padding。当前单 plane NV12 的 Y 起点 y*stride，UV 起点 stride*height，UV 同样按 stride 走行。本板实测 stride=3840=width，但测试额外验证 padding=16。多 plane、独立 UV stride、垂直 padding 不能套用这个公式，需要新的格式元数据和验证。

8. RGB 复用为什么必须考虑 Engine 锁与 SDK？

一个 vector 复用意味着其内容会在下次请求覆盖；若两个推理同时使用它，SDK 可能读取正在改变的输入。当前 VLMEngine mutex 串行化 backend infer，inputs_set→run→outputs_get 都在本次调用内完成；RGB 在 SDK 使用期间不 resize/reassign。Embeddings 独立复制后同步 rkllm_run，直到返回才允许下一次覆盖。若未来改 SDK async，必须重新设计事件和多 buffer 生命周期，现有结论不能直接继承。

9. NV12 转 RGB 优化后尺寸相同，为何还要逐像素比较？

矩阵 BT.601/709、limited/full、RGB/BGR、插值半像素坐标、UV 采样、饱和与舍入都能改变结果。相同 512×512 不等于相同模型输入。5.3 先比较固定原始帧的 RGB 字节，再比较 64×576 float Embeddings 和回答；还用合成红色/方向图确认通道与上下关系。真实画面用户确认补充语义证据，但不替代色彩标定。

10. 如何判断缓存坐标是有效优化？

先在旧算术上建立基线，保持模型、帧、编译模式一致，分离 poll 等待和预处理计算。缓存每个输出行/列的坐标，消除重复的浮点除法/边界计算；对相同输入验证像素。报告样本数、平均、nearest-rank P50/P95、最小/最大，并承认小样本和系统负载影响。总延迟还受约秒级 RKNN、语言生成和 TTS 影响，不能把几毫秒预处理改善说成完整交互等比例加速。

11. DMA-BUF、物理连续内存和缓存一致性是什么关系？

DMA-BUF 是共享内存对象及其 FD/同步约定，不自动保证物理连续；system heap 通常提供可通过 IOMMU 映射的页，是否支持要由实际硬件驱动/Runtime 确认。CPU 映射读写 DMA 缓冲要遵守 begin/end CPU access 或相应 sync ioctl。导入 FD 成功只说明对象被接受，不证明硬

件处理成功。本节 system heap FD 实验仍在首个 RGA job 失败，不能把它描述为完成 DMA 摄像头链路。

12. RGA 校验和 import 成功，为什么运行仍失败？

参数校验和导入是不同阶段，硬件提交还依赖实际驱动、地址映射、格式组合、stride/缩放能力和运行状态。本板虚拟地址、DMA fused、DMA resize 三条路径均在第一个 job 报错，并有内核硬件超时。证据不足以指定唯一根因；正确做法是保留日志、停止扩大试验、保持 CPU 生产路径，不把驱动自己 soft reset 当作应用修复成功。

13. 为什么 RSS 上升不一定是泄漏，但也不能忽略？

池保留三帧容量和 RGB/embedding 缓存，允许以常驻内存换取分配减少；allocator 与 SDK 也可能缓存。泄漏指不可达或不再需要的资源未释放，不能仅凭单个 RSS 值判断。需要观察 bounded 峰值、停止时归还计数、设备 FD 关闭、重复生命周期和长期趋势。5.3 只有有限轮次采样和生命周期测试，没有长期泄漏工具证据，因此明确保留风险，并公开峰值增加的代价。

14. 如何保证统计不“美化”结果？

保留原始版本、所有失败轮次、退出码、输入元数据和测量脚本。区分源代码可见分配事件与 malloc 总次数；区分 Host Frame Age 与曝光时间；融合操作不拆出虚构独立耗时；P95 小样本常等于最大值。排除前三个保存 fixture 的 Frame Age 时必须写明规则并保留原数据。RGA 没有成功样本就标未测量，SDK 内部未知就标未知。

15. drain 与 cancel_pending 的安全退出区别是什么？

两者先关闭新输入，再处理已接收工作。drain 排空有效的已接收任务；cancel_pending 取消等待执行或尚未提交到下游的任务，同时允许已经进入 SDK 的调用返回。取消不是在任意指令点破坏 Runtime。之后按 ASR→推理 Worker→TTS→设备/模型销毁的依赖顺序 join；信号处理机制沿用 5.1，不在异步 signal handler 中调用 mutex、日志、析构或 SDK。强杀只能是超时后的失败保护，不能证明优雅退出。

6 第五阶段 5.4 统一 Profiling 和 TTS 优化

统一使用 steady_clock，Request ID 随 AudioSegment、TaskOptions 及完成回调传递。scope 恢复线程局部上下文，SDK 回调显式携带共享 Trace，没有全局无界请求 map。Frame ID 和 Request ID 不同，不能拼错。每次请求记录 VAD 检测与端点、ASR 队列与推理、路由、推理队列/执行、首文本 chunk、整段答案、TTS 队列/合成、首音频回调、自有 PCM、ALSA 首次成功提交及 drain。

SDK 首个非空文本 chunk 不等于精确首 token；首音频 callback 只保证一批借用 float，当前实现仍等待完整生成再播放。ALSA 首次 writei 提交与 drain 不是耳机真实声学输出。ASR API 包括 stream、AcceptWaveform、Decode 与取文本；VAD 采样索引给出的是主机时间估算，XRUN 使其无效。所有缺失观测保持未测量，不能用 0 或文本长度推算。

完整关键源码 include/common/request_trace.h

```
#pragma once
#include "common/image_profile.h"
#include <memory>
#include <utility>

// One bounded-lifetime object travels through existing queue/task ownership.
// No central map retains completed requests. Raw timestamps use steady_clock.
class RequestTrace {
public:
    using Clock=std::chrono::steady_clock;
    explicit RequestTrace(std::uint64_t id):id_(id){}
    std::uint64_t id() const noexcept {return id_;}
    void mark(const char* event,Clock::time_point at=Clock::now(),double value=-1) const
noexcept {
        ImageProfile::instance().request(id_,event,at,value);
    }
    void text(const char* event,std::string_view value) const noexcept {
        ImageProfile::instance().text(id_,event,value);
    }
private:
    const std::uint64_t id_;
};
using RequestTracePtr=std::shared_ptr<RequestTrace>;
inline RequestTracePtr makeRequestTrace(std::uint64_t id) {
    return
ImageProfile::instance().enabled()?std::make_shared<RequestTrace>(id):RequestTracePtr{};
}
inline RequestTracePtr& currentRequestTrace(){static thread_local RequestTracePtr trace;return
trace;}
class RequestTraceScope {
public:
    explicit RequestTraceScope(RequestTracePtr
trace):previous_(std::move(currentRequestTrace())),previous_id_(image_profile_request_id) {
```

```
currentRequestTrace()=std::move(trace);image_profile_request_id=currentRequestTrace()?currentRe
questTrace()->id():0;
    }

~RequestTraceScope(){currentRequestTrace()=std::move(previous_);image_profile_request_id=previo
us_id_;}
    RequestTraceScope(const RequestTraceScope&)=delete;
    RequestTraceScope& operator=(const RequestTraceScope&)=delete;
private:
    RequestTracePtr previous_;
    std::uint64_t previous_id_;
};
inline void traceMark(const char* event,RequestTrace::Clock::time_point
at=RequestTrace::Clock::now(),double value=-1) noexcept {
    if(currentRequestTrace())currentRequestTrace()->mark(event,at,value);
}
```

完整关键源码 include/common/image_profile.h

```
#pragma once
#include <chrono>
#include <cstddef>
#include <stdexcept>
#include <cstdint>
#include <cstdlib>
#include <fstream>
#include <iostream>
#include <mutex>
#include <string>
#include <string_view>

// Frame IDs and request IDs belong to different namespaces. SDK callbacks carry
// an explicit RequestTrace; ordinary synchronous stages inherit this scoped ID.
inline thread_local std::uint64_t image_profile_request_id=0;

// Optional diagnostic JSONL. Each duration ends before file I/O; no frame data held.
class ImageProfile {
public:
    using Clock=std::chrono::steady_clock;
    static double ms(Clock::time_point start,Clock::time_point end=Clock::now()) {
        return std::chrono::duration<double,std::milli>(end-start).count();
    }
    static ImageProfile& instance(){static ImageProfile profile;return profile;}
    bool enabled() const noexcept {return enabled_;}
    void sample(const char* stage,double duration,std::uint64_t id=0,std::size_t
bytes=0,std::size_t allocations=0) noexcept {
        if(!enabled_ || (!background_ && image_profile_request_id==0))return;
        try {
            std::lock_guard<std::mutex> lock(mutex_);

output_<<"{\"stage\":\""<<stage<<"\",\"ms\":"<<duration<<",\"id\":"<<id<<",\"request_id\":"<<im
age_profile_request_id<<",\"bytes\":"<<bytes<<",\"allocations\":"<<allocations<<"}\n";
            output_.flush();
            if(!output_ && !failed_){failed_=true;std::cerr<<"[ImageProfile ERROR] write
```

```
failed\n";}
        } catch(...) {std::cerr<<"[ImageProfile ERROR] exception\n";}
    }
    void request(std::uint64_t id,const char* event,Clock::time_point at,double value=-1)
noexcept {
        if(!enabled_)return;
        try {
            const auto
ns=std::chrono::duration_cast<std::chrono::nanoseconds>(at.time_since_epoch()).count();
            std::lock_guard<std::mutex> lock(mutex_);

output_<<"{\"kind\":\"request\",\"stage\":\"request_event\",\"ms\":0,\"id\":0,\"bytes\":0,\"all
ocations\":0,\"request_id\":"<<id<<",\"event\":\""<<event<<"\",\"at_ns\":"<<ns<<",\"value\":"<<
value<<"}\n";
            output_.flush();
            if(!output_ && !failed_){failed_=true;std::cerr<<"[ImageProfile ERROR] request
write failed\n";}
        }catch(...){std::cerr<<"[ImageProfile ERROR] request exception\n";}
    }
    // Complete user-visible text shares the existing JSONL mutex and clock.
    // Console streaming from several threads is not a reliable GUI protocol.
    void text(std::uint64_t id,const char* event,std::string_view value) noexcept {
        if(!enabled_)return;
        try {
            const auto
ns=std::chrono::duration_cast<std::chrono::nanoseconds>(Clock::now().time_since_epoch()).count(
);
            std::lock_guard<std::mutex> lock(mutex_);

output_<<"{\"kind\":\"request\",\"stage\":\"request_event\",\"ms\":0,\"id\":0,\"request_id\":"<
<id
                  <<",\"event\":\""<<event<<"\",\"at_ns\":"<<ns<<",\"value\":-1,\"text\":\"";
            constexpr char hex[]="0123456789abcdef";
            for(unsigned char c:value) {
                if(c=='"')output_<<"\\\"";
                else if(c=='\\')output_<<"\\\\";
                else if(c=='\n')output_<<"\\n";
                else if(c=='\r')output_<<"\\r";
                else if(c=='\t')output_<<"\\t";
                else if(c<0x20)output_<<"\\u00"<<hex[c>>4]<<hex[c&15];
                else output_.put(static_cast<char>(c));
            }
            output_<<"\"}\n";output_.flush();
            if(!output_ && !failed_){failed_=true;std::cerr<<"[ImageProfile ERROR] text write
failed\n";}
        }catch(...){std::cerr<<"[ImageProfile ERROR] text exception\n";}
    }
private:
    ImageProfile(){
        const char* path=std::getenv("STAGE5_PROFILE");
        background_=path==nullptr; // Legacy image profiling retains all Camera samples.
        if(!path)path=std::getenv("STAGE5_IMAGE_PROFILE");
        if(path) {
            enabled_=true;output_.open(path,std::ios::out|std::ios::trunc);
            if(!output_){enabled_=false;failed_=true;std::cerr<<"[ImageProfile ERROR] cannot
open log\n";}
        }
    }
```

```
    bool enabled_=false,failed_=false,background_=true;
    std::mutex mutex_;
    std::ofstream output_;
};
inline void imageSample(const char* stage,double ms,std::uint64_t id=0,std::size_t
bytes=0,std::size_t allocations=0) {
    ImageProfile::instance().sample(stage,ms,id,bytes,allocations);
}
```

完整关键源码 src/audio/tts_service.cpp bool TTSService::synthesize(

```
bool TTSService::synthesize(
    const std::string& text,
    TTSAudio& output,
    std::string& error)
{
    output = TTSAudio{};
    error.clear();

    if (tts_ == nullptr)
    {
        error = "TTSService is not initialized";
        return false;
    }

    if (text.empty())
    {
        error = "Input text is empty";
        return false;
    }

    SherpaOnnxGenerationConfig gen{};

    // 关键：使用初始化时选定的说话人。
    gen.sid = speaker_id_;

    gen.speed = 1.0f;
    gen.silence_scale = 0.2f;

    using AudioDeleter = decltype(
        &SherpaOnnxDestroyOfflineTtsGeneratedAudio
    );

    using AudioOwner = std::unique_ptr<
        const SherpaOnnxGeneratedAudio,
        AudioDeleter
    >;

    const auto start =
        std::chrono::steady_clock::now();
    traceMark("tts_generate_begin",start);
    AudioProgress progress;progress.trace=currentRequestTrace();

    // 真正执行 ONNX TTS 推理。
    AudioOwner audio(
```

```
        SherpaOnnxOfflineTtsGenerateWithConfig(
            tts_,
            text.c_str(),
            &gen,
            progress.trace?audioProgress:nullptr,
            progress.trace?&progress:nullptr
        ),
        &SherpaOnnxDestroyOfflineTtsGeneratedAudio
    );

    const auto finish =
        std::chrono::steady_clock::now();
    traceMark("tts_generate_end",finish);

    if (!audio ||
        !audio->samples ||
        audio->n <= 0 ||
        audio->sample_rate <= 0)
    {
        error =
            "TTS generation returned invalid audio";
        return false;
    }

    try
    {
        traceMark("tts_pcm_copy_begin");
        // 复制 SDK PCM 到 C++ 自有缓冲区。
        output.samples.assign(
            audio->samples,
            audio->samples + audio->n
        );
        traceMark("tts_pcm_copy_end");
    }
    catch (const std::exception& e)
    {
        error =
            std::string("PCM copy failed: ") +
            e.what();

        return false;
    }

    output.sample_rate = audio->sample_rate;
    traceMark("tts_full_audio_ready",RequestTrace::Clock::now(),static_cast<double>(audio->n));

    output.synthesis_ms =
        std::chrono::duration<double, std::milli>(
            finish - start
        ).count();

    // audio 离开作用域时自动调用 SDK 删除器。
    return true;
}
```

完整关键源码 src/audio/alsa_playback_service.cpp bool AlsaPlaybackService::play(

```
bool AlsaPlaybackService::play(
    const float* samples,
    std::size_t sample_count,
    std::string& error)
{
    error.clear();

    if (pcm_ == nullptr)
    {
        error = "ALSA device is not initialized";
        return false;
    }

    if (samples == nullptr || sample_count == 0)
    {
        error = "Invalid audio samples";
        return false;
    }

    // 1. 先在内存中完成全部格式转换,
    // 避免播放期间进行耗时的逐样本转换。
    std::vector<std::int16_t> pcm_data;
    traceMark("playback_convert_begin");

    try
    {
        pcm_data.resize(sample_count);
    }
    catch (const std::bad_alloc&)
    {
        error = "Cannot allocate playback PCM buffer";
        return false;
    }

    for (std::size_t i = 0; i < sample_count; ++i)
    {
        float value = samples[i];

        if (!std::isfinite(value))
        {
            value = 0.0f;
        }

        value = std::max(
            -1.0f,
            std::min(1.0f, value)
        );

        const float scale =
            value < 0.0f ? 32768.0f : 32767.0f;

        pcm_data[i] = static_cast<std::int16_t>(
            std::lround(value * scale)
        );
    }
```

```
// 2. 准备播放设备。
traceMark("playback_convert_end");
int rc = snd_pcm_prepare(pcm_);

if (rc < 0)
{
    error = std::string("snd_pcm_prepare: ") +
            snd_strerror(rc);
    return false;
}

// 查询 period，以便按照设备缓冲节奏提交数据。
snd_pcm_uframes_t buffer_frames = 0;
snd_pcm_uframes_t period_frames = 0;

rc = snd_pcm_get_params(
    pcm_,
    &buffer_frames,
    &period_frames
);

if (rc < 0 || period_frames == 0)
{
    error = "Cannot query playback period size";
    return false;
}

std::size_t offset = 0;
int consecutive_recoveries = 0;
int wait_timeouts = 0;
bool first_submission=true;

// 3. 持续将音频送入 ALSA。
while (offset < pcm_data.size())
{
    const std::size_t remaining =
        pcm_data.size() - offset;

    const snd_pcm_uframes_t frames =
        static_cast<snd_pcm_uframes_t>(
            std::min(
                remaining,
                static_cast<std::size_t>(
                    period_frames
                )
            )
        );

    const auto submit_begin=std::chrono::steady_clock::now();
    const snd_pcm_sframes_t written =
        snd_pcm_writei(
            pcm_,
            pcm_data.data() + offset,
            frames
        );
```

```
        if (written > 0)
        {
            if(first_submission){
                traceMark("alsa_first_submit_begin",submit_begin,static_cast<double>(written));

traceMark("alsa_first_submit_complete",std::chrono::steady_clock::now(),static_cast<double>(wri
tten));
                first_submission=false;
            }
            offset += static_cast<std::size_t>(written);

            consecutive_recoveries = 0;
            wait_timeouts = 0;
            continue;
        }

        if (written == -EAGAIN || written == 0)
        {
            const int wait_rc =
                snd_pcm_wait(pcm_, 1000);

            if (wait_rc < 0)
            {
                error = std::string("snd_pcm_wait: ") +
                        snd_strerror(wait_rc);
                return false;
            }

            if (wait_rc == 0)
            {
                if (++wait_timeouts > 5)
                {
                    error = "ALSA wait timeout";
                    return false;
                }
            }

            continue;
        }

        // EPIPE 表示播放缓冲区欠载。
        if (written == -EPIPE)
        {
            ++xrun_count_;

            std::cerr
                << "[ALSA XRUN] write offset="
                << offset
                << " total=" << pcm_data.size()
                << '\n';
        }

        const int recover_rc = snd_pcm_recover(
            pcm_,
            static_cast<int>(written),
            1
        );
```

```
    if (recover_rc < 0)
    {
        error = std::string("snd_pcm_recover: ") +
                snd_strerror(recover_rc);
        return false;
    }

    if (++consecutive_recoveries > 5)
    {
        error = "Too many ALSA recoveries";
        return false;
    }
}

// 4. 记录全部数据写入后的 PCM 状态。
snd_pcm_state_t state = snd_pcm_state(pcm_);

std::cout
    << "[ALSA write]"
    << " submitted_frames=" << offset
    << " state=" << snd_pcm_state_name(state)
    << '\n';

// 对短音频：如果还未达到自动启动阈值，
// 显式启动播放，再进行 drain。
if (state == SND_PCM_STATE_PREPARED)
{
    rc = snd_pcm_start(pcm_);

    if (rc < 0)
    {
        error = std::string("snd_pcm_start: ") +
                snd_strerror(rc);
        return false;
    }
}

// 5. 等待 ALSA 将缓冲区中的音频播放完。
traceMark("alsa_drain_begin");
rc = snd_pcm_drain(pcm_);

if (rc < 0)
{
    if (rc == -EPIPE)
    {
        ++xrun_count_;
    }

    state = snd_pcm_state(pcm_);

    error = std::string("snd_pcm_drain: ") +
            snd_strerror(rc) +
            " state=" +
            snd_pcm_state_name(state);

    return false;
}
```

```
    // XRUN 即使恢复成功，也说明本次播放可能存在断续。
    if (xrun_count_ != 0)
    {
        error = "Playback completed with detected XRUN";
        return false;
    }

    traceMark("alsa_drain_complete");
    return true;
}
```

5.4 关键源码逐句说明与生命周期审查

本文与 完整前后源码附录、性能报告 配套。附录从实际文件导出，不用伪代码替代生产入口。这里解释新增语句的语法、调用次序及边界；既有大段设备初始化和模型参数沿用 5.1～5.3。

操作 1：统一时钟、日志与请求所有权

include/common/image_profile.h 继续使用原来的单例、文件和互斥锁。using Clock=std::chrono::steady_clock 是类型别名，时间不随系统校时跳变。time_since_epoch() 仅供同一进程内相减，不解释为 UTC。duration_cast<nanoseconds> 后输出整数，分析器先做整数相减再转毫秒，避免大绝对值浮点数抵消。

inline thread_local std::uint64_t image_profile_request_id=0 为每个线程保存独立的请求编号；inline 允许头文件被多个翻译单元包含。它不是共享状态，不需要互斥。SDK 自建回调线程不会自动继承这个值，必须显式传 RequestTracePtr。

构造函数先查 STAGE5_PROFILE，不存在才查旧的 STAGE5_IMAGE_PROFILE。background_=path==nullptr 在回退前求值：旧图像诊断仍保留背景 Camera 采样；新请求诊断省去没有请求关联的每帧日志，避免每秒数百条日志干扰 CPU。它没有关闭 Camera 或改变帧池。

request(id,event,at,value) 在锁外把时点转成整数，在 lock_guard 作用域内写一整行再 flush。request_id 和图像样本的 id 分开：一次请求可以使用一帧，多次请求也可以使用同一帧。value 供队列深度、路由或样本数使用，不混作时间。事件名来自编译期常量，不接收未经转义的用户文本。

enabled_、background_ 在单例构造后只读；failed_ 和文件写入受同一把锁保护。写失败显式打印 ERROR，不编造零耗时；它是诊断失败，验收脚本将其列为失败条件。捕获异常避免诊断代码跨 SDK C 回调传播。日志 I/O 会影响相邻区间，微秒级 router 数据是带埋点的墙钟区间，并非无扰动纯计算时间。

include/common/request_trace.h 的 RequestTrace 只有不可变 ID，没有可变阶段表。makeRequestTrace 仅在诊断启用时分配一个控制块；没有中央 map 永久保留请求。shared_ptr 使音频段、排队任务和完成回调各持有自己的强引用，最后一个持有者释放时自动销毁。

currentRequestTrace() 返回函数局部 thread_local shared_ptr 的引用。首次实现用头文件中的 inline TLS shared_ptr，在 MinGW 链接时出现初始化符号重复；改为 accessor 后本地构建通过，原失败日志保留。ARM64 另行构建验证，不能从 Windows 结果推断。

RequestTraceScope 构造时 std::move 取走原 TLS 引用，设置本次引用和数字 ID；析构时恢复上一层。移动 shared_ptr 转移引用，不复制请求对象。禁止复制 scope，防止两次恢复。嵌套同步调用和异常展开均按栈次序恢复；回调需要跨线程时显式捕获 shared_ptr，不能捕获 scope 的地址。

操作 2：沿已有队列传递上下文

include/common/work_control.h 给 TaskOptions 增加 RequestTracePtr trace，未改变 deadline、max_queue_wait、原子取消标志或 disposition 优先级。PipelineAdmission::Ticket::options(max_wait,trace={}) 的第二参数有默认值，旧调用仍有效；std::move(trace) 转移本次局部引用，票据的 deadline/cancelled 仍共享原状态。

AudioSegment 增加同类型成员。音频 vector 的所有权仍随原队列移动，不为埋点再复制音频。AudioBufferQueue::push 先保留一个 trace 引用和实际 enqueued_at；队列关闭时记拒绝，满载覆盖最旧段前记被替换请求。成功 push 仍在同一队列锁下，日志和唤醒沿原流程；分析按时间戳而非文件行出现顺序排序，因为出队线程可能先写日志。

ASRWorker 新增可选 ContextCallback(text,const AudioSegment&)，原 TextCallback 和原构造调用保留。若提供 context callback 就只调用它，避免一次识别发出两次业务请求。const AudioSegment& 只在同步 callback 执行期间有效；入口只复制 trace 引用，不保存 segment 引用，也不保存 samples 裸指针。

出队后创建 RequestTraceScope(segment.trace)，随后记 dequeue、ASR begin/end，并包住原业务 callback。原音频预处理、识别参数及队列关闭逻辑保留。ASRService 内部 stream 创建、AcceptWaveform、Decode 另设标记：外层 API 时间包含这些步骤及文本取回，Decode 区间也不是纯 ONNX 算子时间。

LLMWorker 和 TTSWorker 从既有 TaskOptions 取上下文。记录成功入队时的等待队列深度、真正出队、服务开始及终态；取消和过期在原 disposition 分支记录。工作函数在队列锁外执行，未把模型推理搬入队列临界区。拒绝路径记明确事件，原统计和终态 callback 仍执行。

循环末尾 task=Task{} 释放 inference/done 捕获的票据、上下文和其他对象；scope 的额外引用在本次循环离开时释放。测试通过 weak_ptr 检查 joined 后不再持有上下文。新增的唯一动态对象受原有界队列与在途上限约束，没有无界增长容器。

操作 3：VAD 时间的真实意义

VadAudioWorker 每次喂入原 512 样本窗口后观察 SDK 的 detected 状态，记录上升沿的主机 steady 时点。确认完整 segment 可取时，先记录 endpoint，再复制原有 pre-roll 和语音数据。segment 创建后才有 sequence，因此用 trace->mark(event, earlier_time) 回填已观察到的时点，而不是重新调用 now 冒充起点。

audio_start_estimated 和 audio_end_estimated 用最后一次 read 完成时点与采样索引差回推。只沿用原有无 XRUN/suspend 的 timing_valid 条件；不是声卡 ADC 时间戳，也不是精确人声起止。检测起点、估算起点和预滚起点分别解释，不能相互代替。

可选 STAGE5_CAPTURE_AUDIO_FIXTURES 只在专用测试打开，复制完 VAD 段后写出自有 float 样本及元数据。开始/结束独立计时；写文件会增加 vad_to_queue 和整请求延迟。报告区分留存语音的自然基线与不写 fixture 的后续测量，不拿这点额外 I/O 伪造加速。

操作 4：RKLLM callback 和 VLM 状态

Qwen 的 RunContext 增加 shared_ptr，在同步 rkllm_run 前复制当前上下文。原 mutex 保护 text、failed、first_text_ms。首次非空 chunk 时记录同一个 now；SDK callback 借用的 result->text 仍复制进 string，不能保留该指针。

SmolVLM2 的 GenerationState 增加 mutex、decoder_start、first_text_ms 和 trace。callback 的所有状态读取/写入置于 lock_guard 内；异常展开先销毁 guard，再进入 catch 重新加锁置

failed，避免同线程重复锁。同步 run 返回后主线程先记 decoder_end，再锁 state 检查 finished/failed/text 并移动文本。

state 仍为同步调用栈上的对象，SDK 参数保持 `is_async=false`。run 返回并确认回调结束之前 state 不析构；destroy 仍在 Worker join 之后。若未来换为异步 SDK，必须重审这一契约，不能照搬栈对象。

首回调是“首个非空文本 chunk”，可能包含多个 token；不宣称精确 token 级 TTFT。VISION 的 inference_begin 到首 chunk 包含预处理、RKNN 和语言 decoder；decoder_begin 到首 chunk 只含语言阶段，二者不混用。5.3 的 RGB/Embedding 缓存、输出 RAII、输入转换及固定英文视觉问题全部保留。

操作 5：TTS 和 ALSA 的测量边界

`TTSService::initialize` 仍仅启动时创建一次 SDK 对象。候选把默认 num_threads 从 2 改为 4，命令行显式传 2 可回退；speaker、speed、silence_scale、模型和 provider 的生产默认均未改变。没有新增 TTS 合成线程，也没有自动裁剪答案。

`AudioProgress` 持有 trace 与原子 seen 标记。首个 `n>0 && samples!=nullptr` 回调只记录时间和长度，始终返回 1；不持有 SDK 借用 PCM 指针，不在回调播放，不在回调停止或截断生成。`GenerateWithConfig` 是同步调用，progress 活到调用返回。

`AudioOwner` 仍用 unique_ptr 和 sherpa 删除器托管返回音频。无效输出直接失败，PCM vector::assign 异常返回明确错误，owner 随作用域释放，成功也先复制再释放。分别记录 SDK Generate、应用 PCM copy、完整自有音频 ready。callback 给出第一批音频可用时间，但当前播放路径仍等待整个 Generate 返回；不能把 callback 时间当首个 ALSA 提交时间。

诊断开关 `STAGE5_TTS_ORT_PROFILE_CONFIG` 只用于独立 ORT 实验；配置必须存在，所有输出位于新报告目录。它不是生产默认配置，也不进入主公平对照。ORT model_run 能看到模型会话区间，API 减去 model_run 的剩余值包含文本前端、输出处理、调度及诊断开销，不能直接命名为“纯音素化时间”。

ALSA 沿原 float→S16 转换和写入循环。对首次成功 writei 保存“调用前”时点和成功返回时点；只有 written>0 才记首次提交，错误返回不冒充已提交。全段 writei 完成后的旧 `[ALSA write]` 日志仍保留，但不用于首次提交指标。

snd_pcm_drain 前后另记事件。alsa_drain_complete 表示驱动/ALSA 排空语义，不是麦克风测到的实际声学尾音。buffer=12000、period=3000、start_threshold=6000 的现有配置不改；首次 write 成功也不代表耳机那一刻已经发声。

操作 6：固定输入、回放与信号等待

include/app/profiling_inputs.h 仅在显式测试环境变量启用。NV12 元数据检查非零偶数尺寸、stride≥width、上限、最少 NV12 字节数及文件长度，再读入自有 ImageFrame。没有伪造 received_at，所以固定帧 Frame Age 不可用。该强引用在入口作用域活到异步 Worker join 之后，后台 Camera 的 V4L2 重用不会覆盖这个独立 vector。

音频加载限制 16kHz 单声道 float、最长 16 秒、字节数整除 sizeof(float)，并逐样本检查有限数和范围。部署机 ARM64/Windows 均为小端，文件声明 f32le；不能把其他编码直接送入此接口。fixture 写入拒绝已存在的相同 ID 文件。它用于当前受控新建目录，不是面向不可信并发写者的通用存储服务。

完整入口的 on_text(recognized,supplied_trace={}) 在路由前继承 ASR ID。原文本回放没有 trace 时仍分配 next_id。音频回放生产者使用独立 audio_replay_sequence，不与 ASR callback 线程同时修改 next_id，避免新数据竞争。

STAGE5_REPLAY_AUDIO_FILE 走原 ASRWorker、IntentRouter、InferenceWorker、TTSWorker 和真实 ALSA；绕过麦克风与 VAD，必须在输出和报告中注明。固定帧只允许与显式回放和 VISION 一起使用，普通自然语音仍取最新 Camera 帧。

原文本回放等待使用 sleep_until，长达 100 秒的未来输入会推迟信号响应。候选改为每 20ms 检查既有 StopSignals，再处理原定时刻；没有在信号 handler 做锁、iostream、join 或 destroy。main 退出仍先停生产者/ASR，再排空或取消推理，join 后释放 Qwen，再完成/取消 TTS，最后关闭播放、Camera 与 VLM。取消只作用未开始任务，正在执行的 SDK 调用仍等待其返回；有限超时由测试守护独立记录，强制终止不能算优雅退出。

操作 7：验证如何覆盖这些语句

- request_profile_tests：同一 request_id、不同 frame_id、跨真实 std::thread 的显式回调、TLS 恢复、JSONL flush；固定 PCM roundtrip、NaN 拒绝、覆盖拒绝、NV12 stride 检查及无伪造采集时间。

- async_pipeline_tests：保留原满载/取消/到期/交替任务/停止重启测试，增加 trace 在推理、完成回调、Fake TTS、ASR context callback 间传递及 weak_ptr 最终释放。
- image_pipeline_tests/camera_service_tests：继续验证 5.3 Buffer 所有权、复用与并发读取；使用 Fake，不能当真实摄像头或 NPU 结果。
- 独立手动 benchmark：原 SDK 的真实 ASR/VLM/TTS，固定输入、warm-up 和 CSV；不注册为自动 CTest，避免普通 ctest 隐式占硬件或运行数十分钟。
- 板端完整入口：真实设备释放、信号、排空/取消、队列过期与拒绝；自然语音的耳机效果由当前用户确认，不由 success=true 推断。

测试逐项结果、退出码和剩余边界见主报告及 validation_summary.json。没有 ASan/TSan/Valgrind 的全进程硬件证明，不把本轮有限回归写成任意运行时长下绝无泄漏。

操作 8：手动 benchmark、CMake 与分析脚本

`stage5_04_tts_bench.cpp` 的 argv 长度必须为 5，包括程序名；stoi 后限制线程 1～8、有效重复 1～64。initialize 在循环外调用一次；双层循环外层 iteration，内层中文/英文，顺序固定。iteration0 与 1 分别记录 first_use/warmup，剩余 N 才是 measured。`TTSAudio` 每轮为局部对象，合成返回后按实际样本数/采样率求音频秒数；RTF 使用毫秒除以音频秒数×1000。逐样本检查 finite、abs 最大值、平方和均方根和逐字节 FNV，不能由 hash 不同直接推断退化。仅首个 measured 保存实际 PCM，其余仍逐行 flush CSV。

`stage5_04_asr_bench.cpp` 用 SDK Wave 读取器和自定义删除器持有固定 16kHz 单声道输入，同一 ASRService 循环使用，保存识别文本并检查一致。wall 包含调用外层开销，ASR API 时间来自原服务内部。CSV helper 将引号变为双引号，符合 CSV 约定，不用 C++ quoted 的反斜杠逃逸冒充 CSV。

`stage5_04_vision_bench.cpp` 启动时加载三个固定 NV12 自有帧，循环 `i%3` 选择 fixture，避免每轮读盘混进模型耗时。2 轮初始调用后 30 个样本，恰好每 fixture10 个；这不代表每张图都独立做两次预热。真实 VLMEngine 和既有模型路径保持。输入 RGB 和 64×576 float 输出可选保存，文件以递增 sample 编号命名，重复使用 frame_id 不会覆盖其他样本。

CMake 复用 multimodal_core/audio/tts 及现有 SDK 传递依赖；target_link_libraries PRIVATE 表示仅该手动程序使用依赖，原库的 PUBLIC 头文件/链接传播仍保留。TTS target 的

STAGE5_BENCH_TRACE=1 只启用诊断探针的上下文，不改变库的模型参数。手动探针只 add_executable，不 add_test，因此 ctest 不会隐式占用麦克风、Camera/NPU 或运行 30 轮大模型。request_profile_tests 才注册为带超时的确定性测试。

stage5_04_prepare.py 把实际字节和 SHA 放入 payload，源目录/快照必须不存在。先从冻结 5.3 副本复制，再逐项核对 before 哈希后覆盖**新的本节副本**；不会覆盖已验收路径。revision 支持 v1/v2/v3，旧产物全保留。baseline v2 仅把默认线程退回 2，其他测量路径保持同源。每个构建 step 记录 argv/stdout/stderr/退出码/磁盘采样；余量低于 500MiB 或超时才终止本次新建编译进程组。

stage5_04_run.py 和 voice_run 逐次发现 HyperX，查询四个实际设备节点是否空闲。采样器只读/proc 和 sysfs，CLK_TCK 来自 sysconf。设备权限不靠更改系统配置；sudo 仅只读 fuser。每个 case 目录独占创建。信号守护核对 exe 和/proc 启动 token 后只对本次 PID 发信号，异常强杀单独标失败。voice_run 的 SSH 传输成功与 child.returncode 分别记录，不相互覆盖。

stage5_04_analyze.py 先按 case+request_id 关联事件，再以整数纳秒差求毫秒；按语言、fixture、phase、route、status 分组，缺少事件保持 None。quantile 采用 nearest-rank，不对稀疏失败样本补零。资源统计分别保存 CPU 单核口径、RSS/HWM、频率和原始 NPU 字符串；不能靠读到 100 就声称硬件满载。ORT 诊断是另一 case，算子 dur 之和不等同总墙钟。

stage5_04_plot.py 从原始统计绘制散点/箱线、RTF 经验 CDF、CPU 曲线/RSS 及请求阶段分解，写 PNG/SVG 可分享文件；不用虚构平滑采样。Gantt 各请求从各自首次事件归零，图题明确这不是所有请求共享的全局起点。

操作 9：最终音频回放错误检查的最小修正

文本回放原本不启动 ASR，因此旧 replay_mode || consumer.ok() 的意图成立；加入真实音频回放后不能继续对所有 replay 跳过 ASR 状态。v3 把通过条件改为 replay_mode ? (!audio_replay_path || consumer.ok()) : (producer.ok() && consumer.ok())：文本回放仍免检查，音频回放必须 consumer.ok，自然语音同时检查生产者/消费者。对应错误输出条件也加入 audio_replay_path。

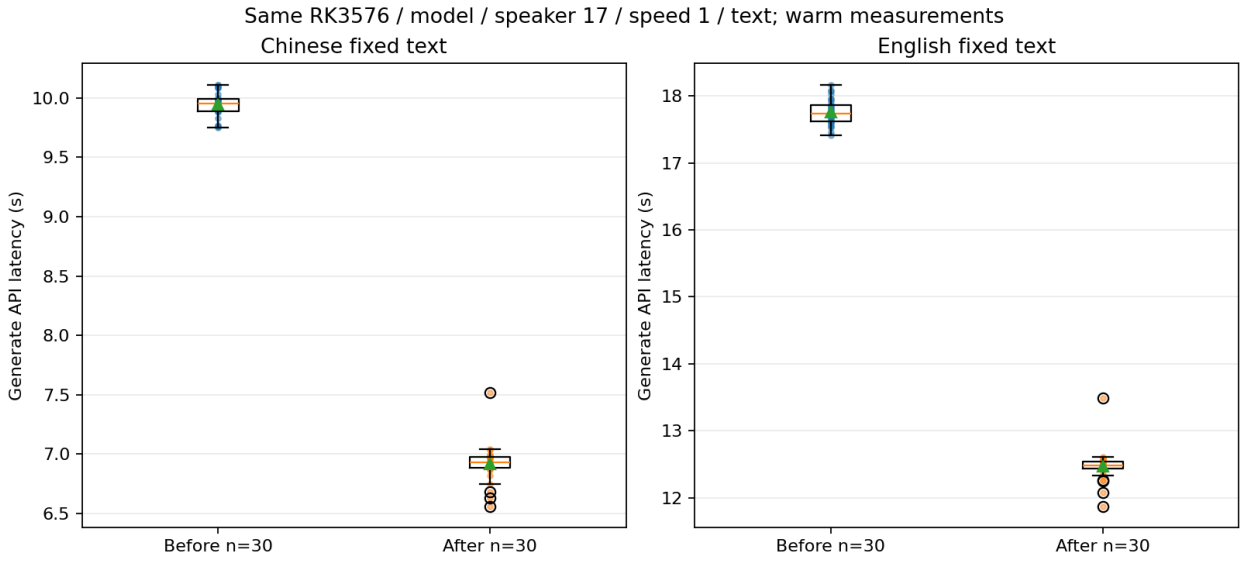
这只修复新测试入口可能出现的假阳性，不改变正常识别、模型调用或队列。之前有效输入 v2 的性能证据保持有效，但不能冒称 v3 执行；最终自然语音、信号和完整构建另用 v3 复测。未对真实 SDK 注入所有内部故障，故不宣称所有错误路径已实机覆盖。

固定文本 每语言 n30	2 线程平均/P50/P95 ms	4 线程平均/P50/P95 ms	平均 RTF 前后
一加一等于二	9945.095/9952.273/10112.211	6920.197/6925.889/7042.744	5.090→3.545
A computer monitor displaying a webpage with some text and images	17758.202/17730.550/18084.155	12476.125/12473.974/12609.867	4.316→3.032

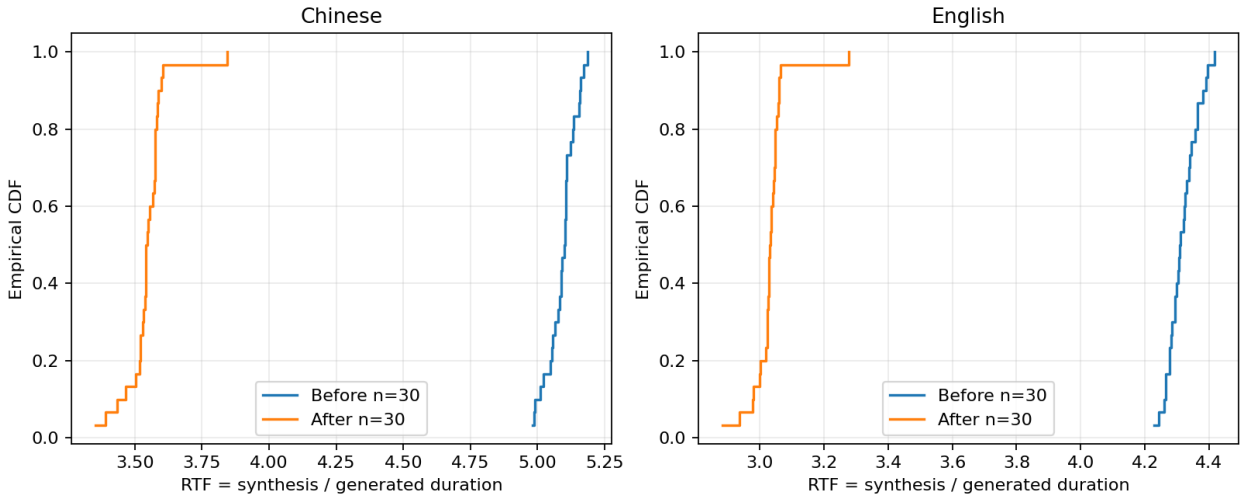
同一台板、同一冻结 5.3 TTS 库和 benchmark、同模型、sid17、speed1、silence_scale0.2 及相同文本；唯一参数差为线程数。每种语言另记 first-use 与 warmup，不混入 30 暖态样本。中文与英文平均合成耗时分别下降 30.42%和 29.74%，RTF 仍大于 1；CPU 约 199.65%到 398.44%（单核 100%），最高观测温度 76.692℃到 85.888℃。这是短时合成收益及资源代价，不是所有子系统都变快。

独立 ORT 诊断 6 次中 model_run 累计占 Generate API 约 99.9766%，支持主要瓶颈为计算；文本前端/音素化没有独立回调，残差不能叫纯音素化时间。没有重复初始化，因此没有编造“去掉重加载”的收益。1 线程更慢，6 线程中文更慢且 CPU 更高，原实验保留未采用。没有更换声音、语速、截断回答或增加并发合成实例。

同音频/固定帧三组 VISION→TEXT 有限观测：VISION 从 ASR 入队至 drain 均值 19.914→16.693 秒，TEXT29.630→24.334 秒；两边均使用 60 秒 TTS 等待和 180 秒期限，避免靠过期制造收益。TEXT 模型服务本身 1149.5→1422.1ms 有回退，不能藏在总延迟下降中。生产 12 秒/45 秒默认策略仍保留。



5.4 固定文本暖态合成分布



5.4 RTF 实测分布

5.4 性能工程面试题与参考答案

答案以本工程实际实现为依据，实测数值见性能报告和原始 CSV。没有测到的阶段不补数。

操作 1：为什么不能使用系统时间计算请求延迟？

system_clock 对应日历时间，NTP、人工校时可能使它前跳或后退；两次相减可能失真。steady_clock 保证单调，适合持续时间。本项目在所有 C++ 阶段记录 steady 纳秒，分析时先相减再转毫秒。它没有跨主机 UTC 同步意义；Linux /proc 采样和 Python monotonic 只在资源曲线各自坐标中使用，不靠猜测把绝对 epoch 拼接。日志接收时间也不能代替模型内部事件时间。

追问：CPU frequency 变化是否改变 steady 计时口径？计时仍测实际经过时间，但频率会改变被测计算速度，因此必须同时保留频率、温度和负载。

操作 2：为什么需要 Request ID，frame_id 为什么不能代替？

异步 ASR、模型和 TTS 的日志会交错，按日志行顺序拼接容易把不同请求相加。request_id 从完整语音段开始传递，TaskOptions、回调和 SDK context 持有同一小型 trace。Camera 独立采集，一帧可被不同请求重复使用；frame_id 描述图像，不能作为请求主键。离线分析使用 case_name + request_id，因为每个进程的编号重新开始。

追问：为什么不建全局请求 map？队列和 callback 已经管理请求寿命；再建 map 会产生清理、锁竞争和无界保留风险。本轮只随现有有界任务携带 shared_ptr，完成后释放，分析表在进程外生成。

操作 3：TLS 为什么不能自动解决 SDK 回调关联？

thread_local 是每个线程独立一份，SDK 在自己的线程回调时看不到提交线程的 TLS。本项目同步业务调用用 RAII scope 设置/恢复 TLS，SDK context 则显式复制 RequestTracePtr。callback 内用该指针 mark，不假设线程身份。回调若保存主线程 scope 地址，scope 退出后就可能悬空。

追问：shared_ptr 是否让对象内容自动线程安全？不会。它保证控制块引用计数安全，RequestTrace ID 不可变，日志另有 mutex；VLM 的 text/finished/failed 仍必须用自己的 mutex。

操作 4：TTFT 应该如何定义？

需要先说明起点和终点。对 TEXT，可测 inference_begin 到首次非空文本回调；对 VISION，整个推理起点包含预处理和 RKNN，而语言 decoder_begin 是另一边界。SDK text chunk 可能包含多个 token，本项目只报告首文本 chunk 延迟，精确 token 粒度 TTFT 未测。异步 submit 返回的 0.0xms 是调度开销，不是 TTFT 或模型推理耗时。

追问：为什么不由输出字数推算 token 时间？tokenizer 切分、批次回调和调度都不确定，推算不能替代观测事件。

操作 5：TTS 首批音频就绪，是否等于用户听到声音？

不是。Kokoro callback 只说明 SDK 已生成第一批 PCM；当前代码仍等待整段合成返回，再复制、转成 S16、调用 ALSA。首次成功 writei 是首次音频提交，也受 ALSA 启动阈值和缓冲影响；drain 完成是驱动排空语义。没有设备声学时间戳或外部回录测量，不能称为实际声学延迟。用户确认“听到了”验证真实播放，但不提供毫秒级声学起点。

追问：能否直接在 callback 里异步播放 samples？不能把借用指针交给其他线程，必须复制或获得 SDK 明确的所有权契约；还需重新设计错误、排队和退出语义。本轮不为名义流式播放冒这个风险。

操作 6：如何用 RTF 公平比较 TTS？

RTF=合成墙钟时间/生成音频时长，两者使用同单位。RTF<1 才表示合成快于播放速度。必须同时固定模型、声音、语速、语言、文本和生成参数，分别报告中文/英文；不同回答长度不能直接混合。即便同文本，SDK 的随机生成可能使采样数和 PCM hash 不同，所以记录每次实际长度、RTF、peak、RMS、非有限数。不能通过缩短答案或提高语速制造同条件加速。

追问：RTF 能代表整请求延迟吗？不能。排队、ASR、NPU、复制和播放都在外；整请求需要独立阶段时间线。

操作 7：为什么线程数越多不一定越快？

线程竞争、同步、缓存、内存带宽和大小核差异都会增加成本，持续负载还可能升温降频。本轮筛查 1、2、4、6 线程，不能只挑一条最快数据；候选需足量复测，报告 CPU 占用和温度。num_threads 会进入 SDK session 配置，但进程还有主线程、Worker 和 Runtime 其他线程，配置值不等于总线程数。实际线程数和 affinity 通过 /proc/PID/task 取证。

追问：为什么不全机改 performance governor？这超出隔离目录授权，会改变测试条件和系统功耗；本轮保留 ondemand 并记录频率，不把未控制变量隐藏掉。

操作 8：如何定位 TTS 队列等待的根因？

先分别测 enqueue→dequeue、Generate、PCM copy、float→S16、write/drain。当前 TTSWorker 单线程先合成整段再完整播放，下一条等待的是前条总服务时间。应用复制只有很

小开销时，减少一次复制不可能解释秒级改善；模型合成慢才是主要瓶颈。线程配置优化减少服务时间，可能间接缩短下一条队列等待，但不会把串行队列变成并行。

追问：为何不立即再开一个合成线程？同一个 TTS 实例的并发契约未确认，多实例又增加内存和 CPU 竞争；必须先证明吞吐收益和生命周期安全。本轮保留串行语义。

操作 9：如何区分冷启动、预热和稳态？

初始化加载模型单列；每个文本 iteration0 标 first_use，iteration1 标 warmup，其后样本才进入主统计。英文 first_use 是该文本首次调用，并非整个实例第一次调用，因为中文已先运行。独立 benchmark 保持同一模型实例，避免每轮重载。真实完整入口的样本少、模型共驻且 Camera 在运行，不能与纯 TTS 进程稳态结果混为一张无条件对照表。

追问：为什么 P95 不能随便插值？可以选择插值，但必须统一说明。本项目用 nearest-rank，排序后取 ceil(0.95n)-1；n=3 的 P95 就是最大值，不能声称已精确估计长期尾延迟。

操作 10：如何证明一次优化是实际计算收益？

主 TTS 对照使用同一个直接链接冻结 5.3 TTS 库的 benchmark 二进制，仅线程参数 2/4 不同，输入和 Runtime 相同，保留全部暖态样本。这样不把新埋点或新业务代码差异归到优化。完整链路另用同一留存音频和 NV12 回放验证调度与端到端影响，并披露回放绕过麦克风/VAD。自然语音仅有限交互回归，不把用户说话时长差异解释成性能收益。

追问：先后运行还有什么偏差？热状态、DVFS 和背景负载仍可能变化；保留温度/频率/CPU，说明不是大规模随机交叉试验，不外推任意环境的固定百分比。

操作 11：取消等待与排空退出有什么不同？

排空：关闭输入，已接收任务按原 FIFO 完成；取消等待：标记 ticket，未开始的推理/TTS 以 cancelled 终态完成，不再新增下游任务；已经进入同步 SDK 的调用仍等待安全返回。两者都先让上游不再提交、唤醒等待线程、join，再 destroy Runtime。signal handler 不做锁、日志或资源释放，既有 sigwait 线程把信号转成协作状态。

追问：timeout 后 kill 是否证明退出成功？不是。守护只能对本次确认 exe/start-token 的 PID 发送最终强杀，必须标 forced_kill=true 和退出失败。成功要求未强杀、正常退出码、完整 shutdown 标记、设备重新可用。

操作 12：长回放等待为什么会破坏信号回归？

原 sleep_until 可能一直等未来输入，即使信号线程已经置位，main 也不能及时进入关闭流程。候选按不超过约 20ms 的片段检查 StopSignals，同时保持原定提交时刻。需要测试一个 100 秒后的未来输入，在前一个请求运行时发信号，确认不是恰好回放已经结束才退出。这项改动只影响显式诊断回放，不重构生产 Worker。

追问：频繁 sleep_for 会不会忙轮询？它会主动休眠，不忙占 CPU；20ms 带来有限调度误差，所以排队输入实际 enqueue 时点仍由 steady 记录，不能用计划偏移替代真实提交时间。

操作 13：为什么不能把 NPU sysfs 的 load 直接当利用率？

本板在无模型进程和 CPU-only TTS 时也读到固定 `100@950000000Hz`。它的有效语义未验证，只能保留原字符串和频率。没有可信利用率、带宽或功耗工具时应填未测量；RKNN run 区间、RKLLM 日志和成功结果仍能证明实际调用，但不能反推出硬件利用率百分比。

追问：CPU 使用率为何可能超过 100%？本项目用单核为 100%的进程口径，多核同时运行可以超过 100%；不能与整机归一化 0～100%的 top 模式混用。

操作 14：怎样评估资源泄漏与测试覆盖的限度？

观察 RSS、VmHWM、线程数、fd、设备 fuser、队列终态和 shutdown 顺序，结合 Fake 的停止/重启、weak_ptr 和异常测试。峰值内存高不等于泄漏；Allocator 缓存也可能保留 RSS。有限实机运行后所有进程结束、设备释放只能证明这组场景没有明显残留，不能替代长稳态压力测试或 sanitizer 对所有 SDK 内部路径的证明。

追问：为什么保留失败实验？错误和回退能说明候选选择依据，也防止把慢配置、小样本或工具失败从证据中删掉。原始日志只追加新 case，不覆盖已验收版本。

7 第五阶段 5.5 Qt 和持续稳定性

5.5 的真实问题、热条件、失败记录、所有版本与验收边界以本节报告为准。下面引用的工作记录在正式生成时与最终数据同步；不把较早热对照源码冒充最后 GUI/结构化文本修复的精确版本。

5.5 Qt 集成与最终系统工程验收报告

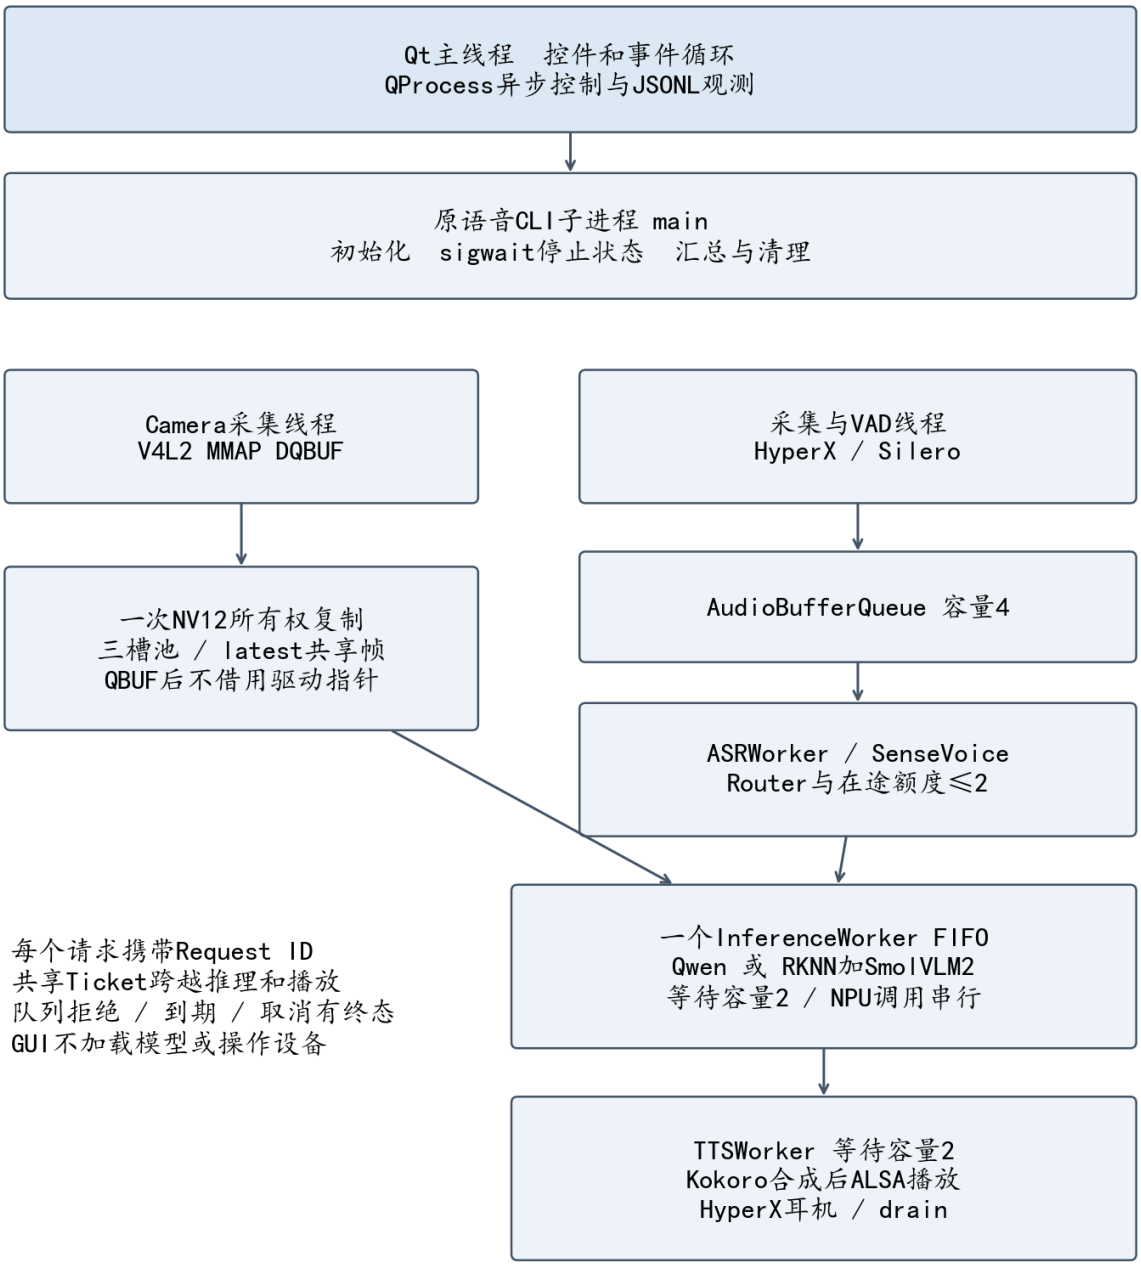
本报告记录 2026 年 10 月 17 日至 18 日香港时间在同一台 RK3576 隔离工程的真实开发与验证。5.1～5.4 已经用户验收；本节工程检查结果以 validation_summary.json 为准，最终用户审核仍待确认。没有将隔离版本覆盖为原稳定工程。有限长测只支持记录工况内结论。

1 继承版本与实际改动

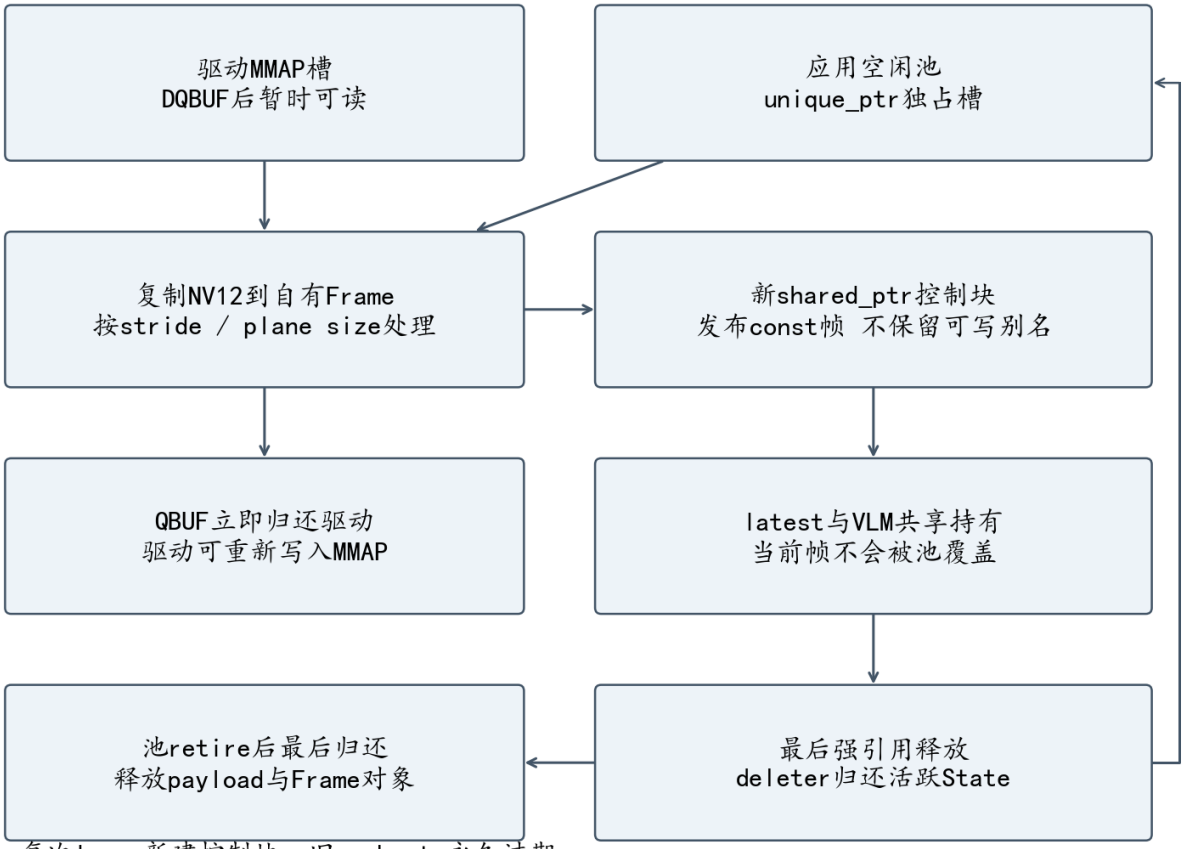
先以 SHA256 核对 5.4 最终 v3 的 96 项源码，再冻结 171 项源码、工具、测试、配置与文档至 backups/stage5_05_before。原稳定目录 321 项、5.1～5.4 四个已验收程序和 5.4 源码分别留存清单。最终生产源码 104 项位于 stage5_05_source_final_v2，构建为 build/stage5_05_final_v2。较早 stage5_05_source_thermal 仅放宽原 CLI 记录秒数及回放偏移上限，用于同版本 2/4 线程热对照；不能拿它冒充最后 Qt 与结构化日志版本。final_v1、qt_v1 是未部署的本地中间快照。

最小改动：CMake 增加默认关闭的 BUILD_QT_GUI；StopSignals 类正文从 CLI 原样移到共用头文件；CLI 监听上限 120→3600 秒、回放偏移上限 120000→3600000ms，默认 12 秒和 20ms 信号轮询不变；复用 ImageProfile 的 steady_clock、mutex 和 JSONL 新增完整识别/回答字符串事件。5.3 池、图像预处理、RKNN/RKLLM 后端、TTS 合成与播放算法及 5.2 队列保持字节不变，未更换模型或生成参数。

实际语音入口 VADAudioWorker→音频段队列→ASRWorker→IntentRouter→额度管理→单消费者 InferenceWorker→Qwen 或 Camera/RKNN/SmolVLM2→TTSWorker/Kokoro/ALSA，没有经过另一个 CLI 入口的 RequestProcessor。Qt 通过 QProcess 复用完整入口，后台原线程运行模型与设备；Qt 主线程只处理事件、有限日志和控件，不进行 SDK 加载、推理或等待音频。


Qt主线程 控件和事件循环
QProcess异步控制与JSONL观测
原语音CLI子进程 main
初始化 sigwait停止状态 汇总与清理
Camera采集线程
V4L2 MMAP DQBUF
采集与VAD线程
HyperX / Silero
一次NV12所有权复制
三槽池 / latest共享帧
QBUF后不借用驱动指针
AudioBufferQueue 容量4
ASRWorker / SenseVoice
Router与在途额度≤2
每个请求携带Request ID
共享Ticket跨越推理和播放
队列拒绝 / 到期 / 取消有终态
GUI不加载模型或操作设备
一个InferenceWorker FIFO
Qwen 或 RKNN加SmolVLM2
等待容量2 / NPU调用串行
TTSWorker 等待容量2
Kokoro合成后ALSA播放
HyperX耳机 / drain

最终线程架构



每次lease新建控制块，旧weak_ptr永久过期。
RGB与Embedding按需复用；保留显式复制，不是零拷贝。

Camera Buffer 生命周期



退出与销毁顺序

2 Qt 运行环境与实际验收

板端已有 Qt5.15.8 Widgets/Test、头文件、平台插件和 GNOME/X11 DISPLAY :0；DSI 已连接。本节没有安装系统软件、迁移车载工程、修改显示或权限配置。实际运行采用 xcb 与现有 cat 认证。QWidget::grab 截取本次真实窗口，未生成模拟截图。启动时 libGL 报告 rockchip DRI 加载失败，但普通 Widgets 页面正常显示；这不能视为硬件 OpenGL 渲染已验证。Kokoro 已有未知 token/phoneme 警告如实保留，不等于本节新引入崩溃。

GUI 显示五模块、识别、TEXT/VISION、完整回答、阶段、队列事件快照、错误、ASR/推理/TTS/首次提交延迟。选项支持 2/4 线程及排空/取消等待。活动时禁止更改配置，关闭事件先 ignore→SIGINT→等待 QProcess finished→关闭窗口；90 秒未退出报告失败，不把强杀算作成功。信号在 QApplication 及 SDK 线程创建前阻塞，由普通 sigwait 线程接收；没有异步 handler 调用

Qt 或锁。QProcess 连接带 QObject context，正常窗口关闭先等待后台，避免回调触达已销毁对象。重新开始是新进程和新 UUID 目录，并非宣称闭源 SDK 实例内重启。

实际 case gui_microphone_final_v2：退出码 0，持续 79.496 秒，所有会话有序退出=True，强制终止=False，设备释放=True。原始记录：Z:/master_T/Linux/资料/code/rk3576_multimodal_stage5_source/rk3576_multimodal/reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/gui_microphone_final_v2/result.json。

实际 case gui_paired_restart_final_v2：退出码 0，持续 102.267 秒，所有会话有序退出=True，强制终止=False，设备释放=True。原始记录：Z:/master_T/Linux/资料/code/rk3576_multimodal_stage5_source/rk3576_multimodal/reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/gui_paired_restart_final_v2/result.json。

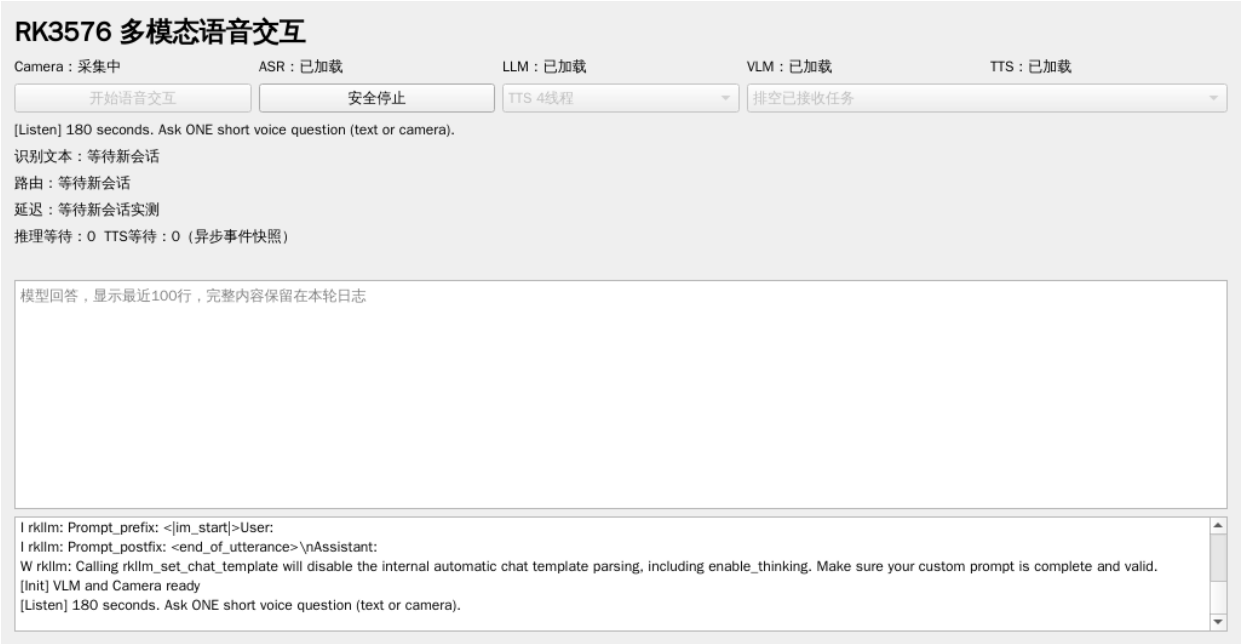
实际 case gui_sigterm_vision_final_v2：退出码 0，持续 53.127 秒，所有会话有序退出=True，强制终止=False，设备释放=True。原始记录：Z:/master_T/Linux/资料/code/rk3576_multimodal_stage5_source/rk3576_multimodal/reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/gui_sigterm_vision_final_v2/result.json。

实际 case gui_mixed_1800s_4t_final_v2：退出码 0，持续 1837.782 秒，所有会话有序退出=True，强制终止=False，设备释放=True。原始记录：Z:/master_T/Linux/资料/code/rk3576_multimodal_stage5_source/rk3576_multimodal/reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/gui_mixed_1800s_4t_final_v2/result.json。

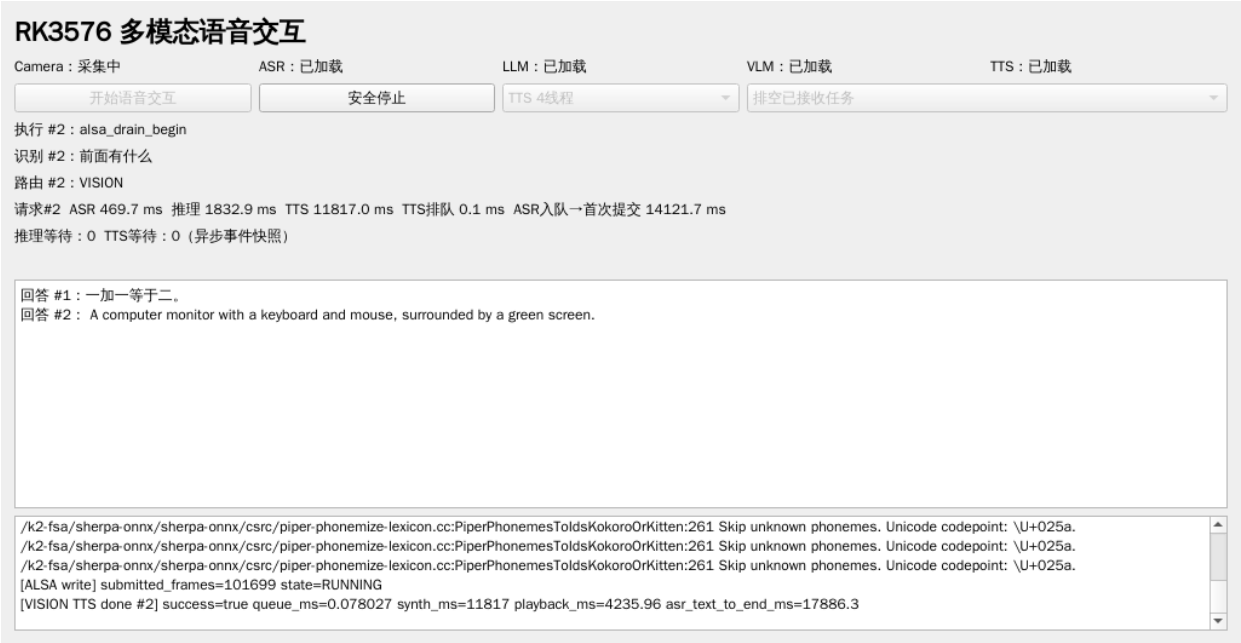
最终进程	CPU 平均/P95 %（80s 后）	RSS 峰值 MiB	VmHWM 观测峰值 MiB	线程峰值	温度峰值℃
Qt 父进程	1.44/8.89	89.059	89.059	4	85.888
后台 AI	280.23/423.24	2715.125	2715.324	13	85.0

本次人工确认原文：“是的，和你描述的一样”。针对该轮明确问题，已记录两个回答均通过 HyperX 实际听到、视觉描述大致相符、Qt 显示识别文本/路由/回答。不能将程序

success=true 替代这份确认。自然语音仅 TEXT/VISION 各 1 条，不能据此推导大样本音质或识别率。



本次真实 xcb 界面进入监听



本次真实视觉回答和延迟



本次有序停止后的真实界面

3 ARM64 构建和确定性测试

build_thermal：成功=True，去重目标 30 个；各步骤真实记录：[{"step": "configure", "returncode": 0, "reason": null, "seconds": 3.0020763280008396}, {"step": "build", "returncode": 0, "reason": null, "seconds": 121.05928409899934}, {"step": "ctest", "returncode": 0, "reason": null, "seconds": 2.0026842519982893}]。

build_final_v2：成功=True，去重目标 36 个；各步骤真实记录：[{"step": "configure", "returncode": 0, "reason": null, "seconds": 3.0020454799996514}, {"step": "build", "returncode": 0, "reason": null, "seconds": 156.08595781799886}, {"step": "ctest", "returncode": 0, "reason": null, "seconds": 7.0067366089970164}]。

注册测试	具体验证	实际 SDK 边界
request_profile_tests	固定音频输入与请求计时、UTF8/控制字符转义、并发完整文本事件	无模型
image_pipeline_tests	stride、池复用、weak_ptr 生命周期、缓存 RGB 与像素一致	CPU/Fake 帧
async_pipeline_tests	连续/交替、满载、取消、过期、	Fake Backend/Service

注册测试	具体验证	实际 SDK 边界
	停止重启、推理和 TTS/播放异常后恢复	
asr_pipeline_tests	空队列停止唤醒、ASR 异常与回调异常、队列终态	Fake ASR
audio_preprocessor_tests	音频转换与边界	CPU
llm_worker_tests	生命周期、停止/重启、异常和回调	Fake LLM
camera_service_tests	打开失败、超时、异常、停止、重启和帧所有权	Fake Camera
gui_session_tests	主线程心跳、显示、无覆盖启动、错误恢复、停止/重启、活跃窗口关闭、关闭优先于自动重启	offscreen Qt 与明确 Fake 子进程

最终 ARM64 CTest 的 8 项通过与 Windows portable 9 项分别保存；它们是确定性逻辑测试，真实 SDK 和硬件回归另列。编译残留未使用函数、测试缩进和 RGA SDK 匿名 struct 警告保留，不能改写成零警告。

4 热测试条件与安全边界

同板、同模型/Runtime、相同真实语音段和固定 NV12、相同推理参数，2/4 线程依次 180 秒短测、1800 秒混合输入长测。所有读到的 zone 低于 55℃才开始，最长冷却 600 秒；保持 ondemand、不改 CPU 频率、亲和性或风扇。长测每 15 秒一个输入，TEXT/TEXT/VISION/VISION/TEXT/VISION 循环，共 121 条；生产 TTS 等待 12 秒、请求期限 45 秒，排队满载明确拒绝。固定音频绕过麦克风/VAD，Camera 真实持续采集，但 Vision 读取同一固定帧，因此固定场景 Frame Age 未测量。

实际 thermal_zone2 little passive 为 75℃/85℃，critical 为 115℃。这些是 Linux 当前配置，不是芯片额定安全温度证明。测试护栏为任一温度≥90℃、温度不可读、MemAvailable<256MiB

或磁盘<500MiB 立即向确认 PID 发 SIGTERM；有限宽限后若仍卡住，只能强制终止本次确认 PID 并记失败。实际没有修改 thermal/sysfs 配置。采样每秒，smaps 约每 5 次；CPU 按一核 100%，HZ 来自本板 sysconf。

真实 case	进程秒数	输入/完成	峰值温度℃
mixed_180s_2t	221.527	10/10	75.769
mixed_180s_4t	218.625	10/10	84.076
mixed_1800s_2t	1839.890	121/121	86.777
mixed_1800s_4t	1833.324	121/121	85.888
同一 case 资源	峰值 RSS MiB	CPU 均值/P95 %（80s 后）	峰值线程
mixed_180s_2t	2718.359	151.18/220.77	11
mixed_180s_4t	2647.305	210.63/422.44	13
mixed_1800s_2t	2647.316	193.23/310.17	11
mixed_1800s_4t	2711.289	280.74/423.20	13

2/4 线程长测 TSV 的 SHA 均为 `5e9f356f3647cdcdbbb31117e0a312f65bee2f9abe58d43e4bf570dd932585b7`，121 行。两轮每条成功完成，失败/超时/拒绝/丢弃均为 0，队列峰值 1、在途峰值 2，Camera 均 29.997FPS。原始队列计数、资源样本及统计口径在 CSV/JSON。2 线程最高 86.777℃，4 线程 85.888℃；此节奏混合负载不能据此推论 4 线程总是更凉。5.4 连续独立合成中 4 线程更热，两类负载占空比与 DVFS 不同。

5 热对照的暖态延迟分布

请求暖态边界从首个 asr_enqueued 起算 5 分钟，RSS 趋势则从进程首次资源采样起算，二者不混用。每轮前 5 分钟请求单列，以下仅 warm_after_5min：TEXT n50、VISION n51。时间单位 ms，格式为均值/P50/P95/最小/最大(n)。合成输出长度可能略变，额外按每条实际 PCM 长

度计算 RTF；不混合中英文回答直接算模型加速。首次提交是 ALSA write 调用边界，drain 是软件排空，均非直接声学测量。

TEXT 同输入路线对照

指标	2 线程	4 线程
asr_rtf	0.446/0.468/0.473/0.365/0.478 (n=50)	0.370/0.370/0.373/0.365/0.376 (n=50)
asr_decode_ms	696.501/733.803/741.115/567.763/748.935 (n=50)	568.772/568.446/570.763/566.119/577.503 (n=50)
asr_api_ms	703.403/739.109/746.828/575.254/754.578 (n=50)	583.846/583.599/588.056/575.318/593.311 (n=50)
inference_queue_ms	0.054/0.044/0.098/0.027/0.105 (n=50)	0.057/0.046/0.091/0.025/0.119 (n=50)
inference_service_ms	961.287/939.296/1158.782/842.889/1241.240 (n=50)	859.151/857.444/881.882/819.899/981.546 (n=50)
tts_queue_ms	3552.556/4501.187/5649.373/31.550/5738.318 (n=50)	45.451/0.255/201.833/0.068/279.053 (n=50)
tts_generate_api_ms	8960.022/8889.523/9351.944/8721.889/9597.135 (n=50)	6978.146/7031.840/7109.401/6747.804/7128.426 (n=50)
tts_rtf	4.587/4.550/4.800/4.460/4.906 (n=50)	3.571/3.596/3.644/3.455/3.652 (n=50)
synthesis_to_first_submit_ms	8960.655/8890.432/9352.623/8722.441/9598.121 (n=50)	6978.775/7032.429/7110.004/6748.446/7129.028 (n=50)
asr_enqueue_to_first_submit_ms	14178.500/15204.241/16710.412/10204.839/16832.826 (n=50)	8468.012/8481.115/8733.416/8181.179/8819.027 (n=50)
asr_enqueue_to_playback_end_ms	16163.164/17189.055/18695.093/12189.038/18817.730	10452.713/10466.217/10718.062/10165.500/10803.763

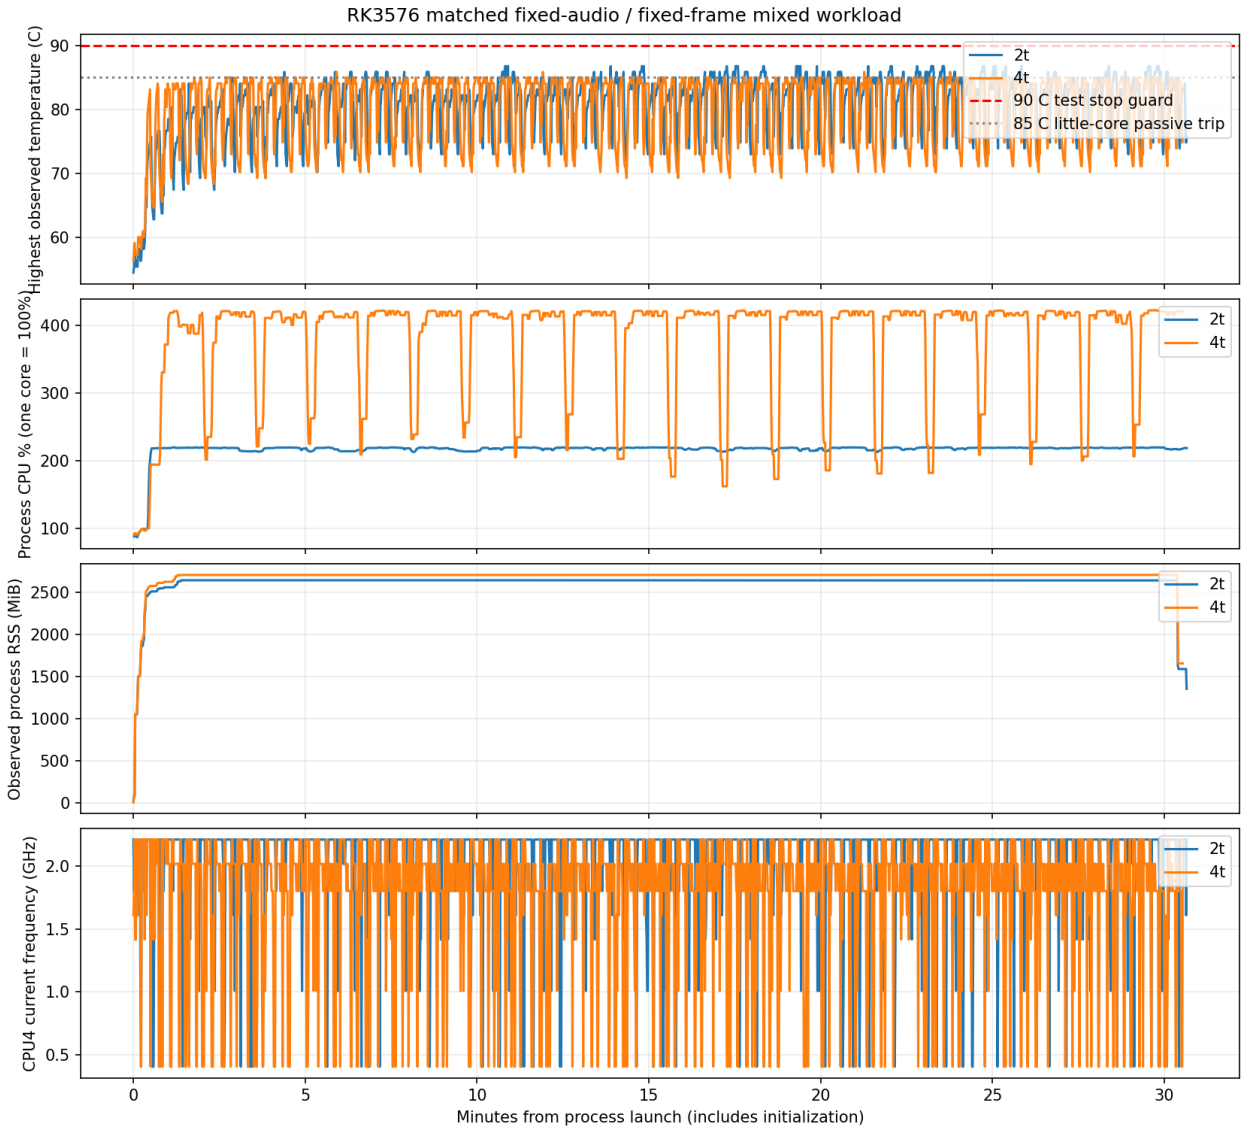
指标	2 线程	4 线程
	(n=50)	(n=50)

VISION 同输入路线对照

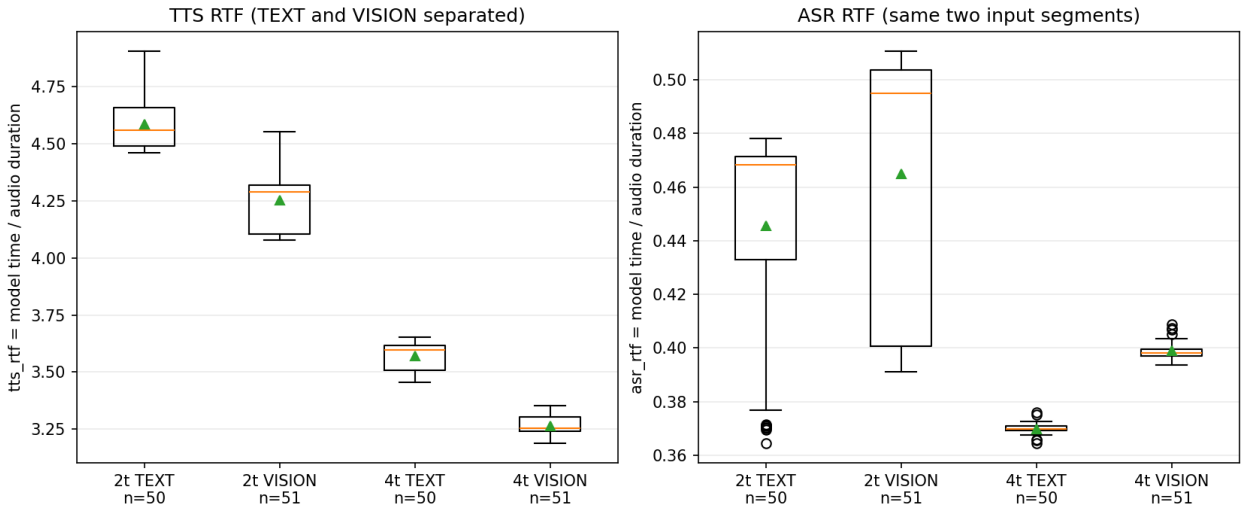
指标	2 线程	4 线程
asr_rtf	0.465/0.495/0.510/0.391/0.511 (n=51)	0.399/0.398/0.407/0.394/0.409 (n=51)
asr_decode_ms	621.921/665.597/685.351/520.897/686.872 (n=51)	525.840/524.469/539.727/522.468/543.218 (n=51)
asr_api_ms	629.708/670.321/690.023/529.719/691.574 (n=51)	540.166/539.342/550.928/533.034/553.677 (n=51)
inference_queue_ms	0.053/0.045/0.090/0.031/0.094 (n=51)	0.068/0.079/0.098/0.028/0.110 (n=51)
inference_service_ms	1531.360/1525.825/1593.761/1485.090/1638.762 (n=51)	1512.997/1509.831/1540.678/1484.732/1546.813 (n=51)
tts_queue_ms	1026.583/1011.173/2212.289/0.023/2247.175 (n=51)	0.046/0.033/0.079/0.024/0.116 (n=51)
tts_generate_api_ms	14310.385/14434.488/14861.235/13718.288/15315.634 (n=51)	10987.520/10955.498/11215.317/10727.668/11281.751 (n=51)
tts_rtf	4.253/4.290/4.417/4.077/4.552 (n=51)	3.266/3.255/3.333/3.188/3.353 (n=51)
synthesis_to_first_submit_ms	14311.316/14435.358/14862.307/13719.105/15316.674 (n=51)	10988.514/10956.430/11216.311/10728.574/11282.700 (n=51)
asr_enqueue_to_first_submit_ms	17499.590/17803.004/19063.752/15779.523/19368.789	13042.522/13010.222/13283.013/12777.380/13362.490

指标	2 线程	4 线程
	(n=51)	(n=51)
asr_enqueue_to_playback_end_ms	20864.221/21174.492/22423.408/19138.686/22728.259 (n=51)	16404.723/16369.595/16642.841/16136.804/16721.965 (n=51)

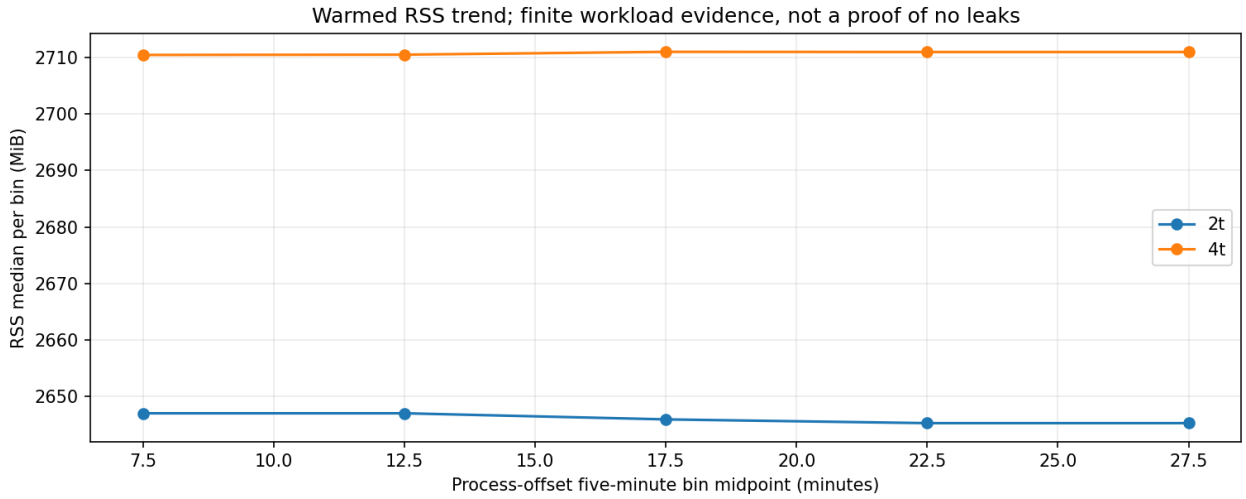
4 线程在本次混合工况下 ASR 没有出现饥饿：TEXT 平均 ASR RTF 约 0.446→0.370，VISION 约 0.465→0.399。模型计算、调度、温度和输入节奏共同作用，不能从这些非随机交叉的整系统数据归因每个子系统必然加速。两边都是每 15 秒到达，30 分钟总体完成数相同，不宣称吞吐提升 30%。TTS 纯同条件计算收益仍引用 5.4 固定文本各语言 n30 的 30.42%/29.74%，不篡改比较条件。



实际热与 CPU 及频率时间序列



暖态请求 RTF 分布



预热后的 RSS 分段变化

6 RSS 趋势与 Linux 降频证据

`mixed_1800s_2t`：5～30 分钟 RSS 斜率-0.110404 MiB/min，5～10 分钟中位数 2647.047 MiB，25～30 分钟中位数 2645.305 MiB。排除初次模型页驻留与退出下降，不用开始/结束两个点证明无泄漏。

cooling 设备或频率	实际读数
/sys/class/thermal/cooling_device1/cur_state	最大 state=2，positive=86/1788
/sys/class/thermal/cooling_device4/cur_state	最大 state=0，positive=0/1788
/sys/class/thermal/cooling_device2/cur_state	最大 state=6，positive=922/1788
/sys/class/thermal/cooling_device0/cur_state	最大 state=8，positive=161/1788
/sys/class/thermal/cooling_device3/cur_state	最大 state=0，positive=0/1788
/sys/devices/system/cpu/cpu4/cpufreq/scaling_max_freq	min=1800000，max=2208000 kHz
/sys/devices/system/cpu/cpu0/cpufreq/scaling_max_freq	min=408000，max=2016000 kHz

`mixed_1800s_4t`：5～30 分钟 RSS 斜率 0.026513 MiB/min，5～10 分钟中位数 2710.434 MiB，25～30 分钟中位数 2710.949 MiB。排除初次模型页驻留与退出下降，不用开始/结束两个点证明无泄漏。

cooling 设备或频率	实际读数
/sys/class/thermal/cooling_device1/cur_state	最大 state=2，positive=959/1771
/sys/class/thermal/cooling_device4/cur_state	最大 state=0，positive=0/1771
/sys/class/thermal/cooling_device2/cur_state	最大 state=6，positive=978/1771
/sys/class/thermal/cooling_device0/cur_state	最大 state=8，positive=961/1771
/sys/class/thermal/cooling_device3/cur_state	最大 state=0，positive=0/1771
/sys/devices/system/cpu/cpu4/cpufreq/scaling_max_freq	min=1800000，max=2208000 kHz
/sys/devices/system/cpu/cpu0/cpufreq/scaling_max_freq	min=408000，max=2016000 kHz

cooling_device0/1 对应 cpufreq-cpu0/cpu4，2 对应 devfreq GPU，3 为 devfreq-dmc，4 为 devfreq NPU，以实际 inventory type 为准。CPU cooling 为正并伴随 scaling_max_freq 收紧，支持发生 Linux 热管理限频；仅 ondemand 的 scaling_cur_freq 变化不能单独证明热降频。GPU cooling 为正不能冒充 CPU 降频。本轮有热管理活动，但未出现 90℃护栏、崩溃、明显 ASR 饥饿或持续 RSS 增长，默认保留 4 线程，2 线程可回退。这个选择仅适用于现有散热与记录负载，更高占空比应再测。

4 线程较早加载后的 RSS 增加不直接判为泄漏。中段与末段真实 smaps 映射比较：DRI RSS 1,369,584kB、heap 903,064kB、匿名映射 424,592kB、video11 48,608kB 保持一致，小量变化集中于文件映射页；暖态中位数仅约 0.516MiB 变化，未见该窗口持续堆/匿名增长。4 线程比 2 线程峰值约多 64MiB。没有 LeakSanitizer/闭源 SDK 泄漏证明，不能写“系统绝无内存泄漏”。

7 最终源码性能与自然输入复核

gui_microphone_final_v2/run_20261017_165440_871_7225107cc44646f68a19282099119fd5

实际最终计数：{"ALSA": {"XRUN": 0, "Suspends": 0, "Recoveries": 0, "RecoveryFailures": 0}, "FramePool": {"allocated": 3, "in_use": 0, "acquired": 1689, "reused": 1686, "exhausted": 0}, "CameraCounters": {"published": 1688, "fps": 29.9073, "timeouts": 0, "driver_sequence_gaps": 0, "pool_discarded": 0}, "AudioQueueStats": {"pushed": 2, "popped": 2, "dropped": 0, "rejected_closed": 0, "peak": 1, "pending": 0}, "QueueStats/inference": {"stage": "inference", "generation": 1, "accepted": 2, "completed": 2, "started": 2, "failed": 0, "cancelled": 0, "expired": 0, "rejected_full": 0, "rejected_stopped": 0, "peak": 1, "pending": 0, "active": 0, "callback_errors": 0, "queue_sum_ms": 0.166924, "queue_max_ms": 0.103264, "service_sum_ms": 2998.84}, "QueueStats/tts": {"stage": "tts", "generation": 1, "accepted": 2, "completed": 2, "started": 2, "failed": 0, "cancelled": 0, "expired": 0, "rejected_full": 0, "rejected_stopped": 0, "peak": 1, "pending": 0, "active": 0, "callback_errors": 0, "queue_sum_ms": 0.17605, "queue_max_ms": 0.098023, "service_sum_ms": 24328.9}, "PipelineStats": {"dispatched": 2, "accepted": 2, "rejected": 0, "inflight": 0, "peak": 1, "limit": 2, "vision_accepted": 1, "vision_rejected": 0, "llm_cancelled": 0, "llm_expired": 0, "vision_cancelled": 0, "vision_expired": 0, "cancelled_before_submit": 0, "downstream_cancelled": 0, "tts_cancelled": 0, "tts_expired": 0}}。

指标	真实统计
TEXT/all_observed/success asr_rtf	0.420/0.420/0.420/0.420/0.420 (n=1)
TEXT/all_observed/success inference_service_ms	1165.693/1165.693/1165.693/1165.693/1165.693 (n=1)
TEXT/all_observed/success tts_generate_api_ms	6290.531/6290.531/6290.531/6290.531/6290.531 (n=1)
TEXT/all_observed/success tts_rtf	3.232/3.232/3.232/3.232/3.232 (n=1)
TEXT/all_observed/success tts_queue_ms	0.098/0.098/0.098/0.098/0.098 (n=1)
TEXT/all_observed/success asr_enqueue_to_first_submit_ms	8027.404/8027.404/8027.404/8027.404/8027.404 (n=1)
TEXT/all_observed/success	10011.762/10011.762/10011.762/10011.762/10

指标	真实统计
asr_enqueue_to_playback_end_ms	011.762 (n=1)
VISION/all_observed/success frame_age_ms	34.146/34.146/34.146/34.146/34.146 (n=1)
VISION/all_observed/success asr_rtf	0.416/0.416/0.416/0.416/0.416 (n=1)
VISION/all_observed/success inference_service_ms	1832.893/1832.893/1832.893/1832.893/1832.893 (n=1)
VISION/all_observed/success tts_generate_api_ms	11817.045/11817.045/11817.045/11817.045/11817.045 (n=1)
VISION/all_observed/success tts_rtf	2.789/2.789/2.789/2.789/2.789 (n=1)
VISION/all_observed/success tts_queue_ms	0.078/0.078/0.078/0.078/0.078 (n=1)
VISION/all_observed/success asr_enqueue_to_first_submit_ms	14121.722/14121.722/14121.722/14121.722/14121.722 (n=1)
VISION/all_observed/success asr_enqueue_to_playback_end_ms	18356.414/18356.414/18356.414/18356.414/18356.414 (n=1)
latest_get	0.001/0.001/0.001/0.001/0.001 (n=1)
preprocess_fused	8.695/8.695/8.695/8.695/8.695 (n=1)
rknn_input_descriptor	0.000/0.000/0.000/0.000/0.000 (n=1)
rknn_inputs_set	17.151/17.151/17.151/17.151/17.151 (n=1)
rknn_run	1184.460/1184.460/1184.460/1184.460/1184.460 (n=1)
rknn_outputs_get	1.283/1.283/1.283/1.283/1.283 (n=1)
embedding_alloc_copy	0.176/0.176/0.176/0.176/0.176 (n=1)
rknn_outputs_release	0.006/0.006/0.006/0.006/0.006 (n=1)

gui_mixed_1800s_4t_final_v2/run_20261017_165918_816_a1845db32d1644028f53ab0f0eb2d172

实际最终计数：{"FramePool": {"allocated": 2, "in_use": 0, "acquired": 54398, "reused": 54396, "exhausted": 0}, "CameraCounters": {"published": 54397, "fps": 29.9952, "timeouts": 0, "driver_sequence_gaps": 1, "pool_discarded": 0}, "AudioQueueStats": {"pushed": 121, "popped": 121, "dropped": 0, "rejected_closed": 0, "peak": 1, "pending": 0}, "QueueStats/inference": {"stage": "inference", "generation": 1, "accepted": 121, "completed": 121, "started": 121, "failed": 0, "cancelled": 0, "expired": 0, "rejected_full": 0, "rejected_stopped": 0, "peak": 1, "pending": 0, "active": 0, "callback_errors": 0, "queue_sum_ms": 10.3541, "queue_max_ms": 1.62733, "service_sum_ms": 144120}, "QueueStats/tts": {"stage": "tts", "generation": 1, "accepted": 121, "completed": 121, "started": 121, "failed": 0, "cancelled": 0, "expired": 0, "rejected_full": 0, "rejected_stopped": 0, "peak": 1, "pending": 0, "active": 0, "callback_errors": 0, "queue_sum_ms": 5207.94, "queue_max_ms": 352.063, "service_sum_ms": 1412040.0}, "PipelineStats": {"dispatched": 121, "accepted": 121, "rejected": 0, "inflight": 0, "peak": 2, "limit": 2, "vision_accepted": 60, "vision_rejected": 0, "llm_cancelled": 0, "llm_expired": 0, "vision_cancelled": 0, "vision_expired": 0, "cancelled_before_submit": 0, "downstream_cancelled": 0, "tts_cancelled": 0, "tts_expired": 0}}。

指标	真实统计
TEXT/initial_5min/success asr_rtf	0.371/0.369/0.386/0.367/0.386 (n=11)
TEXT/initial_5min/success inference_service_ms	887.970/869.762/1139.843/824.914/1139.843 (n=11)
TEXT/initial_5min/success tts_generate_api_ms	6656.969/6701.316/6910.119/6281.554/6910.119 (n=11)
TEXT/initial_5min/success tts_rtf	3.406/3.441/3.535/3.213/3.535 (n=11)
TEXT/initial_5min/success tts_queue_ms	0.231/0.127/1.172/0.061/1.172 (n=11)
TEXT/initial_5min/success asr_enqueue_to_first_submit_ms	8132.759/8144.167/8365.260/7766.734/8365.260 (n=11)
TEXT/initial_5min/success asr_enqueue_to_playback_end_ms	10117.413/10128.731/10349.876/9751.509/10349.876 (n=11)
VISION/initial_5min/success asr_rtf	0.398/0.398/0.402/0.395/0.402 (n=9)
VISION/initial_5min/success	1555.750/1530.691/1754.321/1483.225/1754.3

指标	真实统计
inference_service_ms	21 (n=9)
VISION/initial_5min/success tts_generate_api_ms	10591.360/10579.876/10827.245/10182.274/10827.245 (n=9)
VISION/initial_5min/success tts_rtf	3.148/3.144/3.218/3.025/3.218 (n=9)
VISION/initial_5min/success tts_queue_ms	0.041/0.035/0.085/0.023/0.085 (n=9)
VISION/initial_5min/success asr_enqueue_to_first_submit_ms	12687.884/12643.812/12916.998/12480.087/12916.998 (n=9)
VISION/initial_5min/success asr_enqueue_to_playback_end_ms	16047.637/16004.367/16277.438/15839.690/16277.438 (n=9)
VISION/warm_after_5min/success asr_rtf	0.397/0.397/0.404/0.391/0.406 (n=51)
VISION/warm_after_5min/success inference_service_ms	1514.684/1514.735/1547.570/1474.182/1564.324 (n=51)
VISION/warm_after_5min/success tts_generate_api_ms	11115.807/11096.835/11334.229/10754.742/11392.743 (n=51)
VISION/warm_after_5min/success tts_rtf	3.304/3.300/3.371/3.196/3.388 (n=51)
VISION/warm_after_5min/success tts_queue_ms	0.061/0.070/0.092/0.024/0.107 (n=51)
VISION/warm_after_5min/success asr_enqueue_to_first_submit_ms	13170.243/13150.932/13382.171/12812.704/13421.172 (n=51)
VISION/warm_after_5min/success asr_enqueue_to_playback_end_ms	16532.403/16510.774/16742.080/16172.781/16780.728 (n=51)
TEXT/warm_after_5min/success asr_rtf	0.370/0.370/0.372/0.364/0.377 (n=50)
TEXT/warm_after_5min/success inference_service_ms	861.943/856.393/893.807/826.657/1005.577 (n=50)
TEXT/warm_after_5min/success tts_generate_api_ms	7073.613/7126.916/7199.977/6831.765/7311.876 (n=50)

指标	真实统计
TEXT/warm_after_5min/success tts_rtf	3.620/3.644/3.682/3.489/3.740 (n=50)
TEXT/warm_after_5min/success tts_queue_ms	104.038/58.049/304.655/0.042/352.063 (n=50)
TEXT/warm_after_5min/success asr_enqueue_to_first_submit_ms	8624.309/8636.503/8940.160/8259.332/8970.232 (n=50)
TEXT/warm_after_5min/success asr_enqueue_to_playback_end_ms	10608.991/10621.673/10924.451/10243.597/10955.437 (n=50)
preprocess_fused	7.734/7.698/7.972/7.629/8.246 (n=60)
rknn_input_descriptor	0.000/0.000/0.000/0.000/0.001 (n=60)
rknn_inputs_set	10.291/10.214/10.260/10.168/14.769 (n=60)
rknn_run	1171.226/1169.580/1180.930/1165.410/1184.310 (n=60)
rknn_outputs_get	0.759/0.794/0.913/0.168/1.335 (n=60)
embedding_alloc_copy	0.108/0.107/0.138/0.031/0.473 (n=60)
rknn_outputs_release	0.003/0.003/0.005/0.001/0.010 (n=60)

后台 CPU/RSS/线程/温度完整统计记录在 analysis/performance.json 和 stability_resources.csv，GUI 父进程另有资源样本，不能只报 GUI 几十 MiB 来冒充整机占用。

Camera 序号缺口复核

最终 Qt 长测 Camera 发布 54397 帧，29.9952FPS，记录 1 次 driver_sequence_gaps，pool_discarded=0、timeout=0，不能称零丢帧。源码 video_capture.cpp 在 DQBUF 成功后比较驱动 sequence 差值，大于 1 才计缺口；pool 满时的显式 discard 另外计数，重启时 have_sequence 重置。现有代码没有记录每次缺口的发生时间，因此无法从总计数定位唯一时刻，更不能编造 CPU 饥饿或硬件故障根因。

追加使用最终已有 stage5_03_memory_probe，不改生产源码、内核或设备配置，64 次真实最新 Camera/VLM 调用全部成功，持续 112.841 秒，3337 帧 29.9528FPS，驱动序号缺口 0、

pool 满丢弃 0、timeout0。较早长测 1 次缺口保留为未确定具体原因的非致命风险，不把未复现写成已修复；功能闭环成功不等于严格零丢帧。

64 次真实最新帧指标	均值/P50/P95/最小/最大(n) ms
frame_age_ms	24.797/26.313/39.243/7.905/42.910 (n=64)
get_latest_wall_ms	0.001/0.001/0.001/0.001/0.002 (n=64)
vlm_ms	1705.083/1691.650/1838.400/1633.260/1901.170 (n=64)

该复核只测真实 Camera 与 VLM，不包含 ASR/Qwen/TTS，也没有每帧语义人工标注。内核日志完整保留于 camera_gap_recheck 与 protection_final_after_camera，未发现该窗口新增 OOM、segfault、RKNPU 失败等匹配项；Camera 具体单帧缺口仍未归因。

ASR 打印 RTF 按 ASRService 内部创建 stream 至结果文本复制后的 latency_ms 除以 16kHz 语音时长计算，结束点在 unique_ptr 清理前；asr_begin→asr_end 是外层 recognize 调用墙钟，包含返回前 Result/Stream 清理，因此两者不应强行相等。纯 Decode 区间另列 asr_decode_ms，不把整个 API 耗时冒充单个 NPU 或 CPU 算子。自然麦克风的 VAD 语音起/止是主机估计，不是 ADC 硬件时间戳；完整阶段见 requests.csv。固定输入没有 VAD 事件时保持空。真实声学输出延迟、精确单 token TTFT、可信 NPU 利用率/带宽/功耗仍未测量。RKNN run 与整体 VLM 时长分列，首次文本 chunk 不能改称精确首 token。

8 退出背压异常及设备释放

实际 case	退出码	信号到退出秒数	终态与清理
final_burst_audio	None	None	devices=None forced=None；{}
final_burst_audio_retry1	0	0.9888364610014833	devices=True forced=False；{"dispatched": 4, "accepted": 2, "rejected": 2, "inflight": 0,

实际 case	退出码	信号到退出秒数	终态与清理
			"peak": 2, "limit": 2, "vision_accepted": 1, "vision_rejected": 0, "llm_cancelled": 0, "llm_expired": 0, "vision_cancelled": 0, "vision_expired": 0, "cancelled_before_submit": 0, "downstream_cancelled": 0, "tts_cancelled": 0, "tts_expired": 0}
final_expiry_audio	0	1.898300009001104 6	devices=True forced=False；{"dispatched": 2, "accepted": 2, "rejected": 0, "inflight": 0, "peak": 2, "limit": 2, "vision_accepted": 1, "vision_rejected": 0, "llm_cancelled": 0, "llm_expired": 0, "vision_cancelled": 0, "vision_expired": 0, "cancelled_before_submit": 0, "downstream_cancelled": 0, "tts_cancelled": 0, "tts_expired": 1}
final_sigint_asr	0	16.53417446199819	devices=True forced=False；{"dispatched": 1, "accepted": 1, "rejected": 0, "inflight": 0,

实际 case	退出码	信号到退出秒数	终态与清理
			"peak": 1, "limit": 2, "vision_accepted": 1, "vision_rejected": 0, "llm_cancelled": 0, "llm_expired": 0, "vision_cancelled": 0, "vision_expired": 0, "cancelled_before_submit": 0, "downstream_cancelled": 0, "tts_cancelled": 0, "tts_expired": 0}
final_sigint_drain	0	16.129876066999714	devices=True forced=False；{"dispatched": 1, "accepted": 1, "rejected": 0, "inflight": 0, "peak": 1, "limit": 2, "vision_accepted": 1, "vision_rejected": 0, "llm_cancelled": 0, "llm_expired": 0, "vision_cancelled": 0, "vision_expired": 0, "cancelled_before_submit": 0, "downstream_cancelled": 0, "tts_cancelled": 0, "tts_expired": 0}
final_sigterm_cancel_waiting	0	12.02652530100022	devices=True forced=False；{"dispatched": 2, "accepted": 2, "rejected": 0, "inflight": 0,

实际 case	退出码	信号到退出秒数	终态与清理
			"peak": 2, "limit": 2, "vision_accepted": 1, "vision_rejected": 0, "llm_cancelled": 0, "llm_expired": 0, "vision_cancelled": 0, "vision_expired": 0, "cancelled_before_submit": 0, "downstream_cancelled": 0, "tts_cancelled": 1, "tts_expired": 0}
final_sigterm_initialization	0	23.54417397299767	devices=True forced=False；{"dispatched": 0, "accepted": 0, "rejected": 0, "inflight": 0, "peak": 0, "limit": 2, "vision_accepted": 0, "vision_rejected": 0, "llm_cancelled": 0, "llm_expired": 0, "vision_cancelled": 0, "vision_expired": 0, "cancelled_before_submit": 0, "downstream_cancelled": 0, "tts_cancelled": 0, "tts_expired": 0}
真实故障输入	真实	秒数	设备释放与预期失败

实际 case	退出码	信号到退出秒数	终态与清理
	退出码		
microphone_missing	1	23.901	True / True
camera_missing	1	21.549	True / True
playback_missing	1	19.739	True / True
asr_model_missing	1	0.481	True / True

真实非法路径只验证打开/初始化失败的清理，不模拟拔掉设备、内核故障或 SDK 内存破坏。ASR 推理异常、Camera 超时/异常、TTS 失败/抛异常/无效 PCM、播放失败和后续恢复通过 Fake 验证；真实运行期间没有人为破坏设备。取消等待不强行打断已进入 SDK 的活动请求；排空停止输入后完成已经接收任务。超时和拒绝不算推理成功。生命周期检查结合完整 shutdown 日志、队列 pending/active=0、pool in_use=0、进程消失与 fuser/ALSA 状态，不能只看 exit0。

9 实际问题与修复记录

真实长测中 2 线程请求 86/104、4 线程 41/107 等 stdout 诊断插入流式回答；后台完整字符串和合成内容未受影响，但直接用终端解析 GUI 会错。修复是在既有 ImageProfile 互斥 JSONL 中一次写入完整 UTF8 识别/回答，明确 input_text 与 asr_text，GUI 读取该结构化通道；原始 stdout 保留诊断。控制字符转义、50 并发文本和模型真实回答均检查，未改变模型输出。

最终文档复核还发现一处历史检查脚本的空路径漏洞：5.4 的 source_invariants 列过并不存在的 src/ai/inference_worker.cpp，前后都不存在时旧 sha 辅助函数都返回 null，误显示 unchanged。真实 InferenceWorker 是 include/ai/llm_worker.h 中 LLMWorker 的 using 别名，实现在 llm_worker.cpp；5.5 已改为校验这两个真实文件并强制两侧存在。历史 JSON 保留原样，并未借此否定另有 96 项真实 SHA 匹配的 5.4 验收；本节记录这个检查自身的局限并修正。

长测中段真实 fd 快照还显示 RKNN/RKLLM 打开/dev/dri/card1，GUI 自身没有 Camera/ALSA/NPU 句柄；早期 fuser 仅查对应 renderD129，NPU 占用检查范围不足。保留旧工具，5.5 统一补查同 rknpu 驱动的 card 和 render 节点。新增 primary 检查先拒绝了 systemd/logind/Xorg 既有桌面句柄，AI 程序尚未启动；保留这次工具保护中止。随后只读核实 PID1/932/1619，固定 PID、启动标识、UID 及命令行，Xorg 真实 UID 为 1000 而 fuser 显示其有效 root 身份。Camera/ALSA/render 必须为空，primary 只允许这组精确基线，未知进程仍拒绝；不结束系统服务。最终 CLI 故障/生命周期与保护检查使用这一严格前后对照，资源释放指本次 AI 句柄消失并恢复桌面基线，不能说所有 primary 句柄都关闭。较早退出进程已消失、销毁日志仍有效，但不能声称当时已经查询过 card1。GUI 与后台主线程实际 SigBlk 均 0x4002，即 SIGINT 与 SIGTERM 被阻塞，由普通 sigwait 线程处理。

首轮 GUI 监控使用/proc/PID/task/PID/children，但本内核没有该文件，首轮 mic 及首轮 paired 无后台资源采样；不填造这些数据。修复监控工具为 PPid 查询并核实 exe/start-token，原工具保存在 gui_sampler_original.py，最终长测包含 GUI 和后台分开采样。这个工具修复没有更改已构建生产源码。

主机绘图旧 matplotlib 不支持 tick_labels，改 labels 后重跑；Git 全局 docx textconv 曾使差异变成文本抽取，字节回放失败，保留失败 JSON 后禁用--no-textconv/--no-ext-diff，二进制补丁回放成功；Word 沙箱 COM 失败，使用已授权原生 Word 导出；初次 Word 对象 HWND 为空改用 Document.ActiveWindow.Hwnd。打包 renderer 缺少 LibreOffice，保留错误并用现有 Word 生成 PDF 后复用同一 renderer 光栅化。没有安装软件，不终止用户原 Word 进程。所有失败实验保留，不能作为成功运行计数。

10 保护复现与交付结论

最终保护核对原稳定 321 项 SHA/大小/mtime、四个历史可执行文件、冻结 5.4 和本节源码、设备、内存/磁盘及内核错误窗口。最新保护结果以 protection_final_after_camera/result.json 为准，较早 protection_final 保留。Camera/ALSA/render 无持有者，primary 恢复精确桌面基线；原稳定 321 项及四个历史程序均一致。测试结束磁盘剩余 1,740,128,256 字节，归档后的空间另见 final_delivery_receipt.json。所有写入仅隔离目录；SDK/模型按原有路径读取，没有删除、覆盖模型或修改系统配置。

运行说明见 README_STAGE5_FINAL.md 和 tools/stage5_05_launch_gui.sh；重要命令逐项说明见 stage5_05_commands.md；完整前后源码见 stage5_05_source_appendix.md；关键语句与寿命见 stage5_05_statement_notes.md；12 道完整问答见 stage5_05_interview.md。最终 Word 和 Markdown 手册共同源自 RK3576_STAGE5_ENGINEERING_MANUAL.md，包含 5.1～5.5 及可复核性能成果、真实局限和简历表述。Git 格式 patch 通过全新临时树 apply 和逐字节 SHA 回放，不虚构 Git 提交。

考虑到已出现 Linux 热限频，本轮不继续扩大为单进程 60 分钟负载。没有单进程 60 分钟验收；本节完成记录中的 2/4 线程各约 30 分钟对照和最终 GUI 约 30 分钟时，仍只支持有限工况。当前 VISION 入口把中文识别结果用于路由，向 VLM 提交固定英文问题 `What do you see? Answer briefly.`，不宣称支持任意中文视觉问题原样推理。Frame Age 基于现有主机采集时间戳，不是传感器曝光时间。未实现 RGA 生产路径或 DMA-BUF 端到端零拷贝；TTS RTF 仍>1、播放与合成仍串行、没有 AEC/PTT/语音打断。原稳定版本升级须另经用户审核，当前不执行。

最终工程判定

记录工况内工程检查通过，具备提交最终用户审核条件。5.1～5.4 保持原验收成果，本节未覆盖稳定主工程。完整机器检查项在 validation_summary.json；Word 逐页检查和最终归档收据单独核对。未完成单进程 60 分钟、高占空比任意散热、真实拔插故障或声学仪器测量，不扩大结论。

5.5 Qt 适配与稳定性工具逐句说明

本文对应真实 `BackendSession`、`SessionWindow`、Qt 入口、共用 `StopSignals` 及测试工具。完整源码将由导出器逐文件保留。Qt 代码是否通过真实 ARM64 构建和运行，以最终验收报告为准；本地 SDK 关闭的 9 项测试不能证明 GUI 可运行。

BackendSession 的对象与启动语句

`class BackendSession final : public QObject` 使适配器进入 Qt 对象和信号系统，`final` 阻止派生类改变其停止契约。`Q_OBJECT` 由 AUTOMOC 生成元对象信息；没有它，自定义信号不能连接。`QProcess process_`、`QFile terminal_`和 `QTimer stopDeadline_`是成员值对象，全部由 Qt 线程持有。本类不持有模型、Frame 或 SDK 借用指针。

构造函数将通道设为 MergedChannels，让 SDK stderr 与业务 stdout 按实际到达顺序进入同一日志。connect(sender,signal,this,lambda)中的 this 是接收上下文，Qt 在上下文销毁时断开连接。lambda 只在上下文寿命内访问成员，不把裸窗口指针交给 AI Worker。QProcess 和窗口同属 Qt 线程，因此 readyRead/finished 在该线程更新控件；跨进程传来的是复制字节，绝不是后台 C++对象的悬空引用。

start()先判断 active()，重复启动返回 false 并产生可见错误。QFileInfo(executable).isExecutable()检查外层程序；真正 exec 失败仍由 errorOccurred(FailedToStart)处理。日志使用 WriteOnly|NewOnly，已经存在就拒绝，避免擦掉上轮证据。partial、stopping 和 shutdownSeen 仅在新会话清理，不在旧会话运行时重置。

process_.setProcessEnvironment(environment)设置本次子进程环境，不调用全局 qputenv 与其他线程竞争。process_.start(executable,arguments,ReadOnly)异步启动，立即返回；QStringList 中的每个参数独立传递，不进行 shell 插值。模型路径、设备名含空格或特殊字符也不被解释成命令。生产外层是/usr/bin/stdbuf，argv 顺序为-oL,-eL,CLI,capture,ASR,VAD,Qwen,Kokoro,playback,seconds,threads,sid,VLM,Vision,Camera，threads 的零基下标是 10。

started 只证明操作系统成功启动外层进程，不代表模型和设备全部就绪。页面必须依据原入口的加载、Camera ready 和 Listen 日志更新状态。停止若发生于 Starting，先记 stopping_，等 started 再向已得到的子进程 PID 发送 SIGINT；不会对 PID 0 或进程组发送信号。

停止与窗口关闭

requestStop()先检查状态，再设协作停止标志。::kill(processId,SIGINT)在普通 Qt 槽中执行，只发给 QProcess 拥有的子进程。这里没有异步 signal handler。90 秒单次定时器只报告“停止未通过”，不调用 kill 或 waitForFinished；活跃同步 SDK 仍需要自然完成。真正永久阻塞的 SDK 无法由共享 flag 保证退出，这一限制必须保留。

closeEvent()发现后台仍在运行时先设置 closing，调用 event->ignore()保留窗口和回调接收者，再请求停止。收到 finished 时先排空可读输出、关闭诊断文件、恢复按钮、保存真实退出码和截图，再通过带上下文的 singleShot 关闭窗口。对象没有在 Worker 或 QProcess 回调中自我析构，QProcess 析构也不是正常停止手段。

orderly 同时要求 NormalExit、exitCode=0 和原入口[Shutdown] complete 标记；GUI 不会只凭窗口消失或 kill 返回 0 宣称清理完成。设备释放仍需进程外 fuser、ALSA status、进程存在性和原工程指纹复核。90 秒 GUI 提示与守护 70/90 秒失败清理是不同层次，最终强制终止一律记录失败。

输入缓冲与界面内存

consume()保留 UTF-8 字节到完整换行后才调用 fromUtf8，避免一次 readyRead 正好拆开中文字符。原始字节原样写入独占 terminal.log；超长未换行超过 64KiB 时清理显示缓冲并显式报错，原日志仍保留。窗口日志 400 块、答案 100 块、任务历史 64 条有上限，不把持续交互变为无界容器。

SessionWindow 的控件由父窗口拥有，BackendSession 为值成员；关闭事件保证其析构前子进程已经 finished。startSession 先创建 UTC 时间加 UUID 的独占子目录，旧会话 profile 关闭、任务表清空，再打开新会话。每次启动是一个新的 CLI 进程，不冒称已经专项验证真实 SDK 的进程内 Worker restart。

profile 定时器最多读取 64KiB 并按完整 JSONL 解析，Request ID 与队列阶段分开。每条入队/出队都保留 steady 时间戳，只接受同一请求阶段较新的状态；即使日志写入顺序与实际时间顺序不同，也不会用较旧入队覆盖已观察到的出队。它是异步观测快照，不宣称瞬时硬实时队列长度。退出后不重新打开旧 profile，避免把旧 begin 事件显示成新任务。

Q_ASSERT(QThread::currentThread()==qApp->thread())检查控件访问线程。界面只解析文本、诊断小记录并更新控件，没有加载模型、调用 NPU、等待 ALSA 或同步 join。自动回归使用真实 Qt 事件循环和按钮信号；Fake 进程的文本在原日志明确标 Fake，不计入硬件功能或性能。

共用信号类与 Qt 入口

StopSignals 的类正文从 5.1 修复后的入口移至头文件，算法不变。必须在 QApplication 和 SDK 线程之前构造，后续线程继承阻塞集；普通 sigwait 线程接收 SIGINT/SIGTERM 并写 atomic。Qt 定时器读取该状态，发起普通 closeEvent。没有在 signal handler 调用 Qt、mutex、分配内存或 join。

Qt 的 signals 是宏，因此对象变量命名为 stopSignals，不能用单独的 signals 标识符。QApplication 先析构，StopSignals 最后 join 接收线程并恢复旧掩码。子 CLI 也使用同一类；即使继承了阻塞集，仍由其普通 sigwait 线程处理，停止语义不会退回默认异步终止。

QFileInfo(reportRoot).canonicalFilePath()与隔离 reports 前缀校验限制产物位置；独占创建失败就拒绝启动。6 个模型变量从已有路径脚本导出，GUI 没有拷贝模型或编辑 SDK 配置。BUILD_QT_GUI 默认 OFF，只有明确启用才 find Qt5；SDK 关闭的 portable 构建不依赖 Qt 或 Linux 信号头。

故障测试和长测工具

扩展现有 Fake 异步测试，在 worker 空闲的同步点才改变测试注入变量。等待空闲所使用的互斥锁/条件变量建立先行关系，不能在合成运行时改普通 int。推理标准/未知异常、TTS 返回 false/抛异常/无效 PCM、ALSA 返回 false 分别检查失败计数和错误文本；随后同一 Worker 执行成功项，验证错误不是被吞成成功，也没有让线程入口异常终止。

QtTest 使用没有 SDK 和设备的独立 Fake 进程。它验证点击开始、识别/答案显示、100ms 心跳、点击停止、新子进程重启、活跃窗口关闭、不可执行/exec 失败、恢复和拒绝覆盖日志。测试父进程同样先构造 StopSignals 再建立 QApplication，模拟生产的阻塞掩码继承。Fake 的 signal handler 只写 sig_atomic_t；先安装 handler 再解除继承的阻塞信号，避免测试自身的早到信号竞态。

实机守护每秒读取/proc 与 sysfs，明确记录温度、CPU 频率、cooling state、线程和 RSS，保留实际模型及 TTS 队列事件。90℃是本项目保守测试线而非芯片安全额定值。cooling state 为正只能说明对应 Linux cooling 设备活动；频率下降还可能来自 ondemand 和当前负载，不能自动归因于热降频。

分析器复用 5.4 的 steady 事件定义与 nearest-rank 统计。TTS 时长由 tts_full_audio_ready 的实际样本数除以应用采样率计算；采样率从 ALSA 日志的 buffer_frames/buffer_ms 还原，并核对本模型 24kHz 条件。它不是耳机声学时长。RSS 趋势排除前 5 分钟，并限制到进程第 30 分钟以前，避免模型加载或退出释放伪造斜率；同时比较 5～10 与 25～30 分钟的中位数，不能只凭进程没 OOM 就证明无泄漏。

完整命令、失败修复、实机数据与未验证条件以最终报告为准。文档辅助工具使用打包 python-docx/Poppler，原生 Word 导出仅操作本工程 DOCX；没有捏造 GUI 截图、热曲线或运行日志。

真实 stdout 交错与结构化文本修复

2 线程长测的原始日志中，Qwen 回答的流式片段被 ALSA write 日志插入；完整 result.text 仍正确，模型未失败。原来的 print_mutex 只管理业务打印，无法约束 ALSA 和 SDK 的独立 stdout。GUI 不能把混杂行当作答案协议，原始证据继续保留。

ImageProfile::text 复用既有 mutex 与 steady 时钟，写 kind=request 的完整文本事件。逐字节保留 UTF-8，双引号、反斜杠、换行、回车、tab 和 0x20 以下控制字节做 JSON 转义；循环不把用户内容当事件名或格式串。写入和 flush 都在同一把锁内，错误显式报告；没有另一套计时器或无界请求表。RequestTrace::text 只携带原有不可变 ID。

on_text 在移动 supplied_trace 前记录是否来自 ASR，分别写 asr_text 或 input_text；不会把直接文本回放假装语音识别。LLM/VLM 完成回调把成功的完整 result.text 写 answer_text，失败和取消分别写 request_error/request_terminal。原 Prompt、推理参数、流式 CLI、TTS 提交与生命周期不变。

GUI 从 JSONL 读取识别、路由和完整答案，延迟由同一请求已有 steady 事件相减，缺少点显示未测量。自动停止依据 request_complete 而非 stdout 中的 success 字样，防止交错输出漏计；真实耳机仍必须用户确认。测试用两线程并发 50 条文本事件，加引号、中文、换行及控制字节样本，实际 56 行逐条 JSON 解析和文本回环检查通过；ARM 结果必须另列。

Qt5.15 进程创建路径的源码参考为官方 Qt 仓库。它不能替代当前 Debian Qt5.15.8 的实际信号测试；最终会核对 GUI 和 CLI 的 SigBlk 及真实退出结果。

本轮实际验证补充

最终 final_v2 已在 ARM64 完成全量构建和 8 项 CTest，真实 Qt xcb 页面及两轮新进程重启均正常。用户在 gui_microphone_final_v2 确认两个回答实际通过 HyperX 听到、视觉描述大致相符、窗口显示识别/路由/回答。GUI 外层 SIGTERM 触发普通事件循环关闭，后台通过既有 SIGINT 协作式清理；不把两种信号混称同时由同一进程接收。

当前内核不提供/proc/PID/task/PID/children，首轮监控遗漏后台 RSS；修复工具按 PPid 找直接子进程，并核实 exe 与 start token。原版工具保留，首轮缺失数据不补造。最终长测分别采样 Qt 和 AI 进程，不把 GUI 约 90MiB 等同全系统内存。

全局 Git docx textconv 可能把二进制文档转换成可读文本差异，git apply 返回 0 仍不能证明字节相同。本节确实捕获了 DOCX 字节检查失败，随后显式禁用 textconv 和外部 diff，再以 SHA 验证补丁实际还原；失败结果保留在 patch_roundtrip_before_binaryfix.json。

ASR 统计特别说明：ASRService::recognize 的 latency_ms 结束点在返回前 Result/Stream unique_ptr 析构之前，打印 RTF 沿用这个内部区间；外层 ASRWorker 的 asr_begin/asr_end 包含 recognize 返回所需清理。asr_decode_begin/asr_decode_end 只包含 DecodeOfflineStream。三种口径分别保留，不把差额认定为纯音素化、模型计算或错误计时。

InferenceWorker 实际是 include/ai/llm_worker.h 末尾的 `using InferenceWorker = LLMWorker`。它没有独立 inference_worker.cpp，也没有第二个队列实现。本节检查器明确要求被比较路径在前后两个版本都存在，避免 None==None 造成“未修改”假阳性；早期检查记录保留并注明这个漏洞。

5.5 新增关键源码逐行学习索引

本附录按最终真实文件行号定位，每条列出原句和语法/生命周期含义；完整文件见 source_appendix，设计流程见 statement_notes。生成器不会把说明插入生产源码。

src/gui/backend_session.cpp

职责：Qt 主线程中的 QProcess 适配，不加载模型；QObject context 限制回调寿命，停止是向确认子 PID 发 SIGINT。SHA256：
`b724f970b6636aef8e9c582fa6dea7691c0035af35bacb6f4a7b72a368857225`。

行 1 `#include "gui/backend_session.h"`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 2 `#include <QFileInfo>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 3 `#include <cerrno>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 4 `#include <cstring>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 5 #include <signal.h>: 预处理阶段引入该实际声明；不创建对象、不启动线程。

行 6 #include <sys/types.h>: 预处理阶段引入该实际声明；不创建对象、不启动线程。

行 7 #include <cstdio>: 预处理阶段引入该实际声明；不创建对象、不启动线程。

行 9 BackendSession::BackendSession(QObject* parent):QObject(parent) {: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 10 process_.setProcessChannelMode(QProcess::MergedChannels);: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 11 connect(&process_,&QProcess::readyReadStandardOutput,this,&BackendSession::consume);: 注册 Qt 信号到槽或带 context 的 lambda；由事件循环触发，context 销毁会断开连接；不在此同步推理。

行 12 connect(&process_,&QProcess::started,this,[this] {: 注册 Qt 信号到槽或带 context 的 lambda；由事件循环触发，context 销毁会断开连接；不在此同步推理。

行 13 emit running();: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 14 if(stopping_)requestStop(); // Stop pressed during asynchronous startup.: 按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 15 });: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 16 connect(&process_,&QProcess::errorOccurred,this,[this](QProcess::ProcessError error) {: 注册 Qt 信号到槽或带 context 的 lambda；由事件循环触发，context 销毁会断开连接；不在此同步推理。

行 17 emit problem(process_.errorString());: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 18 if(error==QProcess::FailedToStart) {: 按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 19 stopDeadline_.stop();terminal_.close();emit finished(-1,false);: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 20 }: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 21 });: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 22 connect(&process_,qOverload<int,QProcess::ExitStatus>(&QProcess::finished),this,: 注册 Qt 信号到槽或带 context 的 lambda；由事件循环触发，context 销毁会断开连接；不在此同步推理。

行 23 [this](int code,QProcess::ExitStatus status) {: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 24 consume();: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 25 if(!partial_.isEmpty()){emit lineReceived(QString::fromUtf8(partial_));partial_.clear();}: 维护跨 read 边界的字节片段，完整行后再解析，另有 64KiB 异常上限，避免半个 UTF8 字符被错误解码。

行 26 stopDeadline_.stop();terminal_.close();: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 27 emit finished(code,status==QProcess::NormalExit && code==0 && shutdownSeen_);: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 28 });: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 29 stopDeadline_.setSingleShot(true);: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 30 connect(&stopDeadline_,&QTimer::timeout,this,[this] {: 注册 Qt 信号到槽或带 context 的 lambda；由事件循环触发，context 销毁会断开连接；不在此同步推理。

行 31 emit problem(QStringLiteral("停止等待超过 90 秒，退出未通过；仍保留窗口和进程，不以强杀冒充安全退出"));：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 32 });：结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 33 }：结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 34 BackendSession::~BackendSession() {：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 35 stopDeadline_.stop();：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 36 QObject::disconnect(&process_,nullptr,this,nullptr);：注册 Qt 信号到槽或带 context 的 lambda；由事件循环触发，context 销毁会断开连接；不在此同步推理。

行 37 // Normal owners wait for finished. If an unrelated emergency destroys an：该注释说明相邻代码的工程约束，本行不执行。

行 38 // active owner, prevent callbacks into already-destroyed member buffers.：该注释说明相邻代码的工程约束，本行不执行。

行 39 // QProcess fallback cleanup in that failure path is never counted orderly.：该注释说明相邻代码的工程约束，本行不执行。

行 40 if(active())std::fprintf(stderr,"[GUI FAILURE] active backend destruction; emergency cleanup is NOT graceful\n");：按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 41 }：结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 42 bool BackendSession::start(const QString& executable,const QStringList& arguments,：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 43 const QProcessEnvironment& environment,const QString& terminalPath) {：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 44 if(active()){emit problem(QStringLiteral("已有交互进程，拒绝重复启动"));return false;}：按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 45 if(!QFileInfo(executable).isExecutable()){emit problem(QStringLiteral("入口程序不可执行"));return false;}：按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 46 terminal_.setFileName(terminalPath);：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 47 if(!terminal_.open(QIODevice::WriteOnly|QIODevice::NewOnly)) {：要求文件不存在才创建，防止重复启动覆盖已有终端或验收结果。

行 48 emit problem(QStringLiteral("拒绝覆盖日志或无法创建日志"));return false;：返回结果或提前结束本次函数；局部 RAII 仍正常析构，后台是否已结束由状态机另行保证。

行 49 }：结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 50 partial_.clear();stopping_=shutdownSeen_=false;：维护跨 read 边界的字节片段，完整行后再解析，另有 64KiB 异常上限，避免半个 UTF8 字符被错误解码。

行 51 process_.setProcessEnvironment(environment);：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 52 // argv is structured; paths/text are never interpolated into a shell.：该注释说明相邻代码的工程约束，本行不执行。

行 53 process_.start(executable,arguments,QIODevice::ReadOnly);：用独立程序路径与 QStringList 异步启动子进程，不拼接 shell，不阻塞等待模型加载。

行 54 return true;：返回结果或提前结束本次函数；局部 RAII 仍正常析构，后台是否已结束由状态机另行保证。

行 55 }：结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 56 void BackendSession::requestStop() {：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 57 if(!active())return;：按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 58 stopping_=true;：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 59 if(process_.state()!=QProcess::Running)return;：按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 60 const auto child=process_.processId();：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 61 if(child<=0)return;：按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 62 if(::kill(static_cast<pid_t>(child),SIGINT)!=0 && errno!=ESRCH)：请求本对象持有且已确认的后台进程协作退出；调用返回不等于设备已经释放。

行 63 emit problem(QStringLiteral("发送 SIGINT 失败: ")+QString::fromLocal8Bit(std::strerror(errno)));：请求本对象持有且已确认的后台进程协作退出；调用返回不等于设备已经释放。

行 64 if(!stopDeadline_.isActive())stopDeadline_.start(90000);：按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 65 }：结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 66 void BackendSession::consume() {：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 67 const auto data=process_.readAllStandardOutput();：读取当前可用数据，保留未完整行片段；这不是对 AI 设备的阻塞推理调用。

行 68 if(terminal_.isOpen() && !data.isEmpty()) {：按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 69 if(terminal_.write(data)!=data.size())emit problem(QStringLiteral("终端日志写入失败"));：按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 70 terminal_.flush();：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 71 }：结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 72 partial_+=data;：维护跨 read 边界的字节片段，完整行后再解析，另有 64KiB 异常上限，避免半个 UTF8 字符被错误解码。

行 73 for(int end;(end=partial_.indexOf('\n'))>=0;) {：维护跨 read 边界的字节片段，完整行后再解析，另有 64KiB 异常上限，避免半个 UTF8 字符被错误解码。

行 74 const auto bytes=partial_.left(end);partial_.remove(0,end+1);：维护跨 read 边界的字节片段，完整行后再解析，另有 64KiB 异常上限，避免半个 UTF8 字符被错误解码。

行 75 const auto line=QString::fromUtf8(bytes);：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 76 shutdownSeen_|=line.contains(QStringLiteral("[Shutdown] complete"));：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 77 emit lineReceived(line);：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 78 }：结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 79 if(partial_.size()>65536) {：维护跨 read 边界的字节片段，完整行后再解析，另有 64KiB 异常上限，避免半个 UTF8 字符被错误解码。

行 80 partial_.clear();emit problem(QStringLiteral("异常超长未换行输出已丢弃，原始内容仍在终端日志"));：维护跨 read 边界的字节片段，完整行后再解析，另有 64KiB 异常上限，避免半个 UTF8 字符被错误解码。

行 81 }：结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 82 }：结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

src/gui/session_window.cpp

职责：Qt 窗口只更新控件和读取有界结构化事件；关闭活动窗口先等待后台清理，重新开始创建新进程。SHA256：`30021fd3b2d9c4641a80fa740447bb30f0ae5b023f73a23d03de69f98766bd65`。

行 1 `#include "gui/session_window.h"`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 2 `#include <QCloseEvent>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 3 `#include <QDateTime>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 4 `#include <QDir>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 5 `#include <QGridLayout>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 6 `#include <QJsonDocument>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 7 `#include <QJsonObject>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 8 `#include <QRegularExpression>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 9 `#include <QTextStream>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 10 `#include <QThread>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 11 `#include <QApplication>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 12 `#include <QUuid>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 13 `#include <QVariant>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 14 `#include <utility>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 16 `SessionWindow::SessionWindow(GuiLaunch settings,QWidget* parent)`：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 17 `:QWidget(parent),settings_(std::move(settings)) {`：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 18 setWindowTitle(QStringLiteral("RK3576 端侧多模态交互系统"));resize(980,700);: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 19 auto* grid=new QGridLayout(this);: 构造 QObject/控件或 Qt 内部值对象；布局接管控件 parent，不能让异步回调借用裸临时地址。

行 20 auto* title=new QLabel(QStringLiteral("RK3576 多模态语音交互"));: 构造 QObject/控件或 Qt 内部值对象；布局接管控件 parent，不能让异步回调借用裸临时地址。

行 21 title->setStyleSheet("font-size:22px;font-weight:bold");grid->addWidget(title,0,0,1,5);: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 22 int column=0;: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 23 for(const auto& name:{"Camera","ASR","LLM","VLM","TTS"}) {: 遍历当前已有事件/控件或有限缓存；耗时模型循环仍在后台进程。

行 24 auto* label=new QLabel(QString::fromLatin1(name)+QStringLiteral(": 未启动"));: 构造 QObject/控件或 Qt 内部值对象；布局接管控件 parent，不能让异步回调借用裸临时地址。

行 25 label->setObjectName(QString::fromLatin1(name));modules_[name]=label;grid->addWidget(label,1,column++);: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 26 }: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 27 start_=new QPushButton(QStringLiteral("开始语音交互"));start_->setObjectName("start");: 构造 QObject/控件或 Qt 内部值对象；布局接管控件 parent，不能让异步回调借用裸临时地址。

行 28 stop_=new QPushButton(QStringLiteral("安全停止"));stop_->setObjectName("stop");stop_->setEnabled(false);: 构造 QObject/控件或 Qt 内部值对象；布局接管控件 parent，不能让异步回调借用裸临时地址。

行 29 threads_=new QComboBox;threads_->addItems({"TTS 2 线程","TTS 4 线程"});: 构造 QObject/控件或 Qt 内部值对象；布局接管控件 parent，不能让异步回调借用裸临时地址。

行 30 threads_->setCurrentIndex(settings_.threadArgument>=0 && settings_.arguments.value(settings_.threadArgument)=="2"?0:1);: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 31 stopMode_=new QComboBox;stopMode_->addItems({QStringLiteral("排空已接收任务"),QStringLiteral("取消等待任务")});: 构造 QObject/控件或 Qt 内部值对象；布局接管控件 parent，不能让异步回调借用裸临时地址。

行 32 stopMode_->setCurrentIndex(settings_.environment.value("STAGE5_STOP_MODE")=="cancel_pending"?1:0);: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 33 grid->addWidget(start_,2,0);grid->addWidget(stop_,2,1);grid->addWidget(threads_,2,2);grid->addWidget(stopMode_,2,3,1,2);: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 34 status_=new QLabel(QStringLiteral("就绪，点击开始；首次启动需要加载模型"));: 构造 QObject/控件或 Qt 内部值对象；布局接管控件 parent，不能让异步回调借用裸临时地址。

行 35 asr_=new QLabel(QStringLiteral("识别文本：等待"));asr_->setObjectName("transcript");: 构造 QObject/控件或 Qt 内部值对象；布局接管控件 parent，不能让异步回调借用裸临时地址。

行 36 route_=new QLabel(QStringLiteral("路由：等待"));route_->setObjectName("route");: 构造 QObject/控件或 Qt 内部值对象；布局接管控件 parent，不能让异步回调借用裸临时地址。

行 37 status_->setWordWrap(true);asr_->setWordWrap(true);route_->setWordWrap(true);: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 38 metrics_=new QLabel(QStringLiteral("延迟：尚无实测数据"));metrics_->setWordWrap(true);：构造 QObject/控件或 Qt 内部值对象；布局接管控件 parent，不能让异步回调借用裸临时地址。

行 39 queue_=new QLabel(QStringLiteral("推理等待：0 TTS 等待：0（异步事件快照）"));：构造 QObject/控件或 Qt 内部值对象；布局接管控件 parent，不能让异步回调借用裸临时地址。

行 40 error_=new QLabel;error_->setWordWrap(true);error_->setStyleSheet("color:#a02020");：构造 QObject/控件或 Qt 内部值对象；布局接管控件 parent，不能让异步回调借用裸临时地址。

行 41 grid->addWidget(status_,3,0,1,5);grid->addWidget(asr_,4,0,1,5);grid->addWidget(route_,5,0,1,5);：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 42 grid->addWidget(metrics_,6,0,1,5);grid->addWidget(queue_,7,0,1,5);grid->addWidget(error_,8,0,1,5);：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 43 answers_=new QPlainTextEdit;answers_->setReadOnly(true);answers_->setObjectName("answers");answers_->setMaximumBlockCount(100);：构造 QObject/控件或 Qt 内部值对象；布局接管控件 parent，不能让异步回调借用裸临时地址。

行 44 answers_->setPlaceholderText(QStringLiteral("模型回答，显示最近 100 行，完整内容保留在本轮日志"));：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 45 logs_=new QPlainTextEdit;logs_->setReadOnly(true);logs_->setMaximumBlockCount(400);：构造 QObject/控件或 Qt 内部值对象；布局接管控件 parent，不能让异步回调借用裸临时地址。

行 46 grid->addWidget(answers_,9,0,1,5);grid->addWidget(logs_,10,0,1,5);grid->setRowStretch(9,2);grid->setRowStretch(10,1);：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 47 connect(start_,&QPushButton::clicked,this,&SessionWindow::startSession);：注册 Qt 信号到槽或带 context 的 lambda；由事件循环触发，context 销毁会断开连接；不在此同步推理。

行 48 connect(stop_,&QPushButton::clicked,this,&SessionWindow::stopSession);：注册 Qt 信号到槽或带 context 的 lambda；由事件循环触发，context 销毁会断开连接；不在此同步推理。

行 49 connect(&backend_,&BackendSession::lineReceived,this,&SessionWindow::line);：注册 Qt 信号到槽或带 context 的 lambda；由事件循环触发，context 销毁会断开连接；不在此同步推理。

行 50 connect(&backend_,&BackendSession::problem,this,[this](const QString& message){error_->setText(message);QTextStream(stdout)<<"[GUI error] "<<message<<Qt::endl;});：注册 Qt 信号到槽或带 context 的 lambda；由事件循环触发，context 销毁会断开连接；不在此同步推理。

行 51 connect(&backend_,&BackendSession::running,this,[this]{status_->setText(QStringLiteral("后台进程已启动，正在加载"));});：注册 Qt 信号到槽或带 context 的 lambda；由事件循环触发，context 销毁会断开连接；不在此同步推理。

行 52 connect(&backend_,&BackendSession::finished,this,[this](int code,bool orderly){：注册 Qt 信号到槽或带 context 的 lambda；由事件循环触发，context 销毁会断开连接；不在此同步推理。

行 53 pollProfile();profile_.close();stopping_=false;lastOrderly_=orderly;++completedCycles_;：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 54 start_->setEnabled(true);stop_->setEnabled(false);threads_->setEnabled(true);stopMode_->setEnabled(true);：根据活动状态启用或禁用控制项，防止运行中重复开始或改变当前会话参数。

行 55 status_->setText(QStringLiteral("进程退出码 %1；%2").arg(code).arg(orderly?QStringLiteral("清理完成"):QStringLiteral("未通过安全退出检查")));：构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 56 if(!orderly)error_->setText(QStringLiteral("启动或运行失败，请查看保留的原始日志"));: 构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 57 for(auto* label:modules_)label->setText(label->objectName()+QStringLiteral(": 进程已退出"));: 构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 58 QTextStream(stdout)<<"[GUI finished] code="<<code<<" orderly="<<orderly<<" cycles="<<completedCycles_<<" heartbeat="<<heartbeats_<<Qt::endl;: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 59 QFile result(runFolder_+"/result.json");: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 60 if(result.open(QIODevice::WriteOnly|QIODevice::NewOnly)) {: 要求文件不存在才创建，防止重复启动覆盖已有终端或验收结果。

行 61 QJsonObject object{{"returncode",code},{"orderly",orderly},{"heartbeat",heartbeats_},{"answers_completed",completedAnswers_},{"cycles_completed",completedCycles_}};: 编码/解析一条结构化 JSON 事件，保留 Request ID、UTF8 文本及单调时钟时间，不从交错 stdout 猜业务文本。

行 62 result.write(QJsonDocument(object).toJson());: 编码/解析一条结构化 JSON 事件，保留 Request ID、UTF8 文本及单调时钟时间，不从交错 stdout 猜业务文本。

行 63 } else error_->setText(QStringLiteral("结果写入失败"));: 构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 64 screenshot("finished.png");: 截取真实运行的当前 QWidget 并保存本次 case，不合成运行画面。

行 65 if(!closing_ && settings_.automatic && completedCycles_<settings_.cycles && orderly)QTimer::singleShot(200,this,&SessionWindow::startSession);: 把动作推迟到事件循环执行，并提供 QObject 上下文，避免向已销毁窗口调用。

行 66 else if(closing_ || settings_.automatic)QTimer::singleShot(0,this,&QWidget::close);: 把动作推迟到事件循环执行，并提供 QObject 上下文，避免向已销毁窗口调用。

行 67 });：结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 68 poll_.setInterval(100);：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 69 connect(&poll_,&QTimer::timeout,this,[this]{++heartbeats_;pollProfile();});poll_.start();：注册 Qt 信号到槽或带 context 的 lambda；由事件循环触发，context 销毁会断开连接；不在此同步推理。

行 70 if(settings_.automatic)QTimer::singleShot(100,start_,&QPushButton::click);：把动作推迟到事件循环执行，并提供 QObject 上下文，避免向已销毁窗口调用。

行 71 }：结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 72 void SessionWindow::startSession() {：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 73 if(backend_.active() || closing_)return;：按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 74 runFolder_=QDir(settings_.reportRoot).filePath("run_"+QDateTime::currentDateTimeUtc().toString("yyyyMMdd_HHmmss_zzz")+"_"+QUuid::createUuid().toString(QUuid::Id128));：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 75 if(!QDir().mkdir(runFolder_)){error_->setText(QStringLiteral("无法创建独占运行目录"));return;}：构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 76 auto env=settings_.environment;：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 77 env.insert("STAGE5_PROFILE",runFolder_+"/profile.jsonl");：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 78 env.insert("STAGE5_STOP_MODE",stopMode_->currentIndex()==0?"drain":"cancel_pending");: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 79 auto args=settings_.arguments;: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 80 if(settings_.threadArgument>=0 && settings_.threadArgument<args.size())args[settings_.threadArgument]=threads_->currentIndex()==0?"2":"4";: 按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 81 completedAnswers_=0;lastOrderly_=false;stopping_=false;tasks_.clear();profilePartial_.clear();profile_.close();: 维护跨 read 边界的字节片段，完整行后再解析，另有 64KiB 异常上限，避免半个 UTF8 字符被错误解码。

行 82 profile_.setFileName(runFolder_+"/profile.jsonl");: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 83 error_->clear();answers_->clear();logs_->clear();: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 84 asr_->setText(QStringLiteral("识别文本：等待新会话"));route_->setText(QStringLiteral("路由：等待新会话"));: 构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 85 metrics_->setText(QStringLiteral("延迟：等待新会话实测"));: 构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 86 queue_->setText(QStringLiteral("推理等待：0 TTS 等待：0（异步事件快照）"));: 构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 87 if(backend_.start(settings_.program,args,env,runFolder_+"/terminal.log")) {: 按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 88 start_->setEnabled(false);stop_->setEnabled(true);threads_->setEnabled(false);stopMode_->setEnabled(false);: 根据活动状态启用或禁用控制项，防止运行中重复开始或改变当前会话参数。

行 89 status_->setText(QStringLiteral("异步启动中"));: 构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 90 QTextStream(stdout)<<"[GUI run] "<<runFolder_<<Qt::endl;: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 91 } else if(settings_.automatic)QTimer::singleShot(0,this,&QWidget::close);: 把动作推迟到事件循环执行，并提供 QObject 上下文，避免向已销毁窗口调用。

行 92 }: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 93 void SessionWindow::stopSession() {: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 94 if(!backend_.active() || stopping_)return;: 按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 95 stopping_=true;stopClock_.start();backend_.requestStop();stop_->setEnabled(false);: 根据活动状态启用或禁用控制项，防止运行中重复开始或改变当前会话参数。

行 96 status_->setText(QStringLiteral("正在协作停止，等待后台线程和资源释放"));: 构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 97 screenshot("stopping.png");: 截取真实运行的当前 QWidget 并保存本次 case，不合成运行画面。

行 98 }: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 99 void SessionWindow::closeEvent(QCloseEvent* event) {: 活动后台未退出时阻止窗口销毁，先协作停止；空闲状态才允许接受关闭。

行 100 if(backend_.active()){closing_=true;event->ignore();stopSession();return;}: 活动后台未退出时阻止窗口销毁，先协作停止；空闲状态才允许接受关闭。

行 101 event->accept();：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 102 }：结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 103 void SessionWindow::screenshot(const QString& leaf) {：截取真实运行的当前 QWidget 并保存本次 case，不合成运行画面。

行 104 if(!runFolder_.isEmpty() && !grab().save(runFolder_+'/'+leaf))error_->setText(QStringLiteral("界面截图保存失败"));：截取真实运行的当前 QWidget 并保存本次 case，不合成运行画面。

行 105 }：结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 106 void SessionWindow::line(const QString& text) {：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 107 Q_ASSERT(QThread::currentThread()==qApp->thread());：调试断言要求 GUI 线程上下文；不是跨线程锁，也不替代发布构建的生命周期设计。

行 108 logs_->appendPlainText(text);QTextStream(stdout)<<text<<Qt::endl;：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 109 const auto module=[this](const char* key,const QString& state){modules_[key]->setText(QString::fromLatin1(key)+": "+state);};：构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 110 if(text.contains("Loading RKLLM"))module("LLM",QStringLiteral("加载中"));：按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 111 if(text.contains("Loading SenseVoice")){module("LLM",QStringLiteral("已加载"));module("ASR",QStringLiteral("加载中"));}：按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 112 if(text.contains("Loading Kokoro")){module("ASR",QStringLiteral("已加载"));module("TTS",QStringLiteral("加载中"));}：按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 113 if(text.contains("[ALSA config]"))module("TTS",QStringLiteral("已加载"));: 按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 114 if(text.contains("VLM and Camera ready")){module("Camera",QStringLiteral("采集中"));module("VLM",QStringLiteral("已加载"));}: 按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 115 if(text.contains("[Listen]") || text.contains("[Replay ready]")){status_->setText(text);screenshot("listening.png");}: 截取真实运行的当前 QWidget 并保存本次 case，不合成运行画面。

行 116 if(text.contains("success=false") || text.contains("[Fatal]") || (text.contains("[Init]") && text.contains("failed")) || text.contains("rejected #") || text.contains("[TTS expired"))error_->setText(text);: 构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 117 }: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 118 void SessionWindow::pollProfile() {: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 119 if(!backend_.active() && !profile_.isOpen())return; // Do not replay old events while idle.: 按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 120 if(!profile_.isOpen() && !profile_.fileName().isEmpty() && QFile::exists(profile_.fileName()))profile_.open(QIODevice::ReadOnly);: 按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 121 if(!profile_.isOpen())return;: 按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 122 profilePartial_+=profile_.read(65536);: 读取当前可用数据，保留未完整行片段；这不是对 AI 设备的阻塞推理调用。

行 123 for(int end;(end=profilePartial_.indexOf('\n'))>=0;) {: 维护跨 read 边界的字节片段，完整行后再解析，另有 64KiB 异常上限，避免半个 UTF8 字符被错误解码。

行 124 `const auto bytes=profilePartial_.left(end);profilePartial_.remove(0,end+1);`：维护跨 read 边界的字节片段，完整行后再解析，另有 64KiB 异常上限，避免半个 UTF8 字符被错误解码。

行 125 `const auto object=QJsonDocument::fromJson(bytes).object();`：编码/解析一条结构化 JSON 事件，保留 Request ID、UTF8 文本及单调时钟时间，不从交错 stdout 猜业务文本。

行 126 `if(object.value("kind")!="request")continue;`：按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 127 `const auto id=object.value("request_id").toVariant().toULongLong();`：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 128 `const auto name=object.value("event").toString();`：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 129 `const auto at=object.value("at_ns").toVariant().toLongLong();`：保存 steady_clock 纳秒或按单调时间比较，抵抗并发入队/出队日志写入顺序颠倒。

行 130 `const QStringList timed={"asr_enqueued","asr_begin","asr_end","inference_begin","inference_end","tts_enqueued","tts_dequeued","tts_generate_begin","tts_generate_end","alsa_first_submit_begin","request_complete"};`：使用同 Request ID 的真实完成事件更新成功回答计数；自动测试只在规定完成数后停止。

行 131 `if(timed.contains(name))tasks_[id]["at:"+name].timestamp=at;`：保存 steady_clock 纳秒或按单调时间比较，抵抗并发入队/出队日志写入顺序颠倒。

行 132 `if(name=="asr_text" || name=="input_text")asr_->setText((name=="asr_text"?QStringLiteral("识别 #%1: "):QStringLiteral("文本输入 #%1: ")).arg(id)+object.value("text").toString());`：构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 133 `if(name=="router_end")route_->setText(QStringLiteral("路由 #%1: %2").arg(id).arg(object.value("value").toInt()==1?"VISION":"TEXT"));`：构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 134 if(name=="answer_text")answers_->appendPlainText(QStringLiteral("回答 #%1：%2").arg(id).arg(object.value("text").toString()));：构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 135 if(name=="request_error")error_->setText(object.value("text").toString());：构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 136 if(name=="request_terminal")status_->setText(object.value("text").toString());：构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 137 if(name.contains("rejected") || name.contains("failed") || name.endsWith("_error"))：按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 138 error_->setText(QStringLiteral("请求#%1 阶段状态：%2，详情见本轮日志 ").arg(id).arg(name));：构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 139 if(name.endsWith("_expired") || name.endsWith("_cancelled"))：按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 140 status_->setText(QStringLiteral("请求#%1：%2").arg(id).arg(name));：构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 141 for(const auto& stage:{QString("inference"),QString("tts")}) {：遍历当前已有事件/控件或有限缓存；耗时模型循环仍在后台进程。

行 142 if(name==stage+"_enqueued" || name==stage+"_dequeued") {：按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 143 auto& record=tasks_[id][stage];：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 144 if(at>=record.timestamp){record.timestamp=at;record.pending=name.endsWith("_enqueued");}：保存 steady_clock 纳秒或按单调时间比较，抵抗并发入队/出队日志写入顺序颠倒。

行 145 }：结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 146 }: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 147 if(name.endsWith("_begin"))status_->setText(QStringLiteral("执行 #%1: %2").arg(id).arg(name));: 构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 148 if(timed.contains(name)) {: 按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 149 const auto& task=tasks_[id];: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 150 const auto duration=[&](const char* begin,const char* end) {: 用同一请求的时钟差换算毫秒；缺少任一端点显示未测量，不补零。

行 151 const auto a=task.value("at:"+QString::fromLatin1(begin)).timestamp;: 保存 steady_clock 纳秒或按单调时间比较，抵抗并发入队/出队日志写入顺序颠倒。

行 152 const auto b=task.value("at:"+QString::fromLatin1(end)).timestamp;: 保存 steady_clock 纳秒或按单调时间比较，抵抗并发入队/出队日志写入顺序颠倒。

行 153 return a>0 && b>=a?QString::number((b-a)/1e6,'f',1)+" ms":QStringLiteral("未测量");: 用同一请求的时钟差换算毫秒；缺少任一端点显示未测量，不补零。

行 154 };: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 155 metrics_->setText(QStringLiteral("请求#%1 ASR %2 推理 %3 TTS %4 TTS 排队 %5 ASR 入队→首次提交 %6"): 构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 156 .arg(id).arg(duration("asr_begin","asr_end"),duration("inference_begin","inference_end"),: 用同一请求的时钟差换算毫秒；缺少任一端点显示未测量，不补零。

行 157 duration("tts_generate_begin","tts_generate_end"),duration("tts_enqueued","tts_dequeued"), : 用同一请求的时钟差换算毫秒；缺少任一端点显示未测量，不补零。

行 158 duration("asr_enqueued","alsa_first_submit_begin")));: 用同一请求的时钟差换算毫秒；缺少任一端点显示未测量，不补零。

行 159 }: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 160 if(name=="request_complete") {: 使用同 Request ID 的真实完成事件更新成功回答计数；自动测试只在规定完成数后停止。

行 161 ++completedAnswers_;screenshot("answer_"+QString::number(completedAnswers_)+".png");: 截取真实运行的当前 QWidget 并保存本次 case，不合成运行画面。

行 162 if(settings_.stopAfterAnswers>0 && completedAnswers_>=settings_.stopAfterAnswers)stopSession();: 按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 163 }: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 164 while(tasks_.size()>64)tasks_.erase(tasks_.begin());: 限制 GUI 保留的诊断/回答历史，完整业务证据另存文件，不静默删除任务本身。

行 165 }: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 166 if(profilePartial_.size()>65536){profilePartial_.clear();error_->setText(QStringLiteral("异常超长诊断事件，已记录错误"));}: 维护跨 read 边界的字节片段，完整行后再解析，另有 64KiB 异常上限，避免半个 UTF8 字符被错误解码。

行 167 int inference=0,tts=0;: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 168 for(const auto& task:tasks_){inference+=task.value("inference").pending;tts+=task.value("tts").pending;}: 遍历当前已有事件/控件或有限缓存；耗时模型循环仍在后台进程。

行 169 queue_->setText(QStringLiteral("推理等待：%1 TTS 等待：%2（异步事件快照）").arg(inference).arg(tts));: 构造并显示带实际数值/状态的 Qt 字符串，不把显示动作当成后台任务完成证据。

行 170 }: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

src/gui/main.cpp

职责：在 QApplication 及子线程之前建立 StopSignals，校验隔离路径和参数，再进入 Qt 事件循环。SHA256：`0ffdb49603f373c5cf4feaebd43abfe1f1773bfd20ccc3eb12f750180b0a3820`。

行 1 `#include "app/stop_signals.h"`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 2 `#include "gui/session_window.h"`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 3 `#include <QApplication>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 4 `#include <QCommandLineParser>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 5 `#include <QDir>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 6 `#include <QFileInfo>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 7 `#include <QTextStream>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 8 `#include <QScreen>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 10 `int main(int argc,char** argv) try {`：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 11 `StopSignals stopSignals; // Must precede QApplication and every descendant thread.`：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 12 `QApplication app(argc,argv);`：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 13 `app.setApplicationName("rk3576_multimodal_gui");`：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 14 `QCommandLineParser parser;parser.addHelpOption();`：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 15 parser.addOption({"capture","ALSA capture device, rediscover HyperX before launch","device"});: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 16 parser.addOption({"playback","ALSA playback device","device"});: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 17 parser.addOption({"report-root","Existing isolated report directory; each run creates a new child","path"});: 构造 QObject/控件或 Qt 内部值对象；布局接管控件 parent，不能让异步回调借用裸临时地址。

行 18 parser.addOption({"threads","Kokoro threads (2 or 4)","number","4"});: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 19 parser.addOption({"seconds","Finite listening duration, 1..3600","number","120"});: 用同一请求的时钟差换算毫秒；缺少任一端点显示未测量，不补零。

行 20 parser.addOption({"auto-start","Automated regression: click start after event loop begins"});: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 21 parser.addOption({"stop-after-answers","Automated regression: stop after N successful TTS answers","number","0"});: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 22 parser.addOption({"cycles","Automated regression: fresh child sessions, 1..4","number","1"});: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 23 parser.process(app);: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 24 const auto env=QProcessEnvironment::systemEnvironment();: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 25 const auto review=env.value("STAGE5_REVIEW");: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 26 const auto reports=QFileInfo(parser.value("report-root")).canonicalFilePath();: 验证真实路径或隔离报告根边界，限制输出在授权目录；不会修改模型路径。

行 27 if(review.isEmpty() || reports.isEmpty() || !reports.startsWith(QDir(review).canonicalPath()+"/reports/stage5_05_board/")): 验证真实路径或隔离报告根边界，限制输出在授权目录；不会修改模型路径。

行 28 throw std::runtime_error("report-root must be an existing isolated Stage5.5 report directory");: 验证真实路径或隔离报告根边界，限制输出在授权目录；不会修改模型路径。

行 29 const auto number=[&](const char* key,int lo,int hi){bool ok=false;int n=parser.value(key).toInt(&ok);if(!ok || n<lo || n>hi)throw std::runtime_error("invalid numeric GUI argument");return n;};: 将非法输入或异常转换为明确错误状态/退出码；不是吞掉异常后继续假报成功。

行 30 const int threads=number("threads",2,4),seconds=number("seconds",1,3600);: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 31 if(threads!=2 && threads!=4)throw std::runtime_error("threads must be 2 or 4");: 将非法输入或异常转换为明确错误状态/退出码；不是吞掉异常后继续假报成功。

行 32 if(parser.value("capture").isEmpty() || parser.value("playback").isEmpty())throw std::runtime_error("explicit ALSA devices required");: 将非法输入或异常转换为明确错误状态/退出码；不是吞掉异常后继续假报成功。

行 33 for(const auto* key:{"STAGE5_ASR","STAGE5_VAD","STAGE5_QWEN","STAGE5_KOKORO","STAGE5_VLM","STAGE5_VISION"}): 遍历当前已有事件/控件或有限缓存；耗时模型循环仍在后台进程。

行 34 if(env.value(key).isEmpty())throw std::runtime_error("source and export stage5_board_paths.sh first");: 将非法输入或异常转换为明确错误状态/退出码；不是吞掉异常后继续假报成功。

行 35 GuiLaunch launch;launch.program="/usr/bin/stdbuf";launch.environment=env;launch.reportRoot=reports; : 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 36 launch.arguments=QStringList{"-oL","-eL",QCoreApplication::applicationDirPath()+"/asr_llm_tts_smoke",parser.value("capture"),env.value("STAGE5_ASR"),env.value("STAGE5_VAD"),env.value("STAGE5_QWEN"),env.value("STAGE5_KOKORO"),parser.value("playback"),QString::number(seconds),QString::number(threads),"17",env.value("STAGE5_VLM"),env.value("STAGE5_VISION"),"/dev/video11"};: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 37 launch.automatic=parser.isSet("auto-start");launch.stopAfterAnswers=number("stop-after-answers",0,32);launch.cycles=number("cycles",1,4);: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 38 SessionWindow window(std::move(launch));: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 39 if(auto* screen=QGuiApplication::primaryScreen()) {: 按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 40 const auto size=screen->availableGeometry().size();: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 41 window.resize(qMin(980,size.width()-40),qMin(700,size.height()-60));: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 42 }: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 43 window.show();：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 44 QTimer pollSignals;pollSignals.setInterval(100);：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 45 QObject::connect(&pollSignals,&QTimer::timeout,&window,[&] {：注册 Qt 信号到槽或带 context 的 lambda；由事件循环触发，context 销毁会断开连接；不在此同步推理。

行 46 if(stopSignals.received() || stopSignals.failed())window.close();：按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 47 });pollSignals.start();：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 48 const int code=app.exec();：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 49 return code?code:(stopSignals.failed() || !window.verified()?1:0);：返回结果或提前结束本次函数；局部 RAII 仍正常析构，后台是否已结束由状态机另行保证。

行 50 } catch(const std::exception& error) {：将非法输入或异常转换为明确错误状态/退出码；不是吞掉异常后继续假报成功。

行 51 QTextStream(stderr)<<"[GUI fatal] "<<error.what()<<Qt::endl;return 1;：返回结果或提前结束本次函数；局部 RAII 仍正常析构，后台是否已结束由状态机另行保证。

行 52 }：结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

include/app/stop_signals.h

职责：沿用已验收 sigwait 普通线程，退出前 join 并恢复 owner 线程原信号 mask。SHA256：c8fd4e74fc35c910c195ca789aaaa627c1127c77e018d28e983a860ebb69b5bf。

行 1 #pragma once：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 2 #include <atomic>：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 3 #include <cerrno>：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 4 #include <stdexcept>: 预处理阶段引入该实际声明；不创建对象、不启动线程。

行 5 #include <thread>: 预处理阶段引入该实际声明；不创建对象、不启动线程。

行 6 #include <pthread.h>: 预处理阶段引入该实际声明；不创建对象、不启动线程。

行 7 #include <signal.h>: 预处理阶段引入该实际声明；不创建对象、不启动线程。

行 9 // Construct before SDKs/workers: all descendant threads inherit the blocked set.: 该注释说明相邻代码的工程约束，本行不执行。

行 10 // sigtimedwait runs in an ordinary thread; there is no asynchronous signal handler.: 该注释说明相邻代码的工程约束，本行不执行。

行 11 class StopSignals {: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 12 public:: 指定 C++成员访问权限或 Qt 槽声明，影响接口可见性而不创建线程。

行 13 StopSignals(): 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 14 {: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 15 sigemptyset(&signals_);: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 16 sigaddset(&signals_, SIGINT);: 请求本对象持有且已确认的后台进程协作退出；调用返回不等于设备已经释放。

行 17 sigaddset(&signals_, SIGTERM);: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 18 if (pthread_sigmask(SIG_BLOCK, &signals_, &previous_) != 0): 保存/设置调用线程信号 mask，后续新线程继承；析构恢复 owner 线程原 mask。

行 19 throw std::runtime_error("Cannot block stop signals");: 将非法输入或异常转换为明确错误状态/退出码；不是吞掉异常后继续假报成功。

行 20 try: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 21 {: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 22 thread_ = std::thread([this] {: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 23 const timespec interval{0, 100000000};: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 24 while (!finished_.load()): 通过 atomic 读写线程间标志，避免普通 bool 数据竞争；对象寿命仍须由 join 保证。

行 25 {: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 26 const int received = sigtimedwait(&signals_, nullptr, &interval);: 在普通信号接收线程限时等待被阻塞信号；此处不是异步 signal handler。

行 27 if (received == SIGINT || received == SIGTERM): 请求本对象持有且已确认的后台进程协作退出；调用返回不等于设备已经释放。

行 28 {: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 29 int empty = 0;: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 30 signal_.compare_exchange_strong(empty, received);: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 31 }: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 32 else if (received < 0 && errno != EAGAIN && errno != EINTR): 按当前条件分支决定是否执行后续语句；必须结合括号作用域判断，不能仅按缩进推断。

行 33 {: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 34 wait_failed_.store(true);: 通过 atomic 读写线程间标志，避免普通 bool 数据竞争；对象寿命仍须由 join 保证。

行 35 break;: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 36 }: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 37 }: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 38 });: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 39 }: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 40 catch (...): 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 41 {: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 42 pthread_sigmask(SIG_SETMASK, &previous_, nullptr);: 保存/设置调用线程信号 mask，后续新线程继承；析构恢复 owner 线程原 mask。

行 43 throw;: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 44 }: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 45 }: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 46 ~StopSignals(): 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 47 {: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 48 finished_.store(true);: 通过 atomic 读写线程间标志，避免普通 bool 数据竞争；对象寿命仍须由 join 保证。

行 49 if (thread_.joinable()) thread_.join();: 等待所拥有线程真正结束，必须先发布停止条件；join 前不能销毁线程借用对象。

行 50 pthread_sigmask(SIG_SETMASK, &previous_, nullptr);: 保存/设置调用线程信号 mask，后续新线程继承；析构恢复 owner 线程原 mask。

行 51 }: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 52 StopSignals(const StopSignals&) = delete;: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 53 StopSignals& operator=(const StopSignals&) = delete;: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 54 `int received() const noexcept { return signal_.load(); }`：通过 atomic 读写线程间标志，避免普通 bool 数据竞争；对象寿命仍须由 join 保证。

行 55 `bool failed() const noexcept { return wait_failed_.load(); }`：通过 atomic 读写线程间标志，避免普通 bool 数据竞争；对象寿命仍须由 join 保证。

行 56 `private:`：指定 C++成员访问权限或 Qt 槽声明，影响接口可见性而不创建线程。

行 57 `sigset_t signals_{};`：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 58 `sigset_t previous_{};`：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 59 `std::atomic<int> signal_{0};`：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 60 `std::atomic<bool> finished_{false};`：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 61 `std::atomic<bool> wait_failed_{false};`：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 62 `std::thread thread_;`：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 63 `};`：结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

include/gui/backend_session.h

职责：定义 QProcess 所有权、停止状态及 QObject 信号；值成员的析构顺序必须配合显式 disconnect。SHA256：`d08247679bfe26454c0d27ffa82fedb68c3910d4a711d42ea2b15e46ca2720fa`。

行 1 `#pragma once`：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 2 `#include <QObject>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 3 `#include <QProcess>`：预处理阶段引入该实际声明；不创建对象、不启动线程。

行 4 #include <QProcessEnvironment>: 预处理阶段引入该实际声明；不创建对象、不启动线程。

行 5 #include <QFile>: 预处理阶段引入该实际声明；不创建对象、不启动线程。

行 6 #include <QTimer>: 预处理阶段引入该实际声明；不创建对象、不启动线程。

行 8 // Owns one CLI child. No SDK or device calls execute on the Qt thread.: 该注释说明相邻代码的工程约束，本行不执行。

行 9 // Owner must defer destruction until finished; stop never calls waitForFinished/kill.: 该注释说明相邻代码的工程约束，本行不执行。

行 10 class BackendSession final : public QObject {: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 11 Q_OBJECT: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 12 public:: 指定 C++成员访问权限或 Qt 槽声明，影响接口可见性而不创建线程。

行 13 explicit BackendSession(QObject* parent=nullptr);: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 14 ~BackendSession() override;: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 15 bool start(const QString& executable,const QStringList& arguments,: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 16 const QProcessEnvironment& environment,const QString& terminalPath);: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 17 void requestStop();: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 18 bool active() const { return process_.state()!=QProcess::NotRunning; }: 返回结果或提前结束本次函数；局部 RAII 仍正常析构，后台是否已结束由状态机另行保证。

行 19 qint64 pid() const { return process_.processId(); }: 返回结果或提前结束本次函数；局部 RAII 仍正常析构，后台是否已结束由状态机另行保证。

行 20 signals:: Qt moc 为信号生成元对象代码，signal 发射不是后台模型工作线程。

行 21 void lineReceived(QString line);: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 22 void problem(QString message);: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 23 void running();: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 24 void finished(int code,bool orderly);: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 25 private:: 指定 C++成员访问权限或 Qt 槽声明，影响接口可见性而不创建线程。

行 26 void consume();: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 27 QProcess process_;: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 28 QFile terminal_;: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 29 QByteArray partial_;: 维护跨 read 边界的字节片段，完整行后再解析，另有 64KiB 异常上限，避免半个 UTF8 字符被错误解码。

行 30 QTimer stopDeadline_;: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 31 bool stopping_=false,shutdownSeen_=false;: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 32 };: 结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

include/gui/session_window.h

职责：窗口拥有适配器及控件，任务诊断缓存有界，不持有 AI 回调内的借用 Buffer。

SHA256：92ba03778b34f2c64d26b7981d998330e1408e9e74d0e00133ec0b0485feff98。

行 1 #pragma once: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 2 #include "gui/backend_session.h": 预处理阶段引入该实际声明；不创建对象、不启动线程。

行 3 #include <QWidget>: 预处理阶段引入该实际声明；不创建对象、不启动线程。

行 4 #include <QMap>: 预处理阶段引入该实际声明；不创建对象、不启动线程。

行 5 #include <QLabel>: 预处理阶段引入该实际声明；不创建对象、不启动线程。

行 6 #include <QPushButton>: 预处理阶段引入该实际声明；不创建对象、不启动线程。

行 7 #include <QComboBox>: 预处理阶段引入该实际声明；不创建对象、不启动线程。

行 8 #include <QPlainTextEdit>: 预处理阶段引入该实际声明；不创建对象、不启动线程。

行 9 #include <QElapsedTimer>: 预处理阶段引入该实际声明；不创建对象、不启动线程。

行 11 struct GuiLaunch {: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 12 QString program;: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 13 QStringList arguments;: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 14 QProcessEnvironment environment;: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 15 QString reportRoot;: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 16 int threadArgument=10; // stdbuf argv: -oL -eL CLI device ... seconds threads sid ...: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 17 bool automatic=false;: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 18 int stopAfterAnswers=0;：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 19 int cycles=1;：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 20 };：结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

行 21 class SessionWindow final:public QWidget {：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 22 Q_OBJECT：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 23 public:：指定 C++成员访问权限或 Qt 槽声明，影响接口可见性而不创建线程。

行 24 explicit SessionWindow(GuiLaunch settings,QWidget* parent=nullptr);：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 25 bool active() const {return backend_.active();}：返回结果或提前结束本次函数；局部 RAII 仍正常析构，后台是否已结束由状态机另行保证。

行 26 bool verified() const {return lastOrderly_;}：返回结果或提前结束本次函数；局部 RAII 仍正常析构，后台是否已结束由状态机另行保证。

行 27 int heartbeatCount() const {return heartbeats_;}：返回结果或提前结束本次函数；局部 RAII 仍正常析构，后台是否已结束由状态机另行保证。

行 28 int completedCycles() const {return completedCycles_;}：返回结果或提前结束本次函数；局部 RAII 仍正常析构，后台是否已结束由状态机另行保证。

行 29 public slots:：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 30 void startSession();：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 31 void stopSession();：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 32 protected:: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 33 void closeEvent(QCloseEvent* event) override;: 活动后台未退出时阻止窗口销毁，先协作停止；空闲状态才允许接受关闭。

行 34 private:: 指定 C++成员访问权限或 Qt 槽声明，影响接口可见性而不创建线程。

行 35 void line(const QString& text);: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 36 void pollProfile();: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 37 void screenshot(const QString& leaf);: 截取真实运行的当前 QWidget 并保存本次 case，不合成运行画面。

行 38 GuiLaunch settings_;: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 39 BackendSession backend_;: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 40 QPushButton *start_,*stop_;: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 41 QComboBox *threads_,*stopMode_;: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 42 QLabel *status_,*asr_,*route_,*metrics_,*queue_,*error_;: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 43 QPlainTextEdit *answers_,*logs_;: 声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 44 QMap<QString,QLabel*> modules_;: 执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 45 struct QueueEvent {qint64 timestamp=0;bool pending=false;};: 保存 steady_clock 纳秒或按单调时间比较，抵抗并发入队/出队日志写入顺序颠倒。

行 46 QMap<quint64,QMap<QString,QueueEvent>> tasks_;：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 47 QFile profile_;：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 48 QByteArray profilePartial_;：维护跨 read 边界的字节片段，完整行后再解析，另有 64KiB 异常上限，避免半个 UTF8 字符被错误解码。

行 49 QString runFolder_;：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 50 QTimer poll_;：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 51 QElapsedTimer stopClock_;：执行本作用域的成员更新、函数参数续行或声明；与相邻语句共同构成上述状态机，不能脱离作用域理解生命周期。

行 52 bool closing_=false,stopping_=false,lastOrderly_=true;：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 53 int completedAnswers_=0,completedCycles_=0,heartbeats_=0;：声明/定义当前类型、函数或有作用域的值对象；具体所有权与线程角色见本文件职责和相邻语句。

行 54 };：结束或开始当前作用域/调用；离开拥有局部 RAII 对象的作用域时自动析构。

完整关键源码 include/gui/backend_session.h

```
#pragma once
#include <QObject>
#include <QProcess>
#include <QProcessEnvironment>
#include <QFile>
#include <QTimer>

// Owns one CLI child. No SDK or device calls execute on the Qt thread.
// Owner must defer destruction until finished; stop never calls waitForFinished/kill.
class BackendSession final : public QObject {
    Q_OBJECT
public:
    explicit BackendSession(QObject* parent=nullptr);
    ~BackendSession() override;
    bool start(const QString& executable,const QStringList& arguments,
               const QProcessEnvironment& environment,const QString& terminalPath);
    void requestStop();
```

```
    bool active() const { return process_.state()!=QProcess::NotRunning; }
    qint64 pid() const { return process_.processId(); }
signals:
    void lineReceived(QString line);
    void problem(QString message);
    void running();
    void finished(int code,bool orderly);
private:
    void consume();
    QProcess process_;
    QFile terminal_;
    QByteArray partial_;
    QTimer stopDeadline_;
    bool stopping_=false,shutdownSeen_=false;
};
```

完整关键源码 src/gui/backend_session.cpp

```
#include "gui/backend_session.h"
#include <QFileInfo>
#include <cerrno>
#include <cstring>
#include <signal.h>
#include <sys/types.h>
#include <cstdio>

BackendSession::BackendSession(QObject* parent):QObject(parent) {
    process_.setProcessChannelMode(QProcess::MergedChannels);
    connect(&process_,&QProcess::readyReadStandardOutput,this,&BackendSession::consume);
    connect(&process_,&QProcess::started,this,[this] {
        emit running();
        if(stopping_)requestStop(); // Stop pressed during asynchronous startup.
    });
    connect(&process_,&QProcess::errorOccurred,this,[this](QProcess::ProcessError error) {
        emit problem(process_.errorString());
        if(error==QProcess::FailedToStart) {
            stopDeadline_.stop();terminal_.close();emit finished(-1,false);
        }
    });
    connect(&process_,qOverload<int,QProcess::ExitStatus>(&QProcess::finished),this,
            [this](int code,QProcess::ExitStatus status) {
        consume();
        if(!partial_.isEmpty()){emit
lineReceived(QString::fromUtf8(partial_));partial_.clear();}
        stopDeadline_.stop();terminal_.close();
        emit finished(code,status==QProcess::NormalExit && code==0 && shutdownSeen_);
    });
    stopDeadline_.setSingleShot(true);
    connect(&stopDeadline_,&QTimer::timeout,this,[this] {
        emit problem(QStringLiteral("停止等待超过 90 秒，退出未通过；仍保留窗口和进程，不以强杀冒充安
全退出"));
    });
}
BackendSession::~BackendSession() {
    stopDeadline_.stop();
```

```
    QObject::disconnect(&process_,nullptr,this,nullptr);
    // Normal owners wait for finished. If an unrelated emergency destroys an
    // active owner, prevent callbacks into already-destroyed member buffers.
    // QProcess fallback cleanup in that failure path is never counted orderly.
    if(active())std::fprintf(stderr,"[GUI FAILURE] active backend destruction; emergency
cleanup is NOT graceful\n");
}
bool BackendSession::start(const QString& executable,const QStringList& arguments,
                           const QProcessEnvironment& environment,const QString& terminalPath)
{
    if(active()){emit problem(QStringLiteral("已有交互进程，拒绝重复启动"));return false;}
    if(!QFileInfo(executable).isExecutable()){emit problem(QStringLiteral("入口程序不可执行
"));return false;}
    terminal_.setFileName(terminalPath);
    if(!terminal_.open(QIODevice::WriteOnly|QIODevice::NewOnly)) {
        emit problem(QStringLiteral("拒绝覆盖日志或无法创建日志"));return false;
    }
    partial_.clear();stopping_=shutdownSeen_=false;
    process_.setProcessEnvironment(environment);
    // argv is structured; paths/text are never interpolated into a shell.
    process_.start(executable,arguments,QIODevice::ReadOnly);
    return true;
}
void BackendSession::requestStop() {
    if(!active())return;
    stopping_=true;
    if(process_.state()!=QProcess::Running)return;
    const auto child=process_.processId();
    if(child<=0)return;
    if(::kill(static_cast<pid_t>(child),SIGINT)!=0 && errno!=ESRCH)
        emit problem(QStringLiteral("发送 SIGINT 失败:
")+QString::fromLocal8Bit(std::strerror(errno)));
    if(!stopDeadline_.isActive())stopDeadline_.start(90000);
}
void BackendSession::consume() {
    const auto data=process_.readAllStandardOutput();
    if(terminal_.isOpen() && !data.isEmpty()) {
        if(terminal_.write(data)!=data.size())emit problem(QStringLiteral("终端日志写入失败"));
        terminal_.flush();
    }
    partial_+=data;
    for(int end;(end=partial_.indexOf('\n'))>=0;) {
        const auto bytes=partial_.left(end);partial_.remove(0,end+1);
        const auto line=QString::fromUtf8(bytes);
        shutdownSeen_|=line.contains(QStringLiteral("[Shutdown] complete"));
        emit lineReceived(line);
    }
    if(partial_.size()>65536) {
        partial_.clear();emit problem(QStringLiteral("异常超长未换行输出已丢弃，原始内容仍在终端日
志"));
    }
}
```

完整关键源码 include/gui/session_window.h

```
#pragma once
#include "gui/backend_session.h"
#include <QWidget>
#include <QMap>
#include <QLabel>
#include <QPushButton>
#include <QComboBox>
#include <QPlainTextEdit>
#include <QElapsedTimer>

struct GuiLaunch {
    QString program;
    QStringList arguments;
    QProcessEnvironment environment;
    QString reportRoot;
    int threadArgument=10; // stdbuf argv: -oL -eL CLI device ... seconds threads sid ...
    bool automatic=false;
    int stopAfterAnswers=0;
    int cycles=1;
};
class SessionWindow final:public QWidget {
    Q_OBJECT
public:
    explicit SessionWindow(GuiLaunch settings,QWidget* parent=nullptr);
    bool active() const {return backend_.active();}
    bool verified() const {return lastOrderly_;}
    int heartbeatCount() const {return heartbeats_;}
    int completedCycles() const {return completedCycles_;}
public slots:
    void startSession();
    void stopSession();
protected:
    void closeEvent(QCloseEvent* event) override;
private:
    void line(const QString& text);
    void pollProfile();
    void screenshot(const QString& leaf);
    GuiLaunch settings_;
    BackendSession backend_;
    QPushButton *start_,*stop_;
    QComboBox *threads_,*stopMode_;
    QLabel *status_,*asr_,*route_,*metrics_,*queue_,*error_;
    QPlainTextEdit *answers_,*logs_;
    QMap<QString,QLabel*> modules_;
    struct QueueEvent {qint64 timestamp=0;bool pending=false;};
    QMap<quint64,QMap<QString,QueueEvent>> tasks_;
    QFile profile_;
    QByteArray profilePartial_;
    QString runFolder_;
    QTimer poll_;
    QElapsedTimer stopClock_;
    bool closing_=false,stopping_=false,lastOrderly_=true;
    int completedAnswers_=0,completedCycles_=0,heartbeats_=0;
};
```

完整关键源码 src/gui/session_window.cpp

```
#include "gui/session_window.h"
#include <QCloseEvent>
#include <QDateTime>
#include <QDir>
#include <QGridLayout>
#include <QJsonDocument>
#include <QJsonObject>
#include <QRegularExpression>
#include <QTextStream>
#include <QThread>
#include <QApplication>
#include <QUuid>
#include <QVariant>
#include <utility>

SessionWindow::SessionWindow(GuiLaunch settings,QWidget* parent)
    :QWidget(parent),settings_(std::move(settings)) {
    setWindowTitle(QStringLiteral("RK3576 端侧多模态交互系统"));resize(980,700);
    auto* grid=new QGridLayout(this);
    auto* title=new QLabel(QStringLiteral("RK3576 多模态语音交互"));
    title->setStyleSheet("font-size:22px;font-weight:bold");grid->addWidget(title,0,0,1,5);
    int column=0;
    for(const auto& name:{"Camera","ASR","LLM","VLM","TTS"}) {
        auto* label=new QLabel(QString::fromLatin1(name)+QStringLiteral(": 未启动"));
        label->setObjectName(QString::fromLatin1(name));modules_[name]=label;grid-
>addWidget(label,1,column++);
    }
    start_=new QPushButton(QStringLiteral("开始语音交互"));start_->setObjectName("start");
    stop_=new QPushButton(QStringLiteral("安全停止"));stop_->setObjectName("stop");stop_-
>setEnabled(false);
    threads_=new QComboBox;threads_->addItems({"TTS 2 线程","TTS 4 线程"});
    threads_->setCurrentIndex(settings_.threadArgument>=0 &&
settings_.arguments.value(settings_.threadArgument)=="2"?0:1);
    stopMode_=new QComboBox;stopMode_->addItems({QStringLiteral("排空已接收任务
"),QStringLiteral("取消等待任务")});
    stopMode_-
>setCurrentIndex(settings_.environment.value("STAGE5_STOP_MODE")=="cancel_pending"?1:0);
    grid->addWidget(start_,2,0);grid->addWidget(stop_,2,1);grid->addWidget(threads_,2,2);grid-
>addWidget(stopMode_,2,3,1,2);
    status_=new QLabel(QStringLiteral("就绪，点击开始；首次启动需要加载模型"));
    asr_=new QLabel(QStringLiteral("识别文本：等待"));asr_->setObjectName("transcript");
    route_=new QLabel(QStringLiteral("路由：等待"));route_->setObjectName("route");
    status_->setWordWrap(true);asr_->setWordWrap(true);route_->setWordWrap(true);
    metrics_=new QLabel(QStringLiteral("延迟：尚无实测数据"));metrics_->setWordWrap(true);
    queue_=new QLabel(QStringLiteral("推理等待：0  TTS 等待：0（异步事件快照）"));
    error_=new QLabel;error_->setWordWrap(true);error_->setStyleSheet("color:#a02020");
    grid->addWidget(status_,3,0,1,5);grid->addWidget(asr_,4,0,1,5);grid-
>addWidget(route_,5,0,1,5);
    grid->addWidget(metrics_,6,0,1,5);grid->addWidget(queue_,7,0,1,5);grid-
>addWidget(error_,8,0,1,5);
    answers_=new QPlainTextEdit;answers_->setReadOnly(true);answers_-
>setObjectName("answers");answers_->setMaximumBlockCount(100);
    answers_->setPlaceholderText(QStringLiteral("模型回答，显示最近 100 行，完整内容保留在本轮日志
"));
```

```
    logs_=new QPlainTextEdit;logs_->setReadOnly(true);logs_->setMaximumBlockCount(400);
    grid->addWidget(answers_,9,0,1,5);grid->addWidget(logs_,10,0,1,5);grid-
>setRowStretch(9,2);grid->setRowStretch(10,1);
    connect(start_,&QPushButton::clicked,this,&SessionWindow::startSession);
    connect(stop_,&QPushButton::clicked,this,&SessionWindow::stopSession);
    connect(&backend_,&BackendSession::lineReceived,this,&SessionWindow::line);
    connect(&backend_,&BackendSession::problem,this,[this](const QString& message){error_-
>setText(message);QTextStream(stdout)<<"[GUI error] "<<message<<Qt::endl;});
    connect(&backend_,&BackendSession::running,this,[this]{status_->setText(QStringLiteral("后
台进程已启动，正在加载"));});
    connect(&backend_,&BackendSession::finished,this,[this](int code,bool orderly){
        pollProfile();profile_.close();stopping_=false;lastOrderly_=orderly;++completedCycles_;
        start_->setEnabled(true);stop_->setEnabled(false);threads_->setEnabled(true);stopMode_-
>setEnabled(true);
        status_->setText(QStringLiteral("进程退出
码 %1：%2").arg(code).arg(orderly?QStringLiteral("清理完成"):QStringLiteral("未通过安全退出检查
")));
        if(!orderly)error_->setText(QStringLiteral("启动或运行失败，请查看保留的原始日志"));
        for(auto* label:modules_)label->setText(label->objectName()+QStringLiteral("：进程已退出
"));
        QTextStream(stdout)<<"[GUI finished] code="<<code<<" orderly="<<orderly<<"
cycles="<<completedCycles_<<" heartbeat="<<heartbeats_<<Qt::endl;
        QFile result(runFolder_+"/result.json");
        if(result.open(QIODevice::WriteOnly|QIODevice::NewOnly)) {
            QJsonObject
object{{"returncode",code},{"orderly",orderly},{"heartbeat",heartbeats_},{"answers_completed",c
ompletedAnswers_},{"cycles_completed",completedCycles_}};
            result.write(QJsonDocument(object).toJson());
        } else error_->setText(QStringLiteral("结果写入失败"));
        screenshot("finished.png");
        if(!closing_ && settings_.automatic && completedCycles_<settings_.cycles &&
orderly)QTimer::singleShot(200,this,&SessionWindow::startSession);
        else if(closing_ || settings_.automatic)QTimer::singleShot(0,this,&QWidget::close);
    });
    poll_.setInterval(100);
    connect(&poll_,&QTimer::timeout,this,[this]{++heartbeats_;pollProfile();});poll_.start();
    if(settings_.automatic)QTimer::singleShot(100,start_,&QPushButton::click);
}
void SessionWindow::startSession() {
    if(backend_.active() || closing_)return;

runFolder_=QDir(settings_.reportRoot).filePath("run_"+QDateTime::currentDateTimeUtc().toString(
"yyyyMMdd_HHmmss_zzz")+"_"+QUuid::createUuid().toString(QUuid::Id128));
    if(!QDir().mkdir(runFolder_)){error_->setText(QStringLiteral("无法创建独占运行目录"));return;}
    auto env=settings_.environment;
    env.insert("STAGE5_PROFILE",runFolder_+"/profile.jsonl");
    env.insert("STAGE5_STOP_MODE",stopMode_->currentIndex()==0?"drain":"cancel_pending");
    auto args=settings_.arguments;
    if(settings_.threadArgument>=0 &&
settings_.threadArgument<args.size())args[settings_.threadArgument]=threads_-
>currentIndex()==0?"2":"4";

completedAnswers_=0;lastOrderly_=false;stopping_=false;tasks_.clear();profilePartial_.clear();p
rofile_.close();
    profile_.setFileName(runFolder_+"/profile.jsonl");
    error_->clear();answers_->clear();logs_->clear();
    asr_->setText(QStringLiteral("识别文本：等待新会话"));route_->setText(QStringLiteral("路由：
```

```
等待新会话"));
    metrics_->setText(QStringLiteral("延迟: 等待新会话实测"));
    queue_->setText(QStringLiteral("推理等待: 0  TTS 等待: 0（异步事件快照）"));
    if(backend_.start(settings_.program,args,env,runFolder_+"/terminal.log")) {
        start_->setEnabled(false);stop_->setEnabled(true);threads_-
>setEnabled(false);stopMode_->setEnabled(false);
        status_->setText(QStringLiteral("异步启动中"));
        QTextStream(stdout)<<"[GUI run] "<<runFolder_<<Qt::endl;
    } else if(settings_.automatic)QTimer::singleShot(0,this,&QWidget::close);
}
void SessionWindow::stopSession() {
    if(!backend_.active() || stopping_)return;
    stopping_=true;stopClock_.start();backend_.requestStop();stop_->setEnabled(false);
    status_->setText(QStringLiteral("正在协作停止，等待后台线程和资源释放"));
    screenshot("stopping.png");
}
void SessionWindow::closeEvent(QCloseEvent* event) {
    if(backend_.active()){closing_=true;event->ignore();stopSession();return;}
    event->accept();
}
void SessionWindow::screenshot(const QString& leaf) {
    if(!runFolder_.isEmpty() && !grab().save(runFolder_+'/'+leaf))error_-
>setText(QStringLiteral("界面截图保存失败"));
}
void SessionWindow::line(const QString& text) {
    Q_ASSERT(QThread::currentThread()==qApp->thread());
    logs_->appendPlainText(text);QTextStream(stdout)<<text<<Qt::endl;
    const auto module=[this](const char* key,const QString& state){modules_[key]-
>setText(QString::fromLatin1(key)+": "+state);};
    if(text.contains("Loading RKLLM"))module("LLM",QStringLiteral("加载中"));
    if(text.contains("Loading SenseVoice")){module("LLM",QStringLiteral("已加载
"));module("ASR",QStringLiteral("加载中"));}
    if(text.contains("Loading Kokoro")){module("ASR",QStringLiteral("已加载
"));module("TTS",QStringLiteral("加载中"));}
    if(text.contains("[ALSA config]"))module("TTS",QStringLiteral("已加载"));
    if(text.contains("VLM and Camera ready")){module("Camera",QStringLiteral("采集中
"));module("VLM",QStringLiteral("已加载"));}
    if(text.contains("[Listen]") || text.contains("[Replay ready]")){status_-
>setText(text);screenshot("listening.png");}
    if(text.contains("success=false") || text.contains("[Fatal]") || (text.contains("[Init]")
&& text.contains("failed")) || text.contains("rejected #") || text.contains("[TTS
expired"))error_->setText(text);
}
void SessionWindow::pollProfile() {
    if(!backend_.active() && !profile_.isOpen())return; // Do not replay old events while idle.
    if(!profile_.isOpen() && !profile_.fileName().isEmpty() &&
QFile::exists(profile_.fileName()))profile_.open(QIODevice::ReadOnly);
    if(!profile_.isOpen())return;
    profilePartial_+=profile_.read(65536);
    for(int end;(end=profilePartial_.indexOf('\n'))>=0;) {
        const auto bytes=profilePartial_.left(end);profilePartial_.remove(0,end+1);
        const auto object=QJsonDocument::fromJson(bytes).object();
        if(object.value("kind")!="request")continue;
        const auto id=object.value("request_id").toVariant().toULongLong();
        const auto name=object.value("event").toString();
        const auto at=object.value("at_ns").toVariant().toLongLong();
```

```
        const QStringList
timed={"asr_enqueued","asr_begin","asr_end","inference_begin","inference_end","tts_enqueued","t
ts_dequeued","tts_generate_begin","tts_generate_end","alsa_first_submit_begin","request_complet
e"};
        if(timed.contains(name))tasks_[id]["at:"+name].timestamp=at;
        if(name=="asr_text" || name=="input_text")asr_-
>setText((name=="asr_text"?QStringLiteral("识别 #%1: "):QStringLiteral("文本输入 #%1:
")).arg(id)+object.value("text").toString());
        if(name=="router_end")route_->setText(QStringLiteral("路由
#%1: %2").arg(id).arg(object.value("value").toInt()==1?"VISION":"TEXT"));
        if(name=="answer_text")answers_->appendPlainText(QStringLiteral("回答
#%1: %2").arg(id).arg(object.value("text").toString()));
        if(name=="request_error")error_->setText(object.value("text").toString());
        if(name=="request_terminal")status_->setText(object.value("text").toString());
        if(name.contains("rejected") || name.contains("failed") || name.endsWith("_error"))
            error_->setText(QStringLiteral("请求#%1 阶段状态: %2，详情见本轮日志
").arg(id).arg(name));
        if(name.endsWith("_expired") || name.endsWith("_cancelled"))
            status_->setText(QStringLiteral("请求#%1: %2").arg(id).arg(name));
        for(const auto& stage:{QString("inference"),QString("tts")}) {
            if(name==stage+"_enqueued" || name==stage+"_dequeued") {
                auto& record=tasks_[id][stage];

if(at>=record.timestamp){record.timestamp=at;record.pending=name.endsWith("_enqueued");}
            }
        }
        if(name.endsWith("_begin"))status_->setText(QStringLiteral("执行
#%1: %2").arg(id).arg(name));
        if(timed.contains(name)) {
            const auto& task=tasks_[id];
            const auto duration=[&](const char* begin,const char* end) {
                const auto a=task.value("at:"+QString::fromLatin1(begin)).timestamp;
                const auto b=task.value("at:"+QString::fromLatin1(end)).timestamp;
                return a>0 && b>=a?QString::number((b-a)/1e6,'f',1)+" ms":QStringLiteral("未测量
");
            };
            metrics_->setText(QStringLiteral("请求#%1  ASR %2  推理 %3  TTS %4  TTS 排队 %5  ASR
入队→首次提交 %6")
                .arg(id).arg(duration("asr_begin","asr_end"),duration("inference_begin","infere
nce_end"),

duration("tts_generate_begin","tts_generate_end"),duration("tts_enqueued","tts_dequeued"),
                    duration("asr_enqueued","alsa_first_submit_begin")));
        }
        if(name=="request_complete") {
            ++completedAnswers_;screenshot("answer_"+QString::number(completedAnswers_)+".png");
            if(settings_.stopAfterAnswers>0 &&
completedAnswers_>=settings_.stopAfterAnswers)stopSession();
        }
        while(tasks_.size()>64)tasks_.erase(tasks_.begin());
    }
    if(profilePartial_.size()>65536){profilePartial_.clear();error_->setText(QStringLiteral("异
常超长诊断事件，已记录错误"));}
    int inference=0,tts=0;
    for(const auto&
task:tasks_){inference+=task.value("inference").pending;tts+=task.value("tts").pending;}
```

```
    queue_->setText(QStringLiteral("推理等待: %1  TTS 等待: %2（异步事件快照）
").arg(inference).arg(tts));
}
```

完整关键源码 src/gui/main.cpp

```
#include "app/stop_signals.h"
#include "gui/session_window.h"
#include <QApplication>
#include <QCommandLineParser>
#include <QDir>
#include <QFileInfo>
#include <QTextStream>
#include <QScreen>

int main(int argc,char** argv) try {
    StopSignals stopSignals; // Must precede QApplication and every descendant thread.
    QApplication app(argc,argv);
    app.setApplicationName("rk3576_multimodal_gui");
    QCommandLineParser parser;parser.addHelpOption();
    parser.addOption({"capture","ALSA capture device, rediscover HyperX before
launch","device"});
    parser.addOption({"playback","ALSA playback device","device"});
    parser.addOption({"report-root","Existing isolated report directory; each run creates a new
child","path"});
    parser.addOption({"threads","Kokoro threads (2 or 4)","number","4"});
    parser.addOption({"seconds","Finite listening duration, 1..3600","number","120"});
    parser.addOption({"auto-start","Automated regression: click start after event loop
begins"});
    parser.addOption({"stop-after-answers","Automated regression: stop after N successful TTS
answers","number","0"});
    parser.addOption({"cycles","Automated regression: fresh child sessions,
1..4","number","1"});
    parser.process(app);
    const auto env=QProcessEnvironment::systemEnvironment();
    const auto review=env.value("STAGE5_REVIEW");
    const auto reports=QFileInfo(parser.value("report-root")).canonicalFilePath();
    if(review.isEmpty() || reports.isEmpty()
|| !reports.startsWith(QDir(review).canonicalPath()+"/reports/stage5_05_board/"))
        throw std::runtime_error("report-root must be an existing isolated Stage5.5 report
directory");
    const auto number=[&](const char* key,int lo,int hi){bool ok=false;int
n=parser.value(key).toInt(&ok);if(!ok || n<lo || n>hi)throw std::runtime_error("invalid numeric
GUI argument");return n;};
    const int threads=number("threads",2,4),seconds=number("seconds",1,3600);
    if(threads!=2 && threads!=4)throw std::runtime_error("threads must be 2 or 4");
    if(parser.value("capture").isEmpty() || parser.value("playback").isEmpty())throw
std::runtime_error("explicit ALSA devices required");
    for(const auto*
key:{"STAGE5_ASR","STAGE5_VAD","STAGE5_QWEN","STAGE5_KOKORO","STAGE5_VLM","STAGE5_VISION"})
        if(env.value(key).isEmpty())throw std::runtime_error("source and export
stage5_board_paths.sh first");
    GuiLaunch
launch;launch.program="/usr/bin/stdbuf";launch.environment=env;launch.reportRoot=reports;
    launch.arguments=QStringList{"-oL","-
```

```
eL",QCoreApplication::applicationDirPath()+"/asr_llm_tts_smoke",parser.value("capture"),env.val
ue("STAGE5_ASR"),env.value("STAGE5_VAD"),env.value("STAGE5_QWEN"),env.value("STAGE5_KOKORO"),pa
rser.value("playback"),QString::number(seconds),QString::number(threads),"17",env.value("STAGE5
_VLM"),env.value("STAGE5_VISION"),"/dev/video11"};
    launch.automatic=parser.isSet("auto-start");launch.stopAfterAnswers=number("stop-after-
answers",0,32);launch.cycles=number("cycles",1,4);
    SessionWindow window(std::move(launch));
    if(auto* screen=QGuiApplication::primaryScreen()) {
        const auto size=screen->availableGeometry().size();
        window.resize(qMin(980,size.width()-40),qMin(700,size.height()-60));
    }
    window.show();
    QTimer pollSignals;pollSignals.setInterval(100);
    QObject::connect(&pollSignals,&QTimer::timeout,&window,[&] {
        if(stopSignals.received() || stopSignals.failed())window.close();
    });pollSignals.start();
    const int code=app.exec();
    return code?code:(stopSignals.failed() || !window.verified()?1:0);
} catch(const std::exception& error) {
    QTextStream(stderr)<<"[GUI fatal] "<<error.what()<<Qt::endl;return 1;
}
```

完整关键源码 src/audio/asr_llm_tts_smoke.cpp

```
#include "app/stop_signals.h"

#include "audio/asr_pipeline.h"
#include "app/pipeline_admission.h"
#include "app/pipeline_metrics.h"
#include "app/profiling_inputs.h"
#include <fstream>
#include "audio/asr_service.h"
#include "audio/vad_audio_worker.h"
#include "audio/tts_service.h"
#include "audio/alsa_playback_service.h"
#include "audio/tts_worker.h"

#include "ai/llm_worker.h"
#include "ai/rk_backends.h"
#include "router/intent_router.h"
#include "ai/vlm_engine.h"
#include "video/camera_service.h"
#include "video/latest_frame_buffer.h"

#include <chrono>
#include <algorithm>
#include <fstream>
#include <sstream>
#include <cstdlib>
#include <atomic>
#include <cerrno>
#include <condition_variable>
#include <cstddef>
#include <cstdint>
#include <exception>
```

```cpp
#include <iostream>
#include <memory>
#include <mutex>
#include <stdexcept>
#include <string>
#include <utility>
#include <thread>

#include <pthread.h>
#include <signal.h>

#include <unistd.h>



// ============================================================
// Stage 3.5
//
// ALSA Capture
//     ↓
// Silero VAD
//     ↓
// SenseVoice ASR
//     ↓
// IntentRouter
//     ↓
// LLMWorker -> RKLLM / Qwen2.5
//     ↓
// TTSWorker -> Kokoro
//     ↓
// AlsaPlaybackService
//     ↓
// USB Headset
//
// TEXT and VISION share one asynchronous bounded inference FIFO.
// ============================================================

int main(int argc, char** argv) try
{
    // ---------------------------------------------------------
    // 1. 命令行参数检查
    // ---------------------------------------------------------

    if (argc < 7 || (argc > 10 && argc != 13))
    {
        std::cerr
            << "Usage: asr_llm_tts_smoke "
            << "<capture_device> "
            << "<asr_model_dir> "
            << "<vad_model> "
            << "<rkllm_model> "
            << "<kokoro_dir> "
            << "<playback_device> "
            << "[record_seconds=12] "
            << "[tts_threads=4] "
            << "[sid=17] "
            << "[vlm_rkllm vision_rknn camera_device]\n";
```

```
    return 2;
}

const std::string capture_device = argv[1];
const std::string asr_dir = argv[2];
const std::string vad_model = argv[3];
const std::string llm_model = argv[4];
const std::string kokoro_dir = argv[5];
const std::string playback_device = argv[6];

unsigned int record_seconds = 12;

int tts_threads = 4;
int sid = 17;

// 兼容旧命令。新增三项参数时启用完整视觉语音链路。
// 语音模式须传三个原有可选参数，再传 VLM 模型与 Camera 设备。
const bool enable_vision = (argc == 13);
const std::string vlm_model = enable_vision ? argv[10] : "";
const std::string vision_model = enable_vision ? argv[11] : "";
const std::string camera_device = enable_vision ? argv[12] : "";

// ------------------------------------------------------
// 2. 解析可选参数
// ------------------------------------------------------

try
{
    const auto parse = [](
        const char* arg,
        int lo,
        int hi
    ) -> int
    {
        const std::string value(arg);

        std::size_t used = 0;

        const int result =
            std::stoi(value, &used);

        if (used != value.size() ||
            result < lo ||
            result > hi)
        {
            throw std::invalid_argument(
                "out of range"
            );
        }

        return result;
    };

    if (argc >= 8)
    {
        record_seconds =
            static_cast<unsigned int>(
```

```
                parse(argv[7], 1, 3600)
            );
    }

    if (argc >= 9)
    {
        tts_threads =
            parse(argv[8], 1, 8);
    }

    if (argc >= 10)
    {
        sid =
            parse(argv[9], 0, 10000);
    }
}
catch (const std::exception&)
{
    std::cerr
        << "[Args] Invalid record_seconds / "
        << "threads / sid\n";

    return 2;
}

// ------------------------------------------------------
// 3. 检查 ASR / VAD / LLM 模型文件
// ------------------------------------------------------

const std::string asr_model =
    asr_dir + "/model.int8.onnx";

const std::string asr_tokens =
    asr_dir + "/tokens.txt";

for (const auto& path :
     {asr_model, asr_tokens, vad_model, llm_model})
{
    if (::access(path.c_str(), R_OK) != 0)
    {
        std::cerr
            << "[Init] Cannot read model file: "
            << path
            << '\n';

        return 1;
    }
}

if (enable_vision)
{
    for (const auto& path : {vlm_model, vision_model})
    {
        if (::access(path.c_str(), R_OK) != 0)
        {
            std::cerr << "[Init] Cannot read VLM file: " << path << '\n';
            return 1;
        }
```

```
    }
}

std::string error;

StopSignals stop_signals;

// ------------------------------------------------------
// 4. 初始化 RKLLM
// ------------------------------------------------------

LLMEngine llm(
    std::make_unique<RKLLMBackend>()
);

std::cout
    << "[Init] Loading RKLLM...\n"
    << std::flush;

if (!llm.initialize(
        BackendConfig{llm_model, {}},
        error))
{
    std::cerr
        << "[Init] RKLLM failed: "
        << error
        << '\n';

    return 1;
}

// ------------------------------------------------------
// 5. 初始化 SenseVoice
// ------------------------------------------------------

ASRService asr;

std::cout
    << "[Init] Loading SenseVoice...\n"
    << std::flush;

if (!asr.initialize(
        asr_model,
        asr_tokens,
        error))
{
    std::cerr
        << "[Init] ASR failed: "
        << error
        << '\n';

    llm.shutdown();

    return 1;
}

// ------------------------------------------------------
```

```
// 6. 初始化 Kokoro TTS
// ------------------------------------------------------

TTSService tts;

std::cout
    << "[Init] Loading Kokoro...\n"
    << std::flush;

if (!tts.initialize(
        kokoro_dir,
        error,
        tts_threads,
        sid))
{
    std::cerr
        << "[Init] Kokoro failed: "
        << error
        << '\n';

    llm.shutdown();

    return 1;
}

// ------------------------------------------------------
// 7. 初始化 ALSA Playback
// ------------------------------------------------------

AlsaPlaybackService playback;

if (!playback.open(
        playback_device,
        tts.sampleRate(),
        error))
{
    std::cerr
        << "[Init] ALSA playback failed: "
        << error
        << '\n';

    llm.shutdown();

    return 1;
}

// Callback state precedes workers: reverse destruction joins workers first.
// ------------------------------------------------------
// 10. 创建 ASR 音频队列和线程同步对象
// ------------------------------------------------------

AudioBufferQueue audio_queue(4);

// 保护不同线程的日志输出。
std::mutex print_mutex;

// 保护 LLM/TTS 任务完成计数。
```

```
    std::mutex state_mutex;

    // 通知主线程有任务完成。
    std::condition_variable completed_cv;

    IntentRouter router;

    // 由单个 ASRWorker 回调生成请求 ID。
    std::uint64_t next_id = 1;

    const int max_inflight = pipelineEnv("STAGE5_MAX_INFLIGHT", 2, 1, 8);
    const int request_lifetime_ms = pipelineEnv("STAGE5_REQUEST_LIFETIME_MS", 45000, 1, 300000);
    const int inference_queue_ms = pipelineEnv("STAGE5_INFERENCE_QUEUE_MS", 10000, 1, 60000);
    const int tts_queue_ms = pipelineEnv("STAGE5_TTS_QUEUE_MS", 12000, 1, 60000);
    const char* stop_value = std::getenv("STAGE5_STOP_MODE");
    const std::string stop_mode = stop_value ? stop_value : "drain";
    if (stop_mode != "drain" && stop_mode != "cancel_pending") throw
std::invalid_argument("Invalid STAGE5_STOP_MODE");
    PipelineAdmission admission(static_cast<std::size_t>(max_inflight));
    std::size_t dispatch_calls=0, pipeline_rejected=0, cancelled_before_submit=0;
    std::size_t vision_accepted=0, vision_rejected=0;
    std::size_t llm_cancelled=0, llm_expired=0, vision_cancelled=0, vision_expired=0;
    std::size_t tts_cancelled=0, tts_expired=0, downstream_cancelled=0;
    // Must outlive the asynchronous inference worker, including exception unwinding.
    LatestFrameBuffer frames;
    std::unique_ptr<CameraService> camera;
    std::unique_ptr<VLMEngine> vlm;
    LatestFrameBuffer::FramePtr profiling_frame;
    if(const char* folder=std::getenv("STAGE5_REPLAY_FRAME_DIR")){
        if(!enable_vision || (!std::getenv("STAGE5_REPLAY_FILE")
&& !std::getenv("STAGE5_REPLAY_AUDIO_FILE")))throw std::invalid_argument("Fixed frame is
allowed only with explicit replay and VISION");
        profiling_frame=loadProfilingFrame(folder);
        std::cout<<"[InputMode] fixed NV12 for replay VLM; Camera still captures
independently\n";
    }

    // ------------------------------------------------------
    // 11. LLM 和 TTS 统计
    // ------------------------------------------------------

    std::size_t llm_accepted = 0;
    std::size_t llm_completed = 0;
    std::size_t llm_successful = 0;
    std::size_t llm_failed = 0;
    std::size_t llm_rejected = 0;

    std::size_t skipped_vision = 0;
    std::size_t vision_completed = 0;
    std::size_t vision_successful = 0;
    std::size_t vision_failed = 0;

    std::size_t tts_accepted = 0;
    std::size_t tts_completed = 0;
    std::size_t tts_successful = 0;
    std::size_t tts_failed = 0;
    std::size_t tts_rejected = 0;
```

```
std::size_t tts_empty = 0;

// ------------------------------------------------------
// 8. 创建并启动 TTSWorker
// ------------------------------------------------------
//
// TTSWorker 不拥有 TTSService 和 PlaybackService。
// 两个 Service 必须比 Worker 活得更久。
//
// capacity=2 表示最多允许两个等待任务。
// ------------------------------------------------------

TTSWorker tts_worker(
    tts,
    playback,
    2
);

if (!tts_worker.start(error))
{
    std::cerr
        << "[Init] TTSWorker failed: "
        << error
        << '\n';

    llm.shutdown();

    return 1;
}

// ------------------------------------------------------
// 9. 创建并启动 LLMWorker
// ------------------------------------------------------

LLMWorker llm_worker(
    llm,
    2
);

if (!llm_worker.start(error))
{
    std::cerr
        << "[Init] LLMWorker failed: "
        << error
        << '\n';

    tts_worker.requestStop();
    tts_worker.join();

    llm.shutdown();

    return 1;
}

// Stage 4: 正式 Camera + VLM Backend。保持旧的 TEXT 链路不变。
if (enable_vision)
{
```

```
        constexpr std::uint32_t nv12 = std::uint32_t('N') |
            (std::uint32_t('V') << 8) |
            (std::uint32_t('1') << 16) |
            (std::uint32_t('2') << 24);

        camera = std::make_unique<CameraService>(
            camera_device, 3840, 2160, nv12, frames);
        if (!camera->start())
        {
            std::cerr << "[Init] Camera failed: "
                      << camera->stats().last_error << '\n';
            llm_worker.requestStop();
            llm_worker.join();
            tts_worker.requestStop();
            tts_worker.join();
            llm.shutdown();
            return 1;
        }

        vlm = std::make_unique<VLMEngine>(
            std::make_unique<RK3576VLMBackend>());
        std::cout << "[Init] Loading SmolVLM2 RKNN + RKLLM...\n"
                  << std::flush;
        if (!vlm->initialize(
            BackendConfig{vlm_model, vision_model}, error))
        {
            std::cerr << "[Init] VLM failed: " << error << '\n';
            camera->stop();
            llm_worker.requestStop();
            llm_worker.join();
            tts_worker.requestStop();
            tts_worker.join();
            llm.shutdown();
            return 1;
        }
        std::cout << "[Init] VLM and Camera ready\n";
    }

    // ------------------------------------------------------
    // 12. ASR 识别完成回调
    // ------------------------------------------------------
    //
    // 此回调在 ASRWorker 线程执行。
    //
    // recognized 是 SenseVoice 的识别结果。
    // ------------------------------------------------------

    const auto on_text =
        [&](const std::string& recognized, RequestTracePtr supplied_trace = {})
    {
        const bool recognized_by_asr=static_cast<bool>(supplied_trace);
        const auto request_id = supplied_trace ? supplied_trace->id() : next_id++;
        if(supplied_trace)next_id=std::max(next_id,request_id+1);
        const auto trace=supplied_trace ? std::move(supplied_trace) :
makeRequestTrace(request_id);
        RequestTraceScope trace_scope(trace);
        if(trace)trace->text(recognized_by_asr?"asr_text":"input_text",recognized);
```

```
        traceMark("business_dispatch_begin");
        DispatchTimer dispatch_timer{print_mutex, ++dispatch_calls};
        // ------------------------------------------------
        // 12.1 意图判断
        // ------------------------------------------------

        const RouteDecision route =
            router.route(recognized);

        auto ticket = admission.tryAcquire(request_id,
std::chrono::milliseconds(request_lifetime_ms));
        if (!ticket)
        {
            traceMark("pipeline_rejected_busy");
            ++pipeline_rejected;
            std::lock_guard<std::mutex> out(print_mutex);
            std::cout << "[Pipeline rejected #" << request_id << "] route=" <<
requestTypeName(route.type)
                      << " reason=busy_or_closed limit=" << max_inflight << '\n';
            return;
        }

        if (route.type == RequestType::Vision)
        {
            if (!enable_vision || !vlm)
            {
                traceMark("vision_disabled");
                ++skipped_vision;
                std::lock_guard<std::mutex> out(print_mutex);
                std::cout << "\n[Route] VISION disabled: "
                          << recognized << '\n';
                return;
            }

            const auto question_at = std::chrono::steady_clock::now();
            // 先复用已在实机验证的英语单图问答；中文语音负责触发路由。
            // 避免 256M 模型不稳定的中文指令影响最终闭环验收。
            const std::string vlm_question =
                "What do you see? Answer briefly.";

            {
                std::lock_guard<std::mutex> out(print_mutex);
                std::cout << "\n[ASR->VISION #" << request_id << "] "
                          << recognized << '\n';
            }

            const auto status = llm_worker.submitTask(request_id,
                [&, vlm_question](const LLMStreamCallback&) {
                    // Fetch a fresh owned frame when the task executes, never pin queued full
frames.
                    return vlm->infer(profiling_frame?profiling_frame:frames.getLatest(),
vlm_question);
                }, {},
                [&, question_at, ticket, trace](std::uint64_t request_id, const
InferenceResult& result, double inference_wait_ms)
                {
                    if(trace)trace-
```

```
>text(result.success?"answer_text":result.disposition==TaskDisposition::Completed?"request_erro
r":"request_terminal",result.success?result.text:result.error_message);
                    {
                        std::lock_guard<std::mutex> lock(state_mutex);
                        ++vision_completed;
                        if (result.disposition==TaskDisposition::Cancelled) ++vision_cancelled;
                        else if (result.disposition==TaskDisposition::Expired) ++vision_expired;
                        else if (result.success && !result.text.empty()) ++vision_successful;
                        else ++vision_failed;
                    }

                    {
                        std::lock_guard<std::mutex> out(print_mutex);
                        std::cout << "[VLM done #" << request_id << "] success="
                                  << (result.success ? "true" : "false")
                                  << " queue_ms=" << inference_wait_ms
                                  << " disposition=" << dispositionName(result.disposition)
                                  << " frame_id=" << result.frame_id
                                  << " frame_age_ms=" << result.frame_age_ms
                                  << " latency_ms=" << result.latency_ms
                                  << '\n';
                        if (result.success)
                            std::cout << "[VLM Answer #" << request_id << "] "
                                      << result.text << '\n';
                        else
                            std::cout << (result.disposition==TaskDisposition::Completed ?
"[VLM Error] " : "[VLM terminal] ") << result.error_message << '\n';
                    }

                    if (result.success && !result.text.empty() && ticket->cancelled())
                    {
                        { std::lock_guard<std::mutex> lock(state_mutex);
++downstream_cancelled; }
                        std::lock_guard<std::mutex> out(print_mutex);
                        std::cout << "[Pipeline downstream cancelled #" << request_id << "]
stage=tts\n";
                    }
                    if (result.success && !result.text.empty() && !ticket->cancelled())
                    {
                        const auto status = tts_worker.submit(
                            request_id, result.text,
                            [&, question_at, ticket](
                                std::uint64_t done_id,
                                const TTSWorkerResult& outcome,
                                double queue_ms)
                            {
                                const double e2e_ms = std::chrono::duration<
                                    double, std::milli>(
                                    std::chrono::steady_clock::now() - question_at
                                ).count();
                                {
                                    std::lock_guard<std::mutex> out(print_mutex);
                                    std::cout << "[VISION TTS done #" << done_id
                                              << "] success="
                                              << (outcome.success ? "true" : "false")
                                              << " queue_ms=" << queue_ms
                                              << " synth_ms=" << outcome.synthesis_ms
                                              << " playback_ms=" << outcome.playback_ms
```

```
                                            << " asr_text_to_end_ms=" << e2e_ms
                                            << '\n';
                                    if (!outcome.success)
                                        std::cout <<
(outcome.disposition==TaskDisposition::Completed ? "[TTS error] " : "[TTS terminal] ")
                                                  << outcome.error_message << '\n';
                                }
                                {
                                    std::lock_guard<std::mutex> lock(state_mutex);
                                    ++tts_completed;
                                    if (outcome.success) ++tts_successful;
                                    else if (outcome.disposition==TaskDisposition::Cancelled)
++tts_cancelled;
                                    else if (outcome.disposition==TaskDisposition::Expired)
++tts_expired;
                                    else ++tts_failed;
                                }
                                completed_cv.notify_all();
                    }, ticket->options(std::chrono::milliseconds(tts_queue_ms), trace));

                {
                    std::lock_guard<std::mutex> lock(state_mutex);
                    if (status == TTSSubmitStatus::Accepted)
                        ++tts_accepted;
                    else
                        ++tts_rejected;
                }
                if (status != TTSSubmitStatus::Accepted)
                {
                    std::lock_guard<std::mutex> out(print_mutex);
                    std::cout << "[VISION TTS rejected #" << request_id
                              << "] status=" << static_cast<int>(status)
                              << '\n';
                }
            }
            else if (result.success && result.text.empty())
            {
                std::lock_guard<std::mutex> lock(state_mutex);
                ++tts_empty;
            }
            // Inference/done run on the shared worker; ASR only submits.
                }, ticket->options(std::chrono::milliseconds(inference_queue_ms), trace));
            {
                std::lock_guard<std::mutex> lock(state_mutex);
                if (status==LLMSubmitStatus::Accepted) ++vision_accepted;
                else if (status==LLMSubmitStatus::NotRunning && ticket->cancelled())
++cancelled_before_submit;
                else ++vision_rejected;
            }
            if (status!=LLMSubmitStatus::Accepted)
            {
                std::lock_guard<std::mutex> out(print_mutex);
                std::cout << (ticket->cancelled() ? "[VISION submission cancelled #" : "[VISION
rejected #") << request_id << "] status=" << static_cast<int>(status) << '\n';
            }
            return;
        }
```

```
// ------------------------------------------------
// 12.2 分配请求 ID
// ------------------------------------------------

const std::uint64_t id =
    request_id;

// 记录 ASR 输出文本的时刻。
const auto question_at =
    std::chrono::steady_clock::now();

// 记录 LLM 是否已经输出前缀。
auto prefix_printed =
    std::make_shared<bool>(false);

{
    std::lock_guard<std::mutex>
        out(print_mutex);

    std::cout
        << "\n[ASR->LLM #" << id << "] "
        << recognized
        << '\n';
}

// ------------------------------------------------
// 12.3 构造 LLM Prompt
// ------------------------------------------------
//
// 限制回答长度，降低当前 Kokoro 的合成等待。
// 不改变 ASR 原始文本。
// ------------------------------------------------

const std::string prompt =
    recognized +
    "\n 请直接用一句话回答，不超过 25 个汉字。";

// ------------------------------------------------
// 12.4 非阻塞提交 LLMWorker
// ------------------------------------------------

const auto status =
    llm_worker.submit(
        id,
        prompt,

        // ----------------------------------------
        // LLM 流式文本回调
        // ----------------------------------------

        [&, prefix_printed](
            std::uint64_t request_id,
            const std::string& chunk)
        {
            if (chunk.empty())
            {
                return;
```

```
                    }

                    std::lock_guard<std::mutex>
                        out(print_mutex);

                    if (!*prefix_printed)
                    {
                        std::cout
                            << "\n[LLM #"
                            << request_id
                            << "] ";

                        *prefix_printed = true;
                    }

                    std::cout
                        << chunk
                        << std::flush;
                },

                // ----------------------------------------
                // LLM 推理完成回调
                // ----------------------------------------
                //
                // 关键: 这里把 LLM 答案交给 TTSWorker。
                // ----------------------------------------

                [&, prefix_printed, question_at, ticket, trace](
                    std::uint64_t request_id,
                    const InferenceResult& result,
                    double llm_queue_ms)
                {
                    if(trace)trace-
>text(result.success?"answer_text":result.disposition==TaskDisposition::Completed?"request_erro
r":"request_terminal",result.success?result.text:result.error_message);
                    {
                        std::lock_guard<std::mutex>
                            out(print_mutex);

                        if (*prefix_printed)
                        {
                            std::cout << '\n';
                        }

                        std::cout
                            << "[LLM done #"
                            << request_id
                            << "] success="
                            << (result.success
                                ? "true"
                                : "false")
                            << " queue_ms="
                            << llm_queue_ms
                            << " first_text_ms="
                            << result.first_text_ms
                            << " latency_ms="
                            << result.latency_ms
```

```
                        << '\n';

                    if (!result.success)
                    {
                        std::cout
                            << (result.disposition==TaskDisposition::Completed ? "[LLM
error] " : "[LLM terminal] ")
                            << result.error_message
                            << '\n';
                    }
                }

                // -------------------------------------
                 // 12.5 判断 LLM 是否产生有效文本
                // -------------------------------------

                TTSSubmitStatus tts_status =
                    TTSSubmitStatus::NotRunning;

                std::string tts_submit_error;

                if (result.success && !result.text.empty() && ticket->cancelled())
                {
                    { std::lock_guard<std::mutex> lock(state_mutex);
++downstream_cancelled; }
                    std::lock_guard<std::mutex> out(print_mutex);
                    std::cout << "[Pipeline downstream cancelled #" << request_id << "]
stage=tts\n";
                }
                const bool has_answer =
                    result.success &&
                    !result.text.empty() && !ticket->cancelled();

                if (has_answer)
                {
                    try
                    {
                        // ------------------------------
                         // 12.6 向 TTSWorker 提交答案
                        // ------------------------------

                        tts_status =
                            tts_worker.submit(
                                request_id,
                                result.text,

                                // ----------------------
                                 // TTS 完成回调
                                // ----------------------

                                [&, question_at, ticket](
                                    std::uint64_t tts_id,
                                    const TTSWorkerResult& tts_result,
                                    double tts_queue_ms)
                                {
                                     // 从 ASR 输出文本到
                                     // 播放任务结束的耗时。
```

```
                                        const double e2e_ms =
                                            std::chrono::duration<
                                                double,
                                                std::milli
                                            >(
                                                std::chrono::
                                                    steady_clock::now()
                                                - question_at
                                            ).count();

                                        {
                                            std::lock_guard<
                                                std::mutex
                                            > out(print_mutex);

                                            std::cout
                                                << "[TTS done #"
                                                << tts_id
                                                << "] success="
                                                << (tts_result.success
                                                    ? "true"
                                                    : "false")
                                                << " queue_ms="
                                                << tts_queue_ms
                                                << " synth_ms="
                                                << tts_result.synthesis_ms
                                                << " audio_sec="
                                                << tts_result.audio_seconds
                                                << " playback_ms="
                                                << tts_result.playback_ms
                                                << " xruns="
                                                << tts_result.xrun_count
                                                << " asr_text_to_end_ms="
                                                << e2e_ms
                                                << '\n';

                                            if (!tts_result.success)
                                            {
                                                std::cout
                                                    <<
(tts_result.disposition==TaskDisposition::Completed ? "[TTS error] " : "[TTS terminal] ")
                                                    << tts_result.error_message
                                                    << '\n';
                                            }
                                        }

                                        // ------------------
                                         // 更新 TTS 任务统计
                                        // ------------------

                                        {
                                            std::lock_guard<
                                                std::mutex
                                            > lock(state_mutex);

                                            ++tts_completed;

                                            if (tts_result.success)
```

```
                                            {
                                                ++tts_successful;
                                            }
                                            else if
(tts_result.disposition==TaskDisposition::Cancelled) ++tts_cancelled;
                                            else if
(tts_result.disposition==TaskDisposition::Expired) ++tts_expired;
                                            else ++tts_failed;
                                        }

                                         // 唤醒等待中的主线程。
                                        completed_cv.notify_all();
                                    }, ticket->options(std::chrono::milliseconds(tts_queue_ms),
trace)
                                );
                            }
                            catch (const std::exception& e)
                            {
                                tts_submit_error = e.what();
                            }
                            catch (...)
                            {
                                tts_submit_error =
                                    "unknown exception";
                            }

                            // ---------------------------------
                             // 12.7 处理 TTS 提交失败
                            // ---------------------------------

                            if (tts_status !=
                                TTSSubmitStatus::Accepted)
                            {
                                std::lock_guard<std::mutex>
                                    out(print_mutex);

                                std::cout
                                    << "[TTS rejected #"
                                    << request_id
                                    << "] ";

                                if (!tts_submit_error.empty())
                                {
                                    std::cout
                                        << tts_submit_error;
                                }
                                else if (
                                    tts_status ==
                                    TTSSubmitStatus::QueueFull)
                                {
                                    std::cout
                                        << "queue full";
                                }
                                else
                                {
                                    std::cout
                                        << "not running";
```

```
                        }

                        std::cout << '\n';
                    }
                }
                else if (result.success)
                {
                     // LLM 成功但回答为空,
                     // 不能向 TTS 提交空文本。
                    std::lock_guard<std::mutex>
                        out(print_mutex);

                    std::cout
                        << "[TTS skipped #"
                        << request_id
                        << "] LLM returned empty answer\n";
                }

                // ------------------------------------
                 // 12.8 更新任务计数
                // ------------------------------------
                //
                 // 重要:
                 // 先提交 TTS, 再标记 LLM completed。
                //
                 // 这样主线程等完所有 LLM 后,
                 // 就能确认不再产生新的 TTS 请求。
                // ------------------------------------

                {
                    std::lock_guard<std::mutex>
                        lock(state_mutex);

                    ++llm_completed;

                    if (result.success)
                    {
                        ++llm_successful;
                    }
                    else if (result.disposition==TaskDisposition::Cancelled)
++llm_cancelled;
                    else if (result.disposition==TaskDisposition::Expired) ++llm_expired;
                    else ++llm_failed;

                    if (result.success &&
                        result.text.empty())
                    {
                        ++tts_empty;
                    }

                    if (has_answer)
                    {
                        if (tts_status ==
                            TTSSubmitStatus::Accepted)
                        {
                            ++tts_accepted;
                        }
```

```
                            else
                            {
                                ++tts_rejected;
                            }
                        }
                    }

                    completed_cv.notify_all();
                }, ticket->options(std::chrono::milliseconds(inference_queue_ms), trace)
            );

        // ------------------------------------------------
        // 12.9 处理 LLM 任务提交结果
        // ------------------------------------------------

        if (status == LLMSubmitStatus::Accepted)
        {
            std::lock_guard<std::mutex>
                lock(state_mutex);

            ++llm_accepted;
        }
        else
        {
            // 只有 ASRWorker 修改该计数。
            {
                std::lock_guard<std::mutex> lock(state_mutex);
                if (status==LLMSubmitStatus::NotRunning && ticket->cancelled())
++cancelled_before_submit;
                else ++llm_rejected;
            }

            std::lock_guard<std::mutex>
                out(print_mutex);

            std::cout
                << (ticket->cancelled() ? "[LLM submission cancelled #" : "[LLM rejected #")
                << id
                << "] "
                << (status ==
                    LLMSubmitStatus::QueueFull
                    ? "queue full"
                    : "not running")
                << '\n';
        }
    };

    // ------------------------------------------------
    // 13. 创建 ASRWorker 和 VadAudioWorker
    // ------------------------------------------------

    ASRWorker consumer(
        audio_queue,
        asr,
        print_mutex,
        {},
        [&](const std::string& text,const AudioSegment& segment){on_text(text,segment.trace);}
```

```
    );

    VadAudioWorker producer(
        capture_device,
        vad_model,
        audio_queue,
        print_mutex,
        record_seconds
    );

    const char* replay_path=std::getenv("STAGE5_REPLAY_FILE");
    const char* audio_replay_path=std::getenv("STAGE5_REPLAY_AUDIO_FILE");
    if(replay_path && audio_replay_path)throw std::invalid_argument("Text and audio replay are
mutually exclusive");
    const bool replay_mode=replay_path!=nullptr || audio_replay_path!=nullptr;
    if (!replay_mode)
    {
        std::cout
            << "[Listen] "
            << record_seconds
            << " seconds. "
            << (enable_vision ? "Ask ONE short voice question (text or camera).\n"
                              : "Ask ONE short text question and pause.\n")
            << std::flush;
    }
    else std::cout << (audio_replay_path?"[Replay ready] fixed presegmented audio; real ASR, no
microphone/VAD\n":"[Replay ready] controlled text; microphone/VAD/ASR not run\n") << std::flush;

    // -------------------------------------------------------
    // 14. 启动录音/VAD 和 ASR 工作线程
    // -------------------------------------------------------

    if (replay_mode)
    {
        std::ifstream input(audio_replay_path?audio_replay_path:replay_path);
        if (!input) throw std::runtime_error("Cannot open replay input");
        std::cout << (audio_replay_path?"[InputMode] replay_audio
REAL_ASR_NO_MICROPHONE_OR_VAD\n":"[InputMode] replay_only NO_MICROPHONE_ASR_OR_VAD_INFERENCE\n")
<< std::flush;
        if(audio_replay_path)consumer.start();
        const auto replay_start=std::chrono::steady_clock::now();
        std::uint64_t audio_replay_sequence=1; // Producer-only; next_id belongs to the ASR
callback thread.
        std::string line;
        while (std::getline(input,line))
        {
            if (line.empty()) continue;
            const auto tab=line.find('\t');
            if (tab==std::string::npos) throw std::runtime_error("Invalid replay line");
            std::size_t used=0;
            const long delay=std::stol(line.substr(0,tab),&used);
            if (used!=tab || delay<0 || delay>3600000) throw std::runtime_error("Invalid replay
offset");
            const auto scheduled=replay_start+std::chrono::milliseconds(delay);
            while(stop_signals.received()==0 && std::chrono::steady_clock::now()<scheduled)
                std::this_thread::sleep_for(std::chrono::milliseconds(20));
            if (stop_signals.received()!=0) break;
            std::cout << "[Replay] scheduled_ms=" << delay << (audio_replay_path?"
```

```
source=fixed_audio\n":" source=controlled_text\n") << std::flush;
            if(audio_replay_path){
                AudioSegment segment;segment.sequence=audio_replay_sequence++;
                segment.trace=makeRequestTrace(segment.sequence);
                segment.samples=loadProfilingAudio(line.substr(tab+1));
                segment.enqueued_at=std::chrono::steady_clock::now();
                if(segment.trace)segment.trace->mark("offline_audio_ready",segment.enqueued_at);
                if(!audio_queue.push(std::move(segment)))throw std::runtime_error("Audio replay
queue closed");
            }else on_text(line.substr(tab+1));
        }
        audio_queue.close();
        if(audio_replay_path)consumer.join();
    }
    else
    {
    try
    {
        // ASR 消费者先启动。
        consumer.start();

        // VAD 录音生产者后启动。
        producer.start();
    }
    catch (const std::exception& e)
    {
        std::cerr
            << "[Start] Cannot start capture/ASR thread: "
            << e.what()
            << '\n';

        producer.requestStop();
        audio_queue.close();

        producer.join();
        consumer.join();

        llm_worker.requestStop();
        llm_worker.join();

        tts_worker.requestStop();
        tts_worker.join();

        llm.shutdown();

        return 1;
    }

    // ------------------------------------------------------
    // 15. 等待录音/VAD 和 ASR 完成
    // ------------------------------------------------------

    bool stop_reported = false;
    while (!producer.isFinished())
    {
        if (stop_signals.received() != 0 || stop_signals.failed())
        {
```

```
            producer.requestStop();
            if (stop_mode == "cancel_pending")
            {
                admission.close(true);
                llm_worker.requestStop(StopMode::CancelPending);
            }
            if (!stop_reported)
            {
                std::lock_guard<std::mutex> out(print_mutex);
                std::cout << "[Shutdown] signal=" << stop_signals.received()
                          << " stopping capture; draining accepted work\n" << std::flush;
                stop_reported = true;
            }
        }
        std::this_thread::sleep_for(std::chrono::milliseconds(20));
    }
    producer.join();

    consumer.join();
    }
    asr.shutdown();
    admission.close(false);
    std::cout << (replay_mode ? "[Shutdown] replay input closed; recognizer destroyed\n" :
"[Shutdown] capture/VAD and ASR joined; recognizer destroyed\n") << std::flush;

    // 此时 ASRWorker 已经退出,
    // 不会继续向 LLMWorker 提交新请求。

    // ------------------------------------------------------
    // 16. 通用 Worker 完成等待函数
    // ------------------------------------------------------
    //
    // 在等待期间, 主线程每 2 秒输出一次进度。
    //
    // accepted / completed 都必须由 state_mutex 保护。
    // ------------------------------------------------------

    const auto wait_for_jobs = [&](const char* stage, auto& worker, int deadline_seconds) ->
bool
    {
        const auto
deadline=std::chrono::steady_clock::now()+std::chrono::seconds(deadline_seconds);
        while (!worker.waitIdleFor(std::chrono::milliseconds(100)))
        {
            if ((stop_signals.received()!=0 || stop_signals.failed()) &&
stop_mode=="cancel_pending")
            {
                admission.close(true);
                llm_worker.requestStop(StopMode::CancelPending);
            }
            if (std::chrono::steady_clock::now()>=deadline)
            {
                std::cerr << "[Timeout] " << stage << " did not become idle\n";
                return false;
            }
        }
        return true;
```

```
};

// ------------------------------------------------------
// 17. 等待全部 LLM 任务完成
// ------------------------------------------------------

const bool llm_drained =
    wait_for_jobs(
        "LLM",
        llm_worker,
        180
    );

if (!llm_drained)
{
    std::cerr
        << "[Timeout] LLM tasks "
        << "did not finish in 180s\n";
}

// ------------------------------------------------------
// 18. 停止 LLMWorker
// ------------------------------------------------------
//
// 必须等 LLMWorker 完全停止,
// 才能确认不会再向 TTSWorker 提交任务。
// ------------------------------------------------------

llm_worker.requestStop();
llm_worker.join();

// LLM 不再被工作线程访问后,
// 才允许释放 RKLLM Runtime。
llm.shutdown();

std::cout << "[Shutdown] LLM joined; Qwen runtime destroyed\n" << std::flush;

// ------------------------------------------------------
// 19. 等待全部 TTS 任务完成
// ------------------------------------------------------
//
// 必须先等待 accepted == completed,
// 然后再 requestStop。
//
// 否则会把队列中等待的 TTS 任务取消。
// ------------------------------------------------------

const bool tts_drained =
    wait_for_jobs(
        "TTS",
        tts_worker,
        600
    );

if (!tts_drained)
{
    std::cerr
```

```
        << "[Timeout] TTS tasks "
        << "did not finish in 600s\n";
}

// ------------------------------------------------------
// 20. 停止 TTSWorker
// ------------------------------------------------------

tts_worker.requestStop();
tts_worker.join();

std::cout << "[Shutdown] TTS joined; playback_xruns=" << playback.xrunCount()
          << '\n' << std::flush;

// 只有 Worker 退出以后,
// 才能安全关闭 ALSA 和 TTSService。
playback.close();
tts.shutdown();
if (camera) camera->stop();
if (vlm) vlm->shutdown();
std::cout << "[Shutdown] playback/TTS closed; Camera stopped; VLM destroyed\n"
          << "[Shutdown] complete signal=" << stop_signals.received() << '\n'
          << std::flush;

// ------------------------------------------------------
// 21. 输出整个语音交互链路的统计
// ------------------------------------------------------

{
    std::lock_guard<std::mutex>
        out(print_mutex);

    std::cout
        << "\n=== ASR -> LLM -> TTS summary ===\n"

        << "VAD segments: "
        << producer.producedCount()
        << '\n'

        << "ASR recognized: "
        << consumer.processedCount()
        << '\n'

        << "Audio queue dropped: "
        << audio_queue.droppedCount()
        << '\n'

        << "LLM accepted/completed/"
        << "success/failed/rejected: "
        << llm_accepted
        << '/'
        << llm_completed
        << '/'
        << llm_successful
        << '/'
        << llm_failed
        << '/'
```

```
            << llm_rejected
            << '\n'

            << "TTS accepted/completed/"
            << "success/failed/rejected/empty: "
            << tts_accepted
            << '/'
            << tts_completed
            << '/'
            << tts_successful
            << '/'
            << tts_failed
            << '/'
            << tts_rejected
            << '/'
            << tts_empty
            << '\n'

            << "Skipped VISION: "
            << skipped_vision
            << '\n'
            << "VISION completed/success/failed: "
            << vision_completed << '/'
            << vision_successful << '/'
            << vision_failed << '\n';

        if (!replay_mode && !producer.ok())
        {
            std::cerr
                << "[VAD] "
                << producer.error()
                << '\n';
        }

        if ((!replay_mode || audio_replay_path) && !consumer.ok())
        {
            std::cerr
                << "[ASR] "
                << consumer.error()
                << '\n';
        }
    }

    const auto audio_stats=audio_queue.stats();
    std::cout << "[AudioQueueStats] pushed=" << audio_stats.pushed << " popped=" <<
audio_stats.popped
              << " dropped=" << audio_stats.dropped << " rejected_closed=" <<
audio_stats.rejected_closed
              << " peak=" << audio_stats.peak << " pending=" << audio_stats.pending << '\n';
    const auto inference_stats=llm_worker.stats();
    const auto tts_stats=tts_worker.stats();
    const auto admission_stats=admission.stats();
    printWorkerStats("inference", inference_stats);
    printWorkerStats("tts", tts_stats);
    std::cout << "[PipelineStats] dispatched=" << dispatch_calls << " accepted=" <<
admission_stats.accepted
              << " rejected=" << pipeline_rejected << " inflight=" << admission_stats.inflight
              << " peak=" << admission_stats.peak << " limit=" << max_inflight
```

```
              << " vision_accepted=" << vision_accepted << " vision_rejected=" <<
vision_rejected
              << " llm_cancelled=" << llm_cancelled << " llm_expired=" << llm_expired
              << " vision_cancelled=" << vision_cancelled << " vision_expired=" <<
vision_expired
              << " cancelled_before_submit=" << cancelled_before_submit
              << " downstream_cancelled=" << downstream_cancelled
              << " tts_cancelled=" << tts_cancelled << " tts_expired=" << tts_expired << '\n';

    // ------------------------------------------------------
    // 22. 最终验收条件
    // ------------------------------------------------------

    const bool passed =
        (replay_mode ? (!audio_replay_path || consumer.ok()) : (producer.ok() && consumer.ok()))
&& audio_queue.droppedCount()==0 &&
        llm_drained && tts_drained && !stop_signals.failed() &&
        (stop_signals.received()!=0 || llm_successful+vision_successful>0) &&
        inference_stats.accepted==inference_stats.completed &&
tts_stats.accepted==tts_stats.completed &&
        inference_stats.failed==0 && tts_stats.failed==0 &&
        inference_stats.callback_errors==0 && tts_stats.callback_errors==0 &&
        admission_stats.inflight==0 && llm_rejected==0 && vision_rejected==0 && tts_rejected==0;

    std::cout
        << (passed ? (stop_signals.received() != 0 ? "STOPPED\n" : "PASS\n") : "FAIL\n");

    return passed ? 0 : 1;
}
catch (const std::exception& e)
{
    std::cerr << "[Fatal] Voice pipeline exception: " << e.what() << '\n';
    return 1;
}
catch (...)
{
    std::cerr << "[Fatal] Voice pipeline: unknown exception\n";
    return 1;
}
```

5.5 Qt 与系统稳定性面试题及参考答案

1 为什么选择 QProcess 适配 CLI 而不是在窗口里重新创建模型

项目已经有完整的 Service、Worker、队列和退出机制。Qt 只负责控制和显示，另写一套初始化及推理会产生模型参数、设备所有权和信号行为差异。QProcess 复用原 CLI，在子进程中保持所有已验收线程，使模型加载与同步 SDK 天然离开 GUI 线程。代价是日志协议耦合和进程间观测延迟，需要独立测试解析、启动失败和安全关闭。

2 QProcess 的 started 是否意味着系统可接受语音

不是。它只说明外层进程启动，Qwen、SenseVoice、Kokoro、Camera 和 SmolVLM2 仍可能在加载或失败。必须分别显示加载状态，直到原程序打印 Listen 才提示用户说话。反过来，started 之后发生 exec 或模型失败也应处理 errorOccurred/finished 和真实退出码，不能一直停留在“运行中”。

3 关闭 Qt 窗口时如何避免后台访问已销毁控件

活跃时 closeEvent 先 ignore，保留接收者，再协作停止子进程。所有 connect 使用窗口或控制器作 context，只有 finished 之后才用 singleShot 关闭。后台模型只输出复制的字节，不持有窗口引用；页面不持有 Frame 或 SDK 裸指针。析构不能作为停止手段，尤其不能借 QProcess 析构中的强制终止宣称安全退出。

4 为什么 Qt 中不能直接调用 waitForFinished

GUI 线程阻塞后不能处理绘制、按键和正常状态更新，用户会把长合成误认为程序死锁。finished 信号允许事件循环继续运行；停止只发送协作信号并启动有限观察定时器。测试要同时验证后台真的完成和 GUI 心跳继续推进，单看窗口能显示一次不够。

5 如何在 Qt 程序处理 SIGINT 而不在 handler 调用 Qt

本工程复用 5.1 的信号阻塞与普通 sigtimedwait 线程，在创建 QApplication 和 SDK 线程前完成 pthread_sigmask。线程只写 atomic 状态，Qt 定时器在正常事件循环中读取并调用 close。这样没有异步 signal handler 操作 mutex、内存分配、QObject 或 join。子 CLI 也按同一协议处理信号，而不是依赖默认终止动作。

6 2 线程与 4 线程的短时加速为什么不能决定最终默认值

更多 ORT 线程可以降低一次合成墙钟时间，却增加 CPU 占用、温度以及对 ASR 的竞争。持续运行可能触发 Linux cooling、降频或队列策略，使整体体验变差。应使用相同固定输入、初始温度规则、原模型和相同监控比较长测，再依据实际稳定性决定默认值，保留显式 2/4 线程选择。不能为了保留好看数字隐藏过热或到期请求。

7 如何区分 DVFS 和热降频

ondemand 会随负载主动改变频率；瞬时频率低并不能证明温度造成限制。应同时记录 thermal trip、对应 cooling 设备类型与 cur_state、scaling_max_freq、当前频率、温度和负载。观察正 cooling state 及上限下降能提供 Linux 限制活动证据，但仍需按对应 CPU/GPU/NPU 设备解释，不能把 GPU cooling 状态当 CPU 降频。

8 什么证据支持“没有发现明显内存泄漏”

先排除加载和首次推理缓存，查看稳定区间 RSS 的时间序列、分箱中位数、斜率和波动范围；结合有界帧池/队列的源码所有权、终态计数、设备释放与多轮重启。RSS 增长也可能是 allocator 缓存，RSS 稳定也不能证明闭源 SDK 所有路径无泄漏。因此结论应限定工作负载和实际时长，不应只说“没 OOM 就是无泄漏”。

9 为什么压力测试中的推理成功率和播放交付率要分开

推理可能全部成功，但 TTS 任务在原等待期限下过期、因背压拒绝或停止时取消。模型成功数除以实际执行数，与最终播放数除以输入请求数，是不同指标。必须报告所有输入的终态、拒绝/到期/取消计数及分母，不能只保留成功完成项来宣传系统 100%成功。

10 固定音频回放能替代真实麦克风验收吗

不能。它可以复现 SenseVoice 输入和后续调度，便于比较 CPU 竞争与热状态，但预分段音频没有 USB 采集、VAD 端点、XRUN 和声学环境。固定图像也没有实时 Frame Age。最终必须另做真实麦克风、Camera 及用户耳机确认，并且把 ALSA 提交时间与真实声学延迟区分开。

11 Fake 故障测试为什么仍然重要

真正断开设备或让 SDK 崩溃往往不可控，可能影响已有系统。Fake 可以确定性地注入返回 false、标准/未知异常、无效 PCM、回调异常和精确并发交错，检查错误计数、唤醒、join 和后续恢复。但 Fake 不证明 SDK 内部失败安全，板端无效设备名等非破坏性测试与正常硬件回归仍需单列，不能把两者合为“真实设备恢复全部通过”。

12 如何定义可复现的最终交付

冻结源码和历史版本，保留完整 diff、SHA 清单、原始命令/退出码、模型与 SDK 真实路径、CSV/JSON、输入条件、统计方法和截图来源。构建目录和测试 case 独占，普通用户运行，不覆写稳定工程。手册中的函数、参数和结论必须与最终源码和日志一致，Word 需要真实渲染检查；最终用户审核前不能把隔离版直接升级覆盖主工程。

8 构建运行复现和重要命令

5.5 重要命令及真实输出解析

以下命令来自保存的 argv，复现应选不存在的新 case 和 build 目录。模型/SDK 仅引用现有路径。SSH 传输码和测试子进程退出码分别保存，故意非法路径必须非零且完成清理。

build_final_v2 build

目的：用现有 ARM64 SDK 配置、全量构建或运行确定性测试。

```
cmake --build
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/build/stage5_05_final_v2 --parallel 3
```

参数逐项：bash -c 执行保存的脚本，后续占位名为$0，再依次$1/$2/$3/$4；source 只加载本次环境。cmake -S 冻结源码、-B 独立产物、-DCMAKE_BUILD_TYPE=Release 优化、BUILD_TESTING=ON 测试；BUILD_WITH_RKLLM/BUILD_WITH_VLM/ENABLE_SHERPA_ASR=ON 链接真实 SDK，ROOT/INCLUDE/RUNTIME_LIBRARY 指定原路径，BUILD_QT_GUI=ON 启用 Qt5 Widgets/Test。--build --parallel 3 最多 3 编译任务；ctest --test-dir 选构建、--timeout 30 逐项上限、--output-on-failure 保留错误、--output-junit 保存 XML。

真实退出记录节选：

```
{
  "step": "build",
  "returncode": 0,
  "reason": null,
  "seconds": 156.08595781799886
}
```

真实输出节选（完整 reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/build_final_v2/build.stdout.log）：

```
[ 97%] Building CXX object CMakeFiles/asr_llm_tts_smoke.dir/src/audio/asr_llm_tts_smoke.cpp.o
[ 98%] Linking CXX executable tts_worker_queue_smoke
[ 99%] Linking CXX executable gui_session_tests
[ 99%] Built target tts_worker_queue_smoke
[ 99%] Built target gui_session_tests
[100%] Linking CXX executable asr_llm_tts_smoke
[100%] Built target asr_llm_tts_smoke
```

解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

build_final_v2 configure

目的：用现有 ARM64 SDK 配置、全量构建或运行确定性测试。

```
bash -c 'source "$1/tools/stage5_board_paths.sh"; exec cmake -S "$2" -B "$3" -
DCMAKE_BUILD_TYPE=Release -DBUILD_TESTING=ON -DBUILD_WITH_RKLLM=ON -DBUILD_WITH_VLM=ON -
DENABLE_SHERPA_ASR=ON -DSHERPA_ONNX_ROOT="$STAGE5_SHERPA" -DRKLLM_SDK_ROOT="$STAGE5_RKLLM" -
DRKNN_INCLUDE_DIR="$STAGE5_RKNN_INCLUDE" -DRKNN_RUNTIME_LIBRARY="$STAGE5_RKNN_LIBRARY" -
DBUILD_QT_GUI="$4"' stage5_05 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/stage5_05_source_final_v2
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/build/stage5_05_final_v2 ON
```

参数逐项：bash -c 执行保存的脚本，后续占位名为$0，再依次$1/$2/$3/$4；source 只加载本次环境。cmake -S 冻结源码、-B 独立产物、-DCMAKE_BUILD_TYPE=Release 优化、BUILD_TESTING=ON 测试；BUILD_WITH_RKLLM/BUILD_WITH_VLM/ENABLE_SHERPA_ASR=ON 链接真实 SDK，ROOT/INCLUDE/RUNTIME_LIBRARY 指定原路径，BUILD_QT_GUI=ON 启用 Qt5 Widgets/Test。--build --parallel 3 最多 3 编译任务；ctest --test-dir 选构建、--timeout 30 逐项上限、--output-on-failure 保留错误、--output-junit 保存 XML。

真实退出记录节选：

```
{
  "step": "configure",
  "returncode": 0,
```

```
  "reason": null,
  "seconds": 3.0020454799996514
}
```

真实输出节选（完整 reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/build_final_v2/configure.stdout.log）：

```
-- RKLLM include: /home/cat/projects/RK3576/rkllm_sdk/rkllm-runtime/Linux/librkllm_api/include
-- RKLLM library: /home/cat/projects/RK3576/rkllm_sdk/rkllm-
runtime/Linux/librkllm_api/aarch64/librkllmrt.so
-- Real SmolVLM2 RKNN + RKLLM backend enabled
-- Found ALSA: /usr/lib/aarch64-linux-gnu/libasound.so (found version "1.2.8")
-- Configuring done
-- Generating done
-- Build files have been written to:
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/build/stage5_05_final_v2
```

解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

build_final_v2 ctest

目的：用现有 ARM64 SDK 配置、全量构建或运行确定性测试。

```
bash -c 'source "$1/tools/stage5_board_paths.sh"; QT_QPA_PLATFORM=offscreen exec ctest --test-
dir "$2" --output-on-failure --timeout 30 --output-junit "$3"' stage5_05
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/build/stage5_05_final_v2
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/build_final_v
2/ctest.xml
```

参数逐项：bash -c 执行保存的脚本，后续占位名为$0，再依次$1/$2/$3/$4；source 只加载本次环境。cmake -S 冻结源码、-B 独立产物、-DCMAKE_BUILD_TYPE=Release 优化、BUILD_TESTING=ON 测试；BUILD_WITH_RKLLM/BUILD_WITH_VLM/ENABLE_SHERPA_ASR=ON 链接真实 SDK，ROOT/INCLUDE/RUNTIME_LIBRARY 指定原路径，BUILD_QT_GUI=ON 启用 Qt5 Widgets/Test。--build --parallel 3 最多 3 编译任务；ctest --test-dir 选构建、--timeout 30 逐项上限、--output-on-failure 保留错误、--output-junit 保存 XML。

真实退出记录节选：


```
{
  "step": "ctest",
  "returncode": 0,
  "reason": null,
  "seconds": 7.0067366089970164
}
```


真实输出节选（完整 reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/build_final_v2/ctest.stdout.log）：

```
7/8 Test #7: camera_service_tests .............   Passed    0.22 sec
    Start 8: gui_session_tests
8/8 Test #8: gui_session_tests ................   Passed    5.50 sec

100% tests passed, 0 tests failed out of 8

Total Test time (real) =   6.43 sec
```

解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

thermal_matrix mixed_1800s_2t_command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
python3 -I -B
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/tools/stage5_05_voice_run.py --name
mixed_1800s_2t --tts-threads 2 --audio-replay-file
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/thermal_matri
x/mixed_1800s_2t.tsv --fixed-frame-dir
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_basel
ine --timeout 1960 --grace 70 --seconds 1800 --stop-mode cancel_pending
```

参数逐项：python3 -I -B 隔离用户 Python 环境并禁止字节码写入。 --name 独占 case 目录，存在则拒绝覆盖，实际值 mixed_1800s_2t。 --tts-threadsKokoro 线程数，实际值 2。 --audio-replay-file 预分段真实语音 TSV，执行真实 ASR 但跳过麦克风/VAD，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/thermal_

matrix/mixed_1800s_2t.tsv。 --fixed-frame-dir 固定 NV12 夹具目录，Camera 仍真实采集，Frame Age 不可用，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_baseline。 --timeout 运行截止秒数，超时必须记失败，实际值 1960。 --grace 信号后协作清理宽限秒数，超出强制终止只算失败，实际值 70。 --seconds 有限输入监听秒数，实际值 1800。 --stop-mode 排空或取消等待，活动同步 SDK 不被强行中断，实际值 cancel_pending。

真实退出记录节选：


```
{
  "pid": 32878,
  "returncode": 0,
  "termination_reason": null,
  "sent_signal": null,
  "trigger_observed": true,
  "forced_kill": false,
  "timeout": false,
  "duration_seconds": 1839.8901995140004,
  "input_closed_to_exit_seconds": 17.66012788200169,
  "signal_to_exit_seconds": null,
  "timing_scope": "child exit/output EOF, excludes subsequent device/fingerprint queries",
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "image_profile_errors": false,
  "shutdown_complete_marker": true,
  "program_PASS": true,
  "text_tts_completed": true,
  "vision_tts_completed": true,
  "user_audible_confirmation": null,
  "variant": "candidate",
  "input_mode": "fixed_audio_REAL_ASR_no_microphone_VAD",
  "stop_mode": "cancel_pending"
}
```


真实输出节选（完整 reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/thermal_matrix/mixed_1800s_2t_runner.log）：


```
[QueueStats] stage=tts generation=1 accepted=121 completed=121 started=121 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=265455 queue_max_ms=5738.32 service_sum_ms=1.72508e+06
[PipelineStats] dispatched=121 accepted=121 rejected=0 inflight=0 peak=2 limit=2
vision_accepted=60 vision_rejected=0 llm_cancelled=0 llm_expired=0 vision_cancelled=0
vision_expired=0 cancelled_before_submit=0 downstream_cancelled=0 tts_cancelled=0 tts_expired=0
PASS
[FramePool] allocated=2 in_use=0 acquired=54595 reused=54593 exhausted=0
[CameraCounters] published=54594 fps=29.997 timeouts=0 driver_sequence_gaps=0 pool_discarded=0
STAGE5_05_RUN_RESULT {"pid": 32878, "returncode": 0, "termination_reason": null, "sent_signal":
null, "trigger_observed": true, "forced_kill": false, "timeout": false, "duration_seconds":
```

```
1839.8901995140004, "input_closed_to_exit_seconds": 17.66012788200169, "signal_to_exit_seconds":
null, "timing_scope": "child exit/output EOF, excludes subsequent device/fi
REMOTE_REPORT
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/mixed_1800s_2
t
```

解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

thermal_matrix mixed_1800s_4t_command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
python3 -I -B
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/tools/stage5_05_voice_run.py --name
mixed_1800s_4t --tts-threads 4 --audio-replay-file
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/thermal_matri
x/mixed_1800s_4t.tsv --fixed-frame-dir
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_basel
ine --timeout 1960 --grace 70 --seconds 1800 --stop-mode cancel_pending
```

参数逐项：`python3 -I -B` 隔离用户 Python 环境并禁止字节码写入。 `--name` 独占 case 目录，存在则拒绝覆盖，实际值 `mixed_1800s_4t`。 `--tts-threads`Kokoro 线程数，实际值 `4`。 `--audio-replay-file` 预分段真实语音 TSV，执行真实 ASR 但跳过麦克风/VAD，实际值 `/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/thermal_matrix/mixed_1800s_4t.tsv`。 `--fixed-frame-dir` 固定 NV12 夹具目录，Camera 仍真实采集，Frame Age 不可用，实际值 `/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_baseline`。 `--timeout` 运行截止秒数，超时必须记失败，实际值 `1960`。 `--grace` 信号后协作清理宽限秒数，超出强制终止只算失败，实际值 `70`。 `--seconds` 有限输入监听秒数，实际值 `1800`。 `--stop-mode` 排空或取消等待，活动同步 SDK 不被强行中断，实际值 `cancel_pending`。

真实退出记录节选：

```
{
  "pid": 34293,
  "returncode": 0,
  "termination_reason": null,
```

```
  "sent_signal": null,
  "trigger_observed": true,
  "forced_kill": false,
  "timeout": false,
  "duration_seconds": 1833.323821127,
  "input_closed_to_exit_seconds": 11.171650347998366,
  "signal_to_exit_seconds": null,
  "timing_scope": "child exit/output EOF, excludes subsequent device/fingerprint queries",
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "image_profile_errors": false,
  "shutdown_complete_marker": true,
  "program_PASS": true,
  "text_tts_completed": true,
  "vision_tts_completed": true,
  "user_audible_confirmation": null,
  "variant": "candidate",
  "input_mode": "fixed_audio_REAL_ASR_no_microphone_VAD",
  "stop_mode": "cancel_pending"
}
```


真实输出节选（完整 reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/thermal_matrix/mixed_1800s_4t_runner.log）：


```
[QueueStats] stage=tts generation=1 accepted=121 completed=121 started=121 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=2277.11 queue_max_ms=279.053 service_sum_ms=1.40214e+06
[PipelineStats] dispatched=121 accepted=121 rejected=0 inflight=0 peak=2 limit=2
vision_accepted=60 vision_rejected=0 llm_cancelled=0 llm_expired=0 vision_cancelled=0
vision_expired=0 cancelled_before_submit=0 downstream_cancelled=0 tts_cancelled=0 tts_expired=0
PASS
[FramePool] allocated=2 in_use=0 acquired=54394 reused=54392 exhausted=0
[CameraCounters] published=54393 fps=29.997 timeouts=0 driver_sequence_gaps=0 pool_discarded=0
STAGE5_05_RUN_RESULT {"pid": 34293, "returncode": 0, "termination_reason": null, "sent_signal":
null, "trigger_observed": true, "forced_kill": false, "timeout": false, "duration_seconds":
1833.323821127, "input_closed_to_exit_seconds": 11.171650347998366, "signal_to_exit_seconds":
null, "timing_scope": "child exit/output EOF, excludes subsequent device/finge
REMOTE_REPORT
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/mixed_1800s_4
t
```


解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

thermal_matrix mixed_180s_2t_command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
python3 -I -B
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/tools/stage5_05_voice_run.py --name
mixed_180s_2t --tts-threads 2 --audio-replay-file
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/thermal_matri
x/mixed_180s_2t.tsv --fixed-frame-dir
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_basel
ine --timeout 340 --grace 70 --seconds 180 --stop-mode cancel_pending
```

参数逐项：python3 -I -B 隔离用户 Python 环境并禁止字节码写入。 --name 独占 case 目录，存在则拒绝覆盖，实际值 mixed_180s_2t。 --tts-threadsKokoro 线程数，实际值 2。 --audio-replay-file 预分段真实语音 TSV，执行真实 ASR 但跳过麦克风/VAD，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/thermal_matrix/mixed_180s_2t.tsv。 --fixed-frame-dir 固定 NV12 夹具目录，Camera 仍真实采集，Frame Age 不可用，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_baseline。 --timeout 运行截止秒数，超时必须记失败，实际值 340。 --grace 信号后协作清理宽限秒数，超出强制终止只算失败，实际值 70。 --seconds 有限输入监听秒数，实际值 180。 --stop-mode 排空或取消等待，活动同步 SDK 不被强行中断，实际值 cancel_pending。

真实退出记录节选：


```
{
  "pid": 32366,
  "returncode": 0,
  "termination_reason": null,
  "sent_signal": null,
  "trigger_observed": true,
  "forced_kill": false,
  "timeout": false,
  "duration_seconds": 221.52749982000023,
  "input_closed_to_exit_seconds": 19.741377784001088,
  "signal_to_exit_seconds": null,
  "timing_scope": "child exit/output EOF, excludes subsequent device/fingerprint queries",
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "image_profile_errors": false,
  "shutdown_complete_marker": true,
  "program_PASS": true,
  "text_tts_completed": true,
  "vision_tts_completed": true,
  "user_audible_confirmation": null,
  "variant": "candidate",
```

```
  "input_mode": "fixed_audio_REAL_ASR_no_microphone_VAD",
  "stop_mode": "cancel_pending"
}
```

真实输出节选（完整

reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/thermal_matrix/mixed_180s_2t_runner.log）：

```
[QueueStats] stage=tts generation=1 accepted=10 completed=10 started=10 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=1.14062 queue_max_ms=0.30825 service_sum_ms=138970
[PipelineStats] dispatched=10 accepted=10 rejected=0 inflight=0 peak=1 limit=2
vision_accepted=5 vision_rejected=0 llm_cancelled=0 llm_expired=0 vision_cancelled=0
vision_expired=0 cancelled_before_submit=0 downstream_cancelled=0 tts_cancelled=0 tts_expired=0
PASS
[FramePool] allocated=2 in_use=0 acquired=6042 reused=6040 exhausted=0
[CameraCounters] published=6041 fps=29.9736 timeouts=0 driver_sequence_gaps=0 pool_discarded=0
STAGE5_05_RUN_RESULT {"pid": 32366, "returncode": 0, "termination_reason": null, "sent_signal":
null, "trigger_observed": true, "forced_kill": false, "timeout": false, "duration_seconds":
221.52749982000023, "input_closed_to_exit_seconds": 19.741377784001088,
"signal_to_exit_seconds": null, "timing_scope": "child exit/output EOF, excludes subsequent
device/f
REMOTE_REPORT
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/mixed_180s_2t
```

解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

thermal_matrix mixed_180s_4t_command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
python3 -I -B
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/tools/stage5_05_voice_run.py --name
mixed_180s_4t --tts-threads 4 --audio-replay-file
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/thermal_matri
x/mixed_180s_4t.tsv --fixed-frame-dir
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_basel
ine --timeout 340 --grace 70 --seconds 180 --stop-mode cancel_pending
```

参数逐项：python3 -I -B 隔离用户 Python 环境并禁止字节码写入。 --name 独占 case 目录，存在则拒绝覆盖，实际值 mixed_180s_4t。 --tts-threadsKokoro 线程数，实际值 4。 --audio-

replay-file 预分段真实语音 TSV，执行真实 ASR 但跳过麦克风/VAD，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/thermal_matrix/mixed_180s_4t.tsv。 --fixed-frame-dir 固定 NV12 夹具目录，Camera 仍真实采集，Frame Age 不可用，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_baseline。 --timeout 运行截止秒数，超时必须记失败，实际值 340。 --grace 信号后协作清理宽限秒数，超出强制终止只算失败，实际值 70。 --seconds 有限输入监听秒数，实际值 180。 --stop-mode 排空或取消等待，活动同步 SDK 不被强行中断，实际值 cancel_pending。

真实退出记录节选：


```
{
  "pid": 32558,
  "returncode": 0,
  "termination_reason": null,
  "sent_signal": null,
  "trigger_observed": true,
  "forced_kill": false,
  "timeout": false,
  "duration_seconds": 218.62452942800155,
  "input_closed_to_exit_seconds": 16.46599648800111,
  "signal_to_exit_seconds": null,
  "timing_scope": "child exit/output EOF, excludes subsequent device/fingerprint queries",
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "image_profile_errors": false,
  "shutdown_complete_marker": true,
  "program_PASS": true,
  "text_tts_completed": true,
  "vision_tts_completed": true,
  "user_audible_confirmation": null,
  "variant": "candidate",
  "input_mode": "fixed_audio_REAL_ASR_no_microphone_VAD",
  "stop_mode": "cancel_pending"
}
```


真实输出节选（完整 reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/thermal_matrix/mixed_180s_4t_runner.log）：

```
[QueueStats] stage=tts generation=1 accepted=10 completed=10 started=10 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=1.32898 queue_max_ms=0.259145 service_sum_ms=108754
[PipelineStats] dispatched=10 accepted=10 rejected=0 inflight=0 peak=1 limit=2
vision_accepted=5 vision_rejected=0 llm_cancelled=0 llm_expired=0 vision_cancelled=0
vision_expired=0 cancelled_before_submit=0 downstream_cancelled=0 tts_cancelled=0 tts_expired=0
PASS
```

```
[FramePool] allocated=2 in_use=0 acquired=5948 reused=5946 exhausted=0
[CameraCounters] published=5947 fps=29.9741 timeouts=0 driver_sequence_gaps=0 pool_discarded=0
STAGE5_05_RUN_RESULT {"pid": 32558, "returncode": 0, "termination_reason": null, "sent_signal":
null, "trigger_observed": true, "forced_kill": false, "timeout": false, "duration_seconds":
218.62452942800155, "input_closed_to_exit_seconds": 16.46599648800111, "signal_to_exit_seconds":
null, "timing_scope": "child exit/output EOF, excludes subsequent device/fi
REMOTE_REPORT
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/mixed_180s_4t
```

解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

gui_microphone_final_v2 command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/build/stage5_05_final_v2/rk3576_multi
modal_gui --capture plughw:CARD=III,DEV=0 --playback plughw:CARD=III,DEV=0 --report-root
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/gui_microphon
e_final_v2 --seconds 180 --threads 4 --auto-start --stop-after-answers 2 --cycles 1
```

参数逐项：--capture 当轮动态发现的 HyperX 采集设备，实际值 plughw:CARD=III,DEV=0。 --playback 当轮动态发现的 HyperX 播放设备，实际值 plughw:CARD=III,DEV=0。 --report-root 已存在的隔离日志根，每次创建 UUID 子目录，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/gui_microphone_final_v2。 --seconds 有限输入监听秒数，实际值 180。 --threadsKokoro 线程数，实际值 4。 --auto-start 测试时进入事件循环后点击开始。 --stop-after-answers 测试收到指定成功完成数后停止，0 表示不按回答数停止，实际值 2。 --cyclesfresh 子进程会话轮数，不是在同 SDK 句柄内重启，实际值 1。

真实退出记录节选：

```
{
  "returncode": 0,
  "duration_seconds": 79.4961776759992,
  "signal_to_exit_seconds": null,
  "sent_signal": null,
  "termination_reason": null,
  "forced_kill": false,
  "timeout": false,
```

```
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "all_sessions_orderly": true,
  "platform": "xcb DISPLAY :0 actual existing desktop",
  "input_mode": "microphone",
  "user_audible_confirmation": null
}
```

真实输出节选（完整 reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/gui_microphone_final_v2/terminal.log）：

```
[QueueStats] stage=inference generation=1 accepted=2 completed=2 started=2 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=0.166924 queue_max_ms=0.103264 service_sum_ms=2998.84
[QueueStats] stage=tts generation=1 accepted=2 completed=2 started=2 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=0.17605 queue_max_ms=0.098023 service_sum_ms=24328.9
[PipelineStats] dispatched=2 accepted=2 rejected=0 inflight=0 peak=1 limit=2 vision_accepted=1
vision_rejected=0 llm_cancelled=0 llm_expired=0 vision_cancelled=0 vision_expired=0
cancelled_before_submit=0 downstream_cancelled=0 tts_cancelled=0 tts_expired=0
STOPPED
[FramePool] allocated=3 in_use=0 acquired=1689 reused=1686 exhausted=0
[CameraCounters] published=1688 fps=29.9073 timeouts=0 driver_sequence_gaps=0 pool_discarded=0
[GUI finished] code=0 orderly=1 cycles=1 heartbeat=756
```

解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

gui_paired_restart_final_v2 command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/build/stage5_05_final_v2/rk3576_multi
modal_gui --capture plughw:CARD=III,DEV=0 --playback plughw:CARD=III,DEV=0 --report-root
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/gui_paired_re
start_final_v2 --seconds 180 --threads 4 --auto-start --stop-after-answers 2 --cycles 2
```

参数逐项：--capture 当轮动态发现的 HyperX 采集设备，实际值 plughw:CARD=III,DEV=0。 --playback 当轮动态发现的 HyperX 播放设备，实际值 plughw:CARD=III,DEV=0。 --report-root

已存在的隔离日志根，每次创建 UUID 子目录，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/gui_paired_restart_final_v2。 --seconds 有限输入监听秒数，实际值 180。 --threadsKokoro 线程数，实际值 4。 --auto-start 测试时进入事件循环后点击开始。 --stop-after-answers 测试收到指定成功完成数后停止，0 表示不按回答数停止，实际值 2。 --cyclesfresh 子进程会话轮数，不是在同 SDK 句柄内重启，实际值 2。

真实退出记录节选：

```
{
  "returncode": 0,
  "duration_seconds": 102.26650997400066,
  "signal_to_exit_seconds": null,
  "sent_signal": null,
  "termination_reason": null,
  "forced_kill": false,
  "timeout": false,
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "all_sessions_orderly": true,
  "platform": "xcb DISPLAY :0 actual existing desktop",
  "input_mode": "paired_restart",
  "user_audible_confirmation": null
}
```

真实输出节选（完整 reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/gui_paired_restart_final_v2/terminal.log）：

```
[QueueStats] stage=inference generation=1 accepted=2 completed=2 started=2 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=661.045 queue_max_ms=660.968 service_sum_ms=3666.03
[QueueStats] stage=tts generation=1 accepted=2 completed=2 started=2 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=12502.3 queue_max_ms=12502.2 service_sum_ms=22752.7
[PipelineStats] dispatched=2 accepted=2 rejected=0 inflight=0 peak=2 limit=2 vision_accepted=1
vision_rejected=0 llm_cancelled=0 llm_expired=0 vision_cancelled=0 vision_expired=0
cancelled_before_submit=0 downstream_cancelled=0 tts_cancelled=0 tts_expired=0
STOPPED
[FramePool] allocated=2 in_use=0 acquired=850 reused=848 exhausted=0
[CameraCounters] published=849 fps=29.8017 timeouts=0 driver_sequence_gaps=0 pool_discarded=0
[GUI finished] code=0 orderly=1 cycles=2 heartbeat=976
```

解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；

拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

gui_sigterm_vision_final_v2 command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/build/stage5_05_final_v2/rk3576_multi
modal_gui --capture plughw:CARD=III,DEV=0 --playback plughw:CARD=III,DEV=0 --report-root
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/gui_sigterm_v
ision_final_v2 --seconds 180 --threads 4 --auto-start --stop-after-answers 0 --cycles 1
```

参数逐项：--capture 当轮动态发现的 HyperX 采集设备，实际值 plughw:CARD=III,DEV=0。 --playback 当轮动态发现的 HyperX 播放设备，实际值 plughw:CARD=III,DEV=0。 --report-root 已存在的隔离日志根，每次创建 UUID 子目录，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/gui_sigterm_vision_final_v2。 --seconds 有限输入监听秒数，实际值 180。 --threadsKokoro 线程数，实际值 4。 --auto-start 测试时进入事件循环后点击开始。 --stop-after-answers 测试收到指定成功完成数后停止，0 表示不按回答数停止，实际值 0。 --cyclesfresh 子进程会话轮数，不是在同 SDK 句柄内重启，实际值 1。

真实退出记录节选：


```
{
  "returncode": 0,
  "duration_seconds": 53.1265482710005,
  "signal_to_exit_seconds": 27.24281331900056,
  "sent_signal": "SIGTERM",
  "termination_reason": null,
  "forced_kill": false,
  "timeout": false,
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "all_sessions_orderly": true,
  "platform": "xcb DISPLAY :0 actual existing desktop",
  "input_mode": "sigterm_vision",
  "user_audible_confirmation": null
}
```

真实输出节选（完整 reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/gui_sigterm_vision_final_v2/terminal.log）：

```
[QueueStats] stage=inference generation=1 accepted=1 completed=1 started=1 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=0.097333 queue_max_ms=0.097333 service_sum_ms=1945.74
[QueueStats] stage=tts generation=1 accepted=1 completed=1 started=1 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=0.078494 queue_max_ms=0.078494 service_sum_ms=24007
[PipelineStats] dispatched=1 accepted=1 rejected=0 inflight=0 peak=1 limit=2 vision_accepted=1
vision_rejected=0 llm_cancelled=0 llm_expired=0 vision_cancelled=0 vision_expired=0
cancelled_before_submit=0 downstream_cancelled=0 tts_cancelled=0 tts_expired=0
STOPPED
[FramePool] allocated=3 in_use=0 acquired=869 reused=866 exhausted=0
[CameraCounters] published=868 fps=29.8142 timeouts=0 driver_sequence_gaps=0 pool_discarded=0
[GUI finished] code=0 orderly=1 cycles=1 heartbeat=485
```

解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

gui_mixed_1800s_4t_final_v2 command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/build/stage5_05_final_v2/rk3576_multi
modal_gui --capture plughw:CARD=III,DEV=0 --playback plughw:CARD=III,DEV=0 --report-root
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/gui_mixed_180
0s_4t_final_v2 --seconds 1800 --threads 4 --auto-start --stop-after-answers 0 --cycles 1
```

参数逐项：--capture 当轮动态发现的 HyperX 采集设备，实际值 plughw:CARD=III,DEV=0。 --playback 当轮动态发现的 HyperX 播放设备，实际值 plughw:CARD=III,DEV=0。 --report-root 已存在的隔离日志根，每次创建 UUID 子目录，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/gui_mixed_1800s_4t_final_v2。 --seconds 有限输入监听秒数，实际值 1800。 --threadsKokoro 线程数，实际值 4。 --auto-start 测试时进入事件循环后点击开始。 --stop-after-answers 测试收到指定成功完成数后停止，0 表示不按回答数停止，实际值 0。 --cyclesfresh 子进程会话轮数，不是在同 SDK 句柄内重启，实际值 1。

真实退出记录节选：


```
{
  "returncode": 0,
  "duration_seconds": 1837.7822822689996,
  "signal_to_exit_seconds": null,
  "sent_signal": null,
  "termination_reason": null,
  "forced_kill": false,
  "timeout": false,
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "all_sessions_orderly": true,
  "platform": "xcb DISPLAY :0 actual existing desktop",
  "input_mode": "stability",
  "user_audible_confirmation": null
}
```


真实输出节选（完整 reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/gui_mixed_1800s_4t_final_v2/terminal.log）：


```
[QueueStats] stage=inference generation=1 accepted=121 completed=121 started=121 failed=0
cancelled=0 expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0
callback_errors=0 queue_sum_ms=10.3541 queue_max_ms=1.62733 service_sum_ms=144120
[QueueStats] stage=tts generation=1 accepted=121 completed=121 started=121 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=5207.94 queue_max_ms=352.063 service_sum_ms=1.41204e+06
[PipelineStats] dispatched=121 accepted=121 rejected=0 inflight=0 peak=2 limit=2
vision_accepted=60 vision_rejected=0 llm_cancelled=0 llm_expired=0 vision_cancelled=0
vision_expired=0 cancelled_before_submit=0 downstream_cancelled=0 tts_cancelled=0 tts_expired=0
PASS
[FramePool] allocated=2 in_use=0 acquired=54398 reused=54396 exhausted=0
[CameraCounters] published=54397 fps=29.9952 timeouts=0 driver_sequence_gaps=1 pool_discarded=0
[GUI finished] code=0 orderly=1 cycles=1 heartbeat=18340
```


解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

final_matrix final_burst_audio_command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
/usr/bin/python3 -I -B
```

```
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/tools/stage5_05_voice_run.py --build-name stage5_05_final_v2 --tts-threads 4 --seconds 120 --timeout 180 --grace 70 --fixed-frame-dir /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_baseline --name final_burst_audio --audio-replay-file /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_matrix/burst.tsv --signal SIGINT --trigger both_done --delay 0.1
```

参数逐项：python3 -I -B 隔离用户 Python 环境并禁止字节码写入。 --build-name 指定冻结 ARM64 构建，实际值 stage5_05_final_v2。 --tts-threadsKokoro 线程数，实际值 4。 --seconds 有限输入监听秒数，实际值 120。 --timeout 运行截止秒数，超时必须记失败，实际值 180。 --grace 信号后协作清理宽限秒数，超出强制终止只算失败，实际值 70。 --fixed-frame-dir 固定 NV12 夹具目录，Camera 仍真实采集，Frame Age 不可用，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_baseline。 --name 独占 case 目录，存在则拒绝覆盖，实际值 final_burst_audio。 --audio-replay-file 预分段真实语音 TSV，执行真实 ASR 但跳过麦克风/VAD，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_matrix/burst.tsv。 --signal 实际发出的 SIGINT 或 SIGTERM，实际值 SIGINT。 --trigger 从真实日志定位发送阶段，实际值 both_done。 --delay 触发后等待秒数，实际值 0.1。

真实退出记录节选：

```
{
  "returncode": null,
  "runner_returncode": 1,
  "program_started": false,
  "stage": "preflight",
  "input_mode": "NOT_EXECUTED protection refused preexisting seat DRM owners"
}
```

真实输出节选（完整 reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/final_matrix/final_burst_audio_runner.log）：

```
Traceback (most recent call last):
  File "/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/tools/stage5_05_voice_run.py", line 231, in <module>
    raise SystemExit(main())
                     ^^^^^^
  File "/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/tools/stage5_05_voice_run.py", line 107, in main
    assert pre['clear'],'target device occupied'
AssertionError: target device occupied
```

解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

final_matrix gui_mixed_1800s_4t_final_v2_command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
/usr/bin/python3 -I -B
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/tools/stage5_05_gui_run.py --name
gui_mixed_1800s_4t_final_v2 --build stage5_05_final_v2 --mode stability --seconds 1800 --
timeout 1990 --threads 4 --audio-replay-file
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/thermal_matri
x/mixed_1800s_4t.tsv
```

参数逐项：`python3 -I -B` 隔离用户 Python 环境并禁止字节码写入。 `--name` 独占 case 目录，存在则拒绝覆盖，实际值 `gui_mixed_1800s_4t_final_v2`。 `--build` 指定冻结 ARM64 构建，实际值 `stage5_05_final_v2`。 `--mode` 区分 microphone 真实输入、paired_restart 重启、sigterm_vision 推理中退出或 stability 长测，实际值 `stability`。 `--seconds` 有限输入监听秒数，实际值 `1800`。 `--timeout` 运行截止秒数，超时必须记失败，实际值 `1990`。 `--threads`Kokoro 线程数，实际值 `4`。 `--audio-replay-file` 预分段真实语音 TSV，执行真实 ASR 但跳过麦克风/VAD，实际值 `/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/thermal_matrix/mixed_1800s_4t.tsv`。

真实退出记录节选：


```
{
  "returncode": 0,
  "duration_seconds": 1837.7822822689996,
  "signal_to_exit_seconds": null,
  "sent_signal": null,
  "termination_reason": null,
  "forced_kill": false,
  "timeout": false,
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "all_sessions_orderly": true,
  "platform": "xcb DISPLAY :0 actual existing desktop",
  "input_mode": "stability",
  "user_audible_confirmation": null
}
```

真实输出节选（完整

reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/final_matrix/gui_mixed_1800s_4t_final_v2_runner.log）：

```
[QueueStats] stage=tts generation=1 accepted=121 completed=121 started=121 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=5207.94 queue_max_ms=352.063 service_sum_ms=1.41204e+06
[PipelineStats] dispatched=121 accepted=121 rejected=0 inflight=0 peak=2 limit=2
vision_accepted=60 vision_rejected=0 llm_cancelled=0 llm_expired=0 vision_cancelled=0
vision_expired=0 cancelled_before_submit=0 downstream_cancelled=0 tts_cancelled=0 tts_expired=0
PASS
[FramePool] allocated=2 in_use=0 acquired=54398 reused=54396 exhausted=0
[CameraCounters] published=54397 fps=29.9952 timeouts=0 driver_sequence_gaps=1 pool_discarded=0
[GUI finished] code=0 orderly=1 cycles=1 heartbeat=18340
GUI_RUN_RESULT {"returncode": 0, "duration_seconds": 1837.7822822689996,
"signal_to_exit_seconds": null, "sent_signal": null, "termination_reason": null, "forced_kill":
false, "timeout": false, "process_gone": true, "devices_released": true,
"original_321_unchanged": true, "sessions": [{"answers_completed": 121, "cycles_completed": 1,
"heartbeat": 18340, "or
```

解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

final_matrix gui_paired_restart_final_v2_command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
/usr/bin/python3 -I -B
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/tools/stage5_05_gui_run.py --name
gui_paired_restart_final_v2 --build stage5_05_final_v2 --mode paired_restart
```

参数逐项：`python3 -I -B` 隔离用户 Python 环境并禁止字节码写入。 `--name` 独占 case 目录，存在则拒绝覆盖，实际值 `gui_paired_restart_final_v2`。 `--build` 指定冻结 ARM64 构建，实际值 `stage5_05_final_v2`。 `--mode` 区分 microphone 真实输入、paired_restart 重启、sigterm_vision 推理中退出或 stability 长测，实际值 `paired_restart`。

真实退出记录节选：

```
{
```

```
  "returncode": 0,
  "duration_seconds": 102.26650997400066,
  "signal_to_exit_seconds": null,
  "sent_signal": null,
  "termination_reason": null,
  "forced_kill": false,
  "timeout": false,
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "all_sessions_orderly": true,
  "platform": "xcb DISPLAY :0 actual existing desktop",
  "input_mode": "paired_restart",
  "user_audible_confirmation": null
}
```


真实输出节选（完整

reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/final_matrix/gui_paired_restart_final_v2_runner.log）：


```
[QueueStats] stage=tts generation=1 accepted=2 completed=2 started=2 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=12502.3 queue_max_ms=12502.2 service_sum_ms=22752.7
[PipelineStats] dispatched=2 accepted=2 rejected=0 inflight=0 peak=2 limit=2 vision_accepted=1
vision_rejected=0 llm_cancelled=0 llm_expired=0 vision_cancelled=0 vision_expired=0
cancelled_before_submit=0 downstream_cancelled=0 tts_cancelled=0 tts_expired=0
STOPPED
[FramePool] allocated=2 in_use=0 acquired=850 reused=848 exhausted=0
[CameraCounters] published=849 fps=29.8017 timeouts=0 driver_sequence_gaps=0 pool_discarded=0
[GUI finished] code=0 orderly=1 cycles=2 heartbeat=976
GUI_RUN_RESULT {"returncode": 0, "duration_seconds": 102.26650997400066,
"signal_to_exit_seconds": null, "sent_signal": null, "termination_reason": null, "forced_kill":
false, "timeout": false, "process_gone": true, "devices_released": true,
"original_321_unchanged": true, "sessions": [{"answers_completed": 2, "cycles_completed": 1,
"heartbeat": 484, "orderl
```


解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

final_matrix gui_sigterm_vision_final_v2_command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
/usr/bin/python3 -I -B
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/tools/stage5_05_gui_run.py --name
```

```
gui_sigterm_vision_final_v2 --build stage5_05_final_v2 --mode sigterm_vision --timeout 240
```

参数逐项：python3 -I -B 隔离用户 Python 环境并禁止字节码写入。 --name 独占 case 目录，存在则拒绝覆盖，实际值 gui_sigterm_vision_final_v2。 --build 指定冻结 ARM64 构建，实际值 stage5_05_final_v2。 --mode 区分 microphone 真实输入、paired_restart 重启、sigterm_vision 推理中退出或 stability 长测，实际值 sigterm_vision。 --timeout 运行截止秒数，超时必须记失败，实际值 240。

真实退出记录节选：


```
{
  "returncode": 0,
  "duration_seconds": 53.1265482710005,
  "signal_to_exit_seconds": 27.24281331900056,
  "sent_signal": "SIGTERM",
  "termination_reason": null,
  "forced_kill": false,
  "timeout": false,
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "all_sessions_orderly": true,
  "platform": "xcb DISPLAY :0 actual existing desktop",
  "input_mode": "sigterm_vision",
  "user_audible_confirmation": null
}
```


真实输出节选（完整 reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/final_matrix/gui_sigterm_vision_final_v2_runner.log）：


```
[QueueStats] stage=tts generation=1 accepted=1 completed=1 started=1 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=0.078494 queue_max_ms=0.078494 service_sum_ms=24007
[PipelineStats] dispatched=1 accepted=1 rejected=0 inflight=0 peak=1 limit=2 vision_accepted=1
vision_rejected=0 llm_cancelled=0 llm_expired=0 vision_cancelled=0 vision_expired=0
cancelled_before_submit=0 downstream_cancelled=0 tts_cancelled=0 tts_expired=0
STOPPED
[FramePool] allocated=3 in_use=0 acquired=869 reused=866 exhausted=0
[CameraCounters] published=868 fps=29.8142 timeouts=0 driver_sequence_gaps=0 pool_discarded=0
[GUI finished] code=0 orderly=1 cycles=1 heartbeat=485
GUI_RUN_RESULT {"returncode": 0, "duration_seconds": 53.1265482710005, "signal_to_exit_seconds":
27.24281331900056, "sent_signal": "SIGTERM", "termination_reason": null, "forced_kill": false,
"timeout": false, "process_gone": true, "devices_released": true, "original_321_unchanged":
true, "sessions": [{"answers_completed": 1, "cycles_completed": 1, "heartbea
```

解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

final_matrix_retry1 final_burst_audio_retry1_command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
/usr/bin/python3 -I -B
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/tools/stage5_05_voice_run.py --build-
name stage5_05_final_v2 --tts-threads 4 --seconds 120 --timeout 180 --grace 70 --fixed-frame-
dir
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_basel
ine --name final_burst_audio_retry1 --audio-replay-file
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_matrix_
retry1/burst.tsv --tts-queue-ms 60000 --request-lifetime-ms 180000 --signal SIGINT --trigger
both_done --delay 0.1
```

参数逐项：python3 -I -B 隔离用户 Python 环境并禁止字节码写入。 --build-name 指定冻结 ARM64 构建，实际值 stage5_05_final_v2。 --tts-threadsKokoro 线程数，实际值 4。 --seconds 有限输入监听秒数，实际值 120。 --timeout 运行截止秒数，超时必须记失败，实际值 180。 --grace 信号后协作清理宽限秒数，超出强制终止只算失败，实际值 70。 --fixed-frame-dir 固定 NV12 夹具目录，Camera 仍真实采集，Frame Age 不可用，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_baseline。 --name 独占 case 目录，存在则拒绝覆盖，实际值 final_burst_audio_retry1。 --audio-replay-file 预分段真实语音 TSV，执行真实 ASR 但跳过麦克风/VAD，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_matrix_retry1/burst.tsv。 --tts-queue-msTTS 最大等待毫秒数，实际值 60000。 --request-lifetime-ms 请求绝对寿命毫秒数，实际值 180000。 --signal 实际发出的 SIGINT 或 SIGTERM，实际值 SIGINT。 --trigger 从真实日志定位发送阶段，实际值 both_done。 --delay 触发后等待秒数，实际值 0.1。

真实退出记录节选：

```
{
  "pid": 39930,
  "returncode": 0,
```

```
  "termination_reason": null,
  "sent_signal": "SIGINT",
  "trigger_observed": true,
  "forced_kill": false,
  "timeout": false,
  "duration_seconds": 47.81705280100141,
  "input_closed_to_exit_seconds": 22.62389257000177,
  "signal_to_exit_seconds": 0.9888364610014833,
  "timing_scope": "child exit/output EOF, excludes subsequent device/fingerprint queries",
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "image_profile_errors": false,
  "shutdown_complete_marker": true,
  "program_PASS": false,
  "text_tts_completed": true,
  "vision_tts_completed": true,
  "user_audible_confirmation": null,
  "variant": "candidate",
  "input_mode": "fixed_audio_REAL_ASR_no_microphone_VAD",
  "stop_mode": "drain"
}
```


真实输出节选（完整

reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/final_matrix_retry1/final_burst_audio_retry1_runner.log）：


```
[QueueStats] stage=tts generation=1 accepted=2 completed=2 started=2 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=12064.2 queue_max_ms=12064.1 service_sum_ms=22460.8
[PipelineStats] dispatched=4 accepted=2 rejected=2 inflight=0 peak=2 limit=2 vision_accepted=1
vision_rejected=0 llm_cancelled=0 llm_expired=0 vision_cancelled=0 vision_expired=0
cancelled_before_submit=0 downstream_cancelled=0 tts_cancelled=0 tts_expired=0
STOPPED
[FramePool] allocated=2 in_use=0 acquired=833 reused=831 exhausted=0
[CameraCounters] published=832 fps=29.8147 timeouts=0 driver_sequence_gaps=0 pool_discarded=0
STAGE5_05_RUN_RESULT {"pid": 39930, "returncode": 0, "termination_reason": null, "sent_signal":
"SIGINT", "trigger_observed": true, "forced_kill": false, "timeout": false, "duration_seconds":
47.81705280100141, "input_closed_to_exit_seconds": 22.62389257000177, "signal_to_exit_seconds":
0.9888364610014833, "timing_scope": "child exit/output EOF, excludes sub
REMOTE_REPORT
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_burst_audio_retry1
```


解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

final_matrix_retry1 final_expiry_audio_command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
/usr/bin/python3 -I -B
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/tools/stage5_05_voice_run.py --build-
name stage5_05_final_v2 --tts-threads 4 --seconds 120 --timeout 180 --grace 70 --fixed-frame-
dir
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_basel
ine --name final_expiry_audio --audio-replay-file
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_matrix_
retry1/pair.tsv --tts-queue-ms 1 --signal SIGTERM --trigger ready --delay 25
```

参数逐项：python3 -I -B 隔离用户 Python 环境并禁止字节码写入。 --build-name 指定冻结 ARM64 构建，实际值 stage5_05_final_v2。 --tts-threadsKokoro 线程数，实际值 4。 --seconds 有限输入监听秒数，实际值 120。 --timeout 运行截止秒数，超时必须记失败，实际值 180。 --grace 信号后协作清理宽限秒数，超出强制终止只算失败，实际值 70。 --fixed-frame-dir 固定 NV12 夹具目录，Camera 仍真实采集，Frame Age 不可用，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_baseline。 --name 独占 case 目录，存在则拒绝覆盖，实际值 final_expiry_audio。 --audio-replay-file 预分段真实语音 TSV，执行真实 ASR 但跳过麦克风/VAD，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_matrix_retry1/pair.tsv。 --tts-queue-msTTS 最大等待毫秒数，实际值 1。 --signal 实际发出的 SIGINT 或 SIGTERM，实际值 SIGTERM。 --trigger 从真实日志定位发送阶段，实际值 ready。 --delay 触发后等待秒数，实际值 25。

真实退出记录节选：


```
{
  "pid": 40011,
  "returncode": 0,
  "termination_reason": null,
  "sent_signal": "SIGTERM",
  "trigger_observed": true,
  "forced_kill": false,
  "timeout": false,
  "duration_seconds": 48.21312145699994,
  "input_closed_to_exit_seconds": 1.7845582139998442,
  "signal_to_exit_seconds": 1.8983000090011046,
  "timing_scope": "child exit/output EOF, excludes subsequent device/fingerprint queries",
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "image_profile_errors": false,
  "shutdown_complete_marker": true,
```

```
  "program_PASS": false,
  "text_tts_completed": false,
  "vision_tts_completed": true,
  "user_audible_confirmation": null,
  "variant": "candidate",
  "input_mode": "fixed_audio_REAL_ASR_no_microphone_VAD",
  "stop_mode": "drain"
}
```


真实输出节选（完整 reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/final_matrix_retry1/final_expiry_audio_runner.log）：


```
[QueueStats] stage=tts generation=1 accepted=2 completed=2 started=1 failed=0 cancelled=0
expired=1 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=12435.3 queue_max_ms=12435.2 service_sum_ms=14110.4
[PipelineStats] dispatched=2 accepted=2 rejected=0 inflight=0 peak=2 limit=2 vision_accepted=1
vision_rejected=0 llm_cancelled=0 llm_expired=0 vision_cancelled=0 vision_expired=0
cancelled_before_submit=0 downstream_cancelled=0 tts_cancelled=0 tts_expired=1
STOPPED
[FramePool] allocated=2 in_use=0 acquired=844 reused=842 exhausted=0
[CameraCounters] published=843 fps=29.8136 timeouts=0 driver_sequence_gaps=0 pool_discarded=0
STAGE5_05_RUN_RESULT {"pid": 40011, "returncode": 0, "termination_reason": null, "sent_signal":
"SIGTERM", "trigger_observed": true, "forced_kill": false, "timeout": false, "duration_seconds":
48.21312145699994, "input_closed_to_exit_seconds": 1.7845582139998442, "signal_to_exit_seconds":
1.8983000090011046, "timing_scope": "child exit/output EOF, excludes s
REMOTE_REPORT
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_expiry_
audio
```


解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

final_matrix_retry1 final_sigint_asr_command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
/usr/bin/python3 -I -B
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/tools/stage5_05_voice_run.py --build-
name stage5_05_final_v2 --tts-threads 4 --seconds 120 --timeout 180 --grace 70 --fixed-frame-
dir
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_basel
ine --name final_sigint_asr --audio-replay-file
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_matrix_
retry1/single.tsv --signal SIGINT --trigger ready --delay 0.2
```

参数逐项：python3 -I -B 隔离用户 Python 环境并禁止字节码写入。 --build-name 指定冻结 ARM64 构建，实际值 stage5_05_final_v2。 --tts-threadsKokoro 线程数，实际值 4。 --seconds 有限输入监听秒数，实际值 120。 --timeout 运行截止秒数，超时必须记失败，实际值 180。 --grace 信号后协作清理宽限秒数，超出强制终止只算失败，实际值 70。 --fixed-frame-dir 固定 NV12 夹具目录，Camera 仍真实采集，Frame Age 不可用，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_baseline。 --name 独占 case 目录，存在则拒绝覆盖，实际值 final_sigint_asr。 --audio-replay-file 预分段真实语音 TSV，执行真实 ASR 但跳过麦克风/VAD，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_matrix_retry1/single.tsv。 --signal 实际发出的 SIGINT 或 SIGTERM，实际值 SIGINT。 --trigger 从真实日志定位发送阶段，实际值 ready。 --delay 触发后等待秒数，实际值 0.2。

真实退出记录节选：


```
{
  "pid": 40441,
  "returncode": 0,
  "termination_reason": null,
  "sent_signal": "SIGINT",
  "trigger_observed": true,
  "forced_kill": false,
  "timeout": false,
  "duration_seconds": 38.448516194999684,
  "input_closed_to_exit_seconds": 16.067495203998988,
  "signal_to_exit_seconds": 16.53417446199819,
  "timing_scope": "child exit/output EOF, excludes subsequent device/fingerprint queries",
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "image_profile_errors": false,
  "shutdown_complete_marker": true,
  "program_PASS": false,
  "text_tts_completed": false,
  "vision_tts_completed": true,
  "user_audible_confirmation": null,
  "variant": "candidate",
  "input_mode": "fixed_audio_REAL_ASR_no_microphone_VAD",
  "stop_mode": "drain"
}
```


真实输出节选（完整 reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/final_matrix_retry1/final_sigint_asr_runner.log）：

```
[QueueStats] stage=tts generation=1 accepted=1 completed=1 started=1 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=0.092682 queue_max_ms=0.092682 service_sum_ms=13181.3
[PipelineStats] dispatched=1 accepted=1 rejected=0 inflight=0 peak=1 limit=2 vision_accepted=1
vision_rejected=0 llm_cancelled=0 llm_expired=0 vision_cancelled=0 vision_expired=0
cancelled_before_submit=0 downstream_cancelled=0 tts_cancelled=0 tts_expired=0
STOPPED
[FramePool] allocated=2 in_use=0 acquired=540 reused=538 exhausted=0
[CameraCounters] published=539 fps=29.7063 timeouts=0 driver_sequence_gaps=0 pool_discarded=0
STAGE5_05_RUN_RESULT {"pid": 40441, "returncode": 0, "termination_reason": null, "sent_signal":
"SIGINT", "trigger_observed": true, "forced_kill": false, "timeout": false, "duration_seconds":
38.448516194999684, "input_closed_to_exit_seconds": 16.067495203998988,
"signal_to_exit_seconds": 16.53417446199819, "timing_scope": "child exit/output EOF, excludes
su
REMOTE_REPORT
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_sigint_
asr
```

解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

final_matrix_retry1 final_sigint_drain_command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
/usr/bin/python3 -I -B
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/tools/stage5_05_voice_run.py --build-
name stage5_05_final_v2 --tts-threads 4 --seconds 120 --timeout 180 --grace 70 --fixed-frame-
dir
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_basel
ine --name final_sigint_drain --audio-replay-file
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_matrix_
retry1/single.tsv --signal SIGINT --trigger vision --delay 0.1
```

参数逐项：python3 -I -B 隔离用户 Python 环境并禁止字节码写入。 --build-name 指定冻结 ARM64 构建，实际值 stage5_05_final_v2。 --tts-threadsKokoro 线程数，实际值 4。 --seconds 有限输入监听秒数，实际值 120。 --timeout 运行截止秒数，超时必须记失败，实际值 180。 --grace 信号后协作清理宽限秒数，超出强制终止只算失败，实际值 70。 --fixed-frame-dir 固定 NV12 夹具目录，Camera 仍真实采集，Frame Age 不可用，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_baseline。 --name 独占 case 目录，存在则拒绝覆盖，实际值 final_sigint_drain。 --audio-

replay-file 预分段真实语音 TSV，执行真实 ASR 但跳过麦克风/VAD，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_matrix_retry1/single.tsv。 --signal 实际发出的 SIGINT 或 SIGTERM，实际值 SIGINT。 --trigger 从真实日志定位发送阶段，实际值 vision。 --delay 触发后等待秒数，实际值 0.1。

真实退出记录节选：


```
{
  "pid": 40218,
  "returncode": 0,
  "termination_reason": null,
  "sent_signal": "SIGINT",
  "trigger_observed": true,
  "forced_kill": false,
  "timeout": false,
  "duration_seconds": 38.95098321399928,
  "input_closed_to_exit_seconds": 15.998059295998246,
  "signal_to_exit_seconds": 16.129876066999714,
  "timing_scope": "child exit/output EOF, excludes subsequent device/fingerprint queries",
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "image_profile_errors": false,
  "shutdown_complete_marker": true,
  "program_PASS": false,
  "text_tts_completed": false,
  "vision_tts_completed": true,
  "user_audible_confirmation": null,
  "variant": "candidate",
  "input_mode": "fixed_audio_REAL_ASR_no_microphone_VAD",
  "stop_mode": "drain"
}
```


真实输出节选（完整 reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/final_matrix_retry1/final_sigint_drain_runner.log）：


```
[QueueStats] stage=tts generation=1 accepted=1 completed=1 started=1 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=0.069346 queue_max_ms=0.069346 service_sum_ms=13283.1
[PipelineStats] dispatched=1 accepted=1 rejected=0 inflight=0 peak=1 limit=2 vision_accepted=1
vision_rejected=0 llm_cancelled=0 llm_expired=0 vision_cancelled=0 vision_expired=0
cancelled_before_submit=0 downstream_cancelled=0 tts_cancelled=0 tts_expired=0
STOPPED
[FramePool] allocated=2 in_use=0 acquired=542 reused=540 exhausted=0
[CameraCounters] published=541 fps=29.7076 timeouts=0 driver_sequence_gaps=0 pool_discarded=0
STAGE5_05_RUN_RESULT {"pid": 40218, "returncode": 0, "termination_reason": null, "sent_signal":
"SIGINT", "trigger_observed": true, "forced_kill": false, "timeout": false, "duration_seconds":
38.95098321399928, "input_closed_to_exit_seconds": 15.998059295998246, "signal_to_exit_seconds":
16.129876066999714, "timing_scope": "child exit/output EOF, excludes su
REMOTE_REPORT
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_sigint_
```

```
drain
```

解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

final_matrix_retry1 final_sigterm_cancel_waiting_command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
/usr/bin/python3 -I -B
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/tools/stage5_05_voice_run.py --build-
name stage5_05_final_v2 --tts-threads 4 --seconds 120 --timeout 180 --grace 70 --fixed-frame-
dir
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_basel
ine --name final_sigterm_cancel_waiting --audio-replay-file
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_matrix_
retry1/pair.tsv --signal SIGTERM --trigger vision --delay 5 --stop-mode cancel_pending
```

参数逐项：python3 -I -B 隔离用户 Python 环境并禁止字节码写入。 --build-name 指定冻结 ARM64 构建，实际值 stage5_05_final_v2。 --tts-threadsKokoro 线程数，实际值 4。 --seconds 有限输入监听秒数，实际值 120。 --timeout 运行截止秒数，超时必须记失败，实际值 180。 --grace 信号后协作清理宽限秒数，超出强制终止只算失败，实际值 70。 --fixed-frame-dir 固定 NV12 夹具目录，Camera 仍真实采集，Frame Age 不可用，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_baseline。 --name 独占 case 目录，存在则拒绝覆盖，实际值 final_sigterm_cancel_waiting。 --audio-replay-file 预分段真实语音 TSV，执行真实 ASR 但跳过麦克风/VAD，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_matrix_retry1/pair.tsv。 --signal 实际发出的 SIGINT 或 SIGTERM，实际值 SIGTERM。 --trigger 从真实日志定位发送阶段，实际值 vision。 --delay 触发后等待秒数，实际值 5。 --stop-mode 排空或取消等待，活动同步 SDK 不被强行中断，实际值 cancel_pending。

真实退出记录节选：

```
{
  "pid": 40293,
  "returncode": 0,
```

```
  "termination_reason": null,
  "sent_signal": "SIGTERM",
  "trigger_observed": true,
  "forced_kill": false,
  "timeout": false,
  "duration_seconds": 39.597558984998614,
  "input_closed_to_exit_seconds": 11.768925509997644,
  "signal_to_exit_seconds": 12.02652530100022,
  "timing_scope": "child exit/output EOF, excludes subsequent device/fingerprint queries",
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "image_profile_errors": false,
  "shutdown_complete_marker": true,
  "program_PASS": false,
  "text_tts_completed": false,
  "vision_tts_completed": true,
  "user_audible_confirmation": null,
  "variant": "candidate",
  "input_mode": "fixed_audio_REAL_ASR_no_microphone_VAD",
  "stop_mode": "cancel_pending"
}
```


真实输出节选（完整

reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/final_matrix_retry1/final_sigterm_cancel_waiting_runner.log）：


```
[QueueStats] stage=tts generation=1 accepted=2 completed=2 started=1 failed=0 cancelled=1
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=12414.8 queue_max_ms=12414.7 service_sum_ms=14112.2
[PipelineStats] dispatched=2 accepted=2 rejected=0 inflight=0 peak=2 limit=2 vision_accepted=1
vision_rejected=0 llm_cancelled=0 llm_expired=0 vision_cancelled=0 vision_expired=0
cancelled_before_submit=0 downstream_cancelled=0 tts_cancelled=1 tts_expired=0
STOPPED
[FramePool] allocated=2 in_use=0 acquired=566 reused=564 exhausted=0
[CameraCounters] published=565 fps=29.7285 timeouts=0 driver_sequence_gaps=0 pool_discarded=0
STAGE5_05_RUN_RESULT {"pid": 40293, "returncode": 0, "termination_reason": null, "sent_signal":
"SIGTERM", "trigger_observed": true, "forced_kill": false, "timeout": false, "duration_seconds":
39.597558984998614, "input_closed_to_exit_seconds": 11.768925509997644,
"signal_to_exit_seconds": 12.02652530100022, "timing_scope": "child exit/output EOF, excludes s
REMOTE_REPORT
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_sigterm
_cancel_waiting
```


解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

final_matrix_retry1 final_sigterm_initialization_command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
/usr/bin/python3 -I -B
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/tools/stage5_05_voice_run.py --build-
name stage5_05_final_v2 --tts-threads 4 --seconds 120 --timeout 180 --grace 70 --fixed-frame-
dir
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_basel
ine --name final_sigterm_initialization --audio-replay-file
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_matrix_
retry1/single.tsv --signal SIGTERM --trigger init --delay 0.2
```

参数逐项：python3 -I -B 隔离用户 Python 环境并禁止字节码写入。 --build-name 指定冻结 ARM64 构建，实际值 stage5_05_final_v2。 --tts-threadsKokoro 线程数，实际值 4。 --seconds 有限输入监听秒数，实际值 120。 --timeout 运行截止秒数，超时必须记失败，实际值 180。 --grace 信号后协作清理宽限秒数，超出强制终止只算失败，实际值 70。 --fixed-frame-dir 固定 NV12 夹具目录，Camera 仍真实采集，Frame Age 不可用，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_baseline。 --name 独占 case 目录，存在则拒绝覆盖，实际值 final_sigterm_initialization。 --audio-replay-file 预分段真实语音 TSV，执行真实 ASR 但跳过麦克风/VAD，实际值 /home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_matrix_retry1/single.tsv。 --signal 实际发出的 SIGINT 或 SIGTERM，实际值 SIGTERM。 --trigger 从真实日志定位发送阶段，实际值 init。 --delay 触发后等待秒数，实际值 0.2。

真实退出记录节选：


```
{
  "pid": 40369,
  "returncode": 0,
  "termination_reason": null,
  "sent_signal": "SIGTERM",
  "trigger_observed": true,
  "forced_kill": false,
  "timeout": false,
  "duration_seconds": 23.79481105800005,
  "input_closed_to_exit_seconds": 1.6658188299988979,
  "signal_to_exit_seconds": 23.54417397299767,
  "timing_scope": "child exit/output EOF, excludes subsequent device/fingerprint queries",
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "image_profile_errors": false,
  "shutdown_complete_marker": true,
  "program_PASS": false,
  "text_tts_completed": false,
```

```
  "vision_tts_completed": false,
  "user_audible_confirmation": null,
  "variant": "candidate",
  "input_mode": "fixed_audio_REAL_ASR_no_microphone_VAD",
  "stop_mode": "drain"
}
```

真实输出节选（完整

reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/final_matrix_retry1/final_sigterm_initialization_runner.log）：

```
[QueueStats] stage=tts generation=1 accepted=0 completed=0 started=0 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=0 pending=0 active=0 callback_errors=0
queue_sum_ms=0 queue_max_ms=0 service_sum_ms=0
[PipelineStats] dispatched=0 accepted=0 rejected=0 inflight=0 peak=0 limit=2 vision_accepted=0
vision_rejected=0 llm_cancelled=0 llm_expired=0 vision_cancelled=0 vision_expired=0
cancelled_before_submit=0 downstream_cancelled=0 tts_cancelled=0 tts_expired=0
STOPPED
[FramePool] allocated=2 in_use=0 acquired=92 reused=90 exhausted=0
[CameraCounters] published=91 fps=28.3853 timeouts=0 driver_sequence_gaps=0 pool_discarded=0
STAGE5_05_RUN_RESULT {"pid": 40369, "returncode": 0, "termination_reason": null, "sent_signal":
"SIGTERM", "trigger_observed": true, "forced_kill": false, "timeout": false, "duration_seconds":
23.79481105800005, "input_closed_to_exit_seconds": 1.6658188299988979, "signal_to_exit_seconds":
23.54417397299767, "timing_scope": "child exit/output EOF, excludes su
REMOTE_REPORT
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/final_sigterm
_initialization
```

解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

final_camera_followup camera64_command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
/usr/bin/python3 -I -B
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/tools/stage5_05_camera_recheck.py
```

参数逐项：python3 -I -B 隔离用户 Python 环境并禁止字节码写入。

真实退出记录节选：

```
{
```

```
  "complete": true,
  "steps": [
    {
      "step": "camera64",
      "returncode": 0
    },
    {
      "step": "NPU_inventory",
      "returncode": 0
    },
    {
      "step": "protection_after_camera",
      "returncode": 0
    }
  ],
  "scope": "followup of one Camera driver sequence gap; original gap not rewritten as fixed"
}
```


真实输出节选（完整 reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/final_camera_followup/camera64_runner.log）：


```
CAMERA_RECHECK {"returncode": 0, "duration_seconds": 112.84128189699913, "termination_reason": null, "forced_kill": false, "timeout": false, "process_gone": true, "devices_released": true, "original_321_unchanged": true, "samples": 64, "all_VLM_success": true, "input_mode": "LIVE Camera and real VLM only; no ASR, Qwen or TTS; no pixel/semantic ground truth f
```


解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

final_camera_followup NPU_inventory_command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
/usr/bin/python3 -I -B
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/tools/stage5_05_npu_inventory.py --
output
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/npu_desktop_o
wner_recheck.json
```

参数逐项：`python3 -I -B` 隔离用户 Python 环境并禁止字节码写入。

真实退出记录节选：

```
{
  "complete": true,
  "steps": [
    {
      "step": "camera64",
      "returncode": 0
    },
    {
      "step": "NPU_inventory",
      "returncode": 0
    },
    {
      "step": "protection_after_camera",
      "returncode": 0
    }
  ],
  "scope": "followup of one Camera driver sequence gap; original gap not rewritten as fixed"
}
```


真实输出节选（完整 reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/final_camera_followup/NPU_inventory_runner.log）：


```
DRM_BASELINE_SAVED
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/npu_desktop_owner_recheck.json {"primary_nodes": {"/dev/dri/card1": {"query": {"command": ["sudo", "-n", "--", "/usr/bin/fuser", "-v", "/dev/dri/card1"], "exit_code": 0, "stdout": "     1   932  1619", "stderr": "                     \u7528\u6237     \u8fdb\u
```


解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

final_camera_followup protection_after_camera_command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
/usr/bin/python3 -I -B
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/tools/stage5_05_protect.py --name
protection_final_after_camera
```

参数逐项：python3 -I -B 隔离用户 Python 环境并禁止字节码写入。 --name 独占 case 目录，存在则拒绝覆盖，实际值 protection_final_after_camera。

真实退出记录节选：


```
{
  "complete": true,
  "steps": [
    {
      "step": "camera64",
      "returncode": 0
    },
    {
      "step": "NPU_inventory",
      "returncode": 0
    },
    {
      "step": "protection_after_camera",
      "returncode": 0
    }
  ],
  "scope": "followup of one Camera driver sequence gap; original gap not rewritten as fixed"
}
```


真实输出节选（完整 reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/final_camera_followup/protection_after_camera_runner.log）：


```
PROTECTION_RESULT {"checks": {"original321_exact": true, "four_accepted_binaries": true,
"frozen_sources": true, "devices_clear": true, "disk_above500MiB": true,
"no_new_suspicious_kernel_messages": true}, "accepted_binaries":
{"build/stage5_01_board/asr_llm_tts_smoke": true, "build/stage5_02_board/asr_llm_tts_smoke":
true, "build/stage5_03_board/asr_llm_tts
```


解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

camera_gap_recheck command

目的：在记录输入与有限时限内验证 GUI、模型链路、负载或错误清理。

```
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/build/stage5_05_final_v2/stage5_03_memory_probe
/home/cat/projects/RK3576/rk3576_multimodal/models/vlm/smolvlm2_256m_w4a16_rk3576.rkllm
/home/cat/projects/RK3576/rk3576_multimodal/models/vlm/smolvlm_vision_scatterfix_rk3576.rknn
/dev/video11
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_05_board/camera_gap_recheck 64
```

参数逐项：

真实退出记录节选：

```
{
  "returncode": 0,
  "duration_seconds": 112.84128189699913,
  "termination_reason": null,
  "forced_kill": false,
  "timeout": false,
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "samples": 64,
  "all_VLM_success": true,
  "input_mode": "LIVE Camera and real VLM only; no ASR, Qwen or TTS; no pixel/semantic ground
truth for every frame",
  "scope": "counter and kernel-log recheck, not a claimed fix of the isolated sequence gap"
}
```

真实输出节选（完整

reports/stage5_05_board/collected_20261018_014600/files/reports/stage5_05_board/camera_gap_recheck/terminal.log）：

```
[MemoryProbe] sample=62 success=1 frame=3234 vlm_ms=1716.63 answer= A computer screen with a
blue screen and some text on it. error=
[MemoryProbe] sample=63 success=1 frame=3285 vlm_ms=1702.74 answer= A computer screen with a
blue screen and some text on it. error=
[FramePool] allocated=3 in_use=0 acquired=3338 reused=3335 exhausted=0
[CameraCounters] published=3337 fps=29.9528 timeouts=0 driver_sequence_gaps=0 pool_discarded=0
[MemoryProbe] stopped fps=29.9836 frames=3337 timeouts=0
[FramePool] allocated=3 in_use=0 acquired=3338 reused=3335 exhausted=0
[CameraCounters] published=3337 fps=29.9528 timeouts=0 driver_sequence_gaps=0 pool_discarded=0
```

解释与成功判断：编译需返回 0 且目标生成，CTest 需注册项全部通过；Fake 不能替代硬件。真实测试需子进程退出符合预期、无超时/强杀、shutdown、设备释放和原工程指纹一致；拒绝/到期/取消须核对预期计数。环境影响仅新隔离源码、构建、日志与本次设备占用，不改系统/模型。该命令的结论以对应 result.json 及上述原始日志为准，不从 SSH 退出 0 推测模型成功。

主机收集统计与文档生成

```
python tools/stage5_05_collect.py --complete-only
python tools/stage5_05_analyze.py --collection
reports/stage5_05_board/collected_20261018_014600
```

```
python tools/stage5_05_stability.py --collection
reports/stage5_05_board/collected_20261018_014600
python tools/stage5_05_plots.py
python tools/stage5_05_export.py
python tools/stage5_05_validate.py --collection
reports/stage5_05_board/collected_20261018_014600
python tools/stage5_05_manual.py
```

collect 只读打包本节完成目录，--complete-only 跳过活动 case，逐个验证普通文件/安全相对路径和总字节上限，保留 SHA。analyze 按 case+request_id 关联 steady ns，缺失值为 null；stability 排除前 5 分钟并计算 RSS 趋势和逐条 RTF；plots 只用真实 CSV，不生成假数据。export 用真实 git diff --no-index --binary，core.autocrlf=false 避免换行转换，再在临时树 apply 后逐文件 SHA。validate 核对全部证据，不把本地测试替代 ARM。manual 从最终报告和当前源码抽取完整函数。成功输出和结果分别在 collection manifest、analysis、patch_roundtrip、validation_summary 及 manual_source_manifest。

文档创建使用已解析的 Codex bundled Python 运行 stage5_05_build_docx.py，字体为楷体/Times New Roman 12pt、1.5 倍行距、两字符缩进，代码等宽。packaged renderer 因缺少 LibreOffice 失败的日志保留；原生 Word 只打开本次文档、更新目录并导出 PDF，然后复用 packaged rasterizer 生成 PNG。仅关闭本任务新建且无其他文档的 Word 实例，不结束用户 Word。每页视觉核对与代码逐行回读在 document_build、render 结果与 document_QA 保存，不能只靠 XML 检查声称排版成功。

5.3 重要采集 固定帧和 RGA 命令

5.3 命令、参数与真实输出索引

本节命令均已由保存的 Python payload/command.json 实际执行，复现时必须换一个不存在的报告目录名。此页给出等价的可读形式，真实 argv、stdout、stderr、退出码仍以报告文件为准。不要直接重跑 exclusive 部署脚本覆盖已经冻结的版本。

1. 路径与影响

```
REVIEW=/home/cat/projects/RK3576/rk3576_multimodal_stage5_review
source "$REVIEW/tools/stage5_board_paths.sh"
```

变量 REVIEW 只指向已授权隔离目录。source 在当前 shell 导入已核实的 SDK/模型路径与 LD_LIBRARY_PATH，不修改系统环境文件；脚本只读原工程 CMakeCache 取得实际 SDK 位置。模型直接从原路径读取，没有复制或改写。后台启动使用普通 cat 用户；sudo -n 只用于只读 fuser 查询，不用于构建或程序运行。

`uname -a` 确认目标 ARM64；`free -b` 以字节给出系统内存；`df -B1 "$REVIEW"` 以字节检查当前文件系统可用空间。构建脚本逐秒取 statvfs，低于 500 MiB 即停止。`v4l2-ctl -d /dev/video11 --get-fmt-video` 中 -d 选择设备、--get-fmt-video 查询实际格式，不改设备树或驱动。--get-parm 本轮返回 255、不支持；FPS 使用发布帧数/单调时钟计算。

2. 基线和候选版本构建

```
cmake -S "$REVIEW/stage5_03_source" -B "$REVIEW/build/stage5_03_board" \
  -DCMAKE_BUILD_TYPE=Release -DBUILD_TESTING=ON \
  -DBUILD_WITH_RKLLM=ON -DBUILD_WITH_VLM=ON -DENABLE_SHERPA_ASR=ON \
  -DSHERPA_ONNX_ROOT="$STAGE5_SHERPA" -DRKLLM_SDK_ROOT="$STAGE5_RKLLM" \
  -DRKNN_INCLUDE_DIR="$STAGE5_RKNN_INCLUDE" \
  -DRKNN_RUNTIME_LIBRARY="$STAGE5_RKNN_LIBRARY"
cmake --build "$REVIEW/build/stage5_03_board" --parallel 3
ctest --test-dir "$REVIEW/build/stage5_03_board" --output-on-failure \
  --timeout 30 --output-junit "$REVIEW/reports/stage5_03_board/NEW_NAME/ctest.xml"
```

- -S/-B 把源码和产物明确分离；这里是板端原生 ARM64 编译，没有伪称 Windows 交叉验证。
- Release 保持基线与优化版相同的构建类型；三个并行编译任务避免不受控内存占用。
- 三个 ON 启用真实 RKLLM、VLM 和 sherpa 接口；ROOT/INCLUDE/LIBRARY 只指向现有 SDK，未改其内容。
- BUILD_TESTING 注册确定性测试和手动硬件探针；手动探针没有作为 CTest 自动启动硬件。
- --output-on-failure 显示失败细节，--timeout 30 给每项测试兜底，--output-junit 保存机器可读结果。测试名称自己的 TIMEOUT 若更短仍生效。

细分基线采用同样命令，只替换为 stage5_03_baseline_source、build/stage5_03_baseline。初次候选构建成功 26 个 Target；最终生产源码复测 ARM64 6/6、本地 SDK 关闭的 portable 8/8。不能把目标数量或 SDK 链接解释为全部测试实际执行过 NPU。初次/修复后的完整配置、编译

和 CTest 日志分别在 candidate_build、candidate_retirement_review、candidate_counter_instrumentation、candidate_config_review，失败记录从不覆盖。

3. Camera 和固定帧探针

```
python3 "$REVIEW/tools/stage5_03_probe_run.py" --name NEW_LIVE \
  --variant candidate --samples 12
python3 "$REVIEW/tools/stage5_03_probe_run.py" --name NEW_FIXED \
  --variant candidate --samples 6 --fixed
python3 "$REVIEW/tools/stage5_03_probe_run.py" --name NEW_FALLBACK \
  --variant candidate --samples 6 --fixed --fallback
```

name 为独占新报告目录；variant 选择冻结细分基线或候选二进制；samples 限制 1～64，避免无限采样。fixed 循环使用 raw_5_2_baseline 保存的三个真实 NV12 帧，六次包含每帧两次。fallback 同时设置 CAMERA_POOL=0 和 VISION_PREPROCESS=reference。每个子进程 180 秒上限，检查 exe 和 PID start token 后才向本次子进程发信号；超时或强制终止会明确判失败。

核心等价命令为：

```
STAGE5_IMAGE_PROFILE="$REVIEW/reports/stage5_03_board/NEW_LIVE/image_profile.jsonl" \
  "$REVIEW/build/stage5_03_board/stage5_03_memory_probe" \
  "$STAGE5_VLM" "$STAGE5_VISION" /dev/video11 \
  "$REVIEW/reports/stage5_03_board/NEW_LIVE" 12
```

这是单次进程执行 12 次“按需获取最新帧→VLM”；Camera 持续采集，不是每帧执行 VLM。requests.csv 的 success=1 表示本次引擎成功，result.json 的 returncode=0、devices_released=true、process_gone=true 是进程与设备检查。camera.json 在 stop 前取 FPS；终端 CameraCounters 在 stop 后计算，分母多了一点退出时间，不能混用。

image_profile.jsonl 每行 stage/ms/id/bytes/allocations 分别表示操作边界、毫秒、帧 ID、该操作的数据量和源码可见扩容/控制块事件。capture_alloc_prepare 包含 reserve，capture_payload_reserve 是其中嵌套计时，不应相加。preprocess_fused 同时包含转换与 resize；两者没有单独可靠时间。rknn_inputs_set 是 SDK 输入准备，不是零成本指针传递。

4. 真实麦克风和回放退出

```
python3 "$REVIEW/tools/stage5_03_voice_run.py" --name NEW_VOICE \
  --seconds 120 --timeout 240 --grace 70
python3 "$REVIEW/tools/stage5_03_voice_run.py" --name NEW_INT \
  --signal SIGINT --trigger ready --delay 2 --seconds 30 --timeout 100 --grace 50
python3 "$REVIEW/tools/stage5_03_voice_run.py" --name NEW_TERM_CANCEL \
```

```
  --replay --replay-source pair --stop-mode cancel_pending \
  --signal SIGTERM --trigger vision --delay 0.2 --seconds 30 --timeout 130 --grace 70
python3 "$REVIEW/tools/stage5_03_voice_run.py" --name NEW_TERM_DRAIN \
  --replay --replay-source pair --tts-queue-ms 60000 --request-lifetime-ms 120000 \
  --signal SIGTERM --trigger tts --delay 0.2 --seconds 30 --timeout 170 --grace 80
```

每轮重新从 /proc/asound/cards 与 pcm 节点匹配 HyperX Cloud III，不写死历史数字声卡号。实际 argv 保存 command.json；ALSA 使用 plughw:CARD=识别出的 ID,DEV=识别出的设备。voice 自然输入才验证 USB 麦克风、Silero、SenseVoice；replay 明确跳过它们，只用于可控调度/信号时机。pair 是原 5.2 固定的视觉/文本输入文件，不是伪造 ASR 日志。

signal 选择被测信号，trigger 在日志中观察指定里程碑后才计 delay；tts 观察 ALSA write，意味着播放已提交。grace 只用于本次新子进程的安全等待上限。强制 SIGKILL 保护即使触发也不能算优雅退出；真实测试 result.forced_kill=false 才支持本轮安全退出结论。drain 完成已接收工作；cancel_pending 取消尚未开始或尚未提交的下游工作，不强行中断正在 RKNN/RKLLM 中执行的调用。

退出检查按顺序看 signal 事件及 PID→ASR joined→LLM joined→TTS joined→FramePool in_use=0→Camera stopped/VLM destroyed→shutdown complete。STOPPED 是收到信号后的成功状态，不要求字面 PASS。真正的子进程退出码在 result.json；SSH/Python wrapper 的 0 只表示证据传输完成。

```
sudo -n -- /usr/bin/fuser -v /dev/video11 /dev/snd/实际采集节点 /dev/snd/实际播放节点 /dev/dri/实际 NPU 节点
```

此命令只查占用，没有 -k。没有占用时 fuser 通常退出 1，且 stdout/stderr 为空；这是检查通过，不是程序错误。ALSA status 应为 closed，子进程 /proc/PID 消失。最终另查 /dev/rga，没有对共享进程发信号。

5. RGA 失败实验的复现边界

独立 stage5_03_rga_probe 手动目标分别试过虚拟地址导入、system DMA-BUF 导入、DMA 分步 resize→CSC；原始 argv、result、stdout/stderr 及 dmesg 在 rga_diagnostic、rga_diagnostic_dma、rga_diagnostic_split。三次均在第一个硬件 job 失败，不能输出 RGA P50/P95 或质量通过结论。不应盲目循环重试导致共享设备更多超时；本节已经停止 RGA 实验，生产选择 CPU。驱动自己报告 soft reset，不是本次脚本修改/重置驱动。

只读 dpkg-query -W '*rga*'、/sbin/ldconfig -p 和头文件检查用于区分包版本、SO 文件名、Runtime API 版本；没有执行 ldconfig 更新。reserved heap 不具备普通用户访问权限，没有 chmod、sudo 分配或配置修改。

6. 本地证据整理与补丁验证

```
python tools/stage5_03_collect.py
python tools/stage5_03_analyze.py --collection reports/stage5_03_board/collected_实际时间
python tools/stage5_03_export.py
```

collect 只打包隔离 reports/stage5_03_board 内普通文件，拒绝符号链接、目录穿越和超大成员；解压到独占的新本地目录。analyze 只读取真实 JSONL/CSV；P50/P95 使用 nearest-rank，保留全部原始样本；空项保持未测量。export 使用 git diff --no-index --binary、core.autocrlf=false 生成完整补丁，并在临时复制的精确基线做 git apply --check、实际 apply 和逐文件 SHA256 回环检查；不在真实工作区试贴补丁。目录不是 Git 仓库，不伪造 commit ID。

每次 SSH 的 payload.py、命令、原始 stdout/stderr 和传输退出码位于本地 reports/stage5_03_board/ssh_时间；每个板端进程的真实退出码在采集目录对应 result.json。完整文件映射由 collection manifest 的 SHA256 连接起来。

5.4 固定输入与 ORT 诊断重要命令

操作 baseline_asr_30/run

目的：在指定固定/真实输入条件下采样或回归；不安装软件、不改模型和设备配置。

```
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/build/stage5_04_baseline_v2/stage5_04
_asr_bench /home/cat/projects/RK3576/asr_runtime/sherpa-onnx-sense-voice-zh-en-ja-ko-yue-int8-
2024-07-17 /home/cat/projects/RK3576/asr_runtime/sherpa-onnx-sense-voice-zh-en-ja-ko-yue-int8-
2024-07-17/test_wavs/zh.wav
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_04_board/baseline_asr_
30 30
```

参数：程序绝对路径决定具体冻结版本。TTS bench 依次为模型目录、独占报告目录、线程数、有效重复次数（另加两轮 first-use/warmup）；ASR bench 为模型目录、固定 WAV、报告目录、重复次数；Vision bench 为语言模型、Vision 模型、固定 NV12 目录、报告目录、重复次数。完整语音入口为采集设备、ASR 目录、VAD 模型、Qwen 模型、Kokoro 目录、播放设备、监听秒数、TTS 线程数、sid17、VLM 语言模型、Vision 模型、Camera 节点。stdbuf -oL/-eL 仅

调整输出缓冲，便于按真实监听/信号阶段触发。实际采集/回放模式见 test_parameters 和 environment，不从程序名字猜测。

真实退出/守护记录：


```
{
  "returncode": 0,
  "seconds": 69.57738432000042,
  "termination_reason": null,
  "forced_kill": false,
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "disk_free_bytes": 1974579200
}
```


真实 stdout 节选（完整 terminal.log）：

```
[ASRBench] sample=0 ms=1961.19 text=开饭时间早上九点至下午五点
[ASRBench] sample=1 ms=1984.06 text=开饭时间早上九点至下午五点
[ASRBench] sample=2 ms=1987.9 text=开饭时间早上九点至下午五点
[ASRBench] sample=3 ms=1987.42 text=开饭时间早上九点至下午五点
[ASRBench] sample=4 ms=1987.93 text=开饭时间早上九点至下午五点
[此处省略，完整原始文件见链接]
[ASRBench] sample=24 ms=1987.64 text=开饭时间早上九点至下午五点
[ASRBench] sample=25 ms=1989.57 text=开饭时间早上九点至下午五点
[ASRBench] sample=26 ms=1988.47 text=开饭时间早上九点至下午五点
[ASRBench] sample=27 ms=1987.51 text=开饭时间早上九点至下午五点
[ASRBench] sample=28 ms=1987.53 text=开饭时间早上九点至下午五点
[ASRBench] sample=29 ms=1986.33 text=开饭时间早上九点至下午五点
[ASRBench] sample=30 ms=1986.39 text=开饭时间早上九点至下午五点
[ASRBench] sample=31 ms=1985.69 text=开饭时间早上九点至下午五点
```

真实 stderr 节选（完整 stderr.log）：

输出解释与成功判断：编译需退出 0 且目标生成；CTest 需注册测试全部通过，Fake 仅验证并发/生命周期；硬件程序需核对本 case 真实 returncode、无 timeout/forced_kill、完整 shutdown 和设备释放。拒绝/到期/取消的故意场景还必须核对对应终态计数，不把 SSH 成功当模型成功。环境影响：仅隔离源码/构建/日志写入和本次进程的设备使用，原工程/模型/SDK/系统只读。结论以本 case 原始记录为准，表内空值就是未测量。

操作 baseline_tts_ort_detail/run

目的：在指定固定/真实输入条件下采样或回归；不安装软件、不改模型和设备配置。

```
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/build/stage5_04_baseline_v2/stage5_04
_tts_bench /home/cat/projects/RK3576/tts_runtime/models/kokoro-multi-lang-v1_1
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_04_board/baseline_tts_
ort_detail 2 1
```

参数：程序绝对路径决定具体冻结版本。TTS bench 依次为模型目录、独占报告目录、线程数、有效重复次数（另加两轮 first-use/warmup）；ASR bench 为模型目录、固定 WAV、报告目录、重复次数；Vision bench 为语言模型、Vision 模型、固定 NV12 目录、报告目录、重复次数。完整语音入口为采集设备、ASR 目录、VAD 模型、Qwen 模型、Kokoro 目录、播放设备、监听秒数、TTS 线程数、sid17、VLM 语言模型、Vision 模型、Camera 节点。stdbuf -oL/-eL 仅调整输出缓冲，便于按真实监听/信号阶段触发。实际采集/回放模式见 test_parameters 和 environment，不从程序名字猜测。

真实退出/守护记录：

```
{
  "returncode": 0,
  "seconds": 93.12210873000004,
  "termination_reason": null,
  "forced_kill": false,
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "disk_free_bytes": 1928675328
}
```

真实 stdout 节选（完整 terminal.log）：

```
[SDK] sherpa=1.13.8 git=11afbd00 ort=1.28.2
[TTSInit] ms=7626.07 threads=2 sid=17 sample_rate=24000
[TTSBench] iteration=0 language=zh phase=first_use synth_ms=10050 wall_ms=10050.1
audio_seconds=1.958 nonfinite=0
[TTSBench] iteration=0 language=en phase=first_use synth_ms=17984.7 wall_ms=17984.9
audio_seconds=4.11417 nonfinite=0
[TTSBench] iteration=1 language=zh phase=warmup synth_ms=9907.67 wall_ms=9907.77
audio_seconds=1.95617 nonfinite=0
[TTSBench] iteration=1 language=en phase=warmup synth_ms=18087 wall_ms=18087.2
audio_seconds=4.11404 nonfinite=0
[TTSBench] iteration=2 language=zh phase=measured synth_ms=9859.08 wall_ms=9859.14
audio_seconds=1.958 nonfinite=0
[TTSBench] iteration=2 language=en phase=measured synth_ms=18148.3 wall_ms=18148.4
audio_seconds=4.11421 nonfinite=0
[TTSBench] complete
```

真实 stderr 节选（完整 stderr.log）：

```
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/lexicon.cc:ConvertTokensToIds:93 Unknown token: ？
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
```

输出解释与成功判断：编译需退出 0 且目标生成；CTest 需注册测试全部通过，Fake 仅验证并发/生命周期；硬件程序需核对本 case 真实 returncode、无 timeout/forced_kill、完整 shutdown 和设备释放。拒绝/到期/取消的故意场景还必须核对对应终态计数，不把 SSH 成功当模型成功。环境影响：仅隔离源码/构建/日志写入和本次进程的设备使用，原工程/模型/SDK/系统只读。结论以本 case 原始记录为准，表内空值就是未测量。

操作 baseline_vision_30/run

目的：在指定固定/真实输入条件下采样或回归；不安装软件、不改模型和设备配置。

```
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/build/stage5_04_baseline_v2/stage5_04
_vision_bench
/home/cat/projects/RK3576/rk3576_multimodal/models/vlm/smolvlm2_256m_w4a16_rk3576.rkllm
/home/cat/projects/RK3576/rk3576_multimodal/models/vlm/smolvlm_vision_scatterfix_rk3576.rknn
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_03_board/raw_5_2_basel
ine
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_04_board/baseline_visi
on_30 30
```

参数：程序绝对路径决定具体冻结版本。TTS bench 依次为模型目录、独占报告目录、线程数、有效重复次数（另加两轮 first-use/warmup）；ASR bench 为模型目录、固定 WAV、报告目录、重复次数；Vision bench 为语言模型、Vision 模型、固定 NV12 目录、报告目录、重复次

数。完整语音入口为采集设备、ASR 目录、VAD 模型、Qwen 模型、Kokoro 目录、播放设备、监听秒数、TTS 线程数、sid17、VLM 语言模型、Vision 模型、Camera 节点。stdbuf -oL/-eL 仅调整输出缓冲，便于按真实监听/信号阶段触发。实际采集/回放模式见 test_parameters 和 environment，不从程序名字猜测。

真实退出/守护记录：


```
{
  "returncode": 0,
  "seconds": 60.174319441999614,
  "termination_reason": null,
  "forced_kill": false,
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "disk_free_bytes": 1944166400
}
```


真实 stdout 节选（完整 terminal.log）：

```
[VisionTensor] input_type=1 input_fmt=1 input_elems=786432 input_w_stride=512
input_size=1572864 input_size_with_stride=1572864 output_elems=36864 output_type=1
input_dims=1,512,512,3, output_dims=1,64,576,
I rkllm: rkllm-runtime version: 1.3.1, rknpu driver version: 0.9.8, platform: RK3576
I rkllm: loading rkllm model from
/home/cat/projects/RK3576/rk3576_multimodal/models/vlm/smolvlm2_256m_w4a16_rk3576.rkllm
I rkllm: rkllm-toolkit version: 1.3.1, max_context_limit: 2048, npu_core_num: 2,
target_platform: RK3576, model_dtype: W4A16
I rkllm: Enabled cpus: [4, 5, 6, 7]
[此处省略，完整原始文件见链接]
[VisionBench] sample=24 fixture=0 success=1 ms=1657.82 answer= A computer monitor with a blue
screen and some text on it.
[VisionBench] sample=25 fixture=1 success=1 ms=1728.84 answer= A computer monitor with a blue
screen, and a black stand holding it up to the camera.
[VisionBench] sample=26 fixture=2 success=1 ms=1878.87 answer= A computer monitor with a blue
screen, and a black stand holding it up to the camera.
[VisionBench] sample=27 fixture=0 success=1 ms=1740.9 answer= A computer monitor with a blue
screen and some text on it.
[VisionBench] sample=28 fixture=1 success=1 ms=1843.5 answer= A computer monitor with a blue
screen, and a black stand holding it up to the camera.
[VisionBench] sample=29 fixture=2 success=1 ms=1794.82 answer= A computer monitor with a blue
screen, and a black stand holding it up to the camera.
[VisionBench] sample=30 fixture=0 success=1 ms=1717.08 answer= A computer monitor with a blue
screen and some text on it.
[VisionBench] sample=31 fixture=1 success=1 ms=1753.21 answer= A computer monitor with a blue
screen, and a black stand holding it up to the camera.
```

真实 stderr 节选（完整 stderr.log）：

输出解释与成功判断：编译需退出 0 且目标生成；CTest 需注册测试全部通过，Fake 仅验证并发/生命周期；硬件程序需核对本 case 真实 returncode、无 timeout/forced_kill、完整 shutdown 和设备释放。拒绝/到期/取消的故意场景还必须核对对应终态计数，不把 SSH 成功当模型成功。环境影响：仅隔离源码/构建/日志写入和本次进程的设备使用，原工程/模型/SDK/系统只读。结论以本 case 原始记录为准，表内空值就是未测量。

操作 candidate_pipeline_pairs_4t/run

目的：在指定固定/真实输入条件下采样或回归；不安装软件、不改模型和设备配置。

```
stdbuf -oL -eL
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/build/stage5_04_board_v2/asr_llm_tts_
smoke plughw:CARD=III,DEV=0 /home/cat/projects/RK3576/asr_runtime/sherpa-onnx-sense-voice-zh-
en-ja-ko-yue-int8-2024-07-17 /home/cat/projects/RK3576/asr_runtime/vad/silero_vad.onnx
/home/cat/projects/RK3576/rkllm_sdk/models/Qwen2.5-1.5B-Instruct_RK3576_w4a16.rkllm
/home/cat/projects/RK3576/tts_runtime/models/kokoro-multi-lang-v1_1 plughw:CARD=III,DEV=0 120 4
17 /home/cat/projects/RK3576/rk3576_multimodal/models/vlm/smolvlm2_256m_w4a16_rk3576.rkllm
/home/cat/projects/RK3576/rk3576_multimodal/models/vlm/smolvlm_vision_scatterfix_rk3576.rknn
/dev/video11
```

参数：程序绝对路径决定具体冻结版本。TTS bench 依次为模型目录、独占报告目录、线程数、有效重复次数（另加两轮 first-use/warmup）；ASR bench 为模型目录、固定 WAV、报告目录、重复次数；Vision bench 为语言模型、Vision 模型、固定 NV12 目录、报告目录、重复次数。完整语音入口为采集设备、ASR 目录、VAD 模型、Qwen 模型、Kokoro 目录、播放设备、监听秒数、TTS 线程数、sid17、VLM 语言模型、Vision 模型、Camera 节点。stdbuf -oL/-eL 仅调整输出缓冲，便于按真实监听/信号阶段触发。实际采集/回放模式见 test_parameters 和 environment，不从程序名字猜测。

真实退出/守护记录：


```
{
  "pid": 27671,
  "returncode": 0,
  "sent_signal": null,
  "trigger_observed": true,
  "forced_kill": false,
  "timeout": false,
  "duration_seconds": 127.46573636999892,
  "input_closed_to_exit_seconds": 24.58669599299901,
  "signal_to_exit_seconds": null,
  "timing_scope": "child exit/output EOF, excludes subsequent device/fingerprint queries",
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
```

```
  "image_profile_errors": false,
  "shutdown_complete_marker": true,
  "program_PASS": true,
  "text_tts_completed": true,
  "vision_tts_completed": true,
  "user_audible_confirmation": null,
  "variant": "candidate",
  "input_mode": "fixed_audio_REAL_ASR_no_microphone_VAD",
  "stop_mode": "drain"
}
```


真实 stdout 节选（完整 terminal.log）：

```
[Init] Loading RKLLM...
I rkllm: rkllm-runtime version: 1.3.1, rknpu driver version: 0.9.8, platform: RK3576
I rkllm: loading rkllm model from /home/cat/projects/RK3576/rkllm_sdk/models/Qwen2.5-1.5B-
Instruct_RK3576_w4a16.rkllm
I rkllm: rkllm-toolkit version: 1.2.3, max_context_limit: 4096, npu_core_num: 2,
target_platform: RK3576, model_dtype: W4A16
I rkllm: Enabled cpus: [4, 5, 6, 7]
[此处省略，完整原始文件见链接]
VISION completed/success/failed: 3/3/0
[AudioQueueStats] pushed=6 popped=6 dropped=0 rejected_closed=0 peak=1 pending=0
[QueueStats] stage=inference generation=1 accepted=6 completed=6 started=6 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=1557.8 queue_max_ms=653.118 service_sum_ms=9136.21
[QueueStats] stage=tts generation=1 accepted=6 completed=6 started=6 failed=0 cancelled=0
expired=0 rejected_full=0 rejected_stopped=0 peak=1 pending=0 active=0 callback_errors=0
queue_sum_ms=39326 queue_max_ms=13268 service_sum_ms=69501.3
[PipelineStats] dispatched=6 accepted=6 rejected=0 inflight=0 peak=2 limit=2 vision_accepted=3
vision_rejected=0 llm_cancelled=0 llm_expired=0 vision_cancelled=0 vision_expired=0
cancelled_before_submit=0 downstream_cancelled=0 tts_cancelled=0 tts_expired=0
PASS
[FramePool] allocated=2 in_use=0 acquired=3222 reused=3220 exhausted=0
[CameraCounters] published=3221 fps=29.9508 timeouts=0 driver_sequence_gaps=0 pool_discarded=0
```

输出解释与成功判断：编译需退出 0 且目标生成；CTest 需注册测试全部通过，Fake 仅验证并发/生命周期；硬件程序需核对本 case 真实 returncode、无 timeout/forced_kill、完整 shutdown 和设备释放。拒绝/到期/取消的故意场景还必须核对对应终态计数，不把 SSH 成功当模型成功。环境影响：仅隔离源码/构建/日志写入和本次进程的设备使用，原工程/模型/SDK/系统只读。结论以本 case 原始记录为准，表内空值就是未测量。

操作 raw_tts_baseline_2t/run

目的：在指定固定/真实输入条件下采样或回归；不安装软件、不改模型和设备配置。

```
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_04_board/raw_baseline_
build/tts_bench /home/cat/projects/RK3576/tts_runtime/models/kokoro-multi-lang-v1_1
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_04_board/raw_tts_basel
```

```
ine_2t 2 30
```

参数：程序绝对路径决定具体冻结版本。TTS bench 依次为模型目录、独占报告目录、线程数、有效重复次数（另加两轮 first-use/warmup）；ASR bench 为模型目录、固定 WAV、报告目录、重复次数；Vision bench 为语言模型、Vision 模型、固定 NV12 目录、报告目录、重复次数。完整语音入口为采集设备、ASR 目录、VAD 模型、Qwen 模型、Kokoro 目录、播放设备、监听秒数、TTS 线程数、sid17、VLM 语言模型、Vision 模型、Camera 节点。stdbuf -oL/-eL 仅调整输出缓冲，便于按真实监听/信号阶段触发。实际采集/回放模式见 test_parameters 和 environment，不从程序名字猜测。

真实退出/守护记录：

```
{
  "returncode": 0,
  "seconds": 893.7276720030004,
  "termination_reason": null,
  "forced_kill": false,
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "disk_free_bytes": 2030051328
}
```

真实 stdout 节选（完整 terminal.log）：

```
[SDK] sherpa=1.13.8 git=11afbd00 ort=1.28.2
[TTSInit] ms=6765 threads=2 sid=17 sample_rate=24000
[TTSBench] iteration=0 language=zh phase=first_use synth_ms=10006.9 wall_ms=10006.9
audio_seconds=1.95817 nonfinite=0
[TTSBench] iteration=0 language=en phase=first_use synth_ms=17363.6 wall_ms=17363.6
audio_seconds=4.11479 nonfinite=0
[TTSBench] iteration=1 language=zh phase=warmup synth_ms=9857.1 wall_ms=9857.12
audio_seconds=1.95521 nonfinite=0
[此处省略，完整原始文件见链接]
[TTSBench] iteration=28 language=en phase=measured synth_ms=17413 wall_ms=17413.1
audio_seconds=4.11692 nonfinite=0
[TTSBench] iteration=29 language=zh phase=measured synth_ms=9983.86 wall_ms=9983.88
audio_seconds=1.95617 nonfinite=0
[TTSBench] iteration=29 language=en phase=measured synth_ms=17723.8 wall_ms=17723.9
audio_seconds=4.11613 nonfinite=0
[TTSBench] iteration=30 language=zh phase=measured synth_ms=9888.89 wall_ms=9888.91
audio_seconds=1.95633 nonfinite=0
[TTSBench] iteration=30 language=en phase=measured synth_ms=18168.5 wall_ms=18168.5
audio_seconds=4.11417 nonfinite=0
[TTSBench] iteration=31 language=zh phase=measured synth_ms=10112.5 wall_ms=10112.5
audio_seconds=1.95029 nonfinite=0
[TTSBench] iteration=31 language=en phase=measured synth_ms=17838.5 wall_ms=17838.6
audio_seconds=4.1115 nonfinite=0
```

```
[TTSBench] complete
```

真实 stderr 节选（完整 stderr.log）：

```
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/lexicon.cc:ConvertTokensToIds:93 Unknown token: ?
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
[此处省略，完整原始文件见链接]
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
```

输出解释与成功判断：编译需退出 0 且目标生成；CTest 需注册测试全部通过，Fake 仅验证并发/生命周期；硬件程序需核对本 case 真实 returncode、无 timeout/forced_kill、完整 shutdown 和设备释放。拒绝/到期/取消的故意场景还必须核对对应终态计数，不把 SSH 成功当模型成功。环境影响：仅隔离源码/构建/日志写入和本次进程的设备使用，原工程/模型/SDK/系统只读。结论以本 case 原始记录为准，表内空值就是未测量。

操作 raw_tts_final_4t/run

目的：在指定固定/真实输入条件下采样或回归；不安装软件、不改模型和设备配置。

```
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_04_board/raw_baseline_
build/tts_bench /home/cat/projects/RK3576/tts_runtime/models/kokoro-multi-lang-v1_1
/home/cat/projects/RK3576/rk3576_multimodal_stage5_review/reports/stage5_04_board/raw_tts_final
_4t 4 30
```

参数：程序绝对路径决定具体冻结版本。TTS bench 依次为模型目录、独占报告目录、线程数、有效重复次数（另加两轮 first-use/warmup）；ASR bench 为模型目录、固定 WAV、报告目录、重复次数；Vision bench 为语言模型、Vision 模型、固定 NV12 目录、报告目录、重复次数。完整语音入口为采集设备、ASR 目录、VAD 模型、Qwen 模型、Kokoro 目录、播放设备、监听秒数、TTS 线程数、sid17、VLM 语言模型、Vision 模型、Camera 节点。stdbuf -oL/-eL 仅调整输出缓冲，便于按真实监听/信号阶段触发。实际采集/回放模式见 test_parameters 和 environment，不从程序名字猜测。

真实退出/守护记录：

```
{
  "returncode": 0,
  "seconds": 625.5646094240001,
  "termination_reason": null,
  "forced_kill": false,
  "process_gone": true,
  "devices_released": true,
  "original_321_unchanged": true,
  "disk_free_bytes": 1925214208
}
```

真实 stdout 节选（完整 terminal.log）：

```
[SDK] sherpa=1.13.8 git=11afbd00 ort=1.28.2
[TTSInit] ms=6129.75 threads=4 sid=17 sample_rate=24000
[TTSBench] iteration=0 language=zh phase=first_use synth_ms=6615.46 wall_ms=6615.49
audio_seconds=1.95617 nonfinite=0
[TTSBench] iteration=0 language=en phase=first_use synth_ms=11755.1 wall_ms=11755.2
audio_seconds=4.11412 nonfinite=0
[TTSBench] iteration=1 language=zh phase=warmup synth_ms=6500.74 wall_ms=6500.77
audio_seconds=1.95804 nonfinite=0
[此处省略，完整原始文件见链接]
[TTSBench] iteration=28 language=en phase=measured synth_ms=12486.6 wall_ms=12486.6
audio_seconds=4.11471 nonfinite=0
[TTSBench] iteration=29 language=zh phase=measured synth_ms=6928.58 wall_ms=6928.6
audio_seconds=1.95617 nonfinite=0
[TTSBench] iteration=29 language=en phase=measured synth_ms=12544.1 wall_ms=12544.2
audio_seconds=4.11479 nonfinite=0
```

```
[TTSBench] iteration=30 language=zh phase=measured synth_ms=7042.74 wall_ms=7042.77
audio_seconds=1.95392 nonfinite=0
[TTSBench] iteration=30 language=en phase=measured synth_ms=12583.6 wall_ms=12583.6
audio_seconds=4.11067 nonfinite=0
[TTSBench] iteration=31 language=zh phase=measured synth_ms=6975.86 wall_ms=6975.88
audio_seconds=1.95617 nonfinite=0
[TTSBench] iteration=31 language=en phase=measured synth_ms=12581.4 wall_ms=12581.5
audio_seconds=4.11417 nonfinite=0
[TTSBench] complete
```

真实 stderr 节选（完整 stderr.log）：

```
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/lexicon.cc:ConvertTokensToIds:93 Unknown token: ?
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
[此处省略，完整原始文件见链接]
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
/k2-fsa/sherpa-onnx/sherpa-onnx/csrc/piper-phonemize-
lexicon.cc:PiperPhonemesToIdsKokoroOrKitten:261 Skip unknown phonemes. Unicode codepoint:
\U+025a.
```

输出解释与成功判断：编译需退出 0 且目标生成；CTest 需注册测试全部通过，Fake 仅验证并发/生命周期；硬件程序需核对本 case 真实 returncode、无 timeout/forced_kill、完整

shutdown 和设备释放。拒绝/到期/取消的故意场景还必须核对对应终态计数，不把 SSH 成功当模型成功。环境影响：仅隔离源码/构建/日志写入和本次进程的设备使用，原工程/模型/SDK/系统只读。结论以本 case 原始记录为准，表内空值就是未测量。

所有源码/构建/报告目录必须新建且不存在。源码包先核对 SHA 和安全相对路径，普通 cat 用户构建；磁盘低于 500MiB 停止，不删除历史文件腾空间。主工程、模型、SDK、驱动、设备树和内核保持只读。复现时使用新 label/case，不直接重跑会覆盖同名证据的命令。

9 最终验收边界和局限

最终版本不得自动覆盖主稳定工程。Windows CTest、Fake/Mock、真实 SDK 固定输入、自然麦克风/耳机与 GUI 交互分别计数；同一请求 ID 必须带 case 或会话名。热对照与最终 GUI 长测标明源码版本、时长、输入间隔、冷却条件和保护停止。原始失败保留，若 4 线程触发测试护栏必须如实选择默认配置并重测，不能把强杀当优雅退出。

未测量或未实现：真实声学输出延迟、精确 token 粒度 TTFT、可信 NPU 利用率/带宽/功耗、完整 SDK 内部故障注入、DMA-BUF 端到端零拷贝、成功 RGA 生产路径、AEC/PTT/语音打断和任意环境下的永久稳定性。有限 RSS 稳定不是所有代码无泄漏证明，Linux trip 不等于芯片额定安全阈值。

10 简历项目描述与面试讲述

项目描述可写为：在 RK3576 端侧集成 USB 语音采集、Silero VAD、SenseVoice、Qwen2.5、IMX415、RKNN 加 SmolVLM2、Kokoro 与 ALSA，完成普通/视觉语音交互。使用 C++17 RAII、条件变量、有界 Worker 及跨阶段额度管理请求寿命，提供协作 SIGINT/SIGTERM 和可选 Qt 异步控制页面。

可核验性能成果：将同步 VLM 从 ASR 回调解耦，受控 VISION 提交由 1737.730ms 变为 0.034758ms，此为调度改善；缓存 CPU 预处理在 n12 比较中平均下降 24.67%；固定中英文各 n30 的 4 线程 TTS 合成平均耗时分别下降 30.42%与 29.74%，同时记录近双倍 CPU 和温度代价。持续稳定性与最终默认线程数必须附 5.5 真实条件，不能只写“全链路提速 30%”。

面试叙述顺序：先画实际线程和所有权图，解释 ASR 阻塞与回调寿命问题；再给出有界队列和取消/排空契约；用固定输入、样本量和原始日志说明局部优化；最后主动说明 RGA 失败、

没有零拷贝、TTS 仍非实时以及热稳定性的取舍。不要宣称训练了这些模型、修改了驱动或实现了尚无证据的功能。

11 结果索引和源码一致性

本手册正文是 Word 与 Markdown 的共同来源。完整逐文件源码附录、Git 格式 diff、逐文件 SHA、补丁 apply 检查和字节 roundtrip、原始终端日志、CSV/JSON、真实 GUI 截图、输入及环境清单随最终归档交付。所选关键函数代码从当前真实文件抽取，文件和片段 SHA 记录在 reports/stage5_05_local/manual_source_manifest.json，不使用省略号代替函数体。


```
{
  "all_checks_passed": true,
  "user_acceptance_pending": true,
  "validation_summary": "reports/stage5_05_local/validation_summary.json"
}
```